

NMSA211 Pravděpodobnost¹

Daniel Hlubinka

Šárka Hudecová

KATEDRA PRAVDĚPODOBNOSTI A MATEMATICKÉ STATISTIKY

Email address: daniel.hlubinka@matfyz.cuni.cz



**Matematicko-fyzikální
fakulta**
Univerzita Karlova

¹Verze 11. listopadu 2025

Obsah

Předmluva	xi
Kapitola 1. Axiomy a základy počtu pravděpodobnosti	1
1.1. Pravděpodobnostní prostor	2
1.2. Základní počítání s pravděpodobnostmi	5
1.3. Podmíněná pravděpodobnost	8
1.4. Nezávislost	13
Problémy k dalšímu procvičení	14
Kapitola 2. Náhodné veličiny a vektory	19
2.1. Náhodná veličina a její rozdělení	20
2.2. Náhodný vektor a jeho rozdělení	24
2.3. Nezávislost a vztah sdruženého a marginálních rozdělení	30
2.4. Základní diskrétní rozdělení	33
2.5. Základní spojitá rozdělení	35
2.6. Některá rozdělení náhodných vektorů	36
2.7. Rozdělení funkce náhodné veličiny a vektoru	38
Problémy k dalšímu procvičení	41
Kapitola 3. Momenty a další charakteristiky náhodné veličiny a vektoru	45
3.1. Střední hodnota náhodné veličiny	45
3.2. Momenty vyšších řádů	51
3.3. Momenty náhodných vektorů	54
*3.4. Další charakteristiky náhodných veličin	61
*3.5. Střední hodnota a medián jako optimalizační problém	63
Problémy k dalšímu procvičení	65

Kapitola 4. Náhodný výběr a výběrové momenty	69
4.1. Náhodný výběr a empirické rozdělení	69
4.2. Výběrové momenty a kvantily	72
4.3. Motivace k dalším kapitolám	75
Problémy k dalšímu procvičení	79
Kapitola 5. Konvergence náhodných veličin a základní limitní věty	81
5.1. Konvergence náhodných veličin	81
5.2. Vztahy mezi konverencemi	83
5.3. Nerovnosti Markovova typu	86
*5.4. Borelův a Cantelliův 0-1 zákon	88
*5.5. Chernoffovy meze pro součty náhodných veličin	90
5.6. Zákon velkých čísel	93
5.7. Centrální limitní věta a její použití	96
*5.8. Konvergence L_p a skoro jistě	100
Problémy k dalšímu procvičení	101
Kapitola 6. O odhadech	105
6.1. Výběrová statistika a její realizace	106
6.2. Bodový odhad	107
6.3. Nestrannost a konzistence odhadu	108
6.4. Odhady metodou momentů	112
*6.5. Histogram: odhad hustoty spojitého rozdělení	114
Problémy k dalšímu procvičení	118
Kapitola 7. Principy statistické inference	121
7.1. Asymptotické intervalové odhady	121
7.2. Intervalový odhad pro rozdíl dvou středních hodnot	125
*7.3. Principy statistického rozhodování	129
Problémy k dalšímu procvičení	131
Kapitola 8. Podmiňování	133
8.1. Podmíněné rozdělení a podmíněná střední hodnota diskrétního náhodného vektoru	133
8.2. Podmíněné rozdělení a podmíněná střední hodnota spojitého náhodného vektoru	135
8.3. Podmíněná střední hodnota jako náhodná veličina	137
Kapitola 9. Výsledky	139
Kapitola 1	139
Kapitola 2	140
Kapitola 3	142

Kapitola 4	144
Kapitola 5	144
Kapitola 6	145
Kapitola 7	146
Literatura	149
Rejstřík	151

Předmluva

Tato příručka, řekněme vznikající skripta, je určena k přednášce NMSA211 Pravděpodobnost, která je povinným předmětem bakalářského studia některých matematických programů. Doufáme však, že poučení by v ní mohli najít i další zájemci o úvodní seznámení s pravděpodobností a statistickými úlohami. Zde je na místě upozornit, že jde opravdu o stručný úvod bez ambic pokrýt hlubší partie předmětu.

Jde o postupně vznikající text, který obsahuje všechny definice a věty z přednášky i s důkazy, ale i další doplňkové partie, které považujeme za přínosné. Součástí jsou i návodné příklady a problémy k rozmyšlení, aby skripta mohla sloužit i pro samostudium. Nicméně hlavním cílem této příručky je být pevným bodem k přednášce, ke kterému se můžete vracet a porovnávat zápisky z přednášky s tímto textem v případě nejasností.

Zároveň si zde dovoluujeme místy opustit čistě formální přístup a přidáváme intuitivní pohled s nadějí, že pomůže rychlejšímu osvojení probírané látky a podnítí i k zamyšlení. Budeme také rádi, když si všimnete, jak je náhoda neodmyslitelně přítomná v našich životech a jak i naše chování v mnoha situacích vykazuje známky statistického učení.

Pravděpodobnost jako matematická disciplína si klade za cíl *modelovat* náhodu, něco, co zdánlivě v přesném matematickém světě nemá místo. Přesto se s náhodou setkáváme neustále a naše počínání má statistický charakter: na základě zkušeností činíme rozhodnutí, která reagují na situaci. A snažíme se hledat struktury a zákonitosti, které nám umožní plánovat a optimalizovat rozhodnutí. Proto má pravděpodobnost a statistika nezastupitelné místo v dnešním světě. Cílem přednášky je nejenom předání matematicky přesných definic a pouček, ale zejména úvod do pravděpodobnostního a statistického myšlení. Jedno bez druhého pro nás nemá valného smyslu. Pokud se zaměříme jen na formální stránku,

můžeme se poučky naučit klidně nazpaměť, ale nepochopíme, proč předchozí generace matematiků uvažovaly právě tak. Pokud se naučíme jen výpočetní vzorečky, nebudeme schopni přicházet s vlastními modely, nepochopíme omezení daná předpoklady, můžeme se dopustit vážných chyb v závěrech.

Většina tvrzení a vět je v textu podrobně dokázána. Jedinou výjimkou je, bohužel, centrální limitní věta. Její moderní důkaz vycházející z Fourierovy transformace míry si zde předvést netroufáme, její klasický důkaz je sice krásný, ale velmi dlouhý, tak si dovoluujeme zájemce odkázat na jiná skripta. Místy je text doplněný intuitivním pohledem¹, dovoluujeme si odstup a opouštíme ryze formální matematické vyjadřování. Doufáme, že nám čtenáři toto odpustí a využijí tyto návodné formulace tak, jak zamýšlíme; k lepšímu sžití se s matematickou teorií pravděpodobnosti, náhodný veličin a statistického odhadování a rozhodování. Jsme přesvědčeni, že se tak neděje na úkor matematické přesnosti a korektnosti.

Na druhou stranu jsme nevolili vždy nejsilnější možná tvrzení vět. Jde většinou o případy, kde silnější tvrzení vyžaduje složitý důkaz, případně pokročilejší teorii, a usoudili jsme, že pro první seznámení s pravděpodobností a statistikou stačí jednodušší verze s elementárním důkazem.

Za každou kapitolou jsou příklady k procvičování. Některé jsou lehčí, některé možná na první pokus mohou představovat výzvu. Jsou i příklady, které si přímo říkají o provedení pokusu. Některé z nich jsou označené značkou Ex a doporučujeme je zkusit, mohou být překvapivé a zábavné. K jejich provedení obvykle stačí kostka, nebo si můžete zkusit napsat jednoduchý simulační program třeba v systému R, nebo v některém z komerčních programů. Snažíme se na nich ukázat, že pravděpodobnost může být v rozporu s naší intuicí, zejména jde-li o takzvané málo pravděpodobné jevy.

V textu jsme zvýraznili definice, tvrzení a další poznámky a příklady, které považujeme významné pro práci s pravděpodobností. Neznamená to ale, že pro pochopení látky, *nebo dokonce pro složení zkoušky*, stačí číst jen tyto zvýrazněné části. Nestačí. Jednak jde o náš subjektivní výběr významných pojmů a výsledků, jednak jde také o snahu pomoci v orientaci v učebnici ve chvíli, kdy je používána jako referenční příručka.

Některé části textu jsou psány menším písmem, nebo jsou v poznámkách pod čarou. To jsou části, které pro první čtení představují doplňkovou informaci, často historickou či zasazující do širších souvislostí, ale pro hlubší studium jsou důležité. V přednášce obvykle tyto části nezazní, protože hodinový rozsah tomu nedovoluje. Zájemci o matematickou přesnost, důkladnost a souvislosti tak nejsou ochuzeni, tyto poznámky si přečtou a budou o nich přemýšlet, ostatní se k nim mohou vrátit při druhém čtení příručky.

Za veškeré připomínky k textu budeme vděční, zejména za upozornění na chyby a za návrhy, co přidat, případně změnit.

¹Což je dost subjektivní, každý autor nabídne poněkud jiný náhled. Naší snahou je pomoci čtenáři ke snadnějšímu uchopení vykládané látky.

Axiomy a základy počtu pravděpodobnosti

Pravděpodobnost je intuitivní pojem podepřený naší každodenní zkušeností. Téměř vše, s čím se denně setkáváme, má povahu náhodného jevu—výsledek předem neznáme. Někdy je situace jednoduchá, při hodu kostkou je šest možných výsledků a lze předpokládat, že jsou si z hlediska četnosti výskytu rovnocenné. Majitel restaurace by rád vyhověl všem zákazníkům a zároveň neplýtvat jídlem, ale ráno neví, kolik a jakých obědů se mu podaří prodat, student jedoucí na zkoušku může mít náhodné zpoždění způsobené dopravou. Jak však tyto nejistoty převést do rigorózního matematického modelu?

To, je-li náhoda opravdu součástí světa kolem nás, nebo jde jen o naši neschopnost přesně určit přírodní zákonitosti a spočítat tak budoucnost, zde nevyřešíme a ani se o to nebudeme snažit. Na druhou stranu i kdyby bylo po důkladném přezkoumání a se znalostí dokonalé předpovědi počasí možné předpovědět kolik vzejde rostlinek ze zasazených semínek, náklady na tyto výpočty by byly neúměrné—a mohou být snadno zhacené jediným škůdcem, který pronikne na náš pozemek. A o determinismu v případě lidí, jejich chování či zdraví, si netroufnou nahlas mluvit ani velcí zastánci mechanického světa. Spokojme se tedy s tím, že náhodnost nás provází každý den a je jedno, jde-li jen o zdánlivou náhodnost danou nedokonalostí našich smyslů a znalostí. Ze zkušenosti však víme, že některé jevy nastávají častěji než jiné, některé výsledky jsou očekávatelné a jiné překvapivé, někdy záleží na okolnostech. Pro rozumnou práci s náhodou však potřebujeme předpokládat nějakou stabilitu, tedy to, že budeme-li opakovat stejný experiment s tím, že výsledky jednotlivých pokusů se navzájem neovlivňují, budou se jednotlivé možné výsledky vyskytovat s četnostmi, které odpovídají předpokládaným hypotetickým hodnotám. Jednoduché experimenty s hrací kostkou tomuto předpokladu odpovídají velmi dobře, u složitějších systémů pak hledáme patřičně složitější *modely*.

Připomeňme si pro úplnost, že *četnost* nějakého výsledku je počet opakování, kdy daný výsledek nastal a *relativní četnost* je podíl četnosti a celkového počtu opakování. V dalším výkladu tyto dva pojmy budeme často využívat.

Počátky pravděpodobnosti souvisejí s hazardními hrami a rozvojem kombinatoriky, což je dodnes oblíbeným zdrojem příkladů pro výuku úvodu do pravděpodobnosti. Složitější úlohy však s tímto přístupem nevystačí. Dnes používáme především definice a modely zformulované na přelomu dvacátých a třicátých let dvacátého století A. N. Kolmogorovem.

1.1. Pravděpodobnostní prostor

Základem k matematickému pojetí pojmu pravděpodobnost (jak už slovo samotné naznačuje¹) je předpoklad, že při opakovaných pokusech se jednotlivé výsledky objevují s relativními četnostmi, které se blíží—jsou podobné—nějaké limitní hodnotě, pravdě. Takový pohled je samozřejmě možný jen při *konečně mnoha* možných výsledcích pokusu. Uvažujme například opakované hody pravidelnou šestistěnnou kostkou. Sledujeme-li případy, kdy padne šestka, pak intuitivně očekáváme, že s rostoucím počtem opakování se relativní četnost takových případů bude blížit hodnotě $1/6$.

Z opakovaných měření tedy můžeme ukazovat na obecné zákonitosti spojené s daným náhodným pokusem². Právě proto, že pravděpodobnost vychází intuitivně z počítání relativních četností, udává se v rozmezí 0 až 1, občas je pravděpodobnost udávána v procentech (to však v této přednášce pokud možno dělat nebudeme³). Pravděpodobnost je tak možné definovat jako hodnoty v intervalu $[0, 1]$ přiřazenou jednotlivým výsledkům pokusu. Do našich úvah musíme samozřejmě zapojit množinu všech možných výsledků, případně jevů, jejichž výskyt chceme sledovat. Přirozeným požadavkem je možnost rozšíření definice pravděpodobnosti i pro experimenty s nekonečně, ať již spočetně či nespočetně, mnoha možnými výsledky. Pro pokusy s nejvýše konečně mnoha různými výsledky máme přirozené požadavky na pravděpodobnost, zejména jde o požadavek, aby pravděpodobnost množiny všech možných výsledků byla jedna a aby pravděpodobnost sjednocení dvou disjunktních množin výsledků A a B byla součtem pravděpodobností množiny výsledků A a množiny výsledků B . Rozšíření definice pravděpodobnosti na obecné experimenty s libovolným počtem možných výsledků vyžaduje trochu opatrnosti.

¹Anglické probability—vycházející z latiny—lze vysvětlit jako „ověření schopné“, ruské věrojatnost také souvisí s možností ověřit, důvěřovat, německé Wahrscheinlichkeit je složeninou nepotřebující další rozbor.

²Jedno z raných děl o pravděpodobnosti od Jakoba Bernoulliho vydané roku 1713 (ale sepsané již v osmdesátých letech 17. století) se jmenuje *Ars Conjectandi*, což můžeme volně přeložit jako umění odhadování, nebo umění (činění) závěrů z neúplné informace.

³Stejně tak se vyhneme uvádění pravděpodobnosti v „šancích“, tedy v poměru příznivých a nepříznivých jevů. Přepočít sice není složitý, šance 1:1 znamená pravděpodobnost $1/2$, šance mají svůj význam například v sázkových kancelářích, ale my se striktně držíme pravděpodobnosti.

Definice 1.1: (Pravděpodobnostní prostor)

Trojici $(\Omega, \mathcal{F}, P)$ nazveme *pravděpodobnostní prostor*, pokud

- Ω je neprázdná množina.
- $\mathcal{F}$ je σ -algebra na Ω , tedy systém podmnožin Ω uzavřený na doplňky a spočetná sjednocení a zároveň $\Omega \in \mathcal{F}$.
- $P : \mathcal{F} \rightarrow [0, 1]$ je zobrazení splňující $P(\Omega) = 1$, a pro libovolné po dvou disjunktní $A_1, A_2, \dots \in \mathcal{F}$ platí

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

(tzv. spočetná, neboli σ -aditivita). Tato P se nazývá *pravděpodobnostní míra*, zkráceně též *pravděpodobnost*, na $\mathcal{F}$.

Tato definice úzce navazuje na teorii míry, která od začátku dvacátého století zažívala velký rozmach. Samotné matematické (axiomatické) uchopení pravděpodobnosti inspirované statistickou fyzikou bylo jedním z Hilbertových problémů, které takto vyřešil Kolmogorov ve své krátké monografii z roku 1933.

Pravděpodobnost definujeme jako funkci přiřazující jednotlivým výsledkům (jevům), hodnoty v intervalu $[0, 1]$, požadujeme spočetnou aditivitu, ale jak vidíme, obecně nemusí být možné definovat pravděpodobnost pro *každou* podmnožinu Ω , ale pouze pro prvky systému množin $\mathcal{F}$.

Za množinu Ω můžeme brát jakoukoliv množinu, která svou mohutností stačí k obsáhnutí všech možných výsledků pokusu. V běžných situacích můžeme brát buď podmnožiny přirozených či reálných čísel. Máme-li konečně mnoho možných různých výsledků, lze je ztotožnit s konečnou podmnožinou přirozených čísel, pro (potenciálně) nespočetně mnoho různých možných výsledků použijeme interval reálných čísel.

Příklad 1.2 (Klasický pravděpodobnostní prostor). Bud' Ω neprázdná konečná množina, $\mathcal{F} = 2^\Omega$, tj. $\mathcal{F}$ je soubor všech podmnožin Ω . Definujeme $P(A) = \frac{|A|}{|\Omega|}$ pro všechna $A \subset \Omega$. Potom $(\Omega, \mathcal{F}, P)$ nazýváme *klasický pravděpodobnostní prostor*. $\diamond$

Notoricky známým a intuitivním příkladem klasického pravděpodobnostního prostoru je hod pravidelnou šestistěnnou kostkou. Přirozeně pak volíme za množinu všech výsledků $\Omega = \{1, 2, \dots, 6\}$. Pro hod více kostkami je přirozené volit $\Omega = \{1, 2, \dots, 6\}^k$, kde k označuje počet kostek. Později uvidíme, že tento model se hodí pro situaci, kdy výsledek na jedné kostce neovlivňuje výsledky ostatních kostek.

Příklad 1.3 (Diskrétní pravděpodobnostní prostor). Bud' Ω neprázdná konečná nebo spočetná množina, $\mathcal{F} = 2^\Omega$. Bud' $p : \omega \rightarrow \mathbb{R}$ taková funkce, že $p(\omega) \in [0, 1] \forall \omega \in \Omega$ a $\sum_{\omega \in \Omega} p(\omega) = 1$. Dále definujeme $P(A) = \sum_{\omega \in A} p(\omega)$. Potom $(\Omega, \mathcal{F}, P)$ nazýváme *diskrétní pravděpodobnostní prostor*. $\diamond$

Příklad 1.4 (Reálný spojitý pravděpodobnostní prostor). Bud' $\Omega \subset \mathbb{R}$ omezený či neomezený reálný interval, $\mathcal{F}$ nechť obsahuje všechny otevřené i uzavřené podmnožiny Ω a jejich spočetná sjednocení a doplňky (jde tedy o borelovskou σ -algebru, viz Kapitola 2). Bud' $f : \Omega \rightarrow \mathbb{R}$ taková funkce, že $f(\omega) \geq 0$ a $\int_{\Omega} f(\omega) d\omega =$

1. Dále pro $A \in \mathcal{F}$ definujeme $P(A) = \int_A f(\omega) d\omega$. Potom $(\Omega, \mathcal{F}, P)$ nazýváme *reálný spojitý pravděpodobnostní prostor*. $\diamond$

Cvičení 1.5. Ověřte, že pravděpodobnost P z příkladu 1.4 splňuje definici 1.1. $\diamond$

Povšimněme si

Diskrétní pravděpodobnostní prostor povoluje, v porovnání s klasickým pravděpodobnostním prostorem, nestejné pravděpodobnosti jednotlivých výsledků ω a umožňuje, aby množina Ω byla až spočetná. Povolení nestejných pravděpodobností jednotlivých výsledků je velice potřebný krok. Očividně nemůžeme uvažovat ve smyslu „bud' bude pršet, nebo nebude, víc možností není, takže pravděpodobnost je $1/2$ “. Tato naivita by se projevila na předpovědích.^a

Oproti tomu spojitý reálný pravděpodobnostní prostor umožňuje uvažovat nespočetně mnoho výsledků, například potenciálně zcela přesné fyzikální měření. Musíme se ovšem smířit s faktem, že každý elementární jev $\omega \in \Omega$ má nulovou pravděpodobnost a tím pádem každý náhodný jev obsahující nejvýše spočetně mnoho elementárních jevů má nulovou pravděpodobnost. Nemá tedy cenu ptát se, s jakou pravděpodobností nastane *přesně* jednobodový výsledek, ale má cenu ptát se například na pravděpodobnost intervalů.

^aPřesto se vyskytovaly i podobné úvahy, například při počítání pravděpodobnosti počtu líců u hodu dvou mincí. I někteří slavní matematici minulosti se nechali zmýlit „třemi možnými výsledky“, tedy žádný líc, jeden líc a dva líce, a všem přisoudili stejnou pravděpodobnost $1/3$. Sami snadno ověříte, že je tato úvaha mylná.

Příklad 1.4 ukazuje, proč je nutné uvažovat σ -algebru $\mathcal{F}$. Pro nespočetné množiny Ω totiž nemusí být možné definovat funkci P pro *všechny* podmnožiny Ω tak, aby P splňovala definici 1.1. Je však možné najít vhodně „malou“ $\mathcal{F}$ a definovat P pro všechny její prvky.

Poznámka 1.6 (Základní názvosloví). Nechť $(\Omega, \mathcal{F}, P)$ je pravděpodobnostní prostor. Prvky množiny Ω nazýváme *elementární jevy*. Prvky σ -algebry $\mathcal{F}$ nazýváme *náhodné jevy*. Pro náhodný jev $A \in \mathcal{F}$ nazveme $A^C = \Omega \setminus A$ jevem *doplňkovým*. Pokud $P(A) = 0$, mluvíme o jevu *nemožném*, naopak náhodný jev splňující $P(A) = 1$ je jev *jistý*.

Povšimněme si

Elementární jev není náhodný jev. Elementární jev ω je bodem prostoru Ω , náhodným jevem může být množina $\{\omega\} \subset \Omega$. Uvědomme si ale, že nemusí platit $\{\omega\} \in \mathcal{F}$, takže $\{\omega\}$ nemusí být náhodný jev ve smyslu definice 1.1. V této přednášce se sice s takovou nepříjemností potýkat nebudeme, ale při modelování vývoje náhodných procesů v čase obvykle musíme.

Všem náhodným jevům jsme schopni přiřadit jejich pravděpodobnost. Při realizaci náhody vycházíme z představy, že Ω obsahuje určité osudí se všemi možnými výsledky, ze kterých je s ohledem na P „vybrána“ jedna realizace náhody,

jeden elementární jev ω . Náhodný jev A pak nastane, pokud $\omega \in A$, jinak nenastane. Například hodíme-li třemi kostkami, můžeme za elementární jev brát trojici výsledků na jednotlivých kostkách. Označme S součet výsledků na třech kostkách a uvažujme dva náhodné jevy $A = [S \geq 13]$ a $B = [S \text{ je liché číslo}]$. Je-li výsledek náhodného pokusu trojice $(2, 4, 1)$ (tj. na kostkách padly hodnoty 2, 4 a 1), pak jev A nenastal, zatímco jev B nastal.

Pro diskrétní pravděpodobnostní prostory bývají nemožné jevy triviální; obvykle jde o prázdné množiny. Pro spojité prostory již můžeme najít netriviální příklady.

Příklad 1.7 (Geometrická pravděpodobnost). Navažme na příklad 1.4. Uvažujme pravděpodobnostní prostor $\Omega = [0, 1]^2$ s borelovskou σ -algebrou a $P(A) = \iint_A dx dy$, tedy $f(x, y) = \mathbf{1}(0 \leq x, y \leq 1)$, jde tedy o speciální případ spojitého pravděpodobnostního prostoru.

Náhodný jev $a \times [0, 1] \subset [0, 1]^2$, kde $a \in [0, 1]$ je zřejmě neprázdný, přesto jeho pravděpodobnost je nulová. Dokonce vidíme, že $[0, 1]^2 = \bigcup_{a \in [0, 1]} a \times [0, 1]$, tedy celý prostor Ω splňující $P(\Omega) = 1$ je nespočetným sjednocením jevů nulové pravděpodobnosti. To však není ve sporu s definicí pravděpodobnosti, neboť ta musí splňovat spočetnou aditivitu; zde jde ale o nespočetné sjednocení.

Obecně lze vzít za Ω libovolnou podmnožinu $\mathbb{R}^d$ pro nějaké $d \in \mathbb{N}$ s nenulovou mírou (objemem) $\lambda(\Omega)$ a $f(\mathbf{x}) = \mathbf{1}(\mathbf{x} \in \Omega)/\lambda(\Omega)$. Takto definované pravděpodobnosti říkáme *geometrická* a její uplatnění najdeme například v Buffonově úloze o jehle, viz problém 1. $\diamond$

1.2. Základní počítání s pravděpodobnostmi

V této části se seznámíme se vzorci, které velmi často použijeme při počítání pravděpodobností. Připomeňme si množinové odčítání $A \setminus B = A \cap B^C$, kde B^C označuje doplněk množiny B .

Věta 1.8: (Základní výpočetní vzorce)

Bud' $(\Omega, \mathcal{F}, P)$ pravděpodobnostní prostor. Pak pro každé $A \in \mathcal{F}$ platí

$$(1.1) \quad P(A^C) = 1 - P(A)$$

a dále pro každou dvojici $A, B \in \mathcal{F}$, $A \subset B$, platí

$$(1.2) \quad P(A) \leq P(B) \text{ a také } P(B \setminus A) = P(B) - P(A).$$

Důkaz. Z aditivity pravděpodobnosti plyne $P(A \cup A^C) = P(A) + P(A^C)$ a jelikož $A \cup A^C = \Omega$, pak z identity $P(\Omega) = 1$ vyplývá $P(A) + P(A^C) = 1$.

Je-li $A \subset B$, pak $B = A \cup (B \cap A^C)$, jde proto o sjednocení dvou disjunktních množin. Proto $P(B) = P(A) + P(B \setminus A) \geq P(A)$. $\square$

Jsou-li náhodné jevy po dvou disjunktní, lze pravděpodobnost jejich sjednocení snadno spočítat jako součet jejich pravděpodobností. V případě, že po dvou disjunktní nejsou, můžeme použít princip inkluze a exkluze.

Věta 1.9: (Inkluze a exkluze)

Mějme $A_1, \dots, A_n$ náhodné jevy. Pak

$$\begin{aligned} P\left(\bigcup_{i=1}^n A_i\right) &= \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i \cap A_j \cap A_k) - \dots \\ &\quad \dots + (-1)^{n-1} P\left(\bigcap_{i=1}^n A_i\right) \end{aligned}$$

Důkaz. Matematickou indukcí.

První krok pro $n = 2$: zřejmě $A = (A \setminus B) \cup (A \cap B)$, kde $(A \setminus B)$ a $(A \cap B)$ jsou disjunktní. Podobně, $B = (B \setminus A) \cup (A \cap B)$, a proto

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Indukční krok pro $n - 1 \rightarrow n$:

$$\begin{aligned} P\left(\bigcup_{i=1}^n A_i\right) &= P\left(\bigcup_{i=1}^{n-1} A_i \cup A_n\right) = P\left(\bigcup_{i=1}^{n-1} A_i\right) + P(A_n) - P\left(\bigcup_{i=1}^{n-1} (A_i \cap A_n)\right) \\ &= \sum_{i=1}^{n-1} P(A_i) - \sum_{1 \leq i < j \leq n-1} P(A_i \cap A_j) + \dots + (-1)^{n-2} P\left(\bigcap_{i=1}^{n-1} A_i\right) \\ &\quad + P(A_n) - \sum_{1 \leq i \leq n-1} P(A_i \cap A_n) - \dots - (-1)^{n-2} P\left(\bigcap_{i=1}^n A_i\right) \end{aligned}$$

odkud po vhodném přeuspořádání a sečtení dostaneme

$$\sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j) + \dots + (-1)^{n-1} P\left(\bigcap_{i=1}^n A_i\right).$$


□

Při dokazování některých základních vlastností pravděpodobnosti se mohou hodit tzv. Vennovy diagramy dobře známé ze střední školy. Z nich např. velmi snadno „vyčteme“ vzorec z věty 1.9 pro $n = 2$ a $n = 3$, viz obrázek 1.1, ale i řadu jiných vlastností.


Přestože jsou vzorce z vět 1.8 a 1.9 elementární a jejich důkazy jsou velice jednoduché, jejich vhodným použitím jsme schopni si značně ulehčit výpočty, jak lze vidět například na známém problému šatnářky (problém 3).

Důležitou vlastností pravděpodobnostní míry je její spojitost⁴. Vezměme libovolnou posloupnost náhodných jevů $\{A_i\}_{i=1}^\infty \subset \mathcal{F}$ splňující $A_i \subset A_{i+1}$. Potom pro $A = \bigcup_{i=1}^\infty A_i$ píšeme $A_i \nearrow A$ a říkáme, že systém $\{A_i\}_{i=1}^\infty$ konverguje monotónně

⁴My tuto vlastnost dokážeme pomocí σ -aditivity pravděpodobnostní míry. Ve starších učebnicích je naopak spojitost součástí axiomů a σ -aditivita jejím důsledkem.

Obrázek 1.1. Příklad Vennových digramů pro $n = 2$ a $n = 3$ množiny.

(vzhůru) k A . Analogicky systém, pro který platí $A_i \supset A_{i+1}$, konverguje monotónně (dolů) k $A = \bigcap_{i=1}^{\infty} A_i$, což zapisujeme $A_i \searrow A$. Uvědomme si, že v obou případech je $A \in \mathcal{F}$, protože $\mathcal{F}$ je σ -algebra.

Obrázek 1.2. Monotónní systém jevů, kde $A_i \searrow A = \bigcap_{i=1}^{\infty} A_i$.
Věta 1.10: (Spojitost pravděpodobnostní míry)

Nechť $\{A_i\}_{i=1}^{\infty} \subset \mathcal{F}$ je monotónní posloupnost taková, že $A_i \searrow \emptyset$. Pak

$$\lim_{i \rightarrow \infty} P(A_i) = 0.$$

Důkaz. Víme, že $P(\bigcap_{i=1}^{\infty} A_i) = P(\emptyset) = 0$. To je podle základního vzorce ekvivalentní s rovností $1 = P((\bigcap_{i=1}^{\infty} A_i)^c) = P(\bigcup_{i=1}^{\infty} A_i^c)$. Dále víme, že $A_i \supseteq A_{i+1}$ a díky tomu $A_i^c \subseteq A_{i+1}^c$, tedy $A_i^c \nearrow \Omega$. Nadefinujeme si posloupnost $B_1 = A_1^c$, $B_{i+1} = A_{i+1}^c \setminus A_i^c$. Zřejmě B_i jsou disjunktní, $\bigcup_{i=1}^{\infty} B_i = \Omega$ a $P(\bigcup_{i=1}^{\infty} B_i) = P(\Omega) = 1$ a proto

$\sum_{i=1}^{\infty} P(B_i) = 1$. Poslední součet rozložíme na dva a pro $n \rightarrow \infty$ dostaneme

$$1 = \underbrace{\sum_{i=1}^n P(B_i)}_{\rightarrow 1} + \underbrace{\sum_{i=n+1}^{\infty} P(B_i)}_{\rightarrow 0},$$

což je důsledkem konečnosti a σ -aditivity pravděpodobnosti. Z definice B_i a z vlastností A_i plyne $P(\bigcup_{i=1}^n B_i) = P(\bigcup_{i=1}^n A_i^c) = 1 - P(\bigcap_{i=1}^n A_i) = 1 - P(A_n)$. Víme, že levá strana konverguje k 1, proto také $P(A_n) \rightarrow 0$. $\square$

Poznámka 1.11. Věta 1.10 je formulována pro situaci, kdy $A_i \searrow \emptyset$. Nicméně, analogicky lze ukázat, že pokud $A_i \searrow A$, pak $\lim_{i \rightarrow \infty} P(A_i) = P(A)$. Odtud pak již snadno plyne, že pokud $B_i \nearrow B$, pak také $\lim_{i \rightarrow \infty} P(B_i) = P(B)$.

1.3. Podmíněná pravděpodobnost

Pro zbytek textu se budeme držet úmluvy, že není-li řečeno jinak, pracujeme s pravděpodobnostním prostorem $(\Omega, \mathcal{F}, P)$ a náhodným jevem rozumíme prvek z $\mathcal{F}$.

Pravděpodobnost nějakého jevu vždy odráží naši znalost okolností. Ptáme-li se například na pravděpodobnost toho, že autobus bude mít cestou do Prahy zpoždění nejméně pět minut, záleží například na dni v týdnu a denní době. V počítání pravděpodobnosti jsou dostupné informace zohledněné *podmíněnou pravděpodobností*.

Nechť jev A nastane s pravděpodobností $P(A)$. Nyní dostaneme informaci o tom, že nastal jev B . Pomůže nám tato informace zpřesnit představu o výskytu jevu A , tedy upravíme nějak pravděpodobnost, že jev A nastal, pokud víme, že nastal jev B ?

Příklad 1.12. Z dlouhodobé zkušenosti víme, že teplota v září přesáhne 25°C v polovině dní. Pokud dopředu plánujeme výlet na neděli, pak víme, že s pravděpodobností alespoň $1/2$ budeme mít teplotu nad 25°C . V pátek se ale prudce zatáhne a začne pršet. Není na místě změnit naše očekávání ohledně neděle? $\diamond$

Definice 1.13: (Podmíněná pravděpodobnost)

Bud'te A a B dva náhodné jevy^a. Nechť $P(B) > 0$. Pak definujeme *podmíněnou pravděpodobnost A za podmínky B* předpisem

$$(1.3) \quad P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

^aDle úmluvy výše tedy dva prvky σ -algebry $\mathcal{F}$ z pravděpodobnostního prostoru $(\Omega, \mathcal{F}, P)$.

Podmíněná pravděpodobnost znamená, že jsme na základě informace (tedy platnosti podmínky) schopni vyloučit některé elementární jevy z našich úvah. Nastal-li jev B , pak můžeme některé možnosti vyloučit a tím dostat více informace o možnosti či nemožnosti výskytu jevu A . Jinak řečeno, podmínění znamená přechod ke zúženému pravděpodobnostnímu prostoru

$(B, \mathcal{F}_B, P^B)$, kde $\mathcal{F}_B = \{F : F = A \cap B; A \in \mathcal{F}\}$, $P^B(F) = P(A|B)$ pro $F = A \cap B$.

Příklad 1.14. Uvažujme hod pravidelnou šestistěnnou kostkou s klasickým pravděpodobnostním prostorem $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathcal{F} = 2^\Omega$ a P . Nechť $B = [\text{padlo sudé číslo}]$. Víme-li, že jev B nastal, pak tedy přecházíme ke zúženému pravděpodobnostnímu prostoru $(B, \mathcal{F}_B, P^B)$, tj. ke klasickému pravděpodobnostnímu prostoru na množině $\{2, 4, 6\}$. Pro libovolné $A \in \mathcal{F}$ je pak $P(A|B) = P^B(A \cap B) = \frac{|A \cap B|}{|B|} = \frac{|A \cap B|}{3}$. $\diamond$

Cvičení 1.15. Dokažte, že podmíněná pravděpodobnost skutečně tvoří pravděpodobnostní míru na zúženém pravděpodobnostním prostoru. Jinými slovy, ověřte pro trojici $(B, \mathcal{F}_B, P^B)$ požadavky definice 1.1.

Uvědomte si však, že zatímco opravdu podle principu inkluze a exkluze platí

$$P(A \cup B|F) = P(A|F) + P(B|F) - P(A \cap B|F),$$

tak „v podmínce“ tyto operace provádět nemůžeme. Zejména **obecně neplatí (!)** rovnost $P(A|B) = 1 - P(A|B^C)$ (i když se trochu nabízí). Snadno najdete protipříklady. $\diamond$

S podmíněnou pravděpodobností můžeme výrazně vylepšit naše možnosti počítání pravděpodobností náhodných jevů. Podmiňování si můžeme připodobnit k postupnému odhalování karet při hře.

Povšimněme si

Podíváme-li se na podmíněnou pravděpodobnost, vidíme, že pravděpodobnost nějakého jevu nemůžeme brát za absolutní. Vždy je potřeba uvažovat, v jakém rámci, můžeme říci modelu, pravděpodobnost uvažujeme. U šestistěnné kostky se jako přirozené jeví pro všech šest výsledků uvažovat stejnou pravděpodobnost. To je dobrý model, přiblížení, pokud je kostka naprosto pravidelná, homogenní, a i potom záleží na způsobu házení. **Pravděpodobnost se odvíjí od uvažovaného modelu a dostupných informací.** Jaká je pravděpodobnost, že náhodně vybraný člověk má výšku více než 175 cm? Jaká je pravděpodobnost, že náhodně vybraný basketbalista má více než 175 cm? A co myslíme slovy náhodně vybraný člověk/basketbalista?

Přímo z definice lze odvodit výpočet pravděpodobnosti průniku několika náhodných jevů.

Věta 1.16: (O postupném podmiňování, o násobení pravděpodobností)

Mějme $A_1, \dots, A_n$ náhodné jevy takové, že $P(\bigcap_{i=1}^n A_i) > 0$. Potom

$$P\left(\bigcap_{i=1}^n A_i\right) = P\left(A_n \middle| \bigcap_{i=1}^{n-1} A_i\right) \cdot P\left(A_{n-1} \middle| \bigcap_{i=1}^{n-2} A_i\right) \cdots P(A_2|A_1) \cdot P(A_1).$$

Důkaz. Matematickou indukcí. První krok plyne přímo z definice, protože $P(A_1 \cap A_2) = P(A_1|A_2) \cdot P(A_2)$. Pro indukční krok $n - 1 \rightarrow n$ stačí uvědomit si, že

$$P\left(\bigcap_{i=1}^n A_i\right) = P\left(\bigcap_{i=1}^{n-1} A_i \cap A_n\right) = P\left(A_n \middle| \bigcap_{i=1}^{n-1} A_i\right) \cdot P\left(\bigcap_{i=1}^{n-1} A_i\right).$$

□

Definice 1.17: (Disjunktní rozklad)

Bud' $I \subset \mathbb{N}$ neprázdná množina indexů. Konečný či spočetný systém náhodných jevů $\{B_i\}_{i \in I} \subset \mathcal{F}$ nazveme *disjunktním rozkladem* Ω , pokud:

- (1) $B_i \cap B_j = \emptyset$ pro všechna $i \neq j$,
- (2) $P(\bigcup_{i \in I} B_i) = 1$ (často uvažujeme silnější předpoklad $\bigcup_{i \in I} B_i = \Omega$),
- (3) $P(B_i) > 0$ pro všechna $i \in I$.

Disjunktní rozklad používáme, pokud za jednotlivých podmínek B_i dokážeme určit podmíněnou pravděpodobnost zkoumaného jevu. Poskládat podmíněné pravděpodobnosti do celkové je snadné, nesmíme jen zapomenout, že pravděpodobnost podmínky hraje svou roli.

Věta 1.18: (O úplné pravděpodobnosti)

Mějme náhodný jev A a $\{B_i\}$ disjunktní rozklad Ω . Pak

$$P(A) = \sum_i P(A|B_i) \cdot P(B_i).$$

Důkaz. Z vlastností disjunktního rozkladu plyne, že $A \cap B_i, i = 1, 2, \dots$ jsou po dvou disjunktní množiny. Zřejmě platí $\bigcup_i (A \cap B_i) = A \cap (\bigcup_i B_i) = A \cap \Omega = A$. Odtud z definice podmíněné pravděpodobnosti

$$P(A) = P\left(\bigcup_i (A \cap B_i)\right) = \sum_i P(A \cap B_i) = \sum_i P(A|B_i) \cdot P(B_i).$$

□

Z věty o úplné pravděpodobnosti a z definice podmíněné pravděpodobnosti přímo plyne jedna z významných a nejvíce používaných vět, Bayesův vzorec.

Věta 1.19: (Bayesova)

Mějme A náhodný jev, nechť $P(A) > 0$ a $\{B_i\}$ je disjunktní rozklad Ω . Potom

$$P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{P(A)} = \frac{P(A|B_i) \cdot P(B_i)}{\sum_j P(A|B_j) \cdot P(B_j)}.$$

Důkaz. Využijeme definici podmíněné pravděpodobnosti k ověření

$$P(B_i|A) = \frac{P(A \cap B_i)}{P(A)} = \frac{P(A|B_i) \cdot P(B_i)}{P(A)}.$$

Nyní na jmenovatel použijeme větu o úplné pravděpodobnosti. $\square$

Povšimněme si

Bayesův vzorec používáme v případě, kdy nová informace může pomoci rozhodnout se mezi více potenciálními jevy. Pravděpodobnosti $P(B_i)$ nazýváme *apriorní*. Jde tedy o nějaké „neinformované očekávání“, že nastal právě jev B_i . Je-li nějaký jev B_i málo pravděpodobný, máme tendenci jej vyloučit. Dostaneme-li informaci, že nastal jev A , můžeme přepočítat pravděpodobnost jevu B_i na podmíněnou pravděpodobnost $P(B_i|A)$. Této říkáme *aposteriorní* pravděpodobnost. Tuto úvahu činíme bezděky každodenně při rozhodování. Bayesův vzorec je také základem mnoha statistických metod, kterým se také říká strojové učení^a. Také v medicíně najde Bayesův vzorec své uplatnění, jevy B_i jsou možná onemocnění a jev A je výsledek vyšetření, případně nějaké projevy nemoci. Pro použití Bayesova vzorce je důležité co nejlépe stanovit apriorní pravděpodobnosti $P(B_i)$ a mít také dobrou představu o podmíněných pravděpodobnostech $P(A|B_i)$.

^aCož zahrnuje různé klasifikační úlohy, odhady parametrů, ověřování modelů pro generování dat.

Cvičení 1.20. Každý lékařský test je charakterizován svojí senzitivitou a specificitou, kde

- senzitivita je pravděpodobnost pozitivního výsledku, je-li testovaná osoba nemocná,
- specificita je pravděpodobnost negativního výsledku, je-li testovaná osoba zdravá.

Pro test zjišťující přítomnost HIV⁵ viru v těle se uvádí senzitivita 99.9% a specificita 99.7%. Uvažujme hypotetickou populaci, ve které se vyskytuje 1% lidí s virem HIV.

- (a) Jaká je pravděpodobnost, že je náhodně vybraná osoba s pozitivním výsledkem testu skutečně HIV pozitivní?
- (b) Jaká je pravděpodobnost, že je osoba ve skutečnosti HIV pozitivní, dává-li test negativní výsledek?

$\diamond$

Řešení. Označme jevy B = [náhodně vybraná osoba je HIV pozitivní], A = [test dává pozitivní výsledek]. Ze zadání známe $P(A|B) = 0,999$, $P(A^C|B^C) = 0,997$ a $P(B) = 0,01$. Uvědomíme si, že jevy B a B^C tvoří rozklad Ω . V (a) počítáme

$$\begin{aligned} P(B|A) &= \frac{P(A|B) \cdot P(B)}{P(A)} = \frac{P(A|B) \cdot P(B)}{P(A|B)P(B) + P(A|B^C)P(B^C)} \\ &= \frac{0,999 \cdot 0,01}{0,999 \cdot 0,01 + (1 - 0,997)(1 - 0,01)} = 0,77. \end{aligned}$$

⁵Zatímco test na HIV mnoho lidí nikdy neabsolvuje, v roce 2021 máme téměř všichni zkušenosti s testy na koronaviry; princip je ovšem stejný

Vidíme, že přestože byly senzitivita i specificita testu velmi vysoké (blízké 1), aposteriorní pravděpodobnost je výrazně nižší než apriorní⁶. Poznamenejme, že u pozitivně testovaných jedinců se test provádí ještě jednou. Samostatně pak můžete spočítat, jaká je pravděpodobnost, že je člověk skutečně HIV pozitivní, byl-li i druhým testem označen za HIV pozitivního. Postup bude zcela analogický.

V (b) máme

$$\begin{aligned} P(B|A^C) &= \frac{P(A^C|B) \cdot P(B)}{P(A^C|B) \cdot P(B) + P(A^C|B^C)P(B^C)} \\ &= \frac{(1 - 0,999) \cdot 0,01}{(1 - 0,999) \cdot 0,01 + 0,997 \cdot (1 - 0,01)} = 10^{-5}. \end{aligned}$$

□

Cvičení 1.21. (Pólyovo urnové schéma⁷.) Uvažujme urnu (osudí) s míčky dvou barev. V osudí je b bílých míčků a c černých míčků. V každém tahu vytáhneme jeden míček, přičemž každý míček má stejnou pravděpodobnost být vylosován.

Po vytažení míček vrátíme do osudí a spolu s ním i d míčků stejné barvy. Je-li $d = 0$ mluvíme o tazích s *vracením*, je-li $d = -1$, mluvíme o tazích *bez vracení*; jde o dvě základní nastavení schématu. Zajímavé na tomto modelu je, že ve všech případech kromě tahů s vracením se po každém tahu změní poměr barev v osudí a dokud tento tah neprovedeme, nemůžeme s jistotou říci, k jaké změně dojde.

- Určete pravděpodobnost, že ve druhém tahu vytáhneme bílý míček, taháme-li s vracením/bez vracení.
- Určete podmíněnou pravděpodobnost, že jsme v prvním tahu vytáhli bílý míček za podmínky, že ve druhém tahu byl vytažený bílý míček, taháme-li s vracením/bez vracení.

♠

Věta 1.16 nám dává přesný výpočet pravděpodobnosti současného výskytu n náhodných jevů. V praxi však může být výpočet podmíněných pravděpodobností potřebných pro větu 1.16 velmi náročný. V teorii pravděpodobnosti se proto používají i různé odhady pravděpodobností. Uvedeme zde jednu z častěji používaných.

⁶Intuitivně by nás to ale nemuselo překvapovat. I když test označí za HIV pozitivní jen tři lidi z tisíce negativních, tak při nízké prevalenci (podílu pozitivních lidí v populaci) je náhodně vybraná osoba s velkou pravděpodobností negativní. Představme si, že vybereme náhodně 10 000 lidí. Z nich jen přibližně 100 bude pozitivních a test je s velkou pravděpodobností všechny odhalí. Ale zároveň s nimi označí za pozitivní i okolo 30 negativních, čili test „odhalí“ přibližně 130 pozitivních, z nich je však skutečně pozitivních jen 100. Nezapomeňme však, že *základním předpokladem* pro tyto výpočty je fakt, že jsou testováni náhodní lidé, nikoliv lidé s podezřením, s příznaky či jinak předvybraní.

⁷Známý matematik George (György) Pólya (Budapešť 1887–Palo Alto 1985) zasáhl mimo jiné i do teorie pravděpodobnosti. Urnové schéma je výtečným modelem pro náhodné vybírání z „populací“ skládajících se z různých skupin prvků. S Pólyovým schématem se několikrát potkáme i ve cvičeních.

Věta 1.22: (Bonferroniho nerovnost)

Mějme $A_1, \dots, A_n$ náhodné jevy. Pak

$$P\left(\bigcap_{i=1}^n A_i\right) \geq 1 - \sum_{i=1}^n (1 - P(A_i)).$$

Důkaz. Důkaz je přímočarý s využitím základních pravidel:

$$P\left(\bigcap_{i=1}^n A_i\right) = 1 - P\left(\left(\bigcap_{i=1}^n A_i\right)^c\right) = 1 - P\left(\bigcup_{i=1}^n A_i^c\right) \geq 1 - \sum_{i=1}^n P(A_i^c) = 1 - \sum_{i=1}^n (1 - P(A_i)).$$

□

1.4. Nezávislost

Nezávislost (stochastická nezávislost) náhodných jevů znamená, že výskyt jednoho náhodného jevu neovlivní pravděpodobnost výskytu druhého náhodného jevu. Obecněji lze uvažovat i více náhodných jevů současně.

Pro dva jevy je úvaha jednoduchá. Pokud jsou nezávislé, pak výskyt jednoho neovlivňuje pravděpodobnost výskytu druhého. Uvažujeme-li napřed netriviální náhodné jevy A a B , tedy $P(A) > 0$ a $P(B) > 0$, pak výše řečené znamená, že pravděpodobnost výskytu jevy A není ovlivněna výskytem jevu B , pokud $P(A|B) = P(A)$. Z definice podmíněné pravděpodobnosti (1.3) vidíme, že toto je ekvivalentní požadavku

$$P(A \cap B) = P(A)P(B).$$

Hned na první pohled vidíme, že se jedná o symetrický vztah, ze kterého zároveň plyne $P(B|A) = P(B)$. Nezávislost je tedy vzájemná.

Ve chvíli, kdy máme více než dva náhodné jevy, musíme vzájemnou nezávislost definovat opatrněji.

Definice 1.23: (Nezávislost náhodných jevů)

Bud'te $A_1, A_2, \dots$ náhodné jevy. Tyto jevy nazveme *vzájemně nezávislé*, pokud pro každou konečnou množinu indexů I platí

$$(1.4) \quad P\left(\bigcap_{i \in I} A_i\right) = \prod_{i \in I} P(A_i).$$

Pokud rovnost (1.4) platí pouze pro množiny I takové, že $|I| \leq 2$ mluvíme o *nezávislosti po dvou*. Podobně lze definovat nezávislost *po třech* a tak dále.

Cvičení 1.24. Najděte příklad pravděpodobnostního prostoru a na něm tří jevů, které jsou po dvou nezávislé, ale nejsou (vzájemně) nezávislé. K velmi jednoduchému příkladu by vám měla stačit množina Ω se čtyřmi prvky. ◇

Definice 1.23 je obecná a dá se použít i pro nespočetné množiny náhodných jevů. Dávejte si ale pozor, že i pro ověření nezávislosti *konečně* mnoha jevů musíme ověřit rovnost (1.4) pro *všechny* podmnožiny indexů, viz. předchozí příklad.

Nezávislost výrazně zjednodušuje některé výpočty, například věta 1.16 o postupném podmiňování se stává triviální.

Cvičení 1.25. Všimněte si, že v Pólyově urnovém schématu jsou náhodné jevy [vytažen bílý míček v prvním tahu] a [vytažen bílý míček ve druhém tahu] nezávislé jevy tehdy a jen tehdy, jde-li o tahy s vrácením. Toto obecně platí pro jakékoliv barvy vytažených míčků v jednotlivých tazích. $\diamond$

Problémy k dalšímu procvičení

1. **Buffonova úloha.** Na podlaze jsou rovnoběžné přímky s rozestupem $t > 0$. Z výšky na podlahu házíme jehlu o délce $0 < l < t$ o které předpokládáme, že dopadne v náhodné poloze. S jakou pravděpodobností jehla zasáhne jednu z přímků na podlaze?
Jak na to: Prvně si musíme uvědomit, co je „náhodná poloha“ jehly a jak ji popsat. V našem případě se dá popsat například vzdáleností d středu jehly od nejbližší přímky (zřejmě, že $d \in [0, t/2]$) a úhlem θ mezi jehlou a přímkami (zřejmě lze uvažovat $\theta \in [0, \pi/2]$). Pro dvojice (d, θ) máme tedy možné hodnoty v množině $M = [0, t/2] \times [0, \pi/2]$, ale jen vlastní podmnožina U těchto hodnot vede k zásahu jedné z přímků jehlou. Výslednou pravděpodobnost tedy určíme podílem plochy U k celkové ploše M . Pro zajímavost si můžete tento experiment vyzkoušet s opravdovou jehlou a čarami, případně si naprogramovat malou simulaci. Uvidíte, jak s rostoucím počtem pokusů podíl zásahů míří k vypočítané teoretické hodnotě (empirické se blíží teoretickému).
2. Pravděpodobnostní prostor není jednoznačně určený pokusem. Najděte alespoň dvě možnosti, které mohou posloužit jako pravděpodobnostní prostor pro součet výsledků na dvou kostkách.
 Jako přirozené se jeví hlavně dvě možnosti pro Ω . První z nich je výčet možných výsledků, tedy množina $\{2, 3, \dots, 12\}$. Druhou je záznam výsledků obou kostek, tedy uspořádané dvojice $\{(1, 1), (1, 2), \dots, (6, 5), (6, 6)\}$. Třetí možnost jsou neuspořádané dvojice výsledků, ale pak je ještě mnoho dalších. Rozmyslete si, jak byste pro jednotlivé modely pravděpodobnostního prostoru zavedli pravděpodobnost P a jak byste s její pomocí určili pravděpodobnost, že součet výsledků na dvou kostkách je alespoň 10.
3. **Roztržitá sekretářka.** Tento problém se vyskytuje pod různými jmény a patří mezi tradiční. Sekretářka zalepila do obálek n dopisů určených pro n různých adresátů, ale zapomněla si poznamenat, do které obálky jaký dopis dala. Nyní na obálky nalepuje náhodně adresy (tím rozumíme, že každá adresa je nalepena právě jednou a má stejnou pravděpodobnost být nalepena na každý z dopisů).

(a) S jakou pravděpodobností alespoň jeden dopis najde svého pravého adresáta?

(b) Najděte limitu této pravděpodobnosti pro $n \rightarrow \infty$.

Drobou potíží v této úloze činí fakt, že po vylepení jakékoliv adresy již tato nemůže být použita na žádný z dalších dopisů a naopak. Dopis, který již dostal adresu nemůže dostat druhou. Nejde tedy o disjunktní jevy.

Návod: Předpokládejme, že dopisy máme očíslované $1, \dots, n$. Jev, jehož pravděpodobnost chcete spočítat, si můžete vyjádřit jako sjednocení jevů A_k , kde $A_k = [\text{dopis } k \text{ je správně umístěn}]$. K výpočtu pak použijte princip inkluze a exkluze.

4. Předpokládejme následující experiment. S pravděpodobností p si vezmu jednu hrací kostku (jev $1k$) a s pravděpodobností $1 - p$ dvě hrací kostky (jev $2k$). Oznámím vám celkový počet ok, který padl, ale nikoliv počet kostek, který jsem použil. Předpokládejme, že tento výsledek je 4 (jev S_4). Kolik byste vsadili na to, že jsem házel jednou kostkou?

Pokud bych vycházel z neinformované hodnoty $p = 1/2$ dostanu snadno výsledek. Zkuste však odpovědět na předchozí otázku pro $p = 1/20$ a $p = 19/20$, případně spočítejte aposteriorní pravděpodobnost pro p jako parametr.

A uvědomte si, že v tomto případě za předpokladu, že kostky nejsou falešné, známe přesně podmíněné pravděpodobnosti $P(S_4|1k) = 1/6$ a $P(S_4|2k) = 1/12$.

5. Na dvou kostkách jsme dosáhli v součtu výsledku 6. S jakou pravděpodobností na obou kostkách padla nejvýše čtyřka?

6. Házíme čtyřmi šestistěnnými hracími kostkami. Určete, jaká je pravděpodobnost, že

(a) součet čísel na kostkách bude sudé číslo a zároveň součin čísel bude liché číslo,

(b) součet bude sudé číslo nebo součin bude liché číslo?

7. S jakou pravděpodobností padne alespoň jedna šestka, házíme-li

(a) dvěma kostkami,

(b) n kostkami.

8. Do vlaku s 10 vagóny nastoupilo 16 cestujících, kteří si vagón zvolili náhodně. Určete pravděpodobnost, že do každého vagónu nastoupil alespoň jeden cestující.

9. Máme n různých klíčů a pokoušíme se odemknout zámek. Jaká je pravděpodobnost, že odemkneme právě na k -tý pokus, jestliže vždy

(a) vyzkoušený klíč dáme stranou a náhodně vybereme další klíč ze zbývajících,

(b) vyzkoušený klíč necháme na svazku, klíči zatřese a náhodně vybereme jeden ze svazku.

10. Třikrát po sobě hodíme mincí a zaznamenáme výsledek. Označme rub jako R a líc jako L . Rozhodněte, zda jsou jevy $A = \{RRR, LRR, RLL, LLL\}$, $B = \{RRL, RLR, LLR, LLL\}$ a $C = \{RRL, RLR, LRL, LLL\}$ nezávislé.

11. Rozhodněte o platnosti následujících tvrzení. Své rozhodnutí vždy řádně zdůvodněte (uveďte důkaz nebo protipříklad).

- (a) Jestliže jsou jevy A, B nezávislé, pak o nezávislosti jevů A^C, B^C obecně nemůžeme rozhodnout.
 - (b) Jestliže $P(A|B) \geq P(A) > 0$, pak $P(B|A) \geq P(B)$.
 - (c) Existují A, B neslučitelné jevy, tj. $A \cap B = \emptyset$, takové, že $P(A) \neq 0, P(B) \neq 0$ a A, B jsou nezávislé.
 - (d) Jestliže platí $P(A|B) = P(A|B^C)$, pak jsou jevy A, B nezávislé.
 - (e) Jestliže $P(B) > 0$, pak $P(A|B) \geq P(A)$.
12. Náhodné jevy A, B, C jsou nezávislé. Určete $P(A \cup B \cup C)$, jestliže $P(A) = P(B) = P(C) = 0.1$.
13. Na startu dostihu jsou (mimo jiné) koně Albín a Bertík. Albín zvítězí s pravděpodobností 0.5, Bertík s pravděpodobností 0.3. Jaká je pravděpodobnost, že vyhraje Bertík, jestliže se Albín zranil na startu a závod nepoběží?
14. Tenistka má v prvním podání úspěšnost 60% a v druhém podání má úspěšnost 80%.
- (a) Jaká je pravděpodobnost dvojchyby?
 - (b) S jakou pravděpodobností udělala tenistka v prvním podání chybu, když víme, že nedošlo k dvojchybě?
15. Roztržitý profesor zapomene v obchodě deštník s pravděpodobností $1/4$. Cestou ze školy navštívil čtyři obchody a domů přišel bez deštníku. Jaká je pravděpodobnost, že deštník zapomněl ve čtvrtém obchodě?
16. V populaci je levák každý desátý člověk. Pravděpodobnost, že levák píše s obráceným sklonem je 0,8, zatímco pravděpodobnost, že pravák píše s obráceným sklonem je 0,1. Jaká je pravděpodobnost, že dopis psaný obráceným sklonem psal levák?
17. Tři skupiny studentů řeší obtížný příklad. Ve skupině A jsou 3 velmi chytří studenti a každý z nich vyřeší příklad s pravděpodobností 0.8. Ve skupině B jsou 4 průměrní studenti a každý z nich vyřeší příklad s pravděpodobností 0.6. Ve skupině C jsou 2 slabí studenti a každý z nich vyřeší příklad s pravděpodobností pouze 0.4.
- (a) S jakou pravděpodobností náhodný student vyřeší příklad?
 - (b) Náhodně vybraný student příklad nevyřešil. Ze které skupiny nejpravděpodobněji byl?
 - (c) Studenti pracují nezávisle. S jakou pravděpodobností bude příklad vyřešen?
18. Mezi 100 krabicemi mandarinek ze Španělska je 5 krabic se shnilými, stejně jako mezi 200 krabicemi z Řecka. Nejdříve vybereme náhodně jednu ze zásilek a potom ze zásilky náhodně vybereme krabici. Určete s jakou pravděpodobností obsahuje vybraná krabice shnilé mandarinky.
19. V krabici máme n bílých a m černých koulí. Postupně je taháme všechny ven (bez vrácení). Jaká je pravděpodobnost, že k -tá tažená koule je bílá?
20. V krabici je 15 tenisových míčků, z toho 9 úplně nových. Pro první hru si náhodně vybereme 3 míčky a po skončení hry je vrátíme zpátky. Pro druhou hru vybereme opět 3 míčky. Určete pravděpodobnost toho, že jsou všechny 3 míčky použité v druhé hře nové.

21. Z pošty doručené na server je 80 % spamů. Spamový filtr úspěšně rozpozná 90% všech spamů, ale zároveň 15 % korektní pošty je označeno jako spam.
 - (a) Jaké je pravděpodobnost, že email smazaný filtrem jste si chtěli přečíst?
 - (b) Jaké je procento spamů ve vaší schránce?
22. Tři lovci vystřelili současně na divokého kance, který byl jednou střelou trefen. Určete pravděpodobnost toho, že kance zastřelil první, druhý nebo třetí střelec, jsou-li pravděpodobnosti zásahu po řadě rovny 0,2, 0,4 nebo 0,6.
23. V truhle je neznámý počet mincí: jedna zlatá mince a náhodný počet stříbrných mincí, přičemž stříbrných mincí je právě k s pravděpodobností $\frac{e^{-1}}{k!}$ pro $k = 0, 1, \dots$. Náhodně vylosujeme jednu minci a ta je zlatá. Jaká je pravděpodobnost, že v truhle bylo právě k stříbrných mincí za této dodatečné informace?
24. Na stole leží dvě urny A a B: V urně A jsou dvě bílé a dvě černé kuličky a v urně B jsou dvě černé a jedna bílá kulička. Náhodně vybereme z každé urny jednu kuličku a z těchto dvou kuliček pak náhodně zvolíme jednu. Jaká je pravděpodobnost, že jsme vybrali bílou kuličku?
25. Máme tři truhly se dvěma mincemi. V truhle A jsou dvě zlaté mince, v truhle B dvě stříbrné mince a v truhle C zlatá a stříbrná mince. Náhodně vybereme truhlu a z ní vytáhneme náhodně minci. Ta je zlatá. Jaká je pravděpodobnost, že i druhá mince v této truhle je zlatá?
26. Ve sbírce 50 obrazů je 5 padělků. Jestliže je obraz falešný, znalec to pozná s pravděpodobností 80%. Je-li obraz originál, znalec ho mylně posoudí s pravděpodobností 5%. Určete
 - (a) pravděpodobnost, že obraz je originál, jestliže byl znalcem označen za originál,
 - (b) pravděpodobnost, že obraz je padělaný, jestliže byl znalcem označen za padělek.
27. Házíme dvěma hracími kostkami najednou dokud nepadne součet 5 nebo součet 7 (na obou kostkách dohromady). S jakou pravděpodobností padne dříve součet 5 než součet 7?

Náhodné veličiny a vektory

Jedním z pojmů, které ve své práci A.N.Kolmogorov formálně zavedl je i pojem *náhodná veličina*. Náhodná veličina „propojuje“ elementární jevy s pozorovatelnými jevy. Jak jsme si již říkali dříve, kromě jednoduchých příkladů nejsme schopni přesně určit, jaký elementární jev nastal, ale jsme schopni pozorovat výskyt náhodných jevů. Přirovnáním může být například barva očí. Potkáme-li člověka s modrou barvou očí, nevíme, jakou barvu očí měli jeho prarodiče, ale něco usuzovat můžeme.

Výsledkem experimentu ale nemusí být jenom hodnota 0 či 1, tedy indikátor výskytu nějakého náhodného jevu, ale jedna z více (často *mnoha*) možných hodnot. To je i motivací k zavedení velice užitečného pojmu náhodná veličina¹. Náhodná veličina je předem neznámá hodnota, kterou se dozvíme až po měření či provedení experimentu. Předpokládáme, že jednotlivé výsledky experimentu (hodnoty náhodné veličiny) nemusí mít stejnou pravděpodobnost, často jsou tyto pravděpodobnosti určené nějakým vhodným modelem. Náhodnou veličinu můžeme použít jako vstup do následných symbolických výpočtů a pomocí vlastností náhodné veličiny pak odvodit pravděpodobnosti a další vlastnosti takto odvozených výsledků. Výhodou práce s náhodnou veličinou je, že můžeme obecně odvozovat teoretické vlastnosti, aniž bychom museli řešit každý případ zvlášť.

Příklad 2.1. Náhodnou veličinou je například výsledek hodu na kostce. Předem nevíme, kolik padne. Házeme-li třemi kostkami, můžeme například uvažovat maximum z uvedených tří hodů; toto maximum je samozřejmě předem neznámé a také náhodné, jde proto o novou náhodnou veličinu, můžeme však mluvit o jeho vlastnostech a zákonitostech, aniž bychom museli experiment provádět. Například můžeme určit, s jakou pravděpodobností bude maximum ze tří hodů nejvýše čtyři. ◇

¹Anglickému *random variable* by možná více odpovídalo *náhodná proměnná*, ale v češtině se ustálilo používání výrazu *veličina*, který zdůrazňuje dvojitou povahu tohoto matematického objektu nabývajícího hodnoty podle výsledku experimentu. Ve slovenštině je naopak mnohem častěji používán výraz *náhodná premená*

Poznámka 2.2. V následujícím textu bude užitečné uvažovat systém $\mathcal{B}$ podmnožin reálných čísel $\mathbb{R}$, který splňuje:

- $\mathbb{R} \in \mathcal{B}$.
- Pro každé $a, b \in \mathbb{R}$ (včetně $-\infty, +\infty$) platí $(a, b) \in \mathcal{B}$.
- $B \in \mathcal{B} \Rightarrow B^C \in \mathcal{B}$.
- $\mathcal{B}$ obsahuje všechna spočetná sjednocení svých prvků.

Tento systém množin budeme nazývat *borelovská σ -algebra* a její prvky borelovské množiny.

Jde tedy o systém obsahující všechny otevřené množiny $\mathbb{R}$, jejich spočetná sjednocení, průniky a všechny doplňky. Pro nás je důležité, že v $\mathcal{B}$ jsou obsaženy *všechny* intervaly bez ohledu na otevřenost a všechny jednobodové množiny. Dále $\mathcal{B}$ obsahuje libovolná konečná a spočetná sjednocení i průniky intervalů a jednobodových množin—tedy například i množinu racionálních čísel. Z praktického hlediska nemají jiné reálné podmnožiny velký význam pro aplikace.

2.1. Náhodná veličina a její rozdělení

Definice 2.3: (Náhodná veličina)

Bud' $(\Omega, \mathcal{F}, P)$ pravděpodobnostní prostor. Zobrazení $X : \Omega \rightarrow \mathbb{R}$ takové, že pro všechna $a \in \mathbb{R}$ platí

$$(2.1) \quad X^{-1}(-\infty, a] = \{\omega; X(\omega) \leq a\} \in \mathcal{F},$$

nazveme (reálnou) náhodnou veličinou.

Standardní zkrácené značení, které budeme i my používat, je pro $A \in \mathcal{B}$ a $a \in \mathbb{R}$

$$[X \in A] := \{\omega; X(\omega) \in A\} \text{ a } [X \leq a] := \{\omega; X(\omega) \leq a\}.$$

Všimněme si, že díky definici náhodné veličiny a díky vlastnostem pravděpodobnostní míry P tak dovedeme pro *jakýkoliv* interval říci, s jakou pravděpodobností je hodnota náhodné veličiny v *tomto* intervalu. Tím pádem lze určit i pravděpodobnost $P[X \in B]$ pro všechny množiny $B \in \mathcal{B}$. V teorii míry je podmínka (2.1) ekvivalentní *měřitelnosti* reálné funkce X na (měřitelném) prostoru $(\Omega, \mathcal{F})$.

Cvičení 2.4. Ukažte, že z vlastností $\mathcal{F}$ platí pro libovolná reálná a a b

$$[a < X < b] \in \mathcal{F}, \quad [a \leq X \leq b] \in \mathcal{F}, \quad [a < X \leq b] \in \mathcal{F}.$$

Jinými slovy, všechny výše uvedené jevy (a jim podobné) jsou náhodné jevy a proto má smysl mluvit o *jejich pravděpodobnosti*. $\diamond$

Vidíme tedy, že s náhodnou veličinou je spojen celý systém náhodných jevů, které se odvíjejí od možných hodnot této náhodné veličiny. Konkrétně jde o systém podmnožin (σ -algebru) množiny Ω , která je tvořena vzory borelovských množin. Jde tedy o nejmenší systém uzavřený na doplňky a spočetná sjednocení obsahující všechny množiny typu $\{\omega; X(\omega) \leq a\}$ pro a reálná. Označíme-li tento systém $\mathcal{F}_X$, pak zjevně $\mathcal{F}_X \subset \mathcal{F}$ a platí (ukážete obojí), $\mathcal{F}_X$ je σ -algebra a

$$\mathcal{F}_X = \{X^{-1}(A); A \text{ borelovská podmnožina } \mathbb{R}\}.$$

Cvičení 2.5. Necht' náhodná veličina $X : \Omega \rightarrow \mathbb{R}$ má právě čtyři možné hodnoty $\{1, 2, 3, 4\}$. Pak systém náhodných jevů spojených s touto náhodnou veličinou má právě 2^4 prvků. Popište je. $\diamond$

Co je důležité: na jednom pravděpodobnostním prostoru může být definováno více náhodných veličin. Ve skutečnosti je potřeba při modelování uvažovat pravděpodobnostní prostor, který je dostatečně velký, abychom na něm mohli náhodné veličiny definovat. Náhodnou veličinu se čtyřmi možnými výsledky nelze uvažovat na pravděpodobnostním prostoru, kde $|\Omega| = 3$.

Náhodná veličina přenáší pravděpodobnost do prostoru svých hodnot. Pravděpodobnostní prostor $(\Omega, \mathcal{F}, P)$ je tedy základem (s trochou nadsázky jde o „hřiště náhody“), na kterém se určují výsledky jednotlivých náhodných veličin. Náhoda se projevuje při realizaci náhodných veličin (tedy sledováním výsledků náhodných experimentů) a s nimi spojenými náhodnými jevy. Náhodné jevy generované náhodnými veličinami mají své pravděpodobnosti, což nás dovede k následující definici.

Definice 2.6: (Rozdělení náhodné veličiny)

Bud' $X : \Omega \rightarrow \mathbb{R}$ náhodná veličina. Pravděpodobnostní míru $P_X(A) = P[X \in A]$, $A \in \mathcal{B}$ nazveme *rozdělení náhodné veličiny* X .

Všimněme si, že

- P je pravděpodobnost definovaná na základním prostoru $(\Omega, \mathcal{F})$.
- P_X je obrazem míry P v zobrazení X a jde o pravděpodobnost definovanou na prostoru $(\mathbb{R}, \mathcal{B})$. Hodnoty $P_X(A)$ pro $A \in \mathcal{B}$ jsou dány identitou $P_X(A) = P[X \in A]$.

Pravděpodobnostní prostor je tak světem, ve kterém se uskutečňuje náhoda a náhodná veličina je modelem, který zviditelňuje náhodu pozorováním výsledku (zde v reálných číslech). Díky náhodné veličině nám vzniká *kanonický* pravděpodobnostní prostor $(\mathbb{R}, \mathcal{B}, P_X)$, kde $\mathcal{B}$ obsahuje, mimo jiné, všechny otevřené i uzavřené reálné množiny, jejich spočetná sjednocení a doplňky.

Pravděpodobnost P_X je definovaná na všech borelovských podmnožinách $\mathbb{R}$. Z teorie míry vyplývá, že P_X je jednoznačně určena hodnotami $P_X(-\infty, a] = P[X \leq a]$ pro $a \in \mathbb{R}$.

Pokud se nechceme trápit teorií míry, stačí nám proto vědět, že P_X je definována pro každý interval typu (a, b) , $[a, b]$, $(a, b]$ i $[a, b)$ a splňuje vlastnosti pravděpodobnostní míry, čili se dá rozšířit na všechna spočetná sjednocení i průniky intervalů.

Různé náhodné veličiny mohou mít stejná rozdělení.

Cvičení 2.7. Uvažujme *klasický* pravděpodobnostní prostor $\Omega = \{1, 2, \dots, 12\}$ a na něm náhodné veličiny X, Y a Z . Necht'²

$$X(\omega) = \left\lfloor \frac{\omega - 1}{2} \right\rfloor, \quad Y(\omega) = (\omega - 1) \bmod 6, \quad Z(\omega) = \min(\omega, 13 - \omega) \bmod 6.$$

² $\lfloor x \rfloor$ značí jako obvykle celou část čísla $x \in \mathbb{R}$.

Najděte rozdělení všech tří náhodných veličin. Všimněte si, že funkce X , Y a Z nejsou shodné, jde tedy o *různé* náhodné veličiny. Jistě jste snadno zjistili, že všechny uvedené náhodné veličiny mají stejné rozdělení jako hod ideální šestistěnnou kostkou.

Jako bonus zkuste určit, kolik různých náhodných veličin se stejným rozdělením jako mají X , Y a Z můžete na Ω definovat. Vzhledem ke konečnosti prostoru Ω to samozřejmě musí být konečné číslo, přesto však může být překvapivě velké. $\diamond$

Protože k jednoznačnému určení (pravděpodobnostního) rozdělení P_X náhodné veličiny X stačí znát pravděpodobnosti množin typu $(-\infty, a]$ pro všechna $a \in \mathbb{R}$, zavedeme distribuční funkce náhodných veličin, které v sobě zahrnují všechny pravděpodobnosti těchto intervalů.

Definice 2.8: (Distribuční funkce)

Bud' X náhodná veličina a P_X její rozdělení. Funkce $F_X : \mathbb{R} \rightarrow [0, 1]$ definovaná jako $F_X(x) = P_X(-\infty, x] = P[X \leq x]$ se nazývá *distribuční funkce* náhodné veličiny X .

Povšimněme si

Zatímco rozdělení je pravděpodobnostní mírou, tedy zobrazením $P_X : \mathcal{B} \rightarrow [0, 1]$, distribuční funkce je „jen“ funkcí reálné proměnné.

Distribuční funkce F plně popisuje rozdělení P v tom smyslu, že mají-li náhodné veličiny X a Y stejnou distribuční funkci, jsou *stejně rozdělené*, tedy $P_X = P_Y$.

Věta 2.9: (Vlastnosti distribuční funkce)

Mějme náhodnou veličinu X a její distribuční funkci F_X . Pak

- (1) $\lim_{x \rightarrow -\infty} F_X(x) = 0$,
- (2) $\lim_{x \rightarrow \infty} F_X(x) = 1$,
- (3) F_X je neklesající a zprava spojitá.

Důkaz. Tvrzení plyne z vlastností pravděpodobnostní míry. Monotonie v bodě (3) je důsledkem nezápornosti a aditivity pravděpodobnosti. Opravdu, pro $a < b$ je

$$F_X(a) = P[X \leq a] \leq P[X \leq a] + P[a < X \leq b] = P[X \leq b] = F_X(b).$$

Spojitosť zprava je důsledkem spojitosti pravděpodobnostní míry (věta 1.10, protože posloupnost množin $(-\infty, a + 1/n]$, $n = 1, 2, \dots$ je monotónní s limitou $(-\infty, a]$ a proto $F_X(a + 1/n) = P_X(-\infty, a + 1/n] \rightarrow P_X(-\infty, a] = F_X(a)$). Podobně ze spojitosti míry dokážeme i body (1) a (2). $\square$

Je tomu ale i naopak. Každá funkce, která má vlastnosti distribuční funkce, je distribuční funkcí nějaké náhodné veličiny na vhodném pravděpodobnostním prostoru.


Věta 2.10: (Charakterizace distribuční funkce)

Nechť F splňuje vlastnosti z věty 2.9. Pak existuje pravděpodobnostní prostor $(\Omega, \mathcal{F}, P)$ a náhodná veličina X takové, že F je distribuční funkcí náhodné veličiny X .

Důkaz. Volme³ $\Omega = \mathbb{R}$, $\mathcal{F} = \mathcal{B}$ borelovská σ -algebra z poznámky 2.2, P volme jako pravděpodobnostní míru na $\mathcal{F}$ splňující pro každé $x \in \mathbb{R}$ rovnost $P(-\infty, x] = F(x)$.

Definujme $X : \Omega \rightarrow \mathbb{R}$ vztahem $X(\omega) = \omega$. Potom $F_X(a) = P[X \leq a] = P(-\infty, a] = F(a)$. $\square$

Na obrázku 2.1 jsou uvedeny příklady různých distribučních funkcí. Můžeme si všimnout, že všechny splňují vlastnosti z věty 2.9. Věta 2.10 říká, že každá funkce splňující vlastnosti z věty 2.9 je distribuční funkcí nějaké náhodné veličiny.



Obrázek 2.1. Příklady distribučních funkcí. Všechny splňují vlastnosti z věty 2.9.

³Jde o takzvanou kanonickou konstrukci, zde ukážeme hlavní krok a odvoláme se na charakterizaci P_X prostřednictvím F_X .

2.2. Náhodný vektor a jeho rozdělení

Ve cvičení 2.7 jsme zavedli tři různé náhodné veličiny, které mají stejná rozdělení. Jak se však můžeme snadno přesvědčit, přestože platí $P[X = 0] = P[Y = 0] = P[Z = 0]$, tak⁴ $P[X = 0, Y = 0] \neq P[X = 0, Z = 0]$. Dvojice náhodných veličin (X, Y) a (X, Z) mají zřejmě rozdílné vlastnosti, což znamená, že rozdělení jednotlivých náhodných veličin X, Y , a Z nestačí k popisu jejich společného chování. K tomu potřebujeme sdružené rozdělení a pojem *náhodný vektor*

V následujícím budeme užívat pro jakékoliv dva vektory $\mathbf{a}, \mathbf{b} \in \mathbb{R}^d$ úmluvu

$$\mathbf{a} \leq \mathbf{b} \Leftrightarrow a_i \leq b_i \quad \forall i = 1, 2, \dots, d$$

$$\mathbf{a} \leq \mathbf{b} \Leftrightarrow a_i \leq b_i \quad \forall i = 1, 2, \dots, d, \text{ a existuje } j : a_j < b_j,$$

$$\mathbf{a} < \mathbf{b} \Leftrightarrow a_i < b_i \quad \forall i = 1, 2, \dots, d.$$

Definice 2.11: (Náhodný vektor)

Zobrazení $X : \Omega \rightarrow \mathbb{R}^d$, kde $(\Omega, \mathcal{F}, P)$ je pravděpodobnostní prostor, $d \in \mathbb{N}$, $d \geq 2$ takové, že $\{\omega : X(\omega) \leq \mathbf{a}\} \in \mathcal{F} \quad \forall \mathbf{a} \in \mathbb{R}^d$ nazveme *náhodný vektor*.

Opět tedy vidíme, že jsme schopni přiřadit pravděpodobnost všem jevům typu $[\mathbf{a} < X \leq \mathbf{b}]$ pro libovolná $\mathbf{a}, \mathbf{b} \in \mathbb{R}^d$, potažmo všem jevům typu $[X \in B]$, kde B je borelovská podmnožina $\mathbb{R}^d$ (speciálně libovolná otevřená či uzavřená podmnožina $\mathbb{R}^d$). Můžeme tedy bez obav definovat rozdělení a distribuční funkci pro náhodný vektor.

Poznámka 2.12. Nejprve si ujasněme rozšíření definice systému $\mathcal{B}$ podmnožin $\mathbb{R}$ na systém podmnožin $\mathbb{R}^d$. Jedná se o nejmenší systém podmnožin uzavřený na doplňky a spočetná sjednocení, který obsahuje všechny množiny typu $B = \bigtimes_{i=1}^d B_i$, $B_i \in \mathcal{B}$. Tento systém *borelovských podmnožin* $\mathbb{R}^d$ označíme $\mathcal{B}(\mathbb{R}^d)$.

Definice 2.13: (Rozdělení a distribuční funkce náhodného vektoru)

Bud' X d -rozměrný náhodný vektor. Pravděpodobnostní míru P_X definovanou na $\mathcal{B}(\mathbb{R}^d)$ předpisem

$$P_X(B) = P[X \in B]$$

nazýváme *rozdělením* náhodného vektoru X .

Funkce $F_X : \mathbb{R}^d \rightarrow [0, 1]$ definovaná $F_X(\mathbf{a}) = P[X \leq \mathbf{a}]$ se nazývá *distribuční funkce* náhodného vektoru X .

I zde platí, že distribuční funkce jednoznačně určuje rozdělení. Platí totiž, že hodnoty $P_X(B)$ jsou jednoznačně určené všemi hodnotami

$$P_X\left(\bigtimes_{i=1}^d (-\infty, a_i]\right) = P\left(\bigcap_{i=1}^d [X_i \leq a_i]\right) = P[X \leq \mathbf{a}] = F_X(\mathbf{a}).$$

⁴Užíváme standardní značení, kdy jev $[X = 0, Y = 0]$ je zkratkou za zápis $[X = 0] \cap [Y = 0]$, čárka tedy znamená „platí zároveň“.

Náhodný vektor je vlastně náhodnou veličinou s hodnotami v prostoru $\mathbb{R}^d$. Obecně lze zavést náhodné veličiny s hodnotami i v prostorech s nekonečnou dimenzí. Proto není třeba striktně rozlišovat mezi náhodnými veličinami a vektory (a ve „vyšší“ pravděpodobnosti a statistice se opravdu nerozlišuje), protože lze uvažovat jednotnou definici. Důvod k rozlišování v úvodní přednášce ale je v rozdělení náhodného vektoru, které nese více informace, než jen rozdělení jednotlivých složek.

Věta 2.14: (Vlastnosti distribuční funkce)

Bud' F_X distribuční funkce náhodného vektoru X . Pak:

- (1) $\lim_{a_i \rightarrow -\infty} F_X(\mathbf{a}) = 0$ pro libovolné i ,
- (2) $\lim_{a_i \rightarrow \infty} \forall_i F_X(\mathbf{a}) = 1$,
- (3) v každé složce argumentu je F_X zprava spojitá a neklesající,
- (4) $\forall \mathbf{a} < \mathbf{b}$ platí $\sum_{k=0}^d (-1)^k \sum_{\mathbf{c} \in \Delta_k(\mathbf{a}, \mathbf{b})} F_X(\mathbf{c}) \geq 0$.

Vlastnosti (1)–(3) jsou přímým zobecněním vlastností distribuční funkce jednorozměrné náhodné veličiny. Ovšem nepřehlédněte rozdíl mezi (1) a (2), kdy v prvním případě stačí existence jediného indexu i pro který $x_i \rightarrow -\infty$, zatímco ve druhém případě potřebujeme platnost $x_i \rightarrow \infty$ pro všechny indexy. Důvod tohoto rozdílu si jistě sami snadno rozmyslíte.

Vlastnost (4), která nemá přímou obdobu ve vlastnostech distribuční funkce náhodné veličiny (viz věta 2.9), si zaslouží trochu prozkoumání.

Důkaz. Pro důkaz (4) vyjděme z dvourozměrného náhodného vektoru. Pak podmínka (4) pro $\mathbf{a} = (a_1, a_2), \mathbf{b} = (b_1, b_2)$ říká, že pro $\mathbf{a} < \mathbf{b}$ platí $F_X(b_1, b_2) - F_X(a_1, b_2) - F_X(b_1, a_2) + F_X(a_1, a_2) \geq 0$. Podle definice distribuční funkce jde zřejmě o pravděpodobnost obdélníku $(a_1, b_1] \times (a_2, b_2]$ a ta musí být pochopitelně nezáporná. Čili pro všechny dvojice $\mathbf{a} < \mathbf{b}$ musí podmínka (4) platit.

Zobecnění do více rozměrů je možné provést stejnou úvahou. $\square$


I zde platí, že funkce splňující vlastnosti (1)–(4) věty 2.14 je distribuční funkcí nějaké náhodné veličiny. Na obrázku 2.2 jsou znázorněny příklady distribučních funkcí náhodného vektoru se dvěma složkami, tj. $d = 2$.

Cvičení 2.15. Rozmyslete si, že vlastnost (4) neplyne z vlastností (3) a je pro distribuční funkci podstatná. Najděte funkci $F : \mathbb{R}^2 \rightarrow [0, 1]$ splňující jen (1)–(3), která neodpovídá žádné pravděpodobnosti, neboť dává nějakému obdélníku zápornou hodnotu. $\diamond$

Vraťme se zpět k „rozdílu“ mezi náhodnou veličinou a vektorem. Nejprve si můžeme uvědomit, že z definice náhodného vektoru plyne, že každá jeho složka je náhodnou veličinou. Nechť $\mathbf{X} = (X_1, \dots, X_k)^\top$ je náhodný vektor, pak

$$\{\omega; X_i(\omega) \leq a\} = \{\omega; X_i(\omega) \leq a, X_j(\omega) \leq \infty \text{ pro všechna } j \neq i\} \in \mathcal{F}.$$

Známe-li distribuční funkci F_X náhodného vektoru X (a tím pádem i rozdělení X), pak známe i rozdělení všech jeho složek.



Obrázek 2.2. Příklady distribučních funkcí náhodného vektoru o dvou složkách, tj. $d = 2$.

Definice 2.16: (Marginální rozdělení)

Bud' $X = (X_1, \dots, X_d)^\top$ náhodný vektor a P_X jeho rozdělení. Rozdělení P_{X_i} takové, že pro každé $\mathbf{a} = (a_1, \dots, a_d)$ platí $P_{X_i}(-\infty, a_i] = \lim_{a_j \rightarrow \infty, j \neq i} P_X \left(\bigtimes_{j=1}^d (-\infty, a_j] \right)$ se nazývá *marginální rozdělení* X_i a

$$F_{X_i}(a_i) = \lim_{a_j \rightarrow \infty, j \neq i} F_X(\mathbf{a})$$

se nazývá jeho marginální distribuční funkce X_i .

Povšimněme si

Rozdělení P_X náhodného vektoru se obvykle nazývá *sdužené* a F_X jeho sdužená distribuční funkce.

Máme-li pro $d > 2$ nějaký d -rozměrný náhodný vektor X , pak mezi jeho sduženým rozdělením P_X a marginálními rozděleními P_{X_i} leží rozdělení jeho vlastních (více-rozměrných) podvektorů. Tato rozdělení se podle okolností mohou nazývat marginální (vzhledem k rozdělení P_X), ale také sdužená (pokud je vztahujeme k rozdělení P_{X_i} pro odpovídající indexy i).

Dále zřejmě platí $P_{X_i}(B) = P_X\left(\times_{j=1}^{i-1} \mathbb{R} \times B \times \times_{j=i+1}^d \mathbb{R}\right)$

I když můžeme díky axiomatice založené na teorii míry následující rozlišení náhodných vektorů vynechat, pro úvodní seznámení je užitečné.

Definice 2.17: (Diskrétní náhodný vektor)

Náhodný vektor (veličina) X , je *diskrétní*, pokud nabývá nejvýše spočetně mnoha hodnot. V tom případě existuje nejvýše spočetná množina $\mathbb{S}$ a nezáporné hodnoty $p_s, s \in \mathbb{S}$ takové, že $P[X = s] = p_s > 0$ a $P[X \in A] = \sum_{s \in A} p_s$. Jinými slovy $X(\omega) \in \mathbb{S}$ pro všechna ω . Nutně musí platit

$$\sum_{s \in \mathbb{S}} p_s = 1.$$

Rozdělení diskrétního náhodného vektoru X je zcela charakterizováno souborem hodnot $\{p_s\}_{s \in \mathbb{S}}$.

Dohodněme se, že pro naše účely postačí, pokud diskrétní náhodný vektor nabývá hodnoty vždy v podmnožině $\mathbb{N}_0^d$, neřekneme-li jinak.

Definice 2.18: (Spojitý náhodný vektor)

Náhodný vektor (veličina) X je *spojitý*, pokud pro libovolnou hodnotu platí $P[X = a] = 0$ a existuje-li nezáporná funkce f taková, že $P[X \in A] = \int_A f(x) dx$.

Funkce f musí splňovat

$$1 = P(X \in \mathbb{R}^d) = \int_{\mathbb{R}^d} f(x) dx.$$

Rozdělení spojitého náhodného vektoru je plně charakterizováno nezápornou funkcí f ⁵. Správně bychom měli mluvit o *absolutně spojitém* náhodném vektoru (veličině) a absolutně spojitém rozdělení, ale s jiným případem spojitého rozdělení se zde nesetkáme, proto budeme mluvit jednoduše o spojitém vektoru a spojitém rozdělení.

⁵Tato funkce však není určena jednoznačně. Změníme-li hodnoty funkce f v konečně či spočetně mnoha bodech, integrály $\int_{-\infty}^x f(t) dt$ zůstanou nezměněné. Obvykle volíme f „hezkou“, tedy například po částech spojitou, aby ji bylo možné zapsat co nejjednodušším předpisem.

Hodnoty p_s v případě diskrétního náhodného vektoru a funkci f v případě spojitého náhodného vektoru nazveme *hustotou* náhodného vektoru X .

Poznámka 2.19. Nechť X je náhodná veličina se spojitým rozdělením s hustotou f a s distribuční funkcí F . Pak

$$F(x) = P[X \leq x] = \int_{-\infty}^x f(t) dt$$

a tedy platí, že hustota f je „derivací“ distribuční funkce F . Z vlastností distribuční funkce, konkrétně ze spojitosti zprava, monotonie a omezenosti F , vyplývá existence její derivace F' ve skoro všech bodech (obvykle s výjimkou nejvýše konečně či spočetně mnoha bodů) a pro spojitou náhodnou veličinu tak můžeme za hustotu brát funkci

$$f(x) = \begin{cases} F'(x) & \text{ve všech bodech, kde derivace } F'(x) \text{ existuje,} \\ 0 & \text{jinde.} \end{cases}$$

Dále pak platí $P[X = a] = 0$ pro libovolné číslo $a \in \mathbb{R}$, jelikož

$$P[X = a] = \int_{\{a\}} f(x) dx = 0,$$

protože integrál přes jednobodovou množinu je roven nule. Rozhodně tedy neplatí, že by hodnota hustoty v bodě a byla rovna $P[X = a]$. Jak lze tedy hodnotu $f(a)$ interpretovat? Uvažujme nějaké malé $\varepsilon > 0$ a nechť f je spojitá v a . Pak

$$P[X \in (a - \varepsilon, a + \varepsilon)] = \int_{a-\varepsilon}^{a+\varepsilon} f(x) dx \approx 2\varepsilon \cdot f(a).$$

Z hodnoty hustoty v bodě a tedy můžeme usuzovat, jak je pravděpodobné, že X bude náležet nějakému okolí bodu a . Viz také ilustrační obrázek 2.3.

Z předchozího také plyne, že pro spojitou náhodnou veličinu a libovolné $a, b \in \mathbb{R}$, $a < b$, platí

$$P[X \in [a, b]] = P[X \in (a, b)] = P[X \in [a, b)) = P[X \in (a, b]] = \int_a^b f(x) dx = F(b) - F(a),$$

což je graficky ilustrováno na obrázku 2.4.

Poznámka 2.20. Pro spojitý náhodný vektor také platí, že jeho distribuční funkce má (parciální) derivace ve skoro všech bodech. Můžeme proto volit


$$f(x_1, \dots, x_d) = \begin{cases} \frac{\partial^d}{\partial x_1 \partial x_2 \dots \partial x_d} F(x_1, \dots, x_d) & \text{ve všech bodech, kde tato derivace existuje,} \\ 0 & \text{jinde.} \end{cases}$$

Věta 2.21: (Vztah sdružené a marginální hustoty)


Bud' X spojitý náhodný vektor a $f_X(\mathbf{x})$ jeho hustota. Pak marginální hustota náhodné veličiny X_1 může být zvolena

$$f_{X_1}(x) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f_X(x, t_2, \dots, t_d) dt_d \dots dt_2,$$

v bodech, kde tento integrál má smysl.



Obrázek 2.3. Interpretace hustoty v bodě a . Hodnota $P[X \in (a - \varepsilon, a + \varepsilon)]$ je vyšrafovaný obsah plochy pod křivkou f . Pro ε malé ji lze aproximovat pomocí obsahu obdelníku, tj. pomocí hodnoty $2\varepsilon f(a)$.



Obrázek 2.4. Grafické znázornění výpočtu pravděpodobnosti $P[X \in (a, b)]$ pro spojitou náhodnou veličinu X pomocí její hustoty (vlevo) a pomocí její distribuční funkce (vpravo).

Důkaz. Vzhledem k tomu, že hustota je nezáporná a její integrál je roven jedné, má integrál $\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_X(x, t_2, \dots, t_d) dt_d \dots dt_2$ smysl ve skoro všech bodech x . Pro tyto body platí

$$f_{X_1}(x) = F'_{X_1}(x) = \frac{\partial}{\partial x} \int_{-\infty}^x \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_X(t_1, t_2, \dots, t_d) dt_d \dots dt_1,$$

a ze základní věty analýzy nyní plyne tvrzení věty. $\square$

Poznámka 2.22. Pokud hledáme sdružené rozdělení vlastního podvektoru náhodného vektoru X , můžeme použít jednoduché pravidlo. Ty souřadnice, které se v

podvektoru nevyskytují musíme „odintegrovat“ přes celý obor. Například

$$f_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f_X(x_1, x_2, t_3, \dots, t_d) dt_d \dots dt_3$$

v bodech, ve kterých tento integrál má smysl.

U diskretních náhodných vektorů je situace podobná, jen místo integrování sčítáme přes všechny možné hodnoty. Dostaneme tak

$$P[X_1 = s_1, X_2 = s_2] = \sum_{\mathbf{x}: X_1=s_1, X_2=s_2} P[\mathbf{X} = \mathbf{x}].$$

Náhodný vektor nemusí být ani diskretní, ani spojitý, příkladem může být náhodný vektor (X, Y) udávající počet dní se srážkami za týden (X , diskretní n.v.) a stav podzemních vod (Y , spojitá n.v.). Ale i samotná náhodná veličina může mít diskretní a spojitou složku. Je-li Z úhrn srážek za den, pak s nenulovou pravděpodobností nabude hodnoty 0 (diskretní část), ale jinak jde o spojitou náhodnou veličinu (byť měřenou s přesností na jednotky l/m^2). Takové případy se vždy modelují podle potřeby a protože i pro ně platí obecné výsledky, které zde probereme, stačí se nyní pro jednoduchost zabývat jen čistě diskretními a čistě spojitými náhodnými vektory.

2.3. Nezávislost a vztah sdruženého a marginálních rozdělení

Začneme jednoduchým pozorováním.

Věta 2.23: (O marginálním rozdělení)

Máme-li náhodný vektor $\mathbf{X} = (X_1, \dots, X_d)^\top$ a jeho rozdělení P_X , pak marginální rozdělení složek $X_1, \dots, X_d$ jsou jednoznačně určena rozdělením P_X .

Důkaz. Očividné. □

Naopak ale tvrzení **neplatí**. Navažme na cvičení 2.7.


Cvičení 2.24. Hod' me dvěma kostkami. Jejich výsledky jsou A, B . Dále mějme $C = A - 1$ pro B sudé a $C = A + 1$ pro B liché, přičemž pro C hodnotu 0 změníme na hodnotu 6 a podobně 7 zaměníme s hodnotou 1. Zapišme si sdružená a marginální rozdělení náhodných vektorů (A, B) a (A, C) do tabulky:

$A \backslash B$	1	2	3	4	5	6	
1	1/36	1/36	1/36	1/36	1/36	1/36	1/6
2	1/36	1/36	1/36	1/36	1/36	1/36	1/6
3	1/36	1/36	1/36	1/36	1/36	1/36	1/6
4	1/36	1/36	1/36	1/36	1/36	1/36	1/6
5	1/36	1/36	1/36	1/36	1/36	1/36	1/6
6	1/36	1/36	1/36	1/36	1/36	1/36	1/6
	1/6	1/6	1/6	1/6	1/6	1/6	

$A \backslash C$	1	2	3	4	5	6	
1	0	1/12	0	0	0	1/12	1/6
2	1/12	0	1/12	0	0	0	1/6
3	0	1/12	0	1/12	0	0	1/6
4	0	0	1/12	0	1/12	0	1/6
5	0	0	0	1/12	0	1/12	1/6
6	1/12	0	0	0	1/12	0	1/6
	1/6	1/6	1/6	1/6	1/6	1/6	

Vidíme, že pro náhodné vektory (A, B) a (A, C) jsou jejich marginální rozdělání stejná, ale sdružená rozdělání jsou velmi odlišná. $\diamond$

Cvičení 2.25. Obrázek 2.5 zobrazuje dvě různé sdružené hustoty, kterým odpovídají stejné marginální hustoty složek (jedná se o tzv. normální rozdělání, které bude blíže představeno v Kapitole 2.5). Opět tedy vidíme, že ze znalosti marginálních rozdělání nelze bez další informace nic usuzovat o sdruženém rozdělání. $\diamond$



Obrázek 2.5. Příklad sdružené hustoty $f(x, y)$ náhodného vektoru $(X, Y)^T$, kde X, Y mají tzv. standardní normální rozdělání (viz Kapitola 2.5). Vlevo jsou X a Y závislé, hustota na pravém obrázku pak odpovídá nezávislým složkám.

Je krásným matematickým výsledkem, že jakékoliv mnohorozměrné rozdělání je složeno ze svých marginálních pomocí (v jistém smyslu jednoznačně dané) funkce zvané *kopula* a to následovně. Bud' F_X sdružená distribuční funkce a bud'te $F_{X_i}, i = 1, \dots, d$ její marginální distribuční funkce. Pak existuje (v jistém smyslu jediná, pro spojitě F_X opravdu jediná) funkce $C : [0, 1]^d \rightarrow [0, 1]$ taková, že

$$F_X(\mathbf{x}) = C(F_1(x_1), F_2(x_2), \dots, F_d(x_d)).$$

Funkce C je sama distribuční funkcí, jejíž marginální rozdělání jsou rovnoměrná na intervalu $(0, 1)$. Modelování a odhadování funkce C je předmětem mnoha studií.

Sdružené rozdělání náhodného vektoru X určuje, jaký *stochastický* vztah mezi sebou mají jednotlivé náhodné veličiny v X . Jen z marginálních rozdělání nejsme schopni tento vztah odvodit, proto je tak důležité znát sdružené rozdělání. Zde také leží hlavní význam náhodných vektorů.

Při jednom speciálním vztahu ale platí, že sdružené rozdělení z marginálního určíme vždy.

Definice 2.26: (Nezávislost náhodných veličin)

Mějme $X_1, X_2, \dots, X_k$ náhodné veličiny definované na $(\Omega, \mathcal{F}, P)$. Tyto veličiny jsou (stochasticky) *vzájemně nezávislé*, pokud platí

$$F_X(\mathbf{x}) = \prod_{i=1}^k F_{X_i}(x_i) \text{ pro všechna } \mathbf{x} = (x_1, \dots, x_k) \in \mathbb{R}^k,$$

kde $X = (X_1, \dots, X_k)$.

Všimněte si, že k nezávislosti potřebujeme společný pravděpodobnostní prostor, na kterém jsou náhodné veličiny definované. Ekvivalentně lze nezávislost zavést z rozdělení.

Věta 2.27: (Rozdělení nezávislých náhodných veličin)

Náhodné veličiny $X_1, \dots, X_k$ jsou nezávislé, právě když pro všechna $A_1, \dots, A_k \in \mathcal{B}$ platí

$$P\left(\bigcap_{i=1}^k [X_i \in A_i]\right) = \prod_{i=1}^k P[X_i \in A_i].$$

Důkaz. Plyne z definice distribuční funkce a z charakterizace rozdělení náhodného vektoru pomocí distribuční funkce. $\square$

Věta 2.28: (Ekvivalentní podmínka nezávislosti)

Nechť $X_1, \dots, X_k$ jsou diskrétní náhodné veličiny, kde X_i má rozdělení na $\mathbb{S}_i$. Pak jsou tyto veličiny nezávislé právě tehdy, když

$$P[X = (s_1, \dots, s_k)^\top] = \prod_{i=1}^k P[X_i = s_i] \text{ pro všechna } s_i \in \mathbb{S}_i, i = 1, \dots, k,$$

kde $X = (X_1, \dots, X_k)^\top$.

Spojitě náhodné veličiny $X_1, \dots, X_k$ jsou nezávislé právě tehdy, když rovnost

$$f_X(x_1, \dots, x_k) = \prod_{i=1}^k f_{X_i}(x_i)$$

platí pro skoro všechna^a $(x_1, \dots, x_k)^\top \in \mathbb{R}^k$, kde f_X je hustota $X = (X_1, \dots, X_k)^\top$ a f_{X_i} je marginální hustota X_i .

^aTj. podmínka platí pro všechna $(x_1, \dots, x_k)^\top \in \mathbb{R}^k \setminus M$, kde $M \in \mathcal{B}$ je množina míry nula. Příkladem množiny míry nula je podprostor nižší dimenze, tj. např. v $\mathbb{R}^2$ je množinou míry nula přímka, úsečka, bod, sjednocení spočetně mnoha přímek apod.

Důkaz. Plyne ze vztahu mezi hustotou a distribuční funkcí. $\square$

Na rozdíl od definice nezávislosti náhodných jevů se nemusíme pro konečně mnoho náhodných veličin zabývat podmnožinami indexů. Vybírání podmnožin indexů je obsaženo v požadavku rovnosti $F_X(\mathbf{x}) = \prod_{i=1}^k F_{X_i}(x_i)$ pro všechny vektory $\mathbf{x} \in \mathbb{R}^k$.

2.4. Základní diskrétní rozdělení

Základním kamenem pro diskrétní náhodné veličiny je takzvaný Bernoulliův⁶ pokus. Jde o pokus, ve kterém s pravděpodobností $p \in (0, 1)$ *uspějeme* a s pravděpodobností $1 - p$ dojde k *neúspěchu*.

2.4.1. Alternativní, neboli Bernoulliovo rozdělení. Uvažujme výše popsany Bernoulliův pokus a necht' X je indikátor toho, zda nastal v tomto pokusu úspěch. Pak X nabývá hodnot z množiny $\{0, 1\}$, $P[X = 1] = P_X(\{1\}) = p \in (0, 1)$ a $P[X = 0] = 1 - p$. Parametr p je interpretován jako pravděpodobnost úspěchu. Značíme $\text{Alt}(p)$.

2.4.2. Binomické rozdělení. Představme si posloupnost n nezávislých opakování Bernoulliových pokusů s parametrem p . To znamená, že máme n nezávislých náhodných veličin $Y_1, \dots, Y_n$ se stejným parametrem p . Označme X počet těch indexů, pro které je $Y_i = 1$, jinými slovy jde o celkový počet úspěchů v n nezávislých Bernoulliových pokusech. Pak X nabývá hodnot $0, 1, \dots, n$ a snadno lze ověřit, že platí

$$P[X = k] = \binom{n}{k} p^k (1 - p)^{n-k} \quad \text{pro } k = 0, \dots, n.$$

Toto rozdělení standardně značíme $\text{Bi}(n, p)$.

2.4.3. Geometrické rozdělení. Opět uvažujme nezávislé Bernoulliovy pokusy, tentokrát však nemáme předem daný počet těchto pokusů a proto uvažujeme tentokrát potenciálně nekonečnou⁷ posloupnost nezávislých veličin $Y_1, Y_2, \dots$ se stejným parametrem p . Hodnota X nyní označuje počet neúspěchů před prvním úspěchem, jinými slovy $X = \min\{k; Y_k = 1\} - 1$. Proto X může nabývat všech přirozených čísel s nulou a

$$P[X = k] = p(1 - p)^k, \quad \text{pro } k = 0, 1, \dots$$

Tvar výše uvedených pravděpodobností plyne z toho, že prvních k pokusů (k může být i 0) dopadlo neúspěšně, což jsou jevy s pravděpodobností $(1 - p)^k$, a poslední jev dopadl úspěšně, a to s pravděpodobností p . O zbytek se postará nezávislost pokusů. Toto rozdělení obvykle značíme $\text{Geom}(p)$.

⁶Pojmenováno po Jacobu Bernoulli, autoru *Ars Conjectandi*, kde je tento pokus uvažován.

⁷Je matematicky možné zkonstruovat pravděpodobnostní prostor a na něm definovat nekonečně mnoho nezávislých náhodných veličin se stejným rozdělením.

2.4.4. Negativně binomické rozdělení. Nesledujeme-li dobu do prvního úspěchu, ale dobu do r -tého úspěchu, pak počet *neúspěšných* pokusů X před r -tým úspěšným pokusem má takzvané negativně binomické rozdělení. Pokud $X = k$, tak před r -tým úspěšným pokusem bylo provedeno celkem $k + r - 1$ pokusů, ze kterých právě k skončilo neúspěchem a r úspěchem. Proto není těžké odvodit, že

$$P[X = k] = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, \dots$$

Toto rozdělení označíme $NB(r, p)$.

2.4.5. Poissonovo rozdělení. Toto rozdělení je motivováno různými oblastmi vědy. Představa je taková, že v krátkém časovém úseku dojde jen s malou pravděpodobností k události—například k objednávce na internetu od určitého člověka. Ale pokud máme *hodně* pokusů, tak už nějakou událost můžeme pozorovat s velkou pravděpodobností. Při tomto modelu můžeme vyjít z binomického rozdělení, kde zvyšujeme počet pokusů n a zároveň pravděpodobnost úspěchu p_n v jednom pokusu je zanedbatelná. To odpovídá představě mnoha sázek v loterii (n), každá má jen zanedbatelnou pravděpodobnost úspěchu (stejnou, tedy p_n , úspěch přijde nezávisle na ostatních), a pokud $np_n \rightarrow \lambda > 0$ (tím *samozřejmě* myslíme, že $\lambda < \infty$), pak platí, že rozdělení počtu úspěchů se blíží Poissonovu rozdělení. To je dáno předpisem

$$P[X = k] = \exp(-\lambda) \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

Poissonovým rozdělením se může velmi dobře modelovat počet nehod na dálnici D1 za den, počet prasklých žárovek v budově za týden a podobné události. Obvykle toto rozdělení značíme $Po(\lambda)$.

2.4.6. Hypergeometrické rozdělení.⁸ Mějme konečnou množinu N prvků skládající se z prvků dvou druhů. Z této množiny vylosujeme n prvků (každý může být vybrán právě jednou, tomu se říká výběr bez vracení). S jakou pravděpodobností vybereme právě k prvků prvního druhu?

Označme n_1 počet prvků prvního druhu, očividně tedy $n_2 = N - n_1$ a náhodnou veličinou X počet vylosovaných prvků prvního druhu. Uvědomte si, že můžeme vybrat k prvků prvního druhu, pouze pokud $0 \leq k \leq n_1$ a zároveň $0 \leq n - k \leq n_2$. Pro taková k pak platí

$$P[X = k] = \frac{\binom{n_1}{k} \binom{n_2}{n-k}}{\binom{N}{n}}.$$

2.4.7. Rovnoměrné diskrétní. Toto rozdělení je vlastně jednoduchým modelem, kdy náhodná veličina X nabývá konečně mnoha hodnot a každou z nich se stejnou pravděpodobností. Speciálním případem je alternativní rozdělení s parametrem $p = 1/2$, pro náhodné procházky je významné rozdělení s hodnotami $-1, 1$ a rovnoměrné rozdělení se také používá jako model hodu kostkou a podobné. Toto rozdělení obvykle značíme $R(S)$, kde S je množina možných výsledků náhodné veličiny X .

⁸Povšimněte si, jak toto rozdělení souvisí s Pólyovým schématem a tahy bez vracení. Pro racionální p lze s Pólyovým schématem s vracením spojit alternativní rozdělení a rozdělení z něj odvozená.

2.5. Základní spojitá rozdělení

2.5.1. Rovnoměrné spojité. Rovnoměrné rozdělení na intervalu (a, b) , $-\infty < a < b < \infty$ je charakterizováno tím, že pro každý interval $(c, d) \subset (a, b)$ je pravděpodobnost jevu $X \in (c, d)$ určena pouze délkou intervalu (c, d) . Hustota rovnoměrného rozdělení je proto konstantní a je rovna

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & x \notin (a, b). \end{cases}$$

Toto rozdělení značíme $U(a, b)$ a používá se například jako model „zaokrouhlovací chyby“.

2.5.2. Exponenciální rozdělení. Jde o nejjednodušší rozdělení modelující „dobu do události“. Použití má například v rozdělení doby mezi dvěma objednávkami v internetovém obchodu, pro životnost součástky, nebo podobné doby do „selhání“. Exponenciální rozdělení má hustotu

$$f(x) = \begin{cases} \lambda \exp(-\lambda x), & x \geq 0, \\ 0, & x < 0, \end{cases}$$

kde $\lambda > 0$ je parametrem tohoto rozdělení. Jeho označení je $\text{Exp}(\lambda)$.

2.5.3. Paretovo rozdělení. Paretovo⁹ rozdělení je trochu podobné exponenciálnímu, na rozdíl od něj má ale řádově větší pravděpodobnost velkých hodnot. Používá se například pro modelování výše mezd a příjmů.

Hustota Paretova rozdělení je obvykle zapisována ve tvaru

$$f(x) = \begin{cases} \frac{a}{(x+1)^{a+1}}, & x > 0, \\ 0, & x < 0, \end{cases}$$

kde $a > 0$ je parametrem tohoto rozdělení.

2.5.4. Normální rozdělení. Normální rozdělení, zvané též Gaussovo¹⁰, je asi nejznámějším rozdělením náhodné veličiny. Má veliké množství zajímavých vlastností a souvislostí, my zde ale využijeme jen některé z nich. Jeden z důvodů, proč má normální rozdělení tak výsadní postavení v rámci pravděpodobnosti, je centrální limitní věta, o které se dozvíme později.

Takzvané standardní normální rozdělení má hustotu

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right), \quad x \in \mathbb{R}.$$


⁹Vilfredo Pareto formuloval princip 80/20, který stanoví, že zhruba 80 % jmění je vlastněno 20 % populace. Zajímavostí je, že Paretův vztah přibližně platí i pro skupinu 20 % bohatších, tedy i mezi nimi přibližně 20 % vlastní 80 % jmění, tedy zhruba 4 % vlastní 64 % a tento vztah platí i pro tuto nejbohatší skupinu 4 % populace. Podobné vztahy platí i pro podíl zisku od zákazníků (20 % zákazníků vytvoří 80 % útraty), čas strávený s klienty na přepážce a tak dále, liší se jen parametricky. Paretovo rozdělení velmi dobře reflektuje právě tyto podílové vztahy

¹⁰Carl Friedrich Gauß je považován za největšího matematika historie. Normální rozdělení popsal v souvislosti s prací na metodě nejmenších čtverců, ačkoliv tvar hustoty normálního rozdělení znal již Abraham de Moivre. De Moivre však toto bral jen jako přiblížení pro rozdělení součtu nezávislých náhodných veličin, proto se za „objevitele“ normálního rozdělení považují hlavně Gauss a Pierre-Simon Laplace.

Všimněme si, že toto rozdělení je natolik významné, že si zaslouží vlastní značení pro hustotu— φ . Obecné normální rozdělení má hustotu

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R},$$

kde $\mu \in \mathbb{R}$ a $\sigma^2 > 0$ jsou parametry. Standardní normální rozdělení má tedy parametry $\mu = 0$ a $\sigma^2 = 1$. Normální rozdělení označujeme $N(\mu, \sigma^2)$. Obrázek 2.6 znázorňuje graf hustoty normálního rozdělení. Vidíme, že parametr μ určuje lokaci hustoty, tj. je to bod, v němž je hustota maximální. Parametr σ určuje, nakolik je rozdělení koncentrováno kolem centrálního bodu μ . V další kapitole uvidíme přesný význam těchto pojmů.



Obrázek 2.6. Hustota normálního rozdělení $N(\mu, \sigma^2)$ a grafická interpretace parametrů μ a σ .

2.6. Některá rozdělení náhodných vektorů

V této části si ukážeme několik rozšíření rozdělení náhodné veličiny na náhodné vektory.

2.6.1. Multinomické rozdělení. Multinomické rozdělení je mnohorozměrnou obdobou binomického, místo prostého výsledku „úspěch/neúspěch“ však uvažujeme větší množství možností. Bud' n počet pokusů v nichž může dojít právě k jednomu z k výsledků. Výsledek i má v každém pokusu pravděpodobnost p_i , $\sum_{i=1}^k p_i = 1$, výsledky jednotlivých pokusů se nijak neovlivňují. Náhodný vektor $X = (X_1, X_2, \dots, X_k)$ zachycující počty výsledků v n pokusech má rozdělení s hustotou

$$P[X = (n_1, n_2, \dots, n_k)] = \begin{cases} \frac{n!}{n_1!n_2!\dots n_k!} p_1^{n_1} p_2^{n_2} \dots p_k^{n_k} & n_i \in \mathbb{N}_0, \sum_{i=1}^k n_i = n, \\ 0 & \text{jinak.} \end{cases}$$

Toto rozdělení označujeme zkratkou $\text{Mult}(n, p_1, \dots, p_k)$.

2.6.2. Mnohorozměrné hypergeometrické rozdělení. I zde vycházíme z modelu, kde místo dvou možností máme více druhů prvků, které můžeme vylosovat. Oblíbeným případem je rybník s N rybami v němž je k druhů ryb zastoupených $n_1, n_2, \dots, n_k$ jedinci, $n_i > 0$, $\sum_i n_i = N$. Předpokládejme, že každá ryba může být chycena se stejnou pravděpodobností, rybář ryby nehází zpět a chce vylovit právě n ryb. Jaké je rozdělení druhů ryb mezi vylovenými?

Označme X náhodný vektor, pro který X_i je náhodná veličina udávající počet vylovených ryb i -tého druhu. Zajímá nás $P[X_1 = x_1, \dots, X_k = x_k]$. Určitě musí platit $0 \leq x_i \leq n_i$ a $\sum_i x_i = n$. V takovém případě

$$P[X_1 = x_1, \dots, X_k = x_k] = \frac{\binom{n_1}{x_1} \dots \binom{n_k}{x_k}}{\binom{N}{n}}.$$

2.6.3. Mnohorozměrné normální rozdělení. Mnohorozměrné (zde d -rozměrné) normální rozdělení je dáno hustotou

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} \sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right), \quad \mathbf{x} \in \mathbb{R}^d,$$

a parametry rozdělení jsou $\boldsymbol{\mu} \in \mathbb{R}^d$ a Σ symetrická pozitivně definitní matice typu $d \times d$. Označení tohoto rozdělení je $N_d(\boldsymbol{\mu}, \Sigma)$.

Speciální variantou je *dvourozměrné normální rozdělení*, na kterém si můžeme lépe představit vlastnosti tohoto rozdělení. Uveďme si základní tři varianty tohoto rozdělení.

- (1) *Standardní normované dvourozměrné normální rozdělení* je charakterizováno $\boldsymbol{\mu} = \mathbf{0}$ a $\Sigma = I_2$ je jednotková matice. Jeho hustota má tedy jednoduchý tvar

$$f(\mathbf{x}) = \frac{1}{2\pi} \exp\left(-\frac{1}{2}(x_1^2 + x_2^2)\right).$$

- (2) V případě, kdy $\boldsymbol{\mu} = \mathbf{0}$ a matice Σ má speciální tvar

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \text{ kde } |\rho| < 1,$$

pak mluvíme často také o normovaném normálním rozdělení a jeho hustota má tvar (odvod'te si z obecného normálního rozdělení)

$$f(\mathbf{x}) = \frac{1}{2\pi \sqrt{1 - \rho^2}} \exp\left(-\frac{x_1^2 - 2\rho x_1 x_2 + x_2^2}{2(1 - \rho^2)}\right).$$

Graf této hustoty pro $\rho = 0.9$ a $\rho = 0$ je znázorněn na obrázku 2.5.

- (3) V obecném případě, je hustota dána vzorcem

$$f(\mathbf{x}) = \frac{1}{2\pi \sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right).$$

Všimněme si kvadratické formy v exponentu. Ta zaručuje, že hustota normálního rozdělení má stejnou hodnotu na elipse dané středem (μ_1, μ_2) a maticí Σ . V případě standardního normálního rozdělení pak jde o kružnici se středem v počátku, na kteréž je hodnota hustoty konstantní.

2.7. Rozdělení funkce náhodné veličiny a vektoru

Uvažujme náhodnou veličinu X a funkci $g : \mathbb{R} \rightarrow \mathbb{R}$, která je *měřitelná*¹¹ (tedy taková, že $g^{-1}(A) \in \mathcal{B}$ pro každý otevřený interval $A = (a, b)$). Potom $Y = g(X) : \Omega \rightarrow \mathbb{R}$ je opět náhodná veličina a můžeme najít její rozdělení. Nejsnazší způsob je určit distribuční funkci F_Y náhodné veličiny Y . Vyjdeme-li z definice, pak

$$F_Y(a) = P[Y \leq a] = P[g(X) \leq a] = P[X \in g^{-1}(-\infty, a]].$$

Toto je obecné odvození, které můžeme pro speciální případy zjednodušit.

Je-li funkce g ryze rostoucí, pak existuje inverzní funkce g^{-1} a platí $F_Y(a) = F_{g(X)}(a) = F_X(g^{-1}(a))$. Pro ryze klesající funkci dostáváme

$$F_Y(a) = P[g(X) \leq a] = P[X \geq g^{-1}(a)] = 1 - F_X(g^{-1}(a)) + P[X = g^{-1}(a)] = 1 - F_X(g^{-1}(a)-),$$

kde $F_X(a-) = \lim_{h \rightarrow 0+} F_X(a-h)$. Pro spojitě náhodné veličiny je pochopitelně pravděpodobnost $P[X = g^{-1}(a)]$ nulová a tedy $F_X(a-) = F_X(a)$ pro všechna a .

Speciálním případem je také $g(x) = |x - b|$, případně $g(x) = (x - b)^2$. Snadno zjistíme, že platí

$$F_{|X-b|}(a) = P[b-a \leq X \leq b+a] = F_X(b+a) - F_X((b-a)-),$$

$$F_{(X-b)^2}(a) = F_X(b + \sqrt{a}) - F_X((b + \sqrt{a})-),$$

pokud $a \geq 0$, jinak jde o nulu.

Ze spojitě náhodné veličiny můžeme „vyrobit“ i diskrétní náhodnou veličinu.

Cvičení 2.29. Bud' X náhodná veličina s exponenciálním rozdělením s parametrem 1. Určete rozdělení náhodné veličiny $Y = \lfloor X \rfloor$, kde $\lfloor \cdot \rfloor$ značí celou část čísla. $\diamond$

Naopak, z diskrétní náhodné veličiny pochopitelně nemůžeme transformací dostat spojitou náhodnou veličinu.

Z libovolného spojitěho rozdělení lze dospět k rovnoměrnému spojitěmu rozdělení na intervalu $[0, 1]$ jednoduchou transformací.

Cvičení 2.30. Necht' náhodná veličina X má spojitou distribuční funkci F . Pak náhodná veličina $Y = F(X)$ má rozdělení $U([0, 1])$.

Pro odvození tohoto faktu je snazší předpokládat ryzí monotonii funkce F , která umožní uvažovat inverzní funkci F^{-1} . Nejde ale o nutnou podmínku.

Uvědomte si, že výraz $F(X)$ není možné chápat ve smyslu $P[X \leq X]$! Tento výraz chápeme tak, že do dané funkce F , která je zde zároveň distribuční funkcí náhodné veličiny X , dosadíme náhodnou veličinu, stejně jako když například do funkce $g(\cdot) = |\cdot|$ dosadíme X a dostaneme tak novou náhodnou veličinu $|X|$. $\diamond$

Naopak, ze spojitěho rovnoměrného rozdělení lze dospět k libovolnému rozdělení, spojitěmu i diskrétnímu. K tomu musíme vyřešit problém s inverzí distribuční funkce F . Je-li F ryze rostoucí (stačí v bodech, kde $0 < F(x) < 1$), pak lze pro $p \in (0, 1)$ přirozeně definovat inverzi $F^{-1}(p)$, viz horní panel obrázku 2.7. V obecném případě může být vzor množiny $\{p\}$ prázdný (viz dolní panel obrázku 2.7),

¹¹Každá reálná spojitá funkce je měřitelná, indikátory intervalů jsou měřitelné atd.

nebo nedegenerovaný interval (viz prostřední panel obrázku 2.7). Hodnotu $F^{-1}(p)$ musíme v prvním případě vhodně dodefinovat, ve druhém případě vhodně zvolit, tak, aby šlo o funkci s definičním oborem $(0, 1)$. Abychom dostali funkci F^{-1} také zprava spojitou, je vhodné ji definovat předpisem

$$(2.2) \quad F^{-1}(p) = \inf\{x; F(x) > p\}, p \in (0, 1).$$

Pro hodnoty $p \in \{0, 1\}$ můžeme hodnoty $F^{-1}(0)$ a $F^{-1}(1)$ přirozeně dodefinovat. Funkci F^{-1} nazýváme *kvantilová funkce* a hodnotu $F^{-1}(p)$ nazveme p -kvantilem.

Cvičení 2.31. (1) Ověřte, že funkce F^{-1} definovaná vzorcem (2.2) je neklesající a zprava spojitá.

- (2) Vezměme nyní distribuční funkci F a náhodnou veličinu U s rovnoměrným spojitým rozdělením $U([0, 1])$. Pak je F distribuční funkcí náhodné veličiny $Y = F^{-1}(U)$. Ověřte toto tvrzení pro spojitou ryze rostoucí funkci F a poté jej zkuste zobecnit pro jakoukoliv distribuční funkci F .

♠

Speciálně jsme ukázali, že pro libovolné dvě spojitě náhodné veličiny X a Y existuje transformace g taková, že rozdělení (distribuční funkce) náhodných veličin Y a $g(X)$ jsou stejná.

Pro funkce náhodného vektoru máme opět více možností. Náhodný vektor můžeme transformovat na náhodný vektor stejné dimenze, nižší dimenze, nebo jednorozměrnou náhodnou veličinu. Podle toho můžeme volit vhodný postup. My se zde omezíme jen na transformaci náhodného vektoru na jednorozměrné náhodné veličiny a transformaci dvourozměrného náhodného vektoru na dvourozměrný náhodný vektor.

Bud' $\mathbf{X} = (X_1, \dots, X_k)$ náhodný vektor a $g : \mathbb{R}^k \rightarrow \mathbb{R}$ (měřitelné) zobrazení, takže $Y = g(\mathbf{X})$ je náhodná veličina. Pak distribuční funkci náhodné veličiny Y můžeme spočítat pomocí rozdělení $\mathbf{X}$:

$$F_Y(a) = P[\mathbf{X} \in g^{-1}(-\infty, a]] = P[g(\mathbf{X}) \leq a].$$

Uved'me dva důležité příklady. Nejprve rozdělení součtu dvou náhodných veličin, tedy $g(x_1, x_2) = x_1 + x_2$. Pro $Y = X_1 + X_2$ dostáváme $F_Y(a) = P[X_1 + X_2 \leq a]$. Podívejme se speciálně na spojitý a diskrétní náhodný vektor. Je-li $\mathbf{X}$ spojitý náhodný vektor s hustotou f , pak


$$F_Y(a) = P[(X_1, X_2) \in \{\mathbf{x}; x_2 \leq a - x_1\}] = \int_{-\infty}^{\infty} \int_{-\infty}^{a-x_1} f(x_1, x_2) dx_2 dx_1.$$

Je-li $\mathbf{X}$ diskrétní náhodný vektor s hustotou $p(\mathbf{x})$ a s hodnotami v $\mathbb{Z}^2$, pak

$$F_Y(a) = \sum_{r=-\infty}^{\infty} \sum_{s=-\infty}^{\lfloor a \rfloor - r} p(s, r).$$

V obou případech musíme dát pozor na nosič hustot, nebo též na množinu hodnot $\mathbf{x}$ pro níž je hustota nulová a podle toho upravit meze integrálů a součtů.

Cvičení 2.32. (1) Nechť $\mathbf{X}$ má multinomické rozdělení $\text{Mult}(n, 1/4, 1/4, 1/2)$. Ukažte, že $X_1 + X_2$ má binomické rozdělení s parametry n a $1/2$.



Obrázek 2.7. Různé distribuční funkce F a jim odpovídající kvantilové funkce F^{-1} .

- (2) Necht' (X_1, X_2) má dvourozměrné standardní normované normální rozdělení. Ukažte, že $X_1 + X_2$ má normální rozdělení $N(0, 2)$.



Problémy k dalšímu procvičení

1. Basketbalista háže na koš, jeho pokusy jsou nezávislé a v každém z nich se trefí s pravděpodobností $p \in (0, 1)$. Rozhodl se, že skončí teprve až vhodí k košů. Označme X počet neúspěšných hodů předcházejících k -tému úspěchu (k -tému vhozenému koši). Určete rozdělení náhodné veličiny X .
2. V krabici je N čokoládových bonbónů, z nichž je K plněno karamelovou náplní. Vyberete si z krabice náhodně n bonbónů. Necht' X značí počet vytažených bonbónů s karamelovou náplní. Určete rozdělení X .
3. Předpokládejte, že máme k dispozici perfektní generátor náhodných čísel z intervalu $[0, 1]$. Označme jako X náhodnou veličinu, která nám udává vygenerované číslo.
 - (a) Jakým způsobem popíšeme rozdělení X ?
 - (b) Nakreslete graf distribuční funkce. V obou obrázcích zakreslete pravděpodobnost, s jakou dostaneme číslo menší než 0.5. S jakou pravděpodobností dostaneme přesně 0.5?
 - (c) Získané náhodné číslo X umocníme na druhou a dostaneme tak jiné náhodné číslo Y z intervalu $[0, 1]$. Je rozdělení Y stejné jako rozdělení X ?
 - (d) Jak pomocí X dostaneme náhodné číslo z intervalu $[a, b]$, kde $a < b$, $a, b \in \mathbb{R}$?
4. Doba strávená čekáním na příjezd vlaku (v minutách) je náhodná veličina s hustotou

$$f(x) = \begin{cases} ce^{-x/5}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$
 - (a) Určete konstantu $c > 0$, aby f byla hustota.
 - (b) Určete distribuční funkci F a načrtněte ji.
 - (c) Jaká je pravděpodobnost, že budete na vlak čekat déle než 5 minut? Vyznačte v grafu hustoty a v grafu distribuční funkce.
 - (d) S jakou pravděpodobností bude doba strávená čekáním mezi 2 a 5 min?
 - (e) Aktuálně čekáte 5 min. Jaká je pravděpodobnost, že budete celkově čekat déle než 10 min?
 - (f) Během čekání na vlak si prohlížíte internet na mobilu, přičemž Vám za to Váš operátor účtuje připojovací poplatek 5 Kč a pak spojitou sazbu 3Kč/min. Náhodná veličina Y udává, kolik peněz takto utratíte. Určete rozdělení Y (distribuční funkci a hustotu) a spočítejte, s jakou pravděpodobností utratíte během čekání na vlak více než 35 Kč.
Vyjádřete si Y jako funkci X a následně přepište distribuční funkci $F_Y(y) = P[Y \leq y]$ pomocí F_X . Hustotu spočítáte jako $f_Y = F'_Y$.
 - (g) Váš kamarád má jiný tarif: Operátor mu účtuje 1 Kč za každou započatou minutu. Náhodná veličina Z udává, kolik peněz utratí během čekání na vlak Váš kamarád. Určete rozdělení Z .
Uveďte si, že Z má diskrétní rozdělení. Vyjádřete si $P[Z = k]$.
 - (h) Určete rozdělení náhodné veličiny $U = F(X)$, kde F je distribuční funkce spočtená v (b).

- (i) Navrhněte, jak nasimulovat výše uvedené doby čekání, umíme-li generovat náhodné číslo z intervalu $[0, 1]$.
Využijte výsledek z (h).
5. Uvažujte náhodnou veličinu X se spojitým rozdělením s hustotou
- $$f(x) = \begin{cases} c(1 - |x - 1|) & x \in (0, 2) \\ 0 & \text{jinak} \end{cases}$$
- (a) Nalezněte konstantu $c > 0$, tak aby f byla hustota.
 (b) Spočítejte, s jakou pravděpodobností bude X větší než $1/2$.
 (c) Určete distribuční funkci X a nakreslete její graf.
6. Uvažujte spojitě rozdělení s hustotou $f(x) = ce^{-|x|}$. Dopačítejte konstantu c a určete, s jakou pravděpodobností bude náhodná veličina s tímto rozdělením v absolutní hodnotě větší než 2.
7. Uvažujte náhodnou veličinu X s exponenciálním rozdělením s parametrem λ . Určete podmíněnou pravděpodobnost $P[X > a + d | X > d]$ pro $a > 0$ a $d > 0$. Pokud počítáte správně, uvidíte, proč se o exponenciálním rozdělení říká, že nemá paměť.
8. Nechť X má normální rozdělení $N(\mu, \sigma^2)$ pro $\mu \in \mathbb{R}$ a $\sigma^2 > 0$. Určete rozdělení náhodné veličiny $Y = \exp(X)$.
 X i Y jsou spojitě náhodné veličiny. Určete distribuční funkci Y pomocí rozpisu $P[Y \leq y] = P[e^X \leq y] = P[X \leq \log(y)]$ pro $y > 0$. Poté využijte vztahu $f_Y = F_Y'$, tedy najděte hustotu náhodné veličiny Y .
Rozdělení náhodné veličiny Y se nazývá log-normální a jde o jedno z často používaných rozdělení.
9. Bud'te X_1 a X_2 nezávislé náhodné veličiny a g_1, g_2 reálné funkce (měřitelné). Ukažte, že $g_1(X_1)$ a $g_2(X_2)$ jsou nezávislé.
10. Pravděpodobnost narození dcery je stejná jako pravděpodobnost narození syna. Náhodná veličina X udává počet dcer v náhodně vybrané rodině se třemi dětmi, veličina Y udává počet starších bratrů nejmladšího dítěte v téže rodině.
 (a) Odvod'te rozdělení náhodného vektoru $(X, Y)^T$.
 (b) Jaké jsou marginální rozdělení X a Y ?
 (c) Jsou veličiny X a Y nezávislé?
11. V šuplíku je 6 ponožek: 2 bílé, 2 černé a 2 oranžové. Potmě náhodně vytáhneme z šuplíku 3 ponožky. Označme jako X počet vytažených bílých ponožek a Y je počet vytažených oranžových ponožek.
 (a) Napište tabulku rozdělení náhodného vektoru $(X, Y)^T$.
 (b) Určete, s jakou pravděpodobností jsou mezi třemi vytaženými ponožkami alespoň dvě stejné.
 (c) Jsou X a Y nezávislé?
12. Chystáte oslavu narozenin ve své oblíbené restauraci a zvete všechny své příbuzné (budete za ně platit). Množství peněz, které všichni Vaši hosté dohromady projí a propijí (v tisíci Kč), jsou náhodné veličiny X a Y . Ze zkušenosti

víte, že vektor $(X, Y)^T$ má spojité rozdělení charakterizované sdruženou hustotou

$$f(x, y) = \begin{cases} c(x+y) & \text{pro } 0 < x < 1, 0 < y < 1, \\ 0 & \text{jinak.} \end{cases}$$

- (a) Určete konstantu $c > 0$.
 - (b) Jaké je rozdělení částky, kterou zaplatíte jen za nápoje? Jaké je rozdělení obnosu, který padne jen na jídlo?
 - (c) Jsou veličiny X a Y nezávislé?
 - (d) Jaká je pravděpodobnost, že za pití zaplatíte více než za jídlo?
13. Náhodná veličina X udává dobu, kterou strávíte čekáním na tramvaj na Malostranském náměstí (v minutách) a náhodná veličina Y udává dobu, kterou následně strávíte čekáním na metro A ve stanici Malostranská (také v minutách). Ze zkušenosti víme, že náhodný vektor $(X, Y)^T$ má spojité rozdělení s hustotou
- $$f(x, y) = \begin{cases} \frac{1}{2}e^{-x-y/2} & \text{pro } x > 0, y > 0, \\ 0 & \text{jinak.} \end{cases}$$
- (a) Jaké je rozdělení jednotlivých dob čekání (na tramvaj a na metro zvlášť)?
 - (b) Jsou doby strávené čekáním na tramvaj a na metro nezávislé?
 - (c) S jakou pravděpodobností je doba čekání na tramvaj delší než doba čekání na metro?
14. (příklad 3.22 z [4]) Počátkem 18. století si J. Arbuthnot všiml, že za posledních 82 let se v Londýně každý rok narodilo více hochů než děvčat, což mu přišlo jako zásah „božské prozřetelnosti“.

Předpokládejme, že pravděpodobnost narození chlapce je 0,515, zatímco dívka se narodí s pravděpodobností 0,485 (tato čísla odpovídají přibližně pravděpodobnostem i ve střední Evropě). Ukažte, že pokud se narodí každoročně 20 000 dětí, pak pravděpodobnost toho, že v průběhu 82 let vždy počet narozených hochů převyší počet narozených dívek je nejméně 0,99. (Zanedbejte existenci dvojčat, trojčat atd. a počty narozených děvčat a chlapců v jednotlivých letech považujte za nezávislé náhodné veličiny.)

Návod: Označme jako Z náhodnou veličinu udávající počet děvčat, které se narodí z celkového počtu $2n$ dětí. Pak Z má binomické rozdělení $\text{Bi}(2n, p)$, kde p je pravděpodobnost narození děvčete. Pravděpodobnost, že počet děvčat bude vyšší než počet chlapců je $P[Z > n] = \sum_{k=n+1}^{2n} \binom{2n}{k} p^k q^{2n-k}$. Je-li $p < 1/2$ a $q = 1 - p$, pak s využitím $\binom{2n}{k} \leq \binom{2n}{n}$ dostaneme

$$P[Z > n] \leq \binom{2n}{n} q^{2n} \sum_{k=n+1}^{2n} \left(\frac{p}{q}\right)^k \leq \binom{2n}{n} p^n q^n \frac{q}{q-p},$$

kde jsme využili vzorec pro součet geometrické řady a nerovnosti $p < q$ a $1 - (p/q)^n \leq 1$. Následně rozepište kombinační číslo a použijte Stirlingův vzorec $n! \approx n^n e^{-n} \sqrt{2\pi n}$. Označte $X_i = 1$, pokud se v i -tém roce narodí více chlapců než děvčat a ukažte, že $P[X_i = 1, i = 1, 2, \dots, 82] > 0,99$. Z předpokladu jsou X_i nezávislé.

Momenty a další charakteristiky náhodné veličiny a vektoru

Chování náhodných veličin a vektorů je úplně popsáno jejich rozdělením, případně distribuční funkcí. V této kapitole se zaměříme na číselné charakteristiky rozdělení pravděpodobností. Charakteristiky rozdělení (charakteristiky náhodných veličin) dávají přehlednou informaci o vlastnostech rozdělení. Základní z nich jsou *momenty* náhodné veličiny a z nich pak *střední hodnota* je spolu s *rozptylem* ta nejpoužívanější. Dalšími používanými charakteristikami jsou kvantily, ty se však omezují jen na jednorozměrné náhodné veličiny.¹ Tyto hodnoty shrnují vybrané vlastnosti rozdělení a dávají nám tak představu například o tom, jaké jsou typické hodnoty náhodné veličiny, která hodnota je nejpravděpodobnější, v jakém intervalu se vyskytuje prostřední polovina hodnot X . Spolu s větami v následujících kapitolách tak máme po ruce účinný nástroj pro analýzu pozorovaných dat.

Začneme formální matematickou definicí střední hodnoty.

3.1. Střední hodnota náhodné veličiny

Definice 3.1: (Matematická definice střední hodnoty)

Bud' X náhodná veličina definovaná na pravděpodobnostním prostoru $(\Omega, \mathcal{F}, P)$. Hodnotu

$$E X := \int_{\Omega} X(\omega) dP(\omega)$$

nazveme *střední hodnotou* X , má-li integrál vpravo smysl.

¹I když rozšíření na náhodné vektory je předmětem zájmu již mnoho desítek let a v posledním desetiletí se začala používat definice mnohorozměrných kvantilů pomocí optimálního přenosu.

Střední hodnota je integrál reálné funkce X na prostoru Ω vzhledem k pravděpodobnosti P na tomto prostoru. Tím je střední hodnota *definována*, ale její *výpočet* se provádí obvykle s pomocí hustoty rozdělení náhodné veličiny.

Věta 3.2: (Střední hodnota diskrétní náhodné veličiny)

Bud' X diskrétní náhodná veličina s hodnotami v $\mathbb{S}$ a s hustotou $p_X(s)$. Pak

$$E X = \sum_{s \in \mathbb{S}} s P[X = s] = \sum_{s \in \mathbb{S}} s p_X(s),$$

má-li součet vpravo smysl.

Důkaz. Využijeme definici střední hodnoty $E X$. Množiny $A_s := \{\omega : X(\omega) = s\}$ tvoří disjunktní rozklad Ω . Proto

$$\begin{aligned} E X &= \int_{\bigcup A_s} X(\omega) dP(\omega) = \sum_{s \in \mathbb{S}} \int_{A_s} X(\omega) dP(\omega) \\ &= \sum_{s \in \mathbb{S}} s \int_{A_s} dP(\omega) = \sum_{s \in \mathbb{S}} s P(A_s) \\ &= \sum_{s \in \mathbb{S}} s P[X = s]. \end{aligned}$$

□

Věta 3.3: (Střední hodnota spojitě náhodné veličiny)

Bud' X spojitá náhodná veličina s hustotou $f_X(x)$. Pak

$$E X = \int_{-\infty}^{\infty} x f_X(x) dx,$$

má-li integrál vpravo smysl.

Důkaz. I v tomto případě jde o *přenos integrace* z prostoru Ω na prostor $\mathbb{R}$ a využití faktu

$$P[X \in A] = \int_{\{\omega : X(\omega) \in A\}} dP(\omega) = P_X(A) = \int_A dP_X(x) = \int_A f_X(x) dx.$$

Platí tedy

$$E X = \int_{\Omega} X(\omega) dP(\omega) = \int_{-\infty}^{\infty} x dP_X(x) = \int_{-\infty}^{\infty} x f_X(x) dx.$$

□

Poznámka 3.4. Střední hodnota ve smyslu uvedené definice *má smysl*, i když je nekonečná. Vyjde-li tedy integrál v definici 3.1 nekonečný ($\pm\infty$), má náhodná veličina X nekonečnou střední hodnotu. Integrál nemá smysl, je-li typu „ $\infty - \infty$ “. Tedy $\int_{\mathbb{R}} 1 dx$ je v pořádku (i když jde o nekonečnou hodnotu), zatímco $\int_{\mathbb{R}} x^{-1} dx$ standardně neumíme zavést, integrál (Riemannův ani Lebesgueův) neexistuje.

Povšimněme si

Mluvíme o střední hodnotě *náhodné veličiny*, z definice je ovšem hned zřejmé, že každé dvě náhodné veličiny se stejným rozdělením mají stejnou střední hodnotu (případně neexistuje ani pro jednu z nich). Proto se také někdy mluví o střední hodnotě *rozdělení*, ale význam je týž. Bez pojmu náhodná veličina nemáme pojem rozdělení ani pojem střední hodnota, stejné rozdělení ale může mít nekonečně mnoho různých náhodných veličin.

Cvičení 3.5. Zkuste najít funkci $p_X(s)$, $s \in \mathbb{Z}$, takovou, že:

- (1) $p_X(s) \geq 0$,
- (2) $\sum_{s \in \mathbb{Z}} p_X(s) = 1$,
- (3) $\sum_{s > 0} s p_X(s) = \infty$, $\sum_{s < 0} s p_X(s) = -\infty$.

Pro diskrétní rozdělení zadané pravděpodobnostmi $p_X(s)$ neexistuje střední hodnota, jelikož máme nedefinovanou sumu (typu „ $\infty - \infty$ “). Najít hustotu f_X spojitě náhodné veličiny tak, aby neexistovala střední hodnota je podobně snadné. $\diamond$

Povšimněme si

Náhodná veličina X může mít spojitou i diskrétní složku zároveň, například denní úhrn srážek. V tom případě její rozdělení má dvě složky, diskrétní reprezentovanou pravděpodobnostmi $p_X(s)$, $s \in \mathbb{S}$, a spojitou reprezentovanou hustotou f_X . Ty jsou samozřejmě nezáporné a splňují rovnost

$$\sum_{s \in \mathbb{S}} p_X(s) + \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Střední hodnotu náhodné veličiny X , má-li $E X$ smysl, počítáme jako kombinaci střední hodnoty její diskrétní a spojitě složky, tedy

$$E X = \sum_{s \in \mathbb{S}} s p_X(s) + \int_{-\infty}^{\infty} x f_X(x) dx.$$

Co vlastně je střední hodnota pro rozdělení? Pro diskrétní rozdělení je to očividné, jde o vážený průměr hodnot náhodné veličiny, kde vahami jsou pravděpodobnosti. V případě spojitého rozdělení si můžeme představit úzkou desku zanedbatelné hmotnosti, na níž je hromada písku kopírující hustotu. Střední hodnota je pak těžiště této desky. Nebo si představme rovnou tyč z nehomogenního materiálu, jehož *hustota* (ve fyzikálním slova smyslu) v místě x odpovídá hustotě rozdělení v bodě x . Střední hodnota je opět těžištěm této tyče a vidíme i zdůvodnění pojmu „hustota rozdělení“.

Poznámka 3.6. Platí-li $P[a < X < b] = 1$, pak také $a < E X < b$. Tento jednoduchý fakt může sloužit jako první kontrola správnosti výpočtu. Pokud je X nezáporná náhodná veličina, pak i její střední hodnota je nezáporná. Pokud platí $P[Y > a] \geq P[X > a]$ pro všechna $a \in \mathbb{R}$ ², pak $E Y \geq E X$.

²V tomto případě řekneme, že Y je *stochasticky větší* než X , zkráceně $Y \geq X$.

Další momenty a charakteristiky náhodné veličiny můžeme definovat pomocí střední hodnoty vhodné funkce náhodné veličiny. V předchozí kapitole jsme již studovali transformace náhodné veličiny a jejich rozdělení. Je-li $Y = g(X)$ náhodná veličina, můžeme se zaměřit také na její střední hodnotu. Protože jsme schopni odvodit rozdělení Y , můžeme je využít k výpočtu střední hodnoty podle věty 3.2 nebo věty 3.3. Existence a konečnost střední hodnoty X však nezaručuje existenci a konečnost střední hodnoty Y a naopak.

Formálně je střední hodnota funkce náhodné veličiny definována pomocí integrálu podle pravděpodobnosti.

Definice 3.7: (Střední hodnota funkce náhodné veličiny)

Bud' X náhodná veličina a $g : \mathbb{R} \rightarrow \mathbb{R}$ měřitelná funkce^a. Pak $Eg(X) = \int_{\Omega} g(X(\omega)) dP(\omega)$, má-li integrál vpravo smysl.

^aVzor otevřené množiny je borelovská množina. Postačující podmínkou je spojitost g .

Je-li tedy $Y = g(X)$, pak $EY = Eg(X)$. A naopak, střední hodnotu $Eg(X)$ můžeme spočítat také jako střední hodnotu EY s využitím rozdělení náhodné veličiny Y . Pokud však neznáme rozdělení Y , pak spíš, než počítání EY pomocí rozdělení Y , bývá vhodnější použít následující větu známou též jako „pravidlo pro lineární statistiky“.

Věta 3.8: (Výpočet střední hodnoty II)

Bud' X diskrétní náhodná veličina s hodnotami v $\mathbb{S}$ a s hustotou $p_X(s)$, bud' $g : \mathbb{R} \rightarrow \mathbb{R}$ měřitelná. Pak

$$Eg(X) = \sum_{s \in \mathbb{S}} g(s)P[X = s] = \sum_{s \in \mathbb{S}} g(s)p_X(s),$$

má-li součet vpravo smysl.

Bud' X spojitá náhodná veličina s hustotou $f_X(x)$. Pak

$$Eg(X) = \int_{-\infty}^{\infty} g(x)f_X(x) dx,$$

má-li integrál vpravo smysl.

Je-li například X diskrétní náhodná veličina nabývající hodnot v množině S_X , pak i Y je diskrétní s hodnotami v S_Y a platí

$$Eg(X) = \sum_{s \in S_X} g(s)p_X(s) = \sum_{t \in S_Y} tp_Y(t) = \sum_{t \in S_Y} t \sum_{s: g(s)=t} p_X(s).$$

Obvykle však výpočet přes rozdělení p_Y nebývá snazší; ukážeme si několik příkladů, volba způsobu výpočtu střední hodnoty je v zásadě podobná volbě vhodné substituce při výpočtu integrálu.

Příklad 3.9. Nechť X má rovnoměrné rozdělení na $[0, 1]$, tj. $f_X(x) = I\{x \in [0, 1]\}$. Spočíst střední hodnotu X je velmi snadné:

$$E X = \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^1 x dx = \frac{1}{2}.$$

Analogicky lze ukázat, že střední hodnota rovnoměrného rozdělení na intervalu $[a, b]$, $a < b$, je střed tohoto intervalu, tj. $(a + b)/2$.

Dále nás bude zajímat střední hodnota veličiny $Y = g(X) = \sqrt{X}$. Ukážeme si oba výše popsané způsoby výpočtu. S využitím věty 3.8 dostáváme

$$E Y = \int_{-\infty}^{\infty} \sqrt{x} f_X(x) dx = \int_0^1 \sqrt{x} dx = \frac{2}{3}.$$

Druhý způsob výpočtu vyžaduje nejprve určení rozdělení Y . Použijeme postup z části 2.7. a určíme nejprve distribuční funkci F_Y . Je-li $x < 0$, pak zjevně $F_Y(x) = P[\sqrt{X} \leq x] = 0$. Pro $x \in \mathbb{R}$ dostáváme

$$F_Y(x) = P[\sqrt{X} \leq x] = P[X \leq x^2] = F_X(x^2) = \begin{cases} 0 & x \leq 0 \\ x^2, & 0 < x < 1, \\ 1, & x \geq 1. \end{cases}$$

Této distribuční funkci odpovídá hustota

$$f_Y(x) = \begin{cases} 2x, & x \in [0, 1], \\ 0 & \text{jinak.} \end{cases}$$

S použitím věty 3.3 pak

$$E Y = \int_{-\infty}^{\infty} x f_Y(x) dx = \int_0^1 2x^2 dx = \frac{2}{3}.$$

Dospěli jsme tedy ke stejnému výsledku, postup byl však poněkud pracnější. $\diamond$

Pro afinní funkci g dostaneme jednoduché vyjádření střední hodnoty.

Věta 3.10: (Linearita střední hodnoty)

Bud' X náhodná veličina s konečnou střední hodnotou. Pak pro všechna $a, b \in \mathbb{R}$ platí

$$E(a + bX) = a + b E X.$$

Důkaz. Z definice je střední hodnota integrálem a proto tvrzení platí. Pro výpočetní vzorce jde o jednoduché odvození. $\square$

Cvičení 3.11. Nechť X, Y jsou náhodné veličiny na stejném pravděpodobnostním prostoru takové, že $X(\omega) \leq Y(\omega)$ pro všechna $\omega \in \Omega$ a $E X$ i $E Y$ existují konečně. Ukážeme, že pak $E X \leq E Y$.

Platí

$$E X = \int_{\Omega} X(\omega) dP(\omega) \leq \int_{\Omega} Y(\omega) dP(\omega) = E Y.$$

K platnosti nerovnosti pro střední hodnoty stačí i slabší předpoklad $X(\omega) \leq Y(\omega)$ pro $\omega \in M$, $P(M) = 1$. $\diamond$

Pro konvexní funkci dostaneme nerovnost, která je zobecněním Hölderovy či Schwartzovy nerovnosti. Podstatný je zde fakt, že pravděpodobnost celého prostoru $\mathbb{R}$ je 1.

Věta 3.12: (Jensenova nerovnost)


Bud' X náhodná veličina s konečnou střední hodnotou EX . Bud' φ konvexní funkce. Pak $E\varphi(X) \geq \varphi(EX)$.

Důkaz. Protože je funkce φ konvexní, pro každé zvolené a existuje konstanta λ taková, že $\varphi(x) \geq \varphi(a) + \lambda(x - a)$ pro všechna $x \in \mathbb{R}$. Volbou $a = EX$ tak dostáváme

$$\varphi(X) \geq \varphi(EX) + \lambda(X - EX).$$

Výše uvedená nerovnost platí pro všechna $\omega \in \Omega$. Spočteme-li tedy střední hodnoty z obou stran, nerovnost zůstane zachována, viz cvičení 3.11. Navíc, $E(X - EX) = 0$, odkud již plyne tvrzení věty. $\square$

Grafická ilustrace k Jensenově nerovnosti je uvedena na obrázku 3.1, kde je uvažována diskrétní náhodná veličina, která nabývá pouze dvou hodnot x_1 a x_2 , a to se stejnou pravděpodobností. Střední hodnota EX je pak střed intervalu těžiště bodů x_1 a x_2 , tj. střed úsečky $[x_1, x_2]$. Podobně, $Eg(X)$ je těžištěm bodů $g(x_1)$ a $g(x_2)$. Je-li g ryze konvexní, pak snadno vidíme, že $Eg(X) > g(EX)$. Pro ryze konkávní funkci bychom dostali nerovnost opačnou.



Obrázek 3.1. Ilustrace Jensenovy nerovnosti pro situaci, kdy X nabývá dvou hodnot x_1 a x_2 se stejnou pravděpodobností.

3.2. Momenty vyšších řádů

Definice 3.13: (Významné momenty a funkce)

Bud' X náhodná veličina a uvažujme $r \in \mathbb{N}$. Pak

- (1) $E X^r$ je r -tý moment X ,
- (2) $E |X|^r$ je r -tý absolutní moment X ,
- (3) pro $r \in \mathbb{N}$ je $E(X - EX)^r$ r -tý centrální moment X .
- (4) speciálně pro $r = 2$ je

$$\text{var } X = E(X - EX)^2$$

rozptyl (variance) X ,

- (5) $\mu_3 = \frac{E(X - EX)^3}{(E(X - EX)^2)^{\frac{3}{2}}}$ je tzv. šikmost rozdělení.
- (6) Momentová vytvořující funkce X je definovaná jako

$$\Psi_X(t) = E e^{tX}$$

pro všechna $t \in \mathbb{R}$, pro která má smysl pravá strana.

- (7) Charakteristická funkce^a X je definovaná jako

$$\tilde{F}_X(t) = E e^{itX}$$

pro všechna $t \in \mathbb{R}$.

Všechny uvedené charakteristiky jsou definovány tehdy, mají-li příslušné integrály a součty smysl.

^aJde v podstatě o Fourierovu transformaci, se kterou jste se již mohli setkat.

Nejčastěji se pro popis rozdělení náhodné veličiny X používají první dva momenty, tj. střední hodnota a rozptyl. Třetí centrální moment se využije pro výpočet šikmosti, která měří asymetrii (šikmost) rozdělení. Snadno ověříte, že rozdělení se symetrickou hustotou, pro kterou existuje hodnota μ tak, aby pro všechna³ x platilo $f_X(x - \mu) = f_X(\mu - x)$, mají nulovou šikmost (má-li náhodná veličina konečný třetí moment).

Charakteristická funkce je na rozdíl od momentové vytvořující funkce definovaná pro všechna $t \in \mathbb{R}$ (daný integrál vždy existuje a je konečný, protože $|e^{itx}| = 1$). Charakteristická funkce jednoznačně určuje rozdělení náhodné veličiny X . Vždy platí $\tilde{F}_X(0) = 1 = \Psi_X(0)$. Samotné momenty ale rozdělení charakterizovat nemusí, viz cvičení 3.20.

Poznámka 3.14 (Význam a základní vlastnosti momentů). Momenty shrnují některé vlastnosti náhodných veličin a jejich rozdělení.

- Střední hodnota EX je charakteristikou polohy náhodné veličiny⁴.

³Samozřejmě stačí, aby toto platilo pro všechna $x \in M$, kde $P[X \in M] = 1$.

⁴Jinou charakteristikou polohy je například medián. Jde o číslo, které rozděluje hodnoty náhodné veličiny podle velikosti na dvě (stejně pravděpodobné) poloviny. Přesná definice kvantilů je v části 3.4.

- Rozptyl je charakteristikou variability, jde o střední čtvercovou odchylku od střední hodnoty.⁵
- Existuje-li $\delta > 0$ takové, že momentová vytvořující funkce $\psi_X(t)$ existuje konečná pro všechna $|t| < \delta$, pak pro všechna $r \in \mathbb{N}$ platí $E X^r = \psi_X^{(r)}(0)$ (r -tá derivace $\psi_X(t)$ v bodě 0).

Poslední bod poznámky ukazuje, jak lze momenty veličiny X spočítat pomocí její vytvořující funkce. Někdy může být tento postup výhodnější než výpočet z definice.

Věta 3.15: (Nerovnosti mezi momenty)

Bud' $0 < s < r$. Jestliže $E|X|^r < \infty$, pak $E|X|^s < \infty$ a $|E X^r| < \infty$, má-li druhý výraz smysl (například pro $r \in \mathbb{N}$). Dokonce platí $(E|X|^s)^{1/s} \leq (E|X|^r)^{1/r}$, speciálně $E|X| \leq (E|X|^2)^{1/2} \leq (E|X|^3)^{1/3}$

Důkaz. Zkuste si tuto větu dokázat sami. K důkazu použijte Jensenovu nerovnost pro nezápornou náhodnou veličinu $|X|^q$ a konvexní funkce $g(x) = x^p$ pro $x \geq 0$ a $p > 1$. $\square$

Cvičení 3.16. Uvažujme náhodnou veličinu X s Poissonovým rozdělením s parametrem $\lambda > 0$. Ukážeme si výpočet střední hodnoty jak z definice, tak i pomocí vytvořující funkce. Pomocí definice píšeme

$$E X = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} e^{-\lambda} = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda,$$

kde ve výpočtu jsme přešli od indexu k k indexu $j = k - 1$ a využili jsme rovnost $\sum_{j=0}^{\infty} \lambda^j / (j!) = e^\lambda$. Pokud bychom chtěli počítat vyšší momenty, musíme použít více algebraických úprav, abychom výraz dostali do tvaru rozvoje exponenciály, princip je však stejný.

Vytvořující funkci spočteme jako

$$\psi_X(t) = E e^{tX} = \sum_{k=0}^{\infty} e^{tk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(e^t \lambda)^k}{k!} = e^{-\lambda} e^{e^t \lambda},$$

kde jsme opět použili vzorec pro rozvoje exponenciály, tentokrát v bodě $e^t \lambda$. První derivace je

$$\psi_X'(t) = e^{-\lambda} e^{e^t \lambda} \lambda e^t$$

a tedy podle Poznámky 3.14 je

$$E X = \psi_X'(0) = \lambda.$$

Vyšší momenty bychom už dostali velmi jednoduše, pomocí vyšších derivací funkce ψ_X . $\spadesuit$

⁵Jinou charakteristikou variability je například první absolutní centrální moment $E|X - EX|$.

Vedle střední hodnoty je rozptyl základní charakteristikou náhodných veličin. Rozptyl můžeme spočítat buď přímo z definice, nebo podle některého z početních vzorců.

Věta 3.17: (Výpočet a vlastnosti rozptylu)

Bud' X náhodná veličina s konečným rozptylem. Pak

$$\text{var } X = E X^2 - (E X)^2 = E(X(X-1)) - (E X)(E X - 1).$$

Pro jakékoliv konstanty $a, b \in \mathbb{R}$ platí

$$\text{var}(a + bX) = b^2 \text{var } X.$$

Důkaz. Přímý výpočet: $E(X - E X)^2 = E(X^2 - 2X E X + (E X)^2) = E X^2 - 2E(X E X) + (E X)^2 = E X^2 - (E X)^2$. Použili jsme linearitu střední hodnoty a fakt, že $E X$ je konstanta.

Druhý vztah je natolik snadný, že si jej čtenář ověří sám. $\square$

Rozptyl je střední hodnotou nezáporné funkce náhodné veličiny X a podle výsledku cvičení 3.11 proto nutně platí

$$\text{var } X \geq 0$$

pro každou náhodnou veličinu X , přičemž rovnost nastává pouze v případě, kdy je X konstanta⁶. Všimněme si, že tím pádem musí být $E X^2 \geq (E X)^2$. To ovšem již víme z Jensenovy nerovnosti pro konvexní funkci $g(x) = x^2$.

Definice 3.18: (Směrodatná odchylka)

Pro náhodnou veličinu X s konečným rozptylem $\text{var } X$ definujeme směrodatnou odchylku $\text{std } X = \sqrt{\text{var } X}$.

Důvod pro zavedení směrodatné odchylky je například ten, že směrodatná odchylka je ve stejných jednotkách jako náhodná veličina. Je-li například X doba do události v hodinách, pak $\text{var } X$ má rozměr hod^2 , zatímco směrodatná odchylka je dána také v hodinách. Pro všechna reálná a a b platí $\text{std}(a + bX) = |b| \text{std}(X)$.

Cvičení 3.19. Uvažujte náhodnou veličinu X s normálním rozdělením $N(0, 1)$. Spočítáme její střední hodnotu a rozptyl. Pro střední hodnotu máme

$$\begin{aligned} E X &= \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = \int_{-\infty}^0 x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx + \int_0^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx \\ &= - \int_0^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx + \int_0^{\infty} x \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 0, \end{aligned}$$

(nebo přímo vidíme, že integrujeme lichou integrovatelnou funkci přes symetrický interval a tedy nutně dostáváme 0). Rozptyl je v tomto případě tedy roven $E X^2$, takže

$$\text{var } X = \int_{-\infty}^{\infty} x^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

⁶Ve smyslu, že existuje nějaké $c \in \mathbb{R}$ takové, že $X(\omega) = c$ pro všechna $\omega \in M$, kde $P(M) = 1$.

Uvedený integrál vypočteme pomocí per-partes metody, kde volíme $u = x$ a $v' = xe^{-x^2/2}$. Pak $u' = 1$ a $v = -e^{-x^2/2}$ a tedy

$$\text{var } X = \frac{1}{\sqrt{2\pi}} \left[-xe^{-x^2/2} \right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 0 + 1 = 1,$$

jelikož druhý uvedený integrál je integrál z hustoty přes všechny možné hodnoty náhodné veličiny, je tak nutně roven 1. Umíme-li používat tzv. gama funkci⁷, pak lze předchozí výpočet provést i následovně:

$$\begin{aligned} \text{var } X &= \int_{-\infty}^{\infty} x^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = 2 \int_0^{\infty} x^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = \frac{2}{\sqrt{2\pi}} \cdot \sqrt{2} \int_0^{\infty} \sqrt{y} e^{-y} dy \\ &= \frac{2}{\sqrt{\pi}} \Gamma(3/2) = 1. \end{aligned}$$

Samostatně zkuste spočítat střední hodnotu a rozptyl veličiny X s normálním rozdělením $N(\mu, \sigma^2)$. Ve výpočtu vždy vhodnou substitucí převed'te výpočet na integrály již spočtené pro $N(0, 1)$, nebo nejprve ukažte, že $(X - \mu)/\sigma$ má rozdělení $N(0, 1)$ a pak použijte větu 3.10. Měli byste poměrně snadno dojít k výsledku $E X = \mu$ a $\text{var } X = \sigma^2$. To je v souladu s interpretací střední hodnoty jakožto parametru polohy a rozptylu jakožto charakteristiky variability a hustoty rozdělení na obrázku 2.6. $\diamond$

Cvičení 3.20. Najděte dvě různá diskrétní rozdělení, jejichž střední hodnoty a rozptyly jsou stejné (pro jednoduchost můžete uvažovat nulovou střední hodnotu—to je *velká* nápověda).

Dokážete najít dvě náhodné veličiny se stejnými prvními třemi momenty, ovšem s různým rozdělením? $\diamond$

3.3. Momenty náhodných vektorů

Některé momenty náhodného vektoru plynou rovnou z faktu, že náhodný vektor je vektor náhodných veličin. Jiné musíme ještě definovat.

Definice 3.21: (Střední hodnota náhodného vektoru)

Bud' $\mathbf{X} = (X_1, \dots, X_d)^T$ náhodný vektor. Potom definujeme:

- (1) $E \mathbf{X} = (E X_1, \dots, E X_d)^T$, pokud jednotlivé střední hodnoty existují.
- (2) Nechť $g : \mathbb{R}^d \rightarrow \mathbb{R}$ (taková, že $g(\mathbf{X})$ je náhodná veličina, tedy g musí být měřitelná). Pak definujeme $E g(\mathbf{X}) = \int_{\Omega} g(\mathbf{X}(\omega)) dP(\omega)$, pokud všechny integrály existují.

Střední hodnota náhodného vektoru je tedy vektor středních hodnot. Pro výpočet $E g(\mathbf{X})$ opět uved'me způsob výpočtu v případě diskrétního a spojitého náhodného vektoru.

⁷Gama funkce je definovaná pro $s > 0$ jako $\Gamma(s) = \int_0^{\infty} x^{s-1} e^{-x} dx$ a platí $\Gamma(s) = (s-1)\Gamma(s-1)$, $\Gamma(1) = 1$, $\Gamma(1/2) = \sqrt{\pi}$. Tedy zde $\Gamma(3/2) = \sqrt{\pi}/2$.

Věta 3.22: (Výpočet střední hodnoty náhodného vektoru)

Je-li $\mathbf{X}$ diskrétní s hodnotami v $\mathbb{N}_0^d$, pak $E g(\mathbf{X}) = \sum_{\mathbf{z} \in \mathbb{N}_0^d} g(\mathbf{z}) P[\mathbf{X} = \mathbf{z}]$, existuje-li řada napravo.

Je-li $\mathbf{X}$ spojitý s hodnotami v $\mathbb{R}^d$ a s hustotou $f_{\mathbf{X}}$, pak $E g(\mathbf{X}) = \int_{\mathbb{R}^d} g(\mathbf{z}) f_{\mathbf{X}}(\mathbf{z}) d\mathbf{z}$, existuje-li integrál napravo.

Důkaz. Jde o jednoduchou obměnu důkazu věty 3.8 náhodnou veličinu $g(\mathbf{X})$. $\square$

V obou uvedených případech jde o násobné sčítání či integrování, které se provádí postupně po složkách $\mathbf{z}$.

První, co potřebujeme dokázat je střední hodnota součtu náhodných veličin. Není překvapivé, že jde o součet středních hodnot.

Věta 3.23: (Linearita střední hodnoty II)

Bud' $\mathbf{X} = (X_1, \dots, X_d)$ náhodný vektor a konstanty $a \in \mathbb{R}, b_1, \dots, b_d \in \mathbb{R}$ a $E|X_i| < \infty$ pro všechna i . Pak

$$E \left(a + \sum_{i=1}^d b_i X_i \right) = a + \sum_{i=1}^d b_i E X_i.$$

Důkaz. Důkaz podrobně ukážeme jen pro diskrétní náhodný vektor. Použijeme matematickou indukci a tudíž stačí tvrzení dokázat pro $d = 2$.

Vezměme si (X_1, X_2) a a, b_1, b_2 . Potom

$$\begin{aligned} E(a + b_1 X_1 + b_2 X_2) &= \sum_{\mathbf{z} \in \mathbb{N}_0^2} (a + b_1 z_1 + b_2 z_2) P[X_1 = z_1, X_2 = z_2] \\ &= \sum_{\mathbf{z} \in \mathbb{N}_0^2} a P[X_1 = z_1, X_2 = z_2] + \sum_{\mathbf{z} \in \mathbb{N}_0^2} b_1 z_1 P[X_1 = z_1, X_2 = z_2] \\ &\quad + \sum_{\mathbf{z} \in \mathbb{N}_0^2} b_2 z_2 P[X_1 = z_1, X_2 = z_2] \\ &= a \underbrace{\sum_{\mathbf{z} \in \mathbb{N}_0^2} P[X_1 = z_1, X_2 = z_2]}_1 + b_1 \sum_{z_1 \in \mathbb{N}_0} z_1 \underbrace{\sum_{z_2 \in \mathbb{N}_0} P[X_1 = z_1, X_2 = z_2]}_{P[X_1 = z_1]} \\ &\quad + b_2 \sum_{z_2 \in \mathbb{N}_0} z_2 \underbrace{\sum_{z_1 \in \mathbb{N}_0} P[X_1 = z_1, X_2 = z_2]}_{P[X_2 = z_2]} \\ &= a + b_1 \sum_{z_1 \in \mathbb{N}_0} z_1 P[X_1 = z_1] + b_2 \sum_{z_2 \in \mathbb{N}_0} z_2 P[X_2 = z_2] \\ &= a + b_1 E X_1 + b_2 E X_2. \end{aligned}$$

Takto můžeme pokračovat indukcí.

Linearita však plyne přímo z definice střední hodnoty pomocí integrálu. Pokud všechny střední hodnoty existují a jsou konečné, pak pomocí definice 3.1 dostaneme

$$\begin{aligned} E(a + b_1 X_1 + b_2 X_2) &= \int_{\Omega} a + b_1 X_1(\omega) + b_2 X_2(\omega) dP(\omega) \\ &= \int_{\Omega} a dP(\omega) + \int_{\Omega} b_1 X_1(\omega) dP(\omega) + \int_{\Omega} b_2 X_2(\omega) dP(\omega) \\ &= a + b_1 E X_1 + b_2 E X_2. \end{aligned}$$

□

Jak vidíme, stačí konečnost všech středních hodnot, není třeba žádný předpoklad o vztahu jednotlivých náhodných veličin, jinými slovy, nepotřebujeme znát sdružené rozdělení náhodného vektoru $\mathbf{X}$. Také však o tomto vztazích mezi jednotlivými složkami $\mathbf{X}$ nedostáváme žádnou informaci, je zcela jedno, jsou-li X_j nezávislé, nebo naopak dokonale závislé.

Povšimněme si

Bud' te $X_1, \dots, X_d$ vzájemně nezávislé se stejnou střední hodnotou, řekněme m . Pak $E\left(a + \sum_{j=1}^d X_j\right) = a + dm$. Druhým extrémním případem je, platí-li $X_j = X_1$ pro všechna $j \neq 1$. Pak zřejmě $\sum_{j=1}^d X_j = dX_1$ a z věty 3.10 dostaneme $E(a + dX_1) = a + dm$.

Vzájemné ovlivnění jednotlivých složek $\mathbf{X}$ měří různé jiné charakteristiky. My zde uvedeme pouze jednu nejčastěji užívanou.

Definice 3.24: (Kovariance a korelace)

Bud' $(X_1, X_2)^T$ náhodný vektor takový, že $\text{var } X_1 < \infty$, $\text{var } X_2 < \infty$.

(1) *Kovariance* X_1 a X_2 je definována $\text{cov}(X_1, X_2) = E(X_1 - E X_1)(X_2 - E X_2)$.

(2) *Korelace* X_1 a X_2 je definována

$$\text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var } X_1 \text{ var } X_2}}.$$

Jen pro jistotu připomeňme: předpoklad konečnosti rozptylu v sobě implicitně obsahuje konečnost střední hodnoty.

Význam kovariance: $X_1 - E X_1, X_2 - E X_2$ jsou odchylky veličin X_1, X_2 od jejich středních hodnot. Bez újmy na obecnosti můžeme proto předpokládat, že obě střední hodnoty jsou nulové a věnovat se jen součinu $X_1 X_2$. Tento je kladný, když násobíme hodnoty (tedy $X_1(\omega)$ a $X_2(\omega)$) stejného znaménka a záporný v opačném případě. Takže střední hodnota $E X_1 X_2$ je kladná, pokud hodnoty těchto náhodných veličin „častěji“ mají shodné znaménko. Ale pozor, kovariance je jen indikátor, rozdělení náhodného vektoru je složité a jedna hodnota nemůže postihnout všechny možnosti závislosti X_1 a X_2 . Kovariance je tím větší, čím častěji se společně vyskytují velké hodnoty X_1 a X_2 a malé hodnoty X_1 s malými hodnotami X_2 .

K výpočtu kovariance můžeme využít přímou definici. Ta však nemusí být úplně vhodná pro počítání a často se hodí takzvaný výpočetní vzorec.

Cvičení 3.25 (Výpočetní vzorec pro kovarianci). Odvoďte platnost vzorce

$$\text{cov}(X_1, X_2) = E(X_1 X_2) - E X_1 E X_2.$$

◊

Cvičení 3.26. Uvažujme diskrétní náhodné vektory (X_1, X_2) a (Y_1, Y_2) s rozdělením daným tabulkou

$x_1 \backslash x_2$	-2	-1	1	2	$y_1 \backslash y_2$	-2	-1	1	2
-2	1/8	1/16	1/16	0	-2	1/16	1/16	1/8	0
-1	1/16	1/8	1/16	0	-1	1/16	0	1/8	1/16
1	0	1/16	1/8	1/16	1	1/16	1/8	0	1/16
2	0	1/16	1/16	1/8	2	0	1/8	1/16	1/16

Určete kovarianci a korelaci pro oba náhodné vektory.

◊

Korelaci zavádíme proto, abychom získali hodnotu nezávislou na „jednotkách“. Platí totiž

$$\text{cov}(aX, Y) = a \text{cov}(X, Y), \text{ ale } \text{corr}(aX, Y) = \text{sign}(a) \text{corr}(X, Y).$$

Na rozdíl od kovariance hodnota korelace proto není ovlivněna měřítkem, ve kterém jsou náhodné veličiny měřené. Ve větě 3.33 také uvidíme, že korelace nabývá pouze hodnot z intervalu $[-1, 1]$, což je další výhodou v porovnání s kovariancí, která může být libovolně velká či malá podle zvoleného měřítka.

Věta 3.27: (Nezávislost a korelace)

Nechť náhodné veličiny X a Y jsou nezávislé a mají konečný (nenulový) rozptyl. Pak $\text{cov}(X, Y) = \text{corr}(X, Y) = 0$.

Důkaz. Uvedeme pro diskrétní náhodný vektor (X, Y) , pro spojitý jde o analogický postup. Přímou z výpočtu střední hodnoty funkce $g(X, Y) = XY$ a z nezávislosti X a Y plyne

$$\begin{aligned} E XY &= \sum_m \sum_n mnP[X = m, Y = n] = \sum_m \sum_n mnP[X = m]P[Y = n] \\ &= \sum_m mP[X = m] \sum_n nP[Y = n] = E X E Y. \end{aligned}$$

Kovariance je tedy nulová a proto i korelace je nulová.

□

Pokud náhodné veličiny X_1 a X_2 mají nulovou korelaci, mluvíme o *nekorelovaných* náhodných veličinách, obecně tak označujeme soubor náhodných veličin $\{X_i\}$ pro které každé dvojice mají nulovou korelaci. Každý soubor *po dvou nezávislých* náhodných veličin je také nekorelovaný, speciálně tedy také soubor *vzájemně nezávislých* náhodných veličin.

Pozor, opačná implikace ale neplatí! Snadno lze nalézt veličiny X a Y , které jsou nekorelované, ale nejsou nezávislé, viz cvičení 3.28.

Cvičení 3.28. Necht' X má rovnoměrné spojitě rozdělení na intervalu $[-1, 1]$ a $Y = X^2$. Pak X a Y určitě nejsou nezávislé, jelikož je mezi nimi přímý funkční vztah. Např. vidíme, že

$$P(X > -1/2, Y > 1/4) = P(X > -1/2, X^2 > 1/4) = P(X > 1/2) = 1/4$$

a

$$P(X > -1/2) \cdot P(Y > 1/4) = \frac{3}{4} \cdot \frac{1}{2} = \frac{3}{8} \neq P(X > -1/2, Y > 1/4).$$

Zároveň ale platí $E X = 0$, $E XY = E X^3 = 0$ a tedy $\text{cov}(X, Y) = 0$. $\diamond$

Nulová korelace je nutnou, ale nikoliv postačující podmínkou pro nezávislost. Přesto i nulová korelace je výhodná a pro některé účely může nezávislost dokonce nahradit. Ale jen pro *některé*!

Věta 3.29: (Rozptyl součtu náhodných veličin)

Bud' $\mathbf{X} = (X_1, \dots, X_d)$ náhodný vektor s konečnými rozptyly. Pak

$$\text{var} \left(\sum_{i=1}^d X_i \right) = \sum_{i=1}^d \text{var} X_i + \sum_{1 \leq i \neq j \leq d} \text{cov}(X_i, X_j) = \sum_{i=1}^d \text{var} X_i + 2 \sum_{1 \leq i < j \leq d} \text{cov}(X_i, X_j).$$

Speciálně, jsou-li $X_1, \dots, X_d$ nekorelované^a, pak

$$\text{var} \left(\sum_{i=1}^d X_i \right) = \sum_{i=1}^d \text{var} X_i.$$

^aNekorelovanost je samozřejmě zaručena silnější podmínkou nezávislosti.

Důkaz. Podle definice rozepíšeme a postupnou úpravou:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^d X_i \right) &= E \left(\sum_{i=1}^d X_i - E \left(\sum_{i=1}^d X_i \right) \right)^2 = E \left(\sum_{i=1}^d (X_i - E X_i) \right)^2 \\ &= E \left(\sum_{i=1}^d (X_i - E X_i)^2 + 2 \sum_{1 \leq i < j \leq d} (X_i - E X_i)(X_j - E X_j) \right) \\ &= \sum_{i=1}^d \text{var} X_i + 2 \sum_{1 \leq i < j \leq d} \text{cov}(X_i, X_j). \end{aligned}$$

Tvrzení pro nekorelované náhodné veličiny je již snadným důsledkem. $\square$

Cvičení 3.30. Pomocí vět 3.3 a 3.3 velmi snadno spočteme střední hodnotu a rozptyl binomického rozdělení. Výpočet z definice je podobný jako v případě Poissonova rozdělení ve 3.16, kde použijeme binomickou větu (zkuste sami, výpočet není složitý, pouze pracný). Elegantnější řešení je ale následující: Je-li X počet úspěchů v n nezávislých Bernoulliových pokusech s parametrem p , pak lze zapsat $X = \sum_{i=1}^n Y_i$, kde Y_i je identifikátor toho, zda v i -tém pokuse nastal úspěch. Navíc,

$Y_1, \dots, Y_n$ jsou nezávislé a tedy i nekorelované. Snadno zjistíme přímým výpočtem z definice, že $E Y_i = p$ a $\text{var } Y_i = p(1 - p)$. Proto

$$E X = E \left(\sum_{i=1}^n Y_i \right) = \sum_{i=1}^n E Y_i = np, \quad \text{var } X = \text{var} \left(\sum_{i=1}^n Y_i \right) = \sum_{i=1}^n \text{var } Y_i = np(1 - p).$$

◊

Z definice je zřejmé, že $\text{cov}(X, X) = \text{var}(X)$. Všechny kovariance náhodného vektoru shrneme do takzvané varianční matice.

Definice 3.31: (Varianční a korelační matice)

Bud' $X = (X_1, \dots, X_d)$ náhodný vektor, $\text{var } X_i < \infty$ pro všechna $i = 1, \dots, d$. Potom matici $\text{Var } X = \{\text{cov}(X_i, X_j)\}_{i,j}$ nazýváme varianční matice a korelační maticí nazveme matici $\text{Corr } X = \{\text{corr}(X_i, X_j)\}_{i,j}$.

Není obtížné ověřit, že korelační matice má diagonálu složenou ze samých jedniček.

Cvičení 3.32. Věta 3.3 může být zapsána s pomocí varianční matice jako kvadratická forma

$$\text{var}(\mathbf{1}^T X) = \text{var} \left(\sum_{i=1}^k X_i \right) = \mathbf{1}^T \text{Var}(X) \mathbf{1},$$

kde vektory bereme sloupcové a $\mathbf{1}$ je vektor samých jedniček.

Podobně lze pro jakýkoliv vektor $\mathbf{a} \in \mathbb{R}^k$ ukázat

$$\text{var}(\mathbf{a}^T X) = \text{var} \left(\sum_{i=1}^k a_i X_i \right) = \mathbf{a}^T \text{Var}(X) \mathbf{a},$$

◊

Věta 3.33: (Základní vlastnosti kovariance a korelace)

Bud' $\mathbf{X}$ náhodný vektor s variační maticí $\text{Var } \mathbf{X}$ (která existuje a má konečné prvky). Dále mějme X, Y náhodné veličiny s konečným rozptylem. Potom

(1) platí

$$-1 \leq \text{corr}(X, Y) \leq 1$$

$$a \text{ corr}(X, X) = 1,$$

(2) $|\text{corr}(X, Y)| = 1$ právě tehdy, když existují $a \neq 0, b \in \mathbb{R}$ takové, že $aX + b = Y$ s pravděpodobností 1^a,

(3) platí^b

$$\text{cov}(aX + c, bY + d) = ab \text{ cov}(X, Y),$$

$$a \text{ corr}(aX + c, bY + d) = \text{sign}(ab) \text{ corr}(X, Y),$$

(4) matice $\text{Var } \mathbf{X}, \text{Corr } \mathbf{X}$ jsou symetrické pozitivně semidefinitní matice,

(5) pro každou matici $A \in \mathbb{R}^{\ell \times k}$ a vektor $b \in \mathbb{R}^{\ell}$ a náhodný vektor $\mathbf{X} = (X_1, \dots, X_k)^T$ platí

$$\text{Var}(A\mathbf{X} + b) = A(\text{Var } \mathbf{X})A^T.$$

^aProto občas zdůrazňujeme, že korelace měří míru lineární závislosti X a Y , některé závislosti korelace neumí odhalit. Viz také cvičení 3.28.

^bI pro a či b rovné nule.

Důkaz. Tvrzení (1) plyne z Cauchyovy–Schwartzovy nerovnosti $(E XY)^2 \leq E X^2 E Y^2$. Tu lze dokázat například pomocí nezápornosti momentu

$$0 \leq E(aX - Y)^2 = a^2 E X^2 - 2a E XY + E Y^2,$$

který nabývá minima pro $a = E XY / E X^2$ (výraz je diferencovatelnou funkcí a). Po dosazení tohoto a do nerovnice dostaneme kýžený výsledek. Zbytek důkazu (1) je snadný.

Pro (2) si uvědomme, že rovnost $|\text{cov}(X, Y)| = \sqrt{\text{var } X \text{ var } Y}$ nastává tehdy, když

$$(E(X - E X)(Y - E Y))^2 = E(X - E X)^2 E(Y - E Y)^2,$$

S použitím výpočtu z důkazu (1) vidíme, že po dosazení $a = E(X - E X)(Y - E Y) / E(X - E X)^2$ dostaneme

$$0 = E \left(\frac{E(X - E X)(Y - E Y)}{E(X - E X)^2} (X - E X) - (Y - E Y) \right)^2$$

a musí platit $P[a(X - E X) - (Y - E Y) = 0] = 1$. Proto s pravděpodobností 1 platí $aX - a E X + E Y = Y$.

Bod (3) plyne přímým výpočtem a bod (4) je přímým důsledkem bodu (3) a vlastností rozptylu.

Bod (5) je důsledkem cvičení 3.32 a faktu

$$0 \leq \text{var}(a^T \mathbf{X}) = a^T \text{Var}(\mathbf{X})a$$

pro libovolný vektor $a \in \mathbb{R}^k$. Označme $D^{1/2}$ diagonální (tedy i symetrickou) matici s diagonálou $(\sqrt{\text{var } X_i})$. Pro korelační matici platí

$$\text{Corr } \mathbf{X} = D^{1/2} \text{Var } \mathbf{X} D^{1/2}, \text{ a proto } a^T \text{Corr } \mathbf{X} a = a^T D^{1/2} \text{Var } \mathbf{X} D^{1/2} a \geq 0$$

pro libovolný vektor $\mathbf{a}$.

Bod (6) ověříte přímým výpočtem z definice. □

*3.4. Další charakteristiky náhodných veličin

Pro náhodné veličiny můžeme definovat i další charakteristiky vycházející z potřeb popsat některé jejich vlastnosti. Zde uvedeme jen ty základní.

Definice 3.34: (Kvantil náhodné veličiny)

Nechť X je náhodná veličina a F_X její distribuční funkce. Pro hodnotu $p \in (0, 1)$ definujeme p -kvantil $q(p)$ jako kteroukoliv hodnotu splňující

$$P[X \leq q(p)] = F_X(q(p)) \geq p \text{ a zároveň } P[X \geq q(p)] = 1 - F_X(q(p)-) \geq 1 - p,$$

kde $F_X(x-)$ je limita F_X v x zleva.

Hodnotu (hodnoty) $q(1/2)$ nazýváme *mediánem*, hodnotu $q(1/4)$ *dolním kvantilem* a hodnotu $q(3/4)$ *horním kvantilem* náhodné veličiny X . Medián X budeme značit m_X

Kvantil tedy rozděluje hodnoty náhodné veličiny na dvě části. Hodnoty nejvýše rovné kvantilu jsou nabývány s pravděpodobností nejméně p , hodnoty větší či rovné kvantilu s pravděpodobností nejméně $1 - p$. Medián tedy rozděluje hodnoty podle velikosti na dvě „skoro stejné“ části (ve smyslu pravděpodobnosti).

Všimněme si, že p -kvantil nemusí být hodnotou kvantilové funkce F_X^{-1} v bodě p . Při zavádění kvantilové funkce jsme viděli, že pro dané $p \in (0, 1)$ je množina $\{x : F_X(x) = p\}$ buď prázdná, nebo jednobodová, nebo jde o konečný interval (a, b) . Připomeňme, že kvantilovou funkci jsme proto definovali jako $F_X^{-1}(p) = \inf\{x; F_X(x) > p\}$. V případě, že $\{x : F(x) = p\} = [a, b]$, pak $F^{-1}(p) = b$, viz prostřední řádek obrázku 2.7. Nicméně v tomto případě pro každé $x \in [a, b]$ platí $F_X(x) = p$ a $1 - F_X(x) = 1 - p$ a tedy definici kvantilu 3.34 splňují všechny body z intervalu $[a, b]$. V případě příkladu na posledním řádku obrázku 2.7 by mediánem byla hodnota x_3 , jelikož pro ni platí $F_X(x_3) > 1/2$ a $F_X(x_3-) < 1/2$.

Nejednoznačnost hodnoty kvantilu způsobuje trochu nepohodlí při práci s nimi. Proto se obvykle udávají pravidla pro jednoznačné vybrání kvantilu ze všech možností. Platí, že množina všech platných hodnot $q(p)$ tvoří interval, čili tato pravidla říkají, kterou hodnotu z daného intervalu vybrat⁸. U mediánu je většinou použit střed intervalu množiny mediánů.

Cvičení 3.35. Nechť náhodná veličina X má rovnoměrné diskrétní rozdělení s hodnotami $\{1, 2, 3, 4\}$. Které hodnoty vyhovují definici mediánu? Vyberte medián jako střed intervalu přípustných hodnot mediánu.

⁸Jeden z autorů se setkal se značným znepokojením nad dvěma různými pravidly pro výpočet kvantilu u středoškolského učitele matematiky, pro kterého „nejednoznačnost“ definice v matematice byla něco nepředstavitelného. Definice přitom jednoznačná je, ale splňuje ji více hodnot, což při práci se vzory zobrazení nemůže být překvapivé. Co není úplně jednoznačné je doporučení, kterou z možných hodnot kvantilu vybrat, každý způsob má své výhody a nevýhody a nemusí se hodit pro všechna použití.

Nechť Y má rozdělení také na hodnotách $\{1, 2, 3, 4\}$ s pravděpodobnostmi $p_1 = 1/2, p_2 = 1/6, p_3 = 1/6, p_4 = 1/6$. Najděte medián Y . Je daný jednoznačně? Spočítejte $P[Y \leq m_Y]$ a $P[Y \geq m_Y]$. $\diamond$

Cvičení 3.36. Rozmyslete si, že pokud má X distribuční funkci, která je spojitá a rostoucí na množině $\{x; F(x) \in (0, 1)\}$, pak je $q(p) = F^{-1}(p)$ pro všechna $p \in (0, 1)$. $\diamond$

Podobně jako střední hodnota i medián a další kvantily charakterizují *polohu* náhodné veličiny. Podobnou charakteristikou může být i modus náhodné veličiny.

Definice 3.37: (Modus)

Nechť X je náhodná veličina a f_X její hustota (diskrétní či spojitá). Hodnota M_X maximalizující hustotu je *modus* náhodné veličiny X .

Ani modus nemusí být jednoznačně určený. Triviální příklad jsou veškerá rovnoměrná rozdělení s konstantní hustotou, ale i mnohá další. Hodnoty modu mohou navíc být oddělené body.

Pro některá rozdělení je modus na hranici jejich hodnot, například pro rozdělení s hustotou $f(x) = x^2/2, x \in [0, 1]$ je modem hodnota 1. Pro rozdělení exponenciální s hustotou $e^{-x}, x > 0$ nenabývá hustota maxima, můžeme však beze změny hustotu rozdělení definovat i předpisem $e^{-x}, x \geq 0$. Tato hustota již svého maxima nabývá a modus rozdělení je roven nule. Pro rozdělení s hustotou $2x^{-1/2}, x \in (0, 1)$ však limita hustoty v nule zprava je nekonečná a hustota nenabývá maximální hodnoty a nelze ji beze změny rozdělení ani upravit tak, aby maxima nabývala. Definici modu je možné upravit tak, aby i tomto případě modus vyšel 0, ale vzhledem k malému významu modu u těchto typů rozdělení se nebudeme dále těmito případy zabývat.

Modus hraje roli při hledání „nejpravděpodobnějších hodnot“. U spojitých rozdělení sice pro každé x platí $P[X = x] = 0$, ale pokud je hustota spojitá, tak malé okolí modu má obvykle větší pravděpodobnost než stejně velké okolí jiných bodů. U diskretních rozdělení má modus větší význam, jde skutečně o nejpravděpodobnější hodnotu a modus nachází využití ve spojení s aposteriorním rozdělením (aposteriorními pravděpodobnostmi), se kterým jsme se seznámili v Bayesově větě.

Pokud jde o míru variability, alternativou ke směrodatné odchylce je *mezikvartilové rozpětí*, neboli vzdálenost horního a dolního kvartilu $q(3/4) - q(1/4)$. Opět musíme dbát na vhodně jednoznačně zvolené hodnoty kvartilů. Mezikvartilové rozpětí udává délku (uzavřeného) intervalu, ve kterém se vyskytuje nejméně polovina prostředních hodnot náhodné veličiny. Vně (a včetně) kvartilů se vyskytuje také nejméně polovina hodnot, konkrétně nejméně čtvrtina nejmenších a nejméně čtvrtina největších hodnot náhodné veličiny. Podíly bereme podle pravděpodobnosti intervalů, ne podle mohutnosti (u diskretních) či míry (u spojitých) množin. Spolu s mediánem nám tedy kvartily dávají dobrou představu o poloze a variabilitě náhodné veličiny. Jedná se tak o obdobu střední hodnoty a směrodatné odchylky.

Poznámka 3.38. Na rozdíl od střední hodnoty a směrodatné odchylky, které jsou definovány jen pro náhodné veličiny s konečným rozptylem, medián a kvantily jsou definovány pro všechny *vlastní* náhodné veličiny, tedy pro náhodné veličiny splňující $P[X \in \mathbb{R}] = 1$.

Na druhou stranu kvůli absenci přirozeného lineárního uspořádání v prostorech $\mathbb{R}^d$ pro $d \geq 2$ není možné přímo zobecnit pojem kvantilu pro náhodné vektory⁹.

Věta 3.39: (Kvantily funkce náhodné veličiny)

Nechť X je náhodná veličina a f ryze rostoucí funkce. Pak $q_{-X}(p) = -q_X(1 - p)$ a dále $q_{f(X)}(p) = f(q_X(p))$.

Důkaz. Důkaz je prostým nahlédnutím a použitím skutečností

$$P[-X \leq -q_X(p)] = P[X \geq q_X(p)] \geq 1 - p$$

a také $P[f(X) \leq f(q)] = P[X \leq q]$. □

Speciálně tedy platí linearita (všech) kvantilů pro rostoucí afinní funkce $q_{aX+b}(p) = aq_X(p) + b$ pokud $a > 0$. Ovšem jak vidíme, pro kvantily platí ekvivariance pro mnohem větší třídu transformací než pro střední hodnotu.

*3.5. Střední hodnota a medián jako optimalizační problém

Přestože střední hodnota i medián mají velmi pochopitelnou definici, můžeme se ptát, proč volit zrovna tyto dvě hodnoty jako hodnoty charakterizující *polohu* náhodné veličiny. Ukážeme si, že v jistém smyslu jde pro náhodnou veličinu X o její „nejbližší“ konstanty.

Věta 3.40: (Optimalita střední hodnoty)

Bud' X náhodná veličina s konečným rozptylem $\text{var } X$. Pak platí

$$E(X - EX)^2 \leq E(X - a)^2 \text{ pro všechna } a \in \mathbb{R}.$$

Důkaz. Snadno ověříme

$$E(X - a)^2 = E(X - EX + EX - a)^2 = E(X - EX)^2 + 2E(X - EX)(EX - a) + E(EX - a)^2.$$

Druhý sčítanec je nulový, protože $EX - a$ je konstanta a $E(X - EX) = 0$. Třetí sčítanec je nezáporná konstanta a je nula tehdy a jen tehdy, je-li $a = EX$. □

Střední hodnota je tedy tou hodnotou, která má v průměru nejmenší čtverec vzdálenosti od hodnot náhodné veličiny. Střední hodnota je tak úzce spjata s metodou nejmenších čtverců.

⁹Z mnoha důvodů přitom jde o velmi potřebný koncept, takže jde o stále živou oblast výzkumu.

Věta 3.41: (Optimalita mediánu)

Bud' X náhodná veličina a $E|X| < \infty$. Pak její medián splňuje

$$E|X - m_X| \leq E|X - a| \text{ pro všechna } a \in \mathbb{R}.$$

Medián je tedy ta hodnota, která má v průměru nejmenší absolutní odchylku od hodnot náhodné veličiny.

Důkaz. Důkaz si ukážeme pro spojitě rozdělení. Nechť X je spojitá náhodná veličina s hustotou f_X . Nechť bez újmy na obecnosti je $a > m_X$. Pak

$$\begin{aligned} E|X - a| - E|X - m_X| &= (a - m_X)P[X \leq m_X] + \int_{m_X}^a (a + m_X - 2x)f_X(x) dx \\ &\quad + (m_X - a)P[X \geq a] \\ (3.1) \quad &= (a - m_X)(P[X \leq m_X] - P[X \geq a]) \\ &\quad + \int_{m_X}^a (a + m_X - 2x)f_X(x) dx. \end{aligned}$$

Protože $P[X \leq m_X] = 1/2 = P[X \geq m_X]$, dostaneme rovnost

$$P[X \leq m_X] - P[X \geq a] = P[m_X \leq X \leq a] = \int_{m_X}^a f_X(x) dx.$$

Tuto rovnost použijeme v (3.1) a dostaneme

$$\begin{aligned} E|X - a| - E|X - m_X| &= \int_{m_X}^a (a - m_X)f_X(x) dx + \int_{m_X}^a (a + m_X - 2x)f_X(x) dx \\ &= \int_{m_X}^a 2(a - x)f_X(x) dx \geq 0, \end{aligned}$$

protože integrand je nezáporný. Důkaz pro $a < m_X$ je obdobný. $\square$

Ve znění věty máme podmínku $E|X| < \infty$, ale my můžeme podmínku ve větě přepsat na

$$E(|X - m_X| - |X|) \leq E(|X - a| - |X|) \text{ pro všechna } a \in \mathbb{R}.$$

Snadno se přesvědčíme, že v případě $E|X| < \infty$ jde o ekvivalentní podmínky a tato druhá nevyžaduje konečnost ani existenci střední hodnoty. Proto ji lze použít také jako definici mediánu¹⁰.

Cvičení 3.42. Dokažte větu 3.41 pro diskrétní náhodnou veličinu. $\diamond$

Také pro rozptyl můžeme najít alternativní vzorec, který ukáže tento pojem v jiném světle. Použijeme jednoho z oblíbených triků a tím je přidání *nezávislé kopie* náhodné veličiny do výpočtu. Nicméně následující vzorec má spíše teoretický význam, k výpočtu jej nepoužíváme.

¹⁰A s mírnou obměnou ztrátové funkce i pro definici libovolného kvantilu.

Věta 3.43: (Rozptyl jako střední kontrast)

Nechť X je náhodná veličina s konečným rozptylem. Pak

$$\text{var } X = \frac{1}{2} E(X - \tilde{X})^2,$$

kde $\tilde{X}$ je náhodná veličina se stejným rozdělením jako X a tyto dvě veličiny jsou nezávislé.

Důkaz. Důkaz spočívá ve využití snadno ověřitelných skutečností $E X = E \tilde{X}$ a $E X^2 = E \tilde{X}^2$, které plynou ze shodného rozdělení a dále $(E X)^2 = E(X \tilde{X})$, což plyne ze shodného rozdělení a nezávislosti. Zbytek je ponechán na čtenáři. $\square$

Pokud je rozdělení náhodné veličiny symetrické, střední hodnota i medián (bereme-li jej jako střed intervalu vyhovující definici 3.34) splývají a jsou rovny středu symetrie, pokud střední hodnota existuje.

Věta 3.44: (Symetrie a střední hodnota)

Nechť náhodná veličina X má rozdělení symetrické kolem bodu s , tedy platí že rozdělení náhodné veličiny $X - s$ je stejné jako rozdělení náhodné veličiny $s - X$. Pak platí $m_X = s$. Existuje-li navíc konečná střední hodnota $E X$, je i $E X = s$.

Důkaz. Podle předpokladu platí $P[X \leq s] = P[-X \leq -s]$ a zároveň $P[X < s] = P[-X < -s]$. Zároveň $P[-X \leq -s] = P[X \geq s]$ a $P[-X < -s] = P[X > s]$. Proto

$$1 = P[X < s] + P[X = s] + P[X > s] = 2P[X < s] + P[X = s].$$

Odtud již snadno dostaneme $P[X \leq s] \geq 1/2$ a podobně i $P[X \geq s] \geq 1/2$, čímž jsme dokázali, že s je mediánem rozdělení náhodné veličiny X .

Existuje-li konečná střední hodnota $E X$, pak existuje i konečná $E(X - s)$ a stačí ukázat, že tato je rovna nule. Podle předpokladu je $E(X - s) = E(s - X) = -E(X - s)$ a proto musí být tato hodnota nulová a střední hodnota $E X = s$. $\square$

Problémy k dalšímu procvičení

1. Diskrétní náhodná veličina X nabývá pouze hodnot 1, 2, 3 s pravděpodobnostmi $P(X = k) = c \cdot k^2$, $k = 1, 2, 3$. Spočítejte konstantu c , střední hodnotu $E X$ a rozptyl $\text{var } X$, distribuční funkci F a pravděpodobnost $P(X \geq 2)$. Určete dále rozdělení veličiny $Y = (X - 2)^2$ a $E Y$.
2. Náhodná veličina X nabývá pouze hodnot $-1, 0, 1, 2$, a to s pravděpodobnostmi $P(X = -1) = \frac{1}{6}$, $P(X = 0) = \frac{1}{2}$, $P(X = 1) = \frac{1}{12}$ a $P(X = 2) = a$. Určete konstantu a , tak aby se jednalo o pravděpodobnostní rozdělení. Spočítejte střední hodnotu $E X$ a rozptyl $\text{var } X$. Určete rozdělení veličiny $Y = X^2$ a spočítejte $E Y$.
3. Spočítejte střední hodnotu a rozptyl alternativního rozdělení.

4. Spočítejte střední hodnotu a rozptyl binomického rozdělení.

- (a) Přímo z definice.
 (b) S využitím faktu, že má-li náhodná veličina Y binomické rozdělení $\text{Bi}(n, p)$, lze ji považovat za součet nezávislých stejně rozdělených $X_i, i = 1, 2, \dots, n$, kde X_i je indikátor úspěchu v i -tém pokusu.
 (c) S použitím momentové vytvořující funkce a jejích prvních dvou derivací v bodě 0.

Pro přímý výpočet využijte binomického rozvoje $1 = (p + 1 - p)^k$ a vhodného posunu v indexu. Pro výpočet druhého momentu je zde vhodné použít vztah $EY^2 = EY(Y - 1) + EY$.

5. V krabici je N čokoládových bonbónů, z nichž je K plněno karamelovou náplní. Vyberete si z krabice náhodně n bonbónů. Nechť X značí počet vytažených bonbónů s karamelovou náplní.

- (a) Spočítejte střední hodnotu X .

- (b) Spočítejte rozptyl X .

Využijte, že X můžeme napsat jako součet (závislých) 0-1 veličin.

6. Spočítejte střední hodnotu a rozptyl negativně binomického rozdělení.

Nejprve spočítejte střední hodnotu a rozptyl geometrického rozdělení a poté využijte možnost napsat negativně binomické rozdělení jako součet nezávislých stejně rozdělených geometrických.

7. Spočítejte pro Poissonovo rozdělení s parametrem λ

- (a) střední hodnotu a rozptyl.
 (b) momentovou vytvořující funkci.

8. Spočítejte pro exponenciální rozdělení s parametrem λ

- (a) střední hodnotu a rozptyl.
 (b) momentovou vytvořující funkci.

9. Náhodná veličina X má rozdělení s hustotou

$$f(x) = \begin{cases} ce^x & \text{pro } x \in [0, 1], \\ 0 & \text{jinak,} \end{cases}$$

Určete konstantu c , distribuční funkci $F(x)$, střední hodnotu EX a rozptyl $\text{var } X$.

10. Hrana krychle má náhodnou délku X s rovnoměrným rozdělením na $[0, a]$, $a > 0$. Určete střední hodnotu a rozptyl povrchu a objemu krychle.

11. Náhodná veličina X má rozdělení s hustotou $f(x) = 3x^2$ pro $0 < x < 1$ a $f(x) = 0$ jinak. Určete

- (a) Rozdělení veličiny $Y = X^3$.

- (b) Střední hodnotu a rozptyl veličiny $Z = \frac{1}{X}$.

12. Veličina X má rozdělení s hustotou

$$f(x) = \begin{cases} c \cdot \sin x & \text{pro } 0 < x < \pi, \\ 0 & \text{jinak.} \end{cases}$$

- (a) Určete konstantu $c > 0$ a distribuční funkci F (načrtněte).

- (b) Spočítejte střední hodnotu EX .

- (c) Vyjádřete kvantilovou funkci F^{-1} a určete medián.
13. Házíme třikrát mincí. Označme X počet líců v prvních dvou hodech a Y počet rubů v posledních dvou hodech.
- (a) Určete sdružené rozdělení vektoru (X, Y) .
- (b) Určete marginální rozdělení X a Y . Jsou náhodné veličiny X a Y nezávislé?
- (c) Určete jejich kovarianci a korelační koeficient.
14. Zmatená šatnářka náhodně přiřadí n pánům jejich klobouky. Náhodná veličina X_i je indikátor jevu, zda má i -tý pán správný klobouk, $i = 1, \dots, n$ (tj. $X_i = 1$, pokud i -tý pán má svůj klobouk a $X_i = 0$ jinak).
- (a) Spočítejte střední hodnotu a rozptyl veličiny X_i pro pevně zvolené i .
- (b) Jsou veličiny X_i, X_j pro pevné i, j nezávislé?
- (c) Spočítejte kovarianci X_i a X_j .
- (d) Na základě výše uvedených výsledků spočítejte očekávanou hodnotu a rozptyl počtu správně přiřazených klobouků. (Využijte, že počet správně přiřazených klobouků X lze vyjádřit jako $X = \sum_{i=1}^n X_i$.)
15. Náhodný vektor (X, Y) má rozdělení s hustotou

$$f(x, y) = \begin{cases} ce^{-(x^2+y^2)} & \text{pro } x \geq 0, y \geq 0, \\ 0 & \text{jinak.} \end{cases}$$

- (a) Určete konstantu c tak, aby f byla hustota.
- (b) Spočítejte marginální hustoty f_X a f_Y veličin X a Y . Jsou veličiny X a Y nezávislé?
- (c) Spočítejte $E(X^2 + Y^2)$.

Náhodný výběr a výběrové momenty

Práce s pravděpodobnostmi předpokládá schopnost určit pro jednotlivé náhodné jevy jejich pravděpodobnost a pro náhodné veličiny jejich rozdělení. Pokud zasadíme semínko ředkvičky, vyroste nám ředkvička, nebo nic. Pokud by nám vyrostla kedlubna, pak *víme*, že jsme nezasadili semínko ředkvičky. Ale dopředu nikdy *s jistotou nevíme*, jak velkou úrodu ředkviček se nám podaří vypěstovat, neboť úroda závisí na mnoha faktorech. Když Ernest Rutherford bombardoval tenkou kovovou fólií alfa částicemi, chtěl měřit odchylku dráhy po průchodu fólií a podle tehdejší představy o atomech předpokládal, že tato odchylka nebude velká. Ke svému překvapení však zjistil, že některé částice byly v podstatě odraženy zpět, takže prokázal chybu v tehdy používaném modelu pro atom, což vedlo k objevu atomového jádra. Rutherford pochopitelně věděl, že odchylku dráhy nelze přesně spočítat, protože i tenká kovová fólie je natolik tlustá, že částice musí projít mnoha vrstvami atomů, takže odchylka je pro nás náhodnou veličinou. Na základě modelu byl schopen zhruba předvídat obvyklou velikost (střední hodnotu) a variabilitu (rozptyl) této náhodné veličiny, měl tedy jakousi *představu o rozdělení* odchylek. Pozorování bylo ovšem v naprostém rozporu s očekáváním. Tak jako mnoho vědeckých objevů i zde hrál podstatnou roli náhodný výběr, pozorování náhodné veličiny za stejných podmínek.

Poznámka 4.1. Vřele doporučujeme spolu se čtením od této kapitoly dále používat velice povedené znázornění zde představených pojmů na stránce [Seeing Theory](#).

4.1. Náhodný výběr a empirické rozdělení

Modely pro náhodné veličiny a vektory jsou jen teoretické konstrukty. Někdy mohou být velmi blízké (binomické rozdělení, pokud máme „zaručenu“—ale jak?—nezávislost a homogenitu pokusů), někdy prostě „jen rozumné“.

Obvykle se snažíme model najít, navrhnout, posoudit, odhadnout, otestovat podle *empirických* zkušeností. K tomu ale potřebujeme zkušenost získat a to lze opakovaným pozorováním náhodného jevu či vektoru, o kterém chceme něco zjistit.

Základním modelem je *náhodný výběr*. Jeho podstatou je, že stejnou „náhodnost“ pozorujeme v nezávislých opakováních a z těchto pak můžeme zevšeobecňovat.

Definice 4.2 (Náhodný výběr). Posloupnost $X_1, X_2, \dots, X_n$ náhodných veličin či vektorů takových, že jsou nezávislé a mají stejné rozdělení P , nazvěme náhodný výběr velikosti n z rozdělení P . Ve zkratce říkáme, že $X_1, \dots, X_n$ jsou iid (independent and identically distributed).

Pro různá $\omega \in \Omega$ dostáváme různé realizace náhodného výběru. Uvažujeme-li náhodný výběr 5 hodů kostkou, pak při jedné realizaci (jedno konkrétní $\omega \in \Omega$) naměříme např. 2, 3, 1, 5, 5 a při jiné realizaci dostaneme jinou pětičíslicí hodnot.

Na základě náhodného výběru můžeme hledat vhodné modely a odhady pro neznámé rozdělení náhodné veličiny. Například velmi jednoduše je možné odhadnout hodnotu distribuční funkce takzvanou empirickou distribuční funkcí. Ta je docela dobrým odhadem skutečné distribuční funkce náhodné veličiny. Než však budeme moci říci, co to vlastně *odhad* je a co to znamená *býti dobrým odhadem*, budeme muset pro náhodné veličiny zavést další charakteristiky a odhady pořádně zavedeme až v kapitole 6.


Definice 4.3 (Empirická distribuční funkce). Buď $X_1, \dots, X_n$ náhodný výběr z rozdělení P s distribuční funkcí F . Pak $\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \chi(X_i \leq x)$, kde χ je indikátorová funkce, se nazývá *empirická distribuční funkce*.

Na obrázku 4.1 je uvedena konkrétní realizace empirické distribuční funkce spočtené pro náhodný výběr $X_1, \dots, X_n$ z normálního rozdělení $N(0, 1)$. Pro porovnání je do obrázku přidána i teoretická distribuční funkce F_X . Vidíme, že se zvyšujícím se n se $\widehat{F}_n$ „přibližuje“ F_X a tvar $\widehat{F}_n$ nám tedy dává dobrou představu o tom, z jakého rozdělení bude náš náhodný výběr pocházet.

Cvičení 4.4. Použijte generátor pseudonáhodných čísel z intervalu $(0, 1)$ a pro různá zvyšující se n počítejte $\widehat{F}_n$. Na základě grafického porovnání s F_X rovnoměrného rozdělení usud'te, zda je Váš generátor opravdu „rovnoměrný“. Pokud se $\widehat{F}_n$ od F_X výrazně odlišuje i pro rozumně vysoká n , pak zřejmě generátor není vhodný. $\diamond$

Poznámka 4.5. Zde vidíme náhodnou veličinu z dalšího úhlu pohledu. Empirická distribuční funkce je funkcí náhodných veličin, a proto $\widehat{F}_n(x)$ je sama náhodnou veličinou (to si rozmyslete!). Obecně, $\widehat{F}_n$ je zobrazení, které každému $\omega \in \Omega$ přiřadí funkci, která je po částech lineární, skokovitá, neklesající a její hodnoty jsou v $[0, 1]$. Grafy na obrázku 4.1 odpovídají vždy jednomu konkrétnímu výsledku, tj. jednomu konkrétnímu $\omega \in \Omega$.

Máme tedy vzorec, který pracuje s předem neznámými hodnotami (náhodnou veličinou) a při opakovaných experimentech (náhodných výběrech) dává různé výsledky, jejichž rozdělení se také dá odvodit. Což částečně hned uděláme.



Obrázek 4.1. Příklady empirické distribuční funkce pro náhodný výběr z normálního rozdělení $N(0, 1)$ o rozsahu n .

Věta 4.6 (Rozdělení empirické distribuční funkce I). *Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení P s distribuční funkcí F a zvolme pevné x . Pak $\widehat{F}_n(x)$ má rozdělení dané předpisem*

$$P\left[\widehat{F}_n(x) = \frac{k}{n}\right] = \binom{n}{k} (F(x))^k (1 - F(x))^{n-k}.$$

Jinými slovy náhodná veličina $n\widehat{F}_n(x)$ má pro každé x binomické rozdělení s parametry n a $F(x)$.

Důkaz. Jistě platí, že $n\widehat{F}_n(x) = k$, když právě k z n hodnot v náhodném výběru je nejvýše x . Pro všechny náhodné veličiny X_i z náhodného výběru platí

$$P[\chi(X_i \leq x) = 1] = P[X_i \leq x] = F(x) = 1 - P[\chi(X_i \leq x) = 0],$$

proto součet $\sum_{i=1}^n \chi(X_i \leq x)$ má binomické rozdělení a odtud již tvrzení věty snadno plyne. $\square$

Následující věta ukazuje, že hodnoty $\widehat{F}_n(x), \widehat{F}_n(y)$ pro $x \neq y$, rozhodně nejsou nezávislé.

Věta 4.7 (Rozdělení empirické distribuční funkce II). *Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení P s distribuční funkcí F a zvolme pevná čísla $x < y$. Pak náhodný vektor $(\widehat{F}_n(x), \widehat{F}_n(y))$ má sdružené rozdělení dané pro $0 \leq k \leq \ell \leq n, k, \ell \in \mathbb{N}_0$ předpisem*

$$P \left[\widehat{F}_n(x) = \frac{k}{n}, \widehat{F}_n(y) = \frac{\ell}{n} \right] = \frac{n!}{k!(\ell - k)!(n - \ell)!} (F(x))^k (F(y) - F(x))^{\ell - k} (1 - F(y))^{n - \ell}.$$

Důkaz. Důkaz je podobný důkazu věty 4.6 s tím rozdílem, že nyní právě k prvků náhodného výběru musí být nejvýše rovno x , právě $\ell - k$ z nich musí být větší než x a zároveň nejvýše y a zbylých $n - \ell$ je větších než y . Náhodný vektor $(n\widehat{F}_n(x), n\widehat{F}_n(y))$ má tedy (pochopitelně) multinomické rozdělení. $\square$

Takto bychom mohli pokračovat dále a dostat tak sdružené rozdělení pro empirickou distribuční funkci v libovolných konečně mnoha bodech. Pro diskrétní rozdělení tak můžeme dospět k rozdělení empirické distribuční funkce *jako takové*. Pro spojitě rozdělení je situace podstatně složitější, protože nemáme předem dané hodnoty, v nichž se budou nacházet skoky empirické distribuční funkce.

4.2. Výběrové momenty a kvantily

V předchozí kapitole jsme zavedli náhodný výběr a ukázali jsme si, že pomocí něj můžeme zkonstruovat empirickou distribuční funkci.

Z definice 4.3 plyne, že empirická distribuční funkce splňuje předpoklady věty ?? a je distribuční funkcí nějaké náhodné veličiny a lze uvažovat její střední hodnotu a další momenty.¹

Nebo z jiného pohledu, můžeme definovat i jiné funkce náhodného výběru než byla právě distribuční funkce. Důležitými funkcemi jsou průměr a tzv. výběrový rozptyl.

Definice 4.8 (Výběrový průměr). Bud' $X_1, \dots, X_n$ náhodný výběr. Výběrovým průměrem nazveme

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i.$$

¹Označme tuto náhodnou veličinu Z . Je-li $X_1, \dots, X_n$ náhodný výběr, pak náhodná veličina Z odpovídá výběru jedné z veličin X_i s pravděpodobností $1/n$. Pokud jsou $x_1, \dots, x_n$ naměřené hodnoty náhodného výběru, pak si můžeme náhodnou veličinu Z představit jako náhodné losování z n míčků, na kterých jsou napsané hodnoty x_i . Pokud se některý výsledek vyskytuje v náhodném výběru vícekrát, je napsán na odpovídajícím počtu míčků.

To znamená, že možné hodnoty náhodné veličiny Z jsou dány náhodným výběrem a při jiném náhodném výběru se mohou změnit jak hodnoty náhodné veličiny Z , tak i jejich pravděpodobnosti. Proto můžeme tam, kde je to třeba zdůrazňovat závislost Z na náhodném výběru značením Z_X .

Experiment: Hod'te dvacetkrát hrací kostkou a zaznamenejte si výsledky $X_1, \dots, X_{20}$. Jaké rozdělení má náhodná veličina Z ? Jedná se o diskrétní rozdělení na hodnotách $\{1, 2, \dots, 6\}$, kde

$$P[Z_X = k] = \frac{1}{n} \sum_{i=1}^n \chi(X_i = k),$$

podíl výsledků k ve dvaceti hodech. V tomto případě jde vždy o násobek čísla $1/20$, některé pravděpodobnosti mohou být i nulové. Pokud několikrát zopakujete a všimnete si, jak se mění empirické rozdělení, tedy rozdělení náhodné veličiny spojené s empirickou distribuční funkcí, v závislosti na náhodném výběru.

Zpočátku může být neobvyklé vnímat rozdělení pravděpodobností jako náhodný objekt, ale empirické rozdělení je dáno náhodným výběrem, proto samo je náhodné.

Výběrový průměr je aritmetickým průměrem pozorování a jde o náhodnou veličinu. Každá realizace náhodného výběru může vést k jinému výběrovému průměru.

Věta 4.9. *Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení s distribuční funkcí F_X .*

- (1) *Pokud $E X$ existuje a je konečná, $E \bar{X}_n = E X$.*
- (2) *Pokud $\text{var } X < \infty$, pak $\text{var } \bar{X}_n = \frac{1}{n} \text{var } X$.*
- (3) *Pro každé $x \in \mathbb{R}$ platí $E \hat{F}_n(x) = F_X(x)$.*

Důkaz. Důkaz je snadným použitím linearity střední hodnoty. Z předpokladů věty plyne, že všechny náhodné veličiny X_i jsou nezávislé, mají stejné rozdělení jako náhodná veličina X a tedy střední hodnotu $E X$.

$$E \bar{X}_n = E \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n E X_i = E X.$$

Rozptyl součtu nezávislých náhodných veličin je roven součtu rozptylů, proto

$$\text{var } \bar{X}_n = \text{var } \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n^2} \sum_{i=1}^n \text{var } X_i = \frac{1}{n} \text{var } X.$$

Hodnota $\hat{F}_n(x)$ je výběrovým průměrem náhodného výběru $\chi(X_i \leq x)$, a proto $E \hat{F}_n(x) = E Y$, kde $Y = \chi(X \leq x)$. Stačí si uvědomit, že náhodná veličina Y má alternativní rozdělení s parametrem $F_X(x)$ a proto $E Y = F_X(x)$. $\square$

Pro rozdělení dané empirickou distribuční funkcí můžeme snadno spočítat i rozptyl $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$, který je samozřejmě také náhodnou veličinou. Spočítejme střední hodnotu této náhodné veličiny. Snadno zjistíme, že není rovna rozptylu náhodné veličiny X .

$$\begin{aligned} E \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 &= E \frac{1}{n} \sum_{i=1}^n (X_i - E X + E X - \bar{X}_n)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \underbrace{E(X_i - E X)^2}_{\text{var } X} - 2 \underbrace{E(X_i - E X)}_{\frac{1}{n} \sum (X_j - E X)} \underbrace{(E X - \bar{X}_n)}_{\frac{1}{n} \text{var } X} + \underbrace{E(E X - \bar{X}_n)^2}_{\frac{1}{n} \text{var } X}. \end{aligned}$$

První výraz je samozřejmě roven $\text{var } X$. Pro druhý výraz si rozepíšme

$$E(X_i - E X) \frac{1}{n} \sum_{j=1}^n (X_j - E X) = \frac{1}{n} \sum_{j=1}^n \underbrace{E(X_i - E X)(X_j - E X)}_{\text{var } X \text{ pro } j=i, 0 \text{ pro } j \neq i} = \frac{1}{n} \text{var } X.$$

Dohromady tak dostáváme

$$E \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n-1}{n} \text{var } X.$$

Zřejmě tak platí

$$E \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \text{var } X.$$

Definice 4.10 (Výběrový rozptyl). Bud' $X_1, \dots, X_n$ náhodný výběr. Výběrovým rozptylem nazveme

$$S_n^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

Z výpočtu výše plyne platnost následující věty.

Věta 4.11. Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení s distribuční funkcí F_X . Pokud je $\text{var } X < \infty$, pak $E S_n^2 = \text{var } X$.

Cvičení 4.12. Na stránkách projektu [Seeing Theory](http://seeing-theory.brown.edu) si názorně prohlédněte, jak náhodně se chová výběrový průměr a rozptyl. Můžete si pohrát s nastavením a sledovat, jak se výběrový průměr a rozptyl přizpůsobují. (seeing-theory.brown.edu)

◊

Definice 4.13 (Další výběrové momenty). Bud' $X_1, \dots, X_n$ náhodný výběr. Pak

$$\widehat{\mu}_r = \frac{1}{n} \sum_{i=1}^n X_i^r$$

se nazývá r -tý výběrový moment.

Věta 4.14. Je-li $X_1, \dots, X_n$ náhodný výběr z rozdělení s konečným r -tým momentem $E X^r$, pak $E \widehat{\mu}_r = E X^r$.

Střední hodnota výběrových momentů, výběrového rozptylu i empirické distribuční funkce jsou rovny odpovídajícím teoretickým hodnotám. K tomuto tématu se vrátíme v kapitole o odhadech parametrů.

Chceme-li definovat výběrovou kovarianci, musíme pochopitelně pozorovat náhodné vektory.

Definice 4.15 (Výběrová kovariance a korelace). Bud' $X_1, \dots, X_n$ náhodný výběr d -rozměrných náhodných vektorů z rozdělení s konečnou varianční maticí $\text{Var } X$. Pak

$$\widehat{\text{Var}}(X) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)(X_i - \bar{X}_n)^T,$$

kde vektory X jsou sloupcové. Na místě k, ℓ v matici $\widehat{\text{Var}}(X)$ je tedy prvek² $\widehat{\text{cov}}(X_k, X_\ell)$, pro který platí

$$\widehat{\text{cov}}(X_k, X_\ell) = \frac{1}{n-1} \sum_{i=1}^n (X_{k,i} - \bar{X}_{k,n})(X_{\ell,i} - \bar{X}_{\ell,n}), \text{ kde } \bar{X}_{k,n} = \frac{1}{n} \sum_{i=1}^n X_{k,i}.$$

²Zde je těžší udělat pěkné značení. Náhodný vektor X_i je prvkem náhodného výběru, který má stejné rozdělení jako „vzorový“ náhodný vektor X . Náhodná veličina X_k je k -tou složkou náhodného vektoru X , zatímco náhodná veličina $X_{k,i}$ je k -tou složkou náhodného vektoru X_k . Hodnota $\bar{X}_{k,n}$ je k -tou složkou vektoru výběrových středních hodnot $\bar{X}_n$. Dolní index bohužel slouží jak pro označení složky náhodného vektoru, tak i pro označení prvku náhodného výběru.

Výběrová korelace $r_{k,\ell}$ je definována

$$r_{k,\ell} = \frac{\widehat{\text{cov}}(X_k, X_\ell)}{\sqrt{S_{k,n}^2 S_{\ell,n}^2}}$$

a matici $\widehat{\text{Corr}}(X) = (r_{k,\ell})_{k,\ell=1}^d$ nazveme výběrovou korelační maticí.

Důkaz následujícího tvrzení je stejný jako důkaz věty 4.11.

Věta 4.16. *Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení s konečnou varianční maticí $\text{Var}(X)$. Pak $E \widehat{\text{Var}}(X) = \text{Var}(X)$.*

Pro náhodný výběr můžeme zavádět i další výběrové kvantily. Např. *výběrové kvantily* můžeme definovat jako kvantily empirické distribuční funkce podle definice 3.34. Jelikož empirické rozdělení je ze své podstaty diskrétní, mnoho kvantilů nabývá více možných hodnot a my jsme většinou postaveni před úkol vybrat právě jednu hodnotu kvantilu. Nej-jednodušším řešením v takovém případě je vzít střed intervalu možných hodnot kvantilu. Obecně lze volit vážený průměr krajních bodů intervalu, tedy nějakou formu lineárního vyrovnaní. Volba kvantilu se může také lišit podle toho, je-li teoretické rozdělení diskrétní či spojitě. Pro diskrétní rozdělení není třeba uvažovat složitější volbu než jeden z krajích bodů intervalu kvantilů, případně střed tohoto intervalu. U spojitých rozdělení může být konvexní kombinace krajních bodů vhodnější, protože pak výběrové kvantily pro různá p nabývají různých hodnot.

4.3. Motivace k dalším kapitolám

Uvažujme náhodný výběr $X_1, \dots, X_n$ s konečnou střední hodnotou μ a konečným rozptylem $\sigma^2 \in (0, \infty)$. (Uvědomte si, že tyto hodnoty jsou stejné pro všechny náhodné veličiny X_i , protože ty jsou stejně rozdělené). Na několika příkladech se podíváme na rozdělení výběrového průměru $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ pro zvyšující se rozsah výběru n .

Určit obecně rozdělení $\bar{X}_n$ není vůbec jednoduché. Postup je typicky takový, že musíme určit rozdělení veličiny $S_n = \sum_{i=1}^n X_i$ a z něj již snadnou transformací dostaneme rozdělení $\bar{X}_n$. Vše se tedy točí kolem určení rozdělení součtu n nezávislých a stejně rozdělených veličin. V kapitole 2.7. bylo popsáno, jak spočítat rozdělení součtu dvou veličin. Předpokládejme, že X_i mají spojitě rozdělení s hustotou f . Pak rozdělení $S_2 = X_1 + X_2$ je také spojitě s hustotou, kterou vypočteme jako

$$f_2(z) = \int_{-\infty}^{\infty} f(z-x)f(x)dx.$$

Dále pak rozdělení $S_3 = X_1 + X_2 + X_3 = S_2 + X_3$ bude mít rozdělení s hustotou

$$f_3(x) = \int_{-\infty}^{\infty} f_2(z-x)f(x)dx.$$

A takto bychom mohli postupně pokračovat až do n a získat tak hustotu f_n rozdělení S_n . Výpočet každého z integrálů je ale netriviální záležitost, takže celkový výpočet by byl dosti časově i výpočetně náročný (speciálně, uvažujeme-li n hodně vysoké). Pro diskrétní rozdělení je postup analogický, jen integrály nahradíme vhodnými součty, jak je popsáno v kapitole 2.7. Náročnost celkového výpočtu však

obecně zůstává stejná (výjimku tvoří příklady, kde rozdělení S_n určíme například z principu, nebo lze použít matematickou indukci). Rozdělení průměru $\bar{X}_n$ pak již snadno dopočítáme z rozdělení S_n tak, jak jsme to dělali pro transformaci náhodné veličiny (zde transformace $h(x) = x/n$). U spojitých rozdělení transformace vede k tomu, že $\bar{X}_n$ má rozdělení s hustotou $g_n(x) = n f_n(nx)$, viz opět kapitola 2.7. U diskrétních rozdělení platí $P(\bar{X}_n = k/n) = P(S_n = k)$.

Cvičení 4.17. Zkuste spočítat rozdělení S_n a $\bar{X}_n$ pro $n = 1, 2, 3, 4$ případ, kdy X_i odpovídají výsledkům hodů pravidelnou šestistěnnou kostkou. Pro $n = 1, 2$ je to snadné, pro vyšší n je již výpočet poměrně pracný. $\diamond$


Podíváme se na několik případů, kde je rozdělení S_n (a potažmo $\bar{X}_n$) možné spočítat „snadno“ a zkusíme učinit nějaké obecné závěry. Tyto závěry pak formálně zdůvodní následující kapitoly.

Alternativní rozdělení. Necht' X_i mají $\text{Alt}(p)$ rozdělení, $p \in (0, 1)$. Pak na X_i můžeme nahlížet jako na identifikátor úspěchu v jednom Bernoulliho pokusu a S_n je počet úspěchů v n nezávislých pokusech. Z principu tohoto problému (a také viz problém 4 ke kapitole 3) víme, že S_n má binomické rozdělení $\text{Bi}(n, p)$. Jak bylo uvedeno výše, rozdělení $\bar{X}_n$ získáme jednoduše tak, že celé rozdělení S_n přesuneme z hodnot $k \in \{0, \dots, n\}$ na hodnoty $k/n \in \{0, 1/n, \dots, 1\}$.

Na obrázku 4.2 je znázorněno toto rozdělení $\bar{X}_n$ pro $p = 1/3$ a několik voleb n . Můžeme vidět, že pro rostoucí n se rozdělení průměru „zahušťuje“ a je stále méně patrné, že se jedná o diskrétní rozdělení. Křivka, kterou bychom popsali tvar tohoto rozdělení, velmi připomíná Gaussovu křivku s vrcholem v bodě $1/3$. Připomeňme, že platí $E\bar{X}_n = EX_1 = p$ a $\text{var } \bar{X}_n = \text{var } X_1/n = p(1-p)/n$. Tedy střední hodnota je nezávisle na n rovna parametru p a rozptyl se s rostoucím n snižuje. To je v souladu s tím, že pozorujeme, že s rostoucím n je rozdělení více a více koncentrované kolem hodnoty $p = 1/3$.

Na chování $\bar{X}_n$ pro rostoucí n se podíváme ještě i z jiného pohledu. Pro konkrétní ω můžeme uvažovat posloupnost čísel $\{X_k(\omega)\}_{k=1}^\infty$, ze kterých můžeme postupně počítat průměr $\bar{X}_n(\omega)$ a vykreslit graf vývoje $\bar{X}_n(\omega)$ v závislosti na n . To jsme provedli pro několik různých ω a znázornili na obrázku 4.3, různá ω jsou rozlišena barevně. Je zřejmé, že trajektorie průměru se s rostoucím n „ustaluje“ kolem hodnoty $p = 1/3$, a to pro všechna ω . Jinými slovy obrázek naznačuje, že posloupnost $\{X_k(\omega)\}_{k=1}^\infty$ konverguje k $p = 1/3$ pro všechna uvažovaná ω .

Poissonovo rozdělení. Necht' X_i mají Poissonovo rozdělení s parametrem $\lambda > 0$. Pak s pomocí matematické indukce a výsledku cvičení 4.18 lze snadno vyvodit, že S_n má Poissonovo rozdělení $\text{Po}(n\lambda)$. Rozdělení $\bar{X}_n$ dostaneme opět posunutím rozdělení S_n z $k \in \mathbb{N}_0$ do k/n . Pro volbu $\lambda = 3$ je rozdělení $\bar{X}_n$ znázorněno na obrázku 4.4. Vidíme, že můžeme učinit analogické závěry jako u alternativního rozdělení s tím, že rozdělení průměru se nyní „zahušťuje“ kolem hodnoty $\lambda = 3$. Rozdělení pro vyšší n opět velmi připomíná Gaussovu křivku, tentokrát s vrcholem v bodě 3. Graf vývoje $\bar{X}_n(\omega)$ v závislosti na n je uveden na obrázku 4.3. Ten naznačuje, že pro všechna uvažovaná ω konverguje posloupnost $\{X_n(\omega)\}$ k hodnotě $\lambda = 3$. Připomeňme, že v Poissonově rozdělení platí $EX_i = \text{var } X_i = \lambda$.



Obrázek 4.2. Rozdělení $\bar{X}_n$ pro alternativní rozdělení s parametrem $p = 1/3$.

Cvičení 4.18. Ukažte, že jsou-li X a Y nezávislé a $X \sim \text{Po}(\lambda)$ a $Y \sim \text{Po}(\mu)$, pak $X + Y \sim \text{Po}(\lambda + \mu)$.


Uvědomte si, že

$$P[X + Y = k] = \sum_j P[X = j, Y = k - j] = \sum_{j=0}^k P[X = j]P[Y = k - j],$$

jelikož X, Y jsou nezávislé a mohou nabývat pouze nezáporných hodnot. Pak stačí jen dosadit a výraz upravit pomocí binomické věty. $\diamond$

Exponenciální rozdělení. Nyní uvažujme X_i se spojitým rozdělením, konkrétně nechť $X_i \sim \text{Exp}(\lambda)$, $\lambda > 0$. Pro tento případ je možné použít postup popsáný v úvodu této kapitoly a indukcí ukázat, že S_n má spojitě rozdělení s hustotou

$$f_n(x) = \frac{\lambda^n x^{n-1} e^{-\lambda x}}{(n-1)!}, \quad x \geq 0.$$



Obrázek 4.3. Graf vývoje $\bar{X}_n(\omega)$ v závislosti na n pro alternativní rozdělení s parametrem $p = 1/3$ (vlevo) a pro Poissonovo rozdělení s parametrem $\lambda = 3$ (vpravo) pro různá ω (barevně odlišeno).


Průměr $\bar{X}_n$ pak má hustotu tvaru $g_n(x) = n f_n(xn)$, která je znázorněna na obrázku 4.5. Pro zvyšující se n se hustota se přibližuje symetrické křivce, která opět vypadá jako Gaussova křivka. Pro porovnání je proto do obrázků červeně přidána hustota normálního rozdělení $N(1/\lambda, 1/(n\lambda^2))$. Proč volíme právě normální rozdělení s těmito parametry? Normální rozdělení volíme právě proto, že jeho hustota má tvar Gaussovy křivky. Volba parametrů tohoto rozdělení odpovídá tomu, aby toto rozdělení mělo stejnou střední hodnotu i rozptyl jako $\bar{X}_n$. Připomeňme, že v tomto případě totiž platí $E X_i = \frac{1}{\lambda}$ a $\text{var } X_i = \frac{1}{\lambda^2}$ a tedy $E \bar{X}_n = \frac{1}{\lambda}$ a $\text{var } \bar{X}_n = \frac{1}{n\lambda^2}$. Již pro $n = 50$ jsou obě křivky téměř nerozlišitelné.

Cvičení 4.19. Dokažte pomocí matematické indukce, že pro náhodný výběr z exponenciálního rozdělení $\text{Exp}(\lambda)$ má S_n výše uvedenou hustotu f_n . $\diamond$

Shrnutí. Na základě předchozích pozorování můžeme učinit následující domněnky:

- (1) Zdá se, že výběrový průměr konverguje (v nějakém smyslu) ke střední hodnotě $E X_i$.
- (2) Pro velké n je možné rozdělení průměru „aproximovat“ pomocí normálního rozdělení se vhodně zvolenými parametry, a to nezávisle na tom, z jakého rozdělení pochází původní náhodný výběr.


Abychom mohli zformalizovat domněnku (1), musíme nejprve definovat, co myslíme pod pojmem konvergence náhodných veličin (uvědomte si, že se jedná o funkce na abstraktním prostoru Ω). To provedeme v kapitole 5, kde navíc ukážeme, za jakých předpokladů takové tvrzení opravdu platí. Dále v této kapitole přesně matematicky zformulujeme předpoklady a tvrzení (2). Výsledek (1) pak budeme intenzivně využívat v kapitole 6, kde formálně zavedeme pojem *odhad*. Skutečnost (2) uplatníme při praktických úlohách a při konstrukci tzv. intervalových odhadů a v rámci výkladu základů statistického uvažování.



Obrázek 4.4. Rozdělení $\bar{X}_n$ pro Poissonovo rozdělení s parametrem $\lambda = 3$.

Problémy k dalšímu procvičení

- Nechť $X_1, \dots, X_n$ je náhodný výběr s distribuční funkcí F a hustotou f . Označme $U = \max_{1 \leq i \leq n} X_i$ a $V = \min_{1 \leq i \leq n} X_i$.
 - Spočtěte distribuční funkci a hustotu veličiny U .
 - Spočtěte distribuční funkci a hustotu veličiny V .
 - Nechť F a f odpovídají rovnoměrnému rozdělení na intervalu $[0, 1]$. Spočtěte v tomto případě $E U$, $\text{var}(U)$, $E V$ a $\text{var}(V)$.
- Nechť $X_1, \dots, X_n$ je náhodný výběr a g je reálná (měřitelná) funkce. Uvědomte si, že pak $g(X_1), \dots, g(X_n)$ je opět náhodný výběr, ale z jiného rozdělení.



Obrázek 4.5. Rozdělení $\bar{X}_n$ pro exponenciální rozdělení s parametrem $\lambda = 5$. Červená křivka odpovídá normálnímu rozdělení $N(1/\lambda, 1/(n\lambda^2))$.

Konvergence náhodných veličin a základní limitní věty

V této kapitole si představíme různé typy konvergence náhodné veličiny. My budeme používat zejména dva, konvergenci *v pravděpodobnosti* a konvergenci *v distribuci*.

Představíme si základní nerovnosti pro náhodné veličiny a jejich použití. Dále se budeme zabývat limitními větami pro náhodné veličiny. Důraz bude kladený na *zákon velkých čísel* a na *centrální limitní větu* a jejich dobré pochopení. V následujících kapitolách se budeme věnovat použití limitních vět pro základní statistické úlohy, proto jim věnujme patřičnou pozornost.

5.1. Konvergence náhodných veličin

Náhodná veličina je definována jako zobrazení $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B})$. Z této definice musíme vycházet při definici konvergence posloupnosti náhodných veličin.

Na prostoru Ω máme pravděpodobnost P , na prostoru $\mathbb{R}$ můžeme uvažovat pravděpodobnost P_X , rozdělení náhodné veličiny X . Pokud však chceme dobře definovat konvergenci náhodných veličin, bez společného pravděpodobnostního prostoru a pravděpodobnosti P se neobejdeme.

Definice 5.1 (Konvergence v pravděpodobnosti). Bud' X náhodná veličina a $X_1, X_2, \dots$ posloupnost náhodných veličin definovaných na *stejném* pravděpodobnostním prostoru. Řekneme, že X_n *konverguje v pravděpodobnosti* k X , pokud

$$P[|X_n - X| > \varepsilon] \xrightarrow{n \rightarrow \infty} 0 \quad \forall \varepsilon > 0.$$

Tuto konvergenci značíme $X_n \xrightarrow{P} X$.

Bez toho, že všechny náhodné veličiny v definici 5.1 jsou definovány na stejném pravděpodobnostním prostoru nelze konvergenci v pravděpodobnosti definovat¹.

Posloupnost náhodných vektorů konverguje v pravděpodobnosti, pokud konvergují v pravděpodobnosti všechny složky těchto vektorů. Ekvivalentně lze zavést konvergenci v pravděpodobnosti pro náhodné vektory tak, že náhodné veličiny $\|X_n - X\|$ konvergují v pravděpodobnosti k nule, kde $\|\cdot\|$ značí normu² vektoru.

Zapíšeme-li předchozí konvergenci s využitím *zamlčených* proměnných ω , dostaneme

$$P\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\} \xrightarrow{n \rightarrow \infty} 0.$$

To znamená, že se zvětšujícím se n se „zmenšuje“ (alespoň v pravděpodobnostním smyslu) množina těch elementárních jevů, pro něž se X_n a X liší o více než „zanedbatelnou“ hodnotu. Uvědomme si však, že množina $\Omega_{n,\varepsilon} := \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}$ závisí na n a obecně tyto množiny netvoří monotónní do sebe vnořenou posloupnost. Může se dokonce stát, že $X_n \xrightarrow{P} X$ a přesto $X_n(\omega) \not\rightarrow X(\omega)$ pro $\omega \in N$, kde $P(N) = 1$.

Cvičení 5.2. Zkuste najít příklad posloupnosti náhodných veličin $X_n \xrightarrow{P} 0$ takový, aby pro všechna ω platilo $X_n(\omega) \not\rightarrow 0$.

Stačí uvažovat $\Omega = [0, 1]$ a indikátory vhodných podmnožin $[0, 1]$ jako X_n . Pro každé $\varepsilon > 0$ tedy musí platit současně

$$P[|X_n| \geq \varepsilon] \xrightarrow{n \rightarrow \infty} 0, \quad \text{a zároveň} \quad \forall \omega \forall n \exists m \geq n \text{ tak, že } |X_m(\omega)| > \varepsilon.$$

◊

Poznámka 5.3. Z definice konvergence v pravděpodobnosti je zřejmé, že se nemusíme omezovat na náhodné veličiny. Stejným způsobem můžeme zavést konvergenci v pravděpodobnosti pro náhodné „veličiny“ s hodnotami v metrickém prostoru, kde metrikou nahradíme absolutní hodnotu. Jednoduchým příkladem jsou náhodné vektory, pro které vzdálenost můžeme měřit například standardní Eukleidovou metrikou.

Dalším typem konvergence náhodných veličin je konvergence v distribuci. Ta je naopak poměrně slabou verzí konvergence, jde „jen“ o rozdělení náhodných veličin, nikoliv o jejich konkrétní hodnoty.

Definice 5.4 (Konvergence v distribuci). Buďte X náhodná veličina a $X_1, X_2, \dots$ posloupnost náhodných veličin³. Řekneme, že X_n *konverguje v distribuci* (v rozdělení) k X , pokud $Eg(X_n) \rightarrow Eg(X)$ pro každou omezenou spojitou funkci g .

Tuto konvergenci značíme $X_n \xrightarrow{d} X$.

¹Jste-li seznámeni s konvergencí měřitelných funkcí, vidíte, že jde o konvergenci v míře P .

²Pro d -rozměrné vektory obvykle používáme Eukleidovu vzdálenost.

³Na rozdíl od konvergence v pravděpodobnosti není třeba, aby uvedené náhodné veličiny byly definované na stejném pravděpodobnostním prostoru. Zde jde jen o technický detail, ale v pokročilých partiích pravděpodobnosti jej lze vhodně využít.

Pro konvergenci náhodných veličin v distribuci platí ekvivalence $X_n \xrightarrow{d} X$ tehdy a jen tehdy, když pro posloupnost F_{X_n} distribučních funkcí platí

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x) \text{ pro všechna } x, \text{ v nichž } F_X \text{ je spojitá.}$$

Jinými slovy, pokud x je bodem spojitosti F_X , pak platí

$$X_n \xrightarrow{d} X \Leftrightarrow P[X_n \leq x] \rightarrow P[X \leq x].$$

I konvergence v distribuci může být definována pro obecné náhodné veličiny s hodnotami v metrickém prostoru. Může být definována tehdy, jsme-li schopni definovat reálné spojitě funkce na prostoru hodnot náhodných veličin.

Konvergence v distribuci neříká *vůbec nic* o případné konvergenci posloupnosti náhodných veličin $|X_n - X|$ k nule. Jediné, co z konvergence v distribuci plyne je skutečnost, že pravděpodobnostní chování náhodných veličin X_n se blíží chování náhodné veličiny X . Toho využijeme při použití centrální limitní věty na náhodné výběry. Jedno z použití je odhalení chybného modelu rozdělení náhodných veličin. Pokud máme v modelu dobře popsané a známé limitní rozdělení F_X a rozdělení F_{X_n} založená na náhodném výběru vykazují velké odchylky, je přirozené vznést pochyby o modelu. To je velmi zhruba základní myšlenkou statistického testování⁴

5.2. Vztahy mezi konvergencemi

Věta 5.5 (O vztahu konverencí). *Bud' te $X_1, X_2, \dots$ a X náhodné veličiny definované na stejném pravděpodobnostním prostoru. Pak*

$$X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{d} X.$$

Pokud $X_n \xrightarrow{d} c$, kde c je konstanta, pak také $X_n \xrightarrow{P} c$.

Důkaz. Nechť $X_n \xrightarrow{P} X$ a nechť a je bod spojitosti F_X . Pro každé $\varepsilon > 0$ platí

$$F_{X_n}(a) = P[X_n \leq a] = P[X_n \leq a, |X_n - X| \leq \varepsilon] + P[X_n \leq a, |X_n - X| > \varepsilon].$$

Druhý člen posledního součtu jde limitně k nule při $n \rightarrow \infty$. Dále platí

$$P[X_n \leq a, |X_n - X| \leq \varepsilon] = P[X_n \leq a, X \leq a + \varepsilon, |X_n - X| \leq \varepsilon] \leq P[X \leq a + \varepsilon].$$

První rovnost je důsledkem faktu $X_n(\omega) \leq a, |X_n(\omega) - X(\omega)| \leq \varepsilon \Rightarrow X(\omega) \leq a + \varepsilon$ a z toho plynoucí inkluze $[X_n \leq a, |X_n - X| \leq \varepsilon] \subset [X \leq a + \varepsilon]$. Druhá nerovnost je zřejmá z vlastností pravděpodobnosti.

Na druhou stranu můžeme s podobnými argumenty napsat

$$\begin{aligned} P[X_n \leq a] &\geq P[X_n \leq a, X \leq a - \varepsilon, |X_n - X| \leq \varepsilon] = P[X \leq a - \varepsilon, |X_n - X| \leq \varepsilon] \\ &= P[X \leq a - \varepsilon] - P[X \leq a - \varepsilon, |X_n - X| > \varepsilon]. \end{aligned}$$

⁴Viz také klasické dílo Karla R. Poppera Logika vědeckého bádání, OIKOYMENH 1997, v níž se autor zabývá tvorbou a testováním vědeckých hypotéz. Principům statistického testování se stručně budeme věnovat v dalších kapitolách. Podstatnou otázkou je, co znamená, že chování náhodného výběru vyazuje „velké“ odchylky od modelového.

Poslední člen jde opět k nule při $n \rightarrow \infty$. Celkem jsme tak pro libovolné $\varepsilon > 0$ a n dostatečně velké s ohledem na ε dostali nerovnosti

$$F_X(a - \varepsilon) - \varepsilon \leq F_{X_n}(a) \leq F_X(a + \varepsilon) + \varepsilon.$$

S ohledem na spojitost F_X v bodě a je první část důkazu hotová.

Každá konstanta c je degenerovanou náhodnou veličinou, jejíž distribuční funkce má jediný skok o velikosti 1 a to v bodě c . Proto pokud $X_n \xrightarrow{d} c$, platí $F_{X_n}(x) \rightarrow \chi(c \leq x)$ pro každé $x \neq c$. Pro každé $\varepsilon > 0$ a $\eta > 0$ existuje $n(\eta, \varepsilon)$ tak, že pro všechna $n \geq n(\eta, \varepsilon)$ je

$$F_{X_n}(c - \varepsilon) \leq \eta/2, F_{X_n}(c + \varepsilon) \geq 1 - \eta/2.$$

Pro pevné $\varepsilon > 0$ volme libovolně malé $\eta > 0$. Pro $n \geq n(\eta, \varepsilon)$ dostaneme $P[|X_n - c| \leq \varepsilon] \geq 1 - \eta$ a druhá část tvrzení je tím dokázána. $\square$

Konvergence zůstanou zachovány, pokud náhodné veličiny projdou spojitou transformací⁵.

Věta 5.6 (O spojitém zobrazení). *Předpokládejme, že $X_n \xrightarrow{P} X$ a g je spojitě zobrazení. Pak $g(X_n) \xrightarrow{P} g(X)$.*

Pokud $X_n \xrightarrow{d} X$ a g je spojitě zobrazení, pak $g(X_n) \xrightarrow{d} g(X)$.

Důkaz. Zvolme pevně $\varepsilon > 0$ a $\delta > 0$. Označme $N_\delta = \{x; \exists y \in \mathbb{R}, |x - y| < \delta, |g(x) - g(y)| > \varepsilon\}$. Jde tedy o body x , v jejichž δ okolí se nachází takový bod y , že vzdálenost obrazů $g(x)$ a $g(y)$ je větší než dané ε . Pokud je $\varepsilon > 0$ konstantní, tak $N_\delta \searrow \emptyset$, což plyne ze spojitosti zobrazení g .

Pro konvergenci v pravděpodobnosti začneme s pozorováním

$$P[|g(X_n) - g(X)| > \varepsilon] \leq P[X \in N_\delta] + P[|X_n - X| > \delta]$$

Platí totiž $[X \notin N_\delta] \cap [|X_n - X| \leq \delta] \subset [|g(X_n) - g(X)| \leq \varepsilon]$ ⁶. Pro doplňky proto platí $[|g(X_n) - g(X)| > \varepsilon] \subset [X \in N_\delta] \cup [|X_n - X| > \delta]$ a zbytek je použití subaditivity pravděpodobnosti.

Volme $\eta > 0$ libovolně malé. Pak ze spojitosti P platí, že existuje δ malé natolik, že $P[X \in N_\delta] < \eta/2$ a dále existuje takové $n(\eta, \delta)$, že pro $n \geq n(\eta, \delta)$ je $P[|X_n - X| > \delta] < \eta/2$. Celkově jsme pro každé $\varepsilon > 0$ a $\eta > 0$ dostali

$$P[|g(X_n) - g(X)| > \varepsilon] \leq P[X \in N_\delta] + P[|X_n - X| > \delta] \leq \eta$$

pro každé n dostatečně velké. Tím je důkaz první části hotový.

⁵U obou variant konvergence může být požadavek spojitosti transformace g oslaben na spojitost na množině $S \subset \mathbb{R}$ takové, že $P[X \in S] = 1$. Důkaz vyžaduje trochu víc práce. U konvergence v pravděpodobnosti by úpravu mohl zvládnout čtenář sám, u konvergence v distribuci je nejjednodušší využít Portmanteauovu větu a z ní plynoucí ekvivalentní definici konvergence v distribuci. Jakkoliv ustálený, je název Portmanteau theorem zřejmě hříčkou vymyšlenou Patrickem Billingsleyem pro jeho slavnou knihu. Slovo portmanteau ve francouzštině znamená věšák na oblečení, v angličtině pak výraz *portmanteau word* poprvé použil Lewis Carroll v „Alence za zrcadlem“ k označení slovního novotvaru vzniklého z částí jiných slov—např. *moped* = *motorka* s *pedály*. Oba významy danou větu vystihují. Obsahuje tvrzení která bychom měli mít s *sebou po ruce* při práci s konvergencí v distribuci a zároveň jde o spojení různých variant tvrzení do jedné věty.

⁶Pokud se vám tyto zápisy zdají složité, rozepište si je s pomocí proměnné ω : $[X \notin N_\delta] = \{\omega : X(\omega) \notin N_\delta\}$, neboli v δ okolí bodu $X(\omega)$ jsou funkční hodnoty g v ε okolí hodnoty $g(X(\omega))$.

Pokud $X_n \xrightarrow{d} X$, pak pro každé spojitě omezené zobrazení h platí $E h(X_n) \rightarrow E h(X)$. Složené zobrazení hg je spojitě a omezené⁷ a proto $E h(g(X_n)) \rightarrow E h(g(X))$, což dokazuje druhou část věty. $\square$

Předchozí věta se velmi často používá v případě $X_n \xrightarrow{P} c$, kde c je konstanta. Pak samozřejmě stačí spojitost zobrazení g v bodě c .

Konvergenzi v pravděpodobnosti a v distribuci lze kombinovat.

Věta 5.7 (Sluckého věta). *Nechť $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{P} y$ a $Z_n \xrightarrow{P} z$, kde y, z jsou reálné konstanty. Pak $X_n + Y_n \xrightarrow{d} X + y$ a $X_n Z_n \xrightarrow{d} Xz$.*

Důkaz. Důkaz si ukážeme pro součet, pro součin je analogický. Použijeme již známý rozpis pro pevné a takové, že F_{X+y} je spojitě v a (nebo ekvivalentně F_X je spojitě v $a - y$).

Zvolme $\eta > 0$. Pak existuje $\varepsilon_0 > 0$ takové, že $|F_X(a-y) - F_X(a-y-\varepsilon)| < \eta/3$ pro všechna $|\varepsilon| < \varepsilon_0$. Protože bodů nespojitosti funkce F_X je nejvýše spočetně mnoho⁸, tak v každém okolí bodu $a - y$ najdeme vlevo i vpravo od $a - y$ bod spojitosti F_X . Zvolme tedy $0 < \varepsilon \leq \varepsilon_0$ tak, že F_X je spojitá v $a - y - \varepsilon$ i v $a - y + \varepsilon$. Použitím rozkladu a odhadů podobně jako v důkazu věty 5.6 dostaneme

$$\begin{aligned} P[X_n + Y_n \leq a] &= P[X_n + Y_n \leq a, |Y_n - y| \leq \varepsilon] + P[X_n + Y_n \leq a, |Y_n - y| > \varepsilon] \\ &\leq P[X_n + y \leq a + \varepsilon, |Y_n - y| \leq \varepsilon] + P[|Y_n - y| > \varepsilon] \\ &\leq P[X_n \leq a - y + \varepsilon] + P[|Y_n - y| > \varepsilon]. \end{aligned}$$

Protože F_X je spojitá v $a - y + \varepsilon$ a $Y_n \xrightarrow{P} y$, existuje n_1 takové, že pro všechna $n \geq n_1$ platí současně $P[X_n \leq a - y + \varepsilon] \leq P[X \leq a - y + \varepsilon] + \eta/3$ a $P[|Y_n - y| > \varepsilon] \leq \eta/3$. Dohromady pro $n \geq n_1$ dostáváme

$$P[X_n + Y_n \leq a] \leq P[X \leq a - y + \varepsilon] + 2\eta/3 \leq P[X + y \leq a] + \eta.$$

Opačnou nerovnost dokážeme podobně. Nejprve si uvědomíme platnost nerovnosti

$$\begin{aligned} P[X_n + y \leq a - \varepsilon] &= P[X_n + y \leq a - \varepsilon, |Y_n - y| \leq \varepsilon] + P[X_n + y \leq a - \varepsilon, |Y_n - y| > \varepsilon] \\ &\leq P[X_n + Y_n \leq a] + P[|Y_n - y| > \varepsilon]. \end{aligned}$$

Díky předpokladům věty a volbě ε najdeme n_2 takové, že pro všechna $n \geq n_2$ platí zároveň $P[X_n + y \leq a - \varepsilon] \geq P[X + y \leq a - \varepsilon] - \eta/3$ a $P[|Y_n - y| > \varepsilon] \leq \eta/3$. Pro $n \geq n_2$ tedy platí

$$\begin{aligned} P[X + y \leq a] &\leq P[X + y \leq a - \varepsilon] + \eta/3 \leq P[X_n + y \leq a - \varepsilon] + 2\eta/3 \\ &\leq P[X_n + Y_n \leq a] + P[|Y_n - y| > \varepsilon] + 2\eta/3 \leq P[X_n + Y_n \leq a] + \eta. \end{aligned}$$

Pro $n \geq \max\{n_1, n_2\}$ dohromady dostáváme

$$P[X + y \leq a] - \eta \leq P[X_n + Y_n \leq a] \leq P[X + y \leq a] + \eta,$$

a protože $\eta > 0$ můžeme zvolit libovolně malé, je věta dokázána. $\square$

⁷Složení bereme ve smyslu $hg(x) = h(g(x))$, tedy zobrazení h použité na výsledek zobrazení g .

⁸Toto plyne z vlastností distribuční funkce: F_X je zprava spojitá, neklesající, a omezená

Okamžitým důsledkem předchozí věty je následující tvrzení.

Důsledek 5.8. *Nechť $X_n \xrightarrow{P} x$, $Y_n \xrightarrow{P} y$, kde x, y jsou reálné konstanty. Potom $X_n + Y_n \xrightarrow{P} x + y$ a $X_n \cdot Y_n \xrightarrow{P} xy$*

Důkaz. Podle první části Věty 5.5 konvergence $X_n \xrightarrow{P} x$ implikuje $X_n \xrightarrow{d} x$. Pak z Věty 5.7 plyne, že $X_n + Y_n \xrightarrow{d} x + y$. Podle druhé části věty 5.5 ale toto znamená, že $X_n + Y_n \xrightarrow{P} x + y$. Důkaz pro $X_n \cdot Y_n$ je analogický. $\square$

Zde jsme si ukázali klasické přímé důkazy. Pro snazší důkaz tvrzení uvedené ve větě je možné použít větu o spojitém zobrazení, pokud předtím dokážeme, že předpoklady $X_n \xrightarrow{d} X$ a $Y_n \xrightarrow{P} y$ dohromady implikují⁹ konvergenci $(X_n, Y_n)^\top \xrightarrow{d} (X, y)^\top$.

5.3. Nerovnosti Markovova typu

Jedna z nejznámějších a často používaných nerovností v pravděpodobnosti je slavná Čebyševova nerovnost. Tato nerovnost, která propojuje střední hodnotu a rozptyl náhodné veličiny, je speciální verzí Markovovy nerovnosti, již proto začneme.

Věta 5.9 (Markovova nerovnost). *Bud' X nezáporná náhodná veličina. Potom pro každé $\varepsilon > 0$ platí*

$$P[X \geq \varepsilon] \leq \frac{EX}{\varepsilon}.$$

Důkaz. Z předpokladů plyne $P[X \geq 0] = 1$, neboli $\int_{[X < 0]} dP(\omega) = 0$. Proto pro každé $\varepsilon > 0$ dostaneme

$$P[X \geq \varepsilon] = \int_{[X \geq \varepsilon]} dP(\omega) \leq \int_{[X \geq \varepsilon]} \frac{X}{\varepsilon} dP(\omega) \leq \int_{[X \geq 0]} \frac{X}{\varepsilon} dP(\omega) = \frac{1}{\varepsilon} \int_{\Omega} X dP(\omega) = \frac{EX}{\varepsilon}.$$

$\square$

Povšimněte si, jak jednoduché a poměrně hrubé odhady jsme v obou nerovnostech provedli. Pro první nerovnost jsme konstantu 1 nahradili náhodnou veličinou X/ε , která je pro $\omega \in [X \geq \varepsilon]$ větší či rovna jedné. Stejně tak bychom mohli použít jakoukoliv kladnou mocninu podílu X/ε , čímž se dostaneme k druhé variantě Markovovy nerovnosti.

Věta 5.10. *Bud' X nezáporná náhodná veličina. Potom pro každé $\varepsilon > 0$ a $r > 0$ platí*

$$P[X \geq \varepsilon] \leq \frac{EX^r}{\varepsilon^r}$$

Důkaz je jednoduchou obměnou důkazu věty 5.9. Vzhledem k nezápornosti náhodné veličiny X máme zaručenu existenci všech momentů EX^r , jejich konečnost samozřejmě zaručenu nemáme, pro nekonečné momenty tak dostaneme nezajímavý výsledek. Pro zajímavý výsledek můžeme hledat minimalizovat pravou

⁹Tomuto tvrzení se také říká Sluckého věta. Někdy se můžeme setkat i s názvem Cramérova-Sluckého věta pro toto a podobná tvrzení o kombinaci konvergencí.

stranu nerovnosti přes nezáporná r abychom získali co nejnížší horní mez pro pravděpodobnost jevu $[X \geq \varepsilon]$.

Markovovu nerovnost často používáme pro nezáporné náhodné veličiny $|X|$ a $|X - EX|$. Druhý případ je znám jako Čebyševova nerovnost. Pro její význam ji zformulujeme jako větu.

Věta 5.11 (Čebyševova nerovnost). *Bud' X náhodná veličina s konečnou střední hodnotou EX . Potom pro každé $\varepsilon > 0$ platí*

$$P[|X - EX| \geq \varepsilon] \leq \frac{\text{var } X}{\varepsilon^2}.$$

Důkaz. Použijte Markovovu nerovnost z věty 5.10 pro $r = 2$ a nezápornou náhodnou veličinu $|X - EX|$. $\square$

Cvičení 5.12. Bud' S_n náhodná veličina označující počet šestek v n hodech kostkou. Předpokládejme, že pro pravděpodobnost p šestky platí $p = 1/6$. Použijte Čebyševovu nerovnost k určení horní meze pro $P[|S_{120} - 20| \geq 5]$ a $P[|S_{120} - 20| \geq 10]$.

Příklad můžeme řešit současně. Za předpokladu $p = 1/6$ víme $ES_{120} = 20$ a $\text{var } S_{120} = 50/3$. Z Čebyševovy nerovnosti plyne $P[|S_{120} - 20| \geq k] \leq 50/(3k^2)$. Pro $k = 5$ tak dostáváme $2/3$, pro $k = 10$ je horní mez $1/6$ (nepřekvapivě čtyřikrát menší). $\diamond$

Další speciální verzi věty 5.10 je Chernoffova věta poskytující dvě pravděpodobnostní nerovnosti.

Věta 5.13 (Chernoffovy meze). *Bud' X náhodná veličina a $\psi_X(t) = Ee^{tX}$ její momentová vytvořující funkce. Pak pro každé a platí*

$$P[X \geq a] \leq \inf_{t>0} \frac{\psi_X(t)}{e^{ta}}, \quad P[X \leq a] \leq \inf_{t<0} \frac{\psi_X(t)}{e^{ta}}.$$

Důkaz. První mez plyne z $P[X \geq a] = P[e^{tX} \geq e^{ta}]$ pro $t > 0$. Dostali jsme nezáporné náhodné veličiny e^{tX} , pro něž využijeme Markovovu nerovnost. Pro každé $t > 0$ platí $P[X \geq a] = P[e^{tX} \geq e^{ta}] \leq \frac{Ee^{tx}}{e^{ta}}$. Nyní stačí vzít infimum pravých stran přes všechna $t > 0$.

Druhá mez je dokázána analogicky. $P[X \leq a] = P[e^{tX} \geq e^{ta}] \leq \frac{Ee^{tx}}{e^{ta}}$ pro $t < 0$. $\square$

Cvičení 5.14. Navažme na příklad 5.12. Náhodná veličina S_{120} má momentovou vytvořující funkci

$$\psi(t) = (1 - p + pe^t)^{120}.$$

Chceme zjistit, jaká je pravděpodobnost $P[S_{120} \geq 25]$. K tomuto účelu minimalizujeme přes kladná t výraz $(1 - p + pe^t)^{120} e^{-25t}$ a dostaneme minimum pro $t = \log(25/19) \doteq 0,274$. Podobně můžeme spočítat odhad pro pravděpodobnost $P[S_{120} \leq 15]$ minimalizací výrazu $(1 - p + pe^t)^{120} e^{-15t}$. Ten je minimální pro $t = \log(5/7) \doteq -0,336$.

(Raději ověřte, zda je výpočet správný.) $\diamond$

Cvičení 5.15. Bud' X náhodná veličina s exponenciálním rozdělením s parametrem $\lambda = 1$. Určete pro $a > 0$ přesnou pravděpodobnost $P[X \geq a]$ a porovnejte s odhady získanými pomocí Markovových a Chernoffových nerovností.

Náhodná veličina X je nezáporná a hustota jejího rozdělení je $f(x) = e^{-x}$ pro $x > 0$. Snadno proto spočítáme

$$P[X \geq a] = \int_a^{\infty} e^{-x} dx = e^{-a}.$$

Momenty náhodné veličiny odpovídají funkci gamma

$$E X^r = \int_0^{\infty} x^r e^{-x} dx = \Gamma(r+1),$$

kde $\Gamma(r+1) = r!$ pro $r \in \mathbb{N}$. Omezíme-li se pouze na celočíselné momenty, dostaneme odhady

$$P[X \geq a] \leq \frac{r!}{a^r}, \quad r \in \mathbb{N}.$$

Pro $r = 0$ dostáváme triviální horní mez 1, pro $r = 1$ mez $1/a$ a tak dále, pro $a > 1$ od určitého r tato mez začne růst díky faktoriálu v čitateli. Markovova nerovnost pro obecné r je

$$P[X \geq a] \leq \int_a^{\infty} \left(\frac{x}{a}\right)^r e^{-x} dx = \int_a^{\infty} \exp\left\{r \log\left(\frac{x}{a}\right) - x\right\} dx,$$

což je spojitá funkce r a pro dané a můžeme hledat (numericky) její minimum.

Momentová vytvořující funkce exponenciálního rozdělení je

$$\psi_X(t) = \int_0^{\infty} e^{tx} e^{-x} dx = \int_0^{\infty} e^{-x(1-t)} dx = \frac{1}{1-t}, \quad t < 1,$$

pro $t \geq 1$ je nekonečná. Chernoffovu horní mez najdeme minimalizací pravé strany nerovnosti

$$P[X \geq a] \leq \frac{1}{(1-t)e^{ta}}$$

na množině $t \in (0, 1)$. Protože na dané množině jde pro každé $a > 0$ o diferencovatelnou funkci, najdeme s pomocí derivace minimum v bodě $t = 1 - 1/a$, takže minimum se nachází v intervalu $(0, 1)$ jen pro $a > 1$ a výsledná mez je $P[X \geq a] \leq ae^{-a+1}$, což je ae krát vyšší než přesná hodnota. Může se to zdát hodně, ale uvědomme si, že nerovnosti Markovova typu jsou jen hrubé odhady, takže zdaleka nejsou optimální. Čebyševova nerovnost či základní Markovovy nerovnosti jsou navíc stejné pro všechna rozdělení se stejnými příslušnými momenty, nezávisí proto na konkrétním rozdělení. Uvědomte si, že pro *všechna* rozdělení s nulovou střední hodnotou a rozptylem σ^2 dostaneme z Čebyševovy nerovnosti horní mez $P[|X| \geq a] \leq (\sigma/a)^2$. $\diamond$

*5.4. Borelův a Cantelliův 0-1 zákon

Házeme-li hrací kostkou, pak nám intuice (správně) říká, že počet šestek bude růst nade všechny meze, pokud budeme házet dál a dál. V některých případech si ale nemůžeme být jisti. Představme si, že začneme s jednou hrací kostkou a budeme s ní házet. Poté, co padne šestka přidáme jednu kostku a budeme házet dál. Vždy,

když padnou na všech kostkách šestky, přidáme další kostku a házeme dál. Pokud bychom mohli provést nekonečně mnoho hodů a měli k dispozici nekonečně mnoho kostek, je nevyhnutelné, aby nekonečněkrát na všech kostkách padly samé šestky?

Tato otázka je již mnohem složitější a naše zkušenost a představivost úplně nestačí k tomu, abychom na ni našli odpověď. Na některé podobné problémy můžeme použít takzvané 0-1 zákony, které říkají, že existují limitní náhodné jevy s pravděpodobností nabývající pouze hodnotu 0, nebo 1, žádnou jinou. My si ukážeme pouze základní 0-1 zákon; jde o známé a často používané Borelovo-Cantelliovo lemma.

Nejprve si připomeňme dva pojmy.

Definice 5.16 (Množinové $\limsup$ a $\liminf$). Bud'te $A_n, n = 1, 2, \dots$ množiny. Definujme

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} A_i, \quad \liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{i=n}^{\infty} A_i.$$

Jinými slovy, jestliže $a \in \limsup_{n \rightarrow \infty} A_n$, potom existuje *nekonečně* mnoho množin A_i , pro které $a \in A_i$. Jestliže $b \in \liminf_{n \rightarrow \infty} A_n$, potom existuje nejvýše *konečně* mnoho množin A_i , pro něž $b \notin A_i$, neboli $b \in A_i$ pro všechna i až na konečně mnoho výjimek.

Cvičení 5.17. Ověřte:

- (1) $\limsup_{n \rightarrow \infty} A_n = (\liminf_{n \rightarrow \infty} A_n^C)^C.$
- (2) $\liminf_{n \rightarrow \infty} A_n \subset \limsup_{n \rightarrow \infty} A_n.$

◊

Pokud za množiny dosadíme náhodné jevy, pak $\limsup_{n \rightarrow \infty} A_n$ a $\liminf_{n \rightarrow \infty} A_n$ jsou opět náhodné jevy. Máme-li posloupnost pokusů, kde v i -tém pokusu buď nastane, nebo nenastane jev A_i , pak $\limsup_{n \rightarrow \infty} A_n$ odpovídá elementárním jevům (experimentům), pro které nastanou jevy A_i pro *nekonečně mnoho* indexů. Příkladem může být nekonečná posloupnost házení jednou hrací kostkou a jevem A_n je jev *v n -tém hodu padla jednička*. Každý experiment, který skončí nekonečně mnoha jedničkami patří do $\limsup A_n$. Intuitivně cítíme, že pokud každý jev A_n má (stejnou) kladnou pravděpodobnost, pak v nekonečně pokusech by mělo nastat nekonečně mnoho jevů A_n .

Náhodný jev $\liminf_{n \rightarrow \infty} A_n$ obsahuje ty elementární jevy, pro které nastanou *všechny* jevy A_i s výjimkou *konečně mnoha* indexů. Zde se vhodný a přirozený příklad hledá hůře. Podvědomě víme, že pravděpodobnost doplňku A_n^C musí konvergovat k nule, ale není na první pohled jasné *jak rychle*. Odpověď dává následující tvrzení.

Věta 5.18 (Borelův-Cantelliův 0-1 zákon). *Předpokládejme, že máme nekonečný soubor náhodných jevů $A_1, A_2, \dots$*

- (1) *Vždy platí implikace*

$$\sum_{i=1}^{\infty} P(A_i) < \infty \Rightarrow P\left(\limsup_{n \rightarrow \infty} A_n\right) = 0.$$

(2) Jsou-li navíc $A_n, n = 1, 2, \dots$ nezávislé, pak

$$\sum_{i=1}^{\infty} P(A_i) = \infty \Rightarrow P\left(\limsup_{n \rightarrow \infty} A_n\right) = 1.$$

Důkaz. První část se někdy říká Cantelliova a dokáže se snadno.

$$P\left(\limsup_{n \rightarrow \infty} A_n\right) = P\left(\bigcap_{n=1}^{\infty} \bigcup_{i=n}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} P\left(\bigcup_{i=n}^{\infty} A_i\right) \leq \lim_{n \rightarrow \infty} \sum_{i=n}^{\infty} P(A_i) = 0.$$

Druhá rovnost plyne ze spojitosti pravděpodobnosti. Protože pravděpodobnost je subaditivní, dostáváme nerovnost a poslední rovnost plyne ze sčitatelnosti řady $\sum_i P(A_i)$.

Předpokládejme, že náhodné jevy A_i jsou nezávislé. Ze cvičení 5.17 plyne

$$1 - P\left(\limsup_{n \rightarrow \infty} A_n\right) = P\left(\liminf_{n \rightarrow \infty} A_n^C\right) = P\left(\bigcup_{n=1}^{\infty} \bigcap_{i=n}^{\infty} A_i^C\right) = \lim_{n \rightarrow \infty} P\left(\bigcap_{i=n}^{\infty} A_i^C\right).$$

Díky nezávislosti náhodných jevů A_i platí

$$P\left(\bigcap_{i=n}^{\infty} A_i^C\right) = \lim_{N \rightarrow \infty} P\left(\bigcap_{i=n}^N A_i^C\right) = \prod_{i=n}^{\infty} P(A_i^C) \leq \prod_{i=n}^{\infty} \exp[-P(A_i)] = \exp\left[-\sum_{i=n}^{\infty} P(A_i)\right] = 0,$$

když jsme využili nerovnost $P(A^C) = 1 - P(A) \leq \exp[-P(A)]$ a z divergence řady plynoucí fakt $\sum_{i=n}^{\infty} P(A_i) = \infty$ pro všechna n . Odtud již snadno plyne i závěr celého důkazu, tedy

$$\lim_{n \rightarrow \infty} P\left(\bigcap_{i=n}^{\infty} A_i^C\right) \leq \lim_{n \rightarrow \infty} \exp\left[-\sum_{i=n}^{\infty} P(A_i)\right] = 0.$$

Této druhé implikaci se někdy samostatně říká Borelova. $\square$

Cvičení 5.19. Odvod'te z bodu (1) věty 5.18 podmínku pro $P(\liminf A_n) = 1$. $\diamond$

Všimněme si, že v případě nezávislých náhodných jevů dostáváme pro $\limsup_n A_n$ pravděpodobnost vždy právě jednu z hodnot 0, nebo 1.

Borelův-Cantelliův 0-1 zákon se často používá ve spojení s identitou uvedenou ve cvičení 5.17 k počítání pravděpodobností jevů $\liminf_n A_n$.

Cvičení 5.20. V urně je jeden bílý a jeden černý míč. V každém tahu vytáhneme náhodně jeden míč a poté jej do urny vrátíme a přidáme jeden černý míč navíc. S jakou pravděpodobností vytáhneme v nekonečně mnoha tazích bílý míč jen v konečně mnoha pokusech? $\diamond$

*5.5. Chernoffovy meze pro součty náhodných veličin

Připomeňme si definici 4.3 empirické distribuční funkce. V ní vidíme součet nezávislých náhodných veličin, podobně jako při počítání průměru z náhodného výběru. Zde si ukážeme několik základních tvrzení pro součty nezávislých náhodných veličin.

Definice 5.21 (Poissonovské pokusy). Bud'te $X_1, X_2, \dots$ nezávislé náhodné veličiny takové, že $P[X_i = 1] = p_i = 1 - P[X_i = 0]$, $p_i \in (0, 1)$. Takové pokusy se nazývají nezávislé poissonovské pokusy.

Jestliže u poissonovských pokusů bude každé $p_i = p$ pro nějaké konstantní p , dostaneme bernoulliiovské pokusy.

Věta 5.22 (Horní Chernoffovy meze pro poissonovské pokusy). Bud'te $X_1, X_2, \dots$ nezávislé poissonovské pokusy s parametry $p_1, p_2, \dots$. Označme $S_n = \sum_{i=1}^n X_i$, $\mu_S = \sum_{i=1}^n p_i$.

(1) Pro $\delta > 0$:

$$P[S_n \geq (1 + \delta)\mu_S] \leq \left(\frac{e^\delta}{(1 + \delta)^{(1 + \delta)}} \right)^{\mu_S}$$

(2) Pro $0 < \delta \leq 1$:

$$P[S_n \geq (1 + \delta)\mu_S] \leq e^{-\mu_S \delta^2/3}$$

(3) Pro $\delta > 6\mu_S$:

$$P[S_n > \delta] \leq 2^{-\delta}$$

Důkaz. Dokážeme jen první nerovnost, další jsou obměnou s použitím jiných horních mezí. Pro Poissonovo rozdělení dostaneme momentovou vytvořující funkci $\psi_{X_i}(t) = Ee^{tX_i} = p_i e^t + (1 - p_i) = 1 + p_i(e^t - 1)$ a z nezávislosti $\psi_{S_n} = \prod_{i=1}^n \psi_{X_i}(t)$. Přepíšme obecnou horní Chernoffovu mez pro speciální případ

$$P[S_n \geq (1 + \delta)\mu_S] \leq \frac{\psi_{S_n}(t)}{e^{t(1 + \delta)\mu_S}}.$$

Protože

$$\begin{aligned} \psi_{S_n}(t) &= \prod_{i=1}^n (1 + p_i(e^t - 1)) = \exp \left[\sum_{i=1}^n \log(1 + p_i(e^t - 1)) \right] \\ &\leq \exp \left[(e^t - 1) \sum_{i=1}^n p_i \right] = \exp[(e^t - 1)\mu_S], \end{aligned}$$

dosazením do vzorce, dostáváme

$$\frac{\psi_{S_n}(t)}{e^{t(1 + \delta)\mu_S}} \leq \frac{\exp[(e^t - 1)\mu_S]}{\exp[t(1 + \delta)\mu_S]} = \exp[\mu_S(e^t - 1 - t(1 + \delta))].$$

Minimalizací pravé strany přes množinu $t > 0$ zjistíme minimum v bodě $t = \log(1 + \delta)$ a po dosazení dostáváme výsledek

$$P[S_n \geq (1 + \delta)\mu_S] \leq \exp[\mu_S((1 + \delta) - 1 - (1 + \delta) \log(1 + \delta))] = \left(\frac{\exp(\delta)}{(1 + \delta)^{1 + \delta}} \right)^{\mu_S}.$$

□

Podobně bychom mohli dokázat i dolní meze, takže větu uvedeme bez důkazu.

Věta 5.23 (Dolní Chernoffovy meze pro poissonovské pokusy). Bud'te $X_1, \dots, X_n$ nezávislé poissonovské pokusy s pravděpodobnostmi $P[X_i = 1] = p_i$. Bud' $S_n = \sum_{i=1}^n X_i$ a $\mu_S = \sum_{i=1}^n p_i$. Pak

(1) Pro $0 < \delta < 1$

$$P[S_n \leq (1 - \delta)\mu_S] \leq \left(\frac{e^{-\delta}}{(1 - \delta)^{1-\delta}} \right)^{\mu_S}.$$

(2) Pro $0 < \delta \leq 1$

$$P[S_n \leq (1 - \delta)\mu_S] \leq e^{-\mu_S \delta^2/2}.$$

Kombinací horní a dolní Chernoffovy meze můžeme dostat i „oboustrannou“ variantu nerovnosti.

Důsledek 5.24. Bud' $X_1, \dots, X_n$ nezávislé poissonovské pokusy s pravděpodobnostmi $P[X_i = 1] = p_i$. Bud' $S_n = \sum_{i=1}^n X_i$ a $\mu_S = \sum_{i=1}^n p_i$. Pro $0 < \delta \leq 1$ platí

$$P[|S_n - \mu| \geq \delta\mu_S] \leq 2e^{-\mu_S \delta^2/3}.$$

Pro součty Poissonovských pokusů dává Chernoffova nerovnost v některých případech lepší výsledky než Čebyševova.

Cvičení 5.25. Bud' $X_1, X_2, \dots$ bernoulliiovské pokusy s pravděpodobností úspěchu $p = 1/2$. Označme $S_n = \sum_{i=1}^n X_i$ a $\mu_n = n/2$. Snadno ověříme, že $E S_n = n/2$ a $\text{var } S_n = n/4$.

Odhadněte shora pravděpodobnost $P[|S_n - \mu_n| \geq \delta\mu_n]$ pro $0 < \delta \leq 1$ pomocí Čebyševovy nerovnosti a Chernoffovy nerovnosti uvedené v důsledku 5.24.

Pomocí Čebyševovy nerovnosti dostaneme

$$P[|S_n - \mu_n| \geq \delta\mu_n] \leq \frac{\text{var } S_n}{\delta^2 \mu_n^2} = \frac{\frac{n}{4}}{\frac{\delta^2 n^2}{4}} = \frac{1}{n\delta^2}.$$

Z Chernoffovy nerovnosti dostaneme

$$P[|S_n - \mu| \geq \delta\mu_S] \leq 2e^{-\mu_n \delta^2/3} = 2 \exp(-n\delta^2/6).$$

Pro jaká n a δ dává Chernoffova nerovnost lepší výsledek? Můžeme si pomoci opět jednoduchým odhadem, podělme

$$(5.1) \quad \frac{2 \exp(-n\delta^2/6)}{\frac{1}{n\delta^2}} = \frac{2n\delta^2}{\exp(n\delta^2/6)} = \frac{2n\delta^2}{1 + \frac{n\delta^2}{6} + \frac{n^2\delta^4}{72} + \dots}.$$

Pro relativně malé hodnoty $n\delta^2$ (jednotky) může Chernoffova nerovnost dávat horší výsledky než Čebyševova. Ale protože v takovém případě ani Čebyševova nerovnost nedává moc zajímavou informaci ($1/(n\delta^2)$ je v tom případě stále velké číslo), nemusíme se tímto znepokojovat. Pokud $n\delta$ je již v řádu desítek, pak z podílu (5.1) dostaneme Chernoffovu mez mnohem nižší než Čebyševovu.

Často udávanou hodnotou je $\delta = \sqrt{6 \log(n)/n}$. V tomto případě dostaneme z Čebyševovy nerovnosti

$$P[|S_n - n/2| \geq \sqrt{6n \log(n)}/2] \leq \frac{1}{6 \log(n)} \xrightarrow{n \rightarrow \infty} 0,$$

což je krásný odhad, ale Chernoffova mez je ještě lepší, jmenovitě

$$P[|S_n - n/2| \geq \sqrt{6n \log(n)}/2] \leq \frac{2}{n}.$$

V obou případech jsme potvrdili důležitou skutečnost. Budeme-li nezávisle házet symetrickou hrací kostkou, pak pravděpodobnost, že po n hodech se počet sudých výsledků bude od střední hodnoty $n/2$ řádově lišit o více než $\sqrt{n \log(n)}$ je pro velká n zanedbatelná¹⁰. Podobný výsledek lze odvodit i pro jiné pravděpodobnosti úspěchu. $\spadesuit$

Při použití Chernoffovy nerovnosti si ale musíme dát pozor na fakt, že pracujeme s nezávislými náhodnými veličinami, zatímco Čebyševova nerovnost platí i pro nekorelované náhodné veličiny. Pro použití Čebyševovy nerovnosti nám navíc stačí znát rozptyl, zatímco pro Chernoffovu nerovnost musíme znát momentovou vytvořující funkci a tedy i rozdělení náhodných veličin, případně, jako je tomu v důsledku 5.24 předpokládat poissonovské pokusy (což ale znamená také znát alespoň třídu rozdělení a celkovou hodnotu μ_S).

5.6. Zákon velkých čísel

Výsledek naznačený ve cvičení 5.25 je již blízko zákonu velkých čísel, jedné z nejslavnějších vět teorie pravděpodobnosti.

Věta 5.26 ((Slabý nebo též Čebyševův) Zákon velkých čísel). *Bud' $X_1, X_2, \dots$ iid náhodné veličiny s konečnou střední hodnotou $E X_1 = \mu$ a s konečným rozptylem $\text{var } X_1 = \sigma^2$. Pro libovolné $\varepsilon > 0$*

$$P \left[\left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| > \varepsilon \right] \xrightarrow{n \rightarrow \infty} 0.$$

Důkaz. Nejjednodušší důkaz této věty je s pomocí Čebyševovy nerovnosti. Pro náhodnou veličinu $Y_n = \frac{1}{n} \sum_{i=1}^n X_i$ platí

$$E Y_n = E \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \sum_{i=1}^n E X_i = \mu$$

a z nezávislosti dostaneme rozptyl

$$\text{var } Y_n = \text{var} \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n^2} \sum_{i=1}^n \text{var } X_i = \frac{\sigma^2}{n}.$$

Z Čebyševovy nerovnosti proto plyne

$$P[|Y_n - \mu| \geq \varepsilon] \leq \frac{\sigma^2}{n\varepsilon^2},$$

kde pro n jdoucí do nekonečna pravá strana konverguje k nule pro libovolné $\varepsilon > 0$. $\square$

¹⁰Při interpretaci tohoto výsledku je nutné být opatrný! Zde tvrdíme, že pokud provedeme n pokusů, budeme s velkou pravděpodobností s počtem sudých výsledků někde v intervalu $n/2 \pm \sqrt{n \log(n)}$. Pokud ale sledujeme maximální odchylku $\max |S_k - k/2|$, $k = 1, 2, \dots, n$, tedy maximální průběžné odchylky počtu sudých od očekávané hodnoty, Čebyševova ani Chernoffova nerovnost nám nepomohou.

Zákon velkých čísel tedy říká, že aritmetický průměr náhodného výběru konverguje v pravděpodobnosti¹¹ ke střední hodnotě pozorovaných náhodných veličin.

Ve skutečnosti lze předchozí větu dokázat i se slabšími předpoklady. Zprvč můžeme nezávislost nahradit nekorelovaností; v tom případě je rozptyl součtu také součtem rozptylů,

$$\text{var} \sum_i X_i = \sum_i \text{var} X_i + \sum_{i \neq j} \underbrace{\text{cov}(X_i, X_j)}_{=0} = \sum_i \text{var} X_i.$$

Dokonce stačí požadovat ještě méně a to aby kovariance byly dostatečně rychle mizějící se vzdáleností indexů i a j , aby $n^{-2} \text{var} \sum_i X_i$ konvergovalo k nule při n rostoucím do nekonečna, k čemuž stačí

$$\frac{1}{n^2} \sum_{1 \leq i < j \leq n} \text{cov}(X_i, X_j) \xrightarrow{n \rightarrow \infty} 0.$$

Pro nezávislé a stejně rozdělené náhodné veličiny můžeme nahradit předpoklad konečného rozptylu konečností prvního momentu, tedy nahradit požadavek $\text{var} X_1 < \infty$ předpokladem $E|X_1| < \infty$. Důkaz tohoto zesíleného tvrzení zde vynecháme.

Existují i varianty zákona velkých čísel bez požadavku stejného rozdělení, případně pro po dvou nezávislé náhodné veličiny a další varianty. My je zde nepoužijeme, zájemce proto odkazujeme na dostupnou literaturu.

Co zákon velkých čísel neříká? Celkem rozšířená je chybná interpretace zákona velkých čísel pomíjející průměrování v jeho znění. Ukážeme si tuto častou chybu na příkladu opakovaných hodů symetrickou hrací kostkou. Označme si $X_i = 1$, pokud padne jednička a $X_i = 0$ jinak. Pak máme iid náhodné veličiny a $P[X_i = 1] = 1/6$. Správnou interpretací zákona velkých čísel je tvrzení, že relativní podíl jedniček v n hodech, tedy $\sum_1^n X_i/n$ konverguje v pravděpodobnosti ke střední hodnotě $E X_1 = 1/6$. Jinými slovy empirická relativní četnost jedniček se limitně blíží k pravděpodobnosti jedničky (ve smyslu konvergence v pravděpodobnosti). Naopak chybnou interpretací zákona velkých čísel je představa, že absolutní počet jedniček v n pokusech je přibližně (blíží se) hodnotě $n/6$. Je tomu právě naopak. Pro libovolné pevné $d > 0$ pravděpodobnost, že se absolutní počet jedniček liší od $n/6$ o více než d , roste s n .

Cvičení 5.27. Připomeňte si cvičení 5.25 a všimněte si, že určitou roli hraje „obálka“ $\delta = \sqrt{\log n/n}$. Zkuste tuto obálku nahradit „o trochu menší“ obálkou $\delta = \sqrt{1/n}$ a všimněte si, co se stane. Zkuste naopak nepatrně zúžit meze použitím $\delta = 1/n^{\frac{1}{2}+\varepsilon}$ pro $\varepsilon > 0$. Jaký závěr z toho můžeme učinit? $\diamond$

Platnost zákona velkých čísel ilustrují obrázky 4.2–4.5 uvedené v Kapitole 4.3., které znázorňují chování výběrového průměru $\bar{X}_n$ pro rostoucí n . Na nich můžeme pozorovat, že se výběrový průměr pro rostoucí rozsah výběru blíží ke skutečné střední hodnotě $E X_1$. Zároveň na obrázcích zřetelně vidíme, že výběrový průměr je náhodná veličina.


¹¹Silnější typ konvergence, konvergence skoro jistě, je předmětem silného zákona velkých čísel. Slabý zákon se někdy nazývá Čebyševův, silný Kolmogorovův.

Cvičení 5.28. Uvažujme iid veličiny $X_1, X_2, \dots$ z rozdělení s hustotou

$$f(x) = \begin{cases} p/x^{p+1} & x \geq 1, \\ 0 & x < 1, \end{cases}$$

kde $p > 0$ je parameter¹². Spočtete střední hodnotu náhodné veličiny $E X_1$ a diskutujte chování výběrového průměru $\bar{X}_n$ pro (a) $p = 4$ a (b) $p = 1$.

Přímým výpočtem snadno zjistíme, že pro $p \in (0, 1]$ je $E X_1 = \infty$ a pro $p > 1$ je $E X_1 = p/(p - 1) < \infty$. Pro $p = 4$ jsou tedy splněny předpoklady Věty 5.26 a $\bar{X}_n$ konverguje v pravděpodobnosti k $4/3$. Pro $p = 1$ předpoklad Věty 5.26 splněn není. Pro lepší představu si vykreslíme graf chování $\bar{X}_n(\omega)$ v závislosti na n pro několik různých ω na obrázku 5.1. Pro $p = 4$ je patrné, že se trajektorie průměru s rostoucím n ustalují kolem pevné hodnoty $4/3$. Naproti tomu pro $p = 1$ vidíme, že i přes zvětšení rozsahu na ose y není pozorovatelné takové snížení rozptylu, aby došlo k ustalování výběrového průměru kolem nějaké konečné hodnoty pro rostoucí n . V tomto případě zjevně průměr nekonverguje v pravděpodobnosti k žádné konstantě. Jinými slovy, pro každou konstantu a existují $\varepsilon > 0$ a $\delta > 0$ závislé jenom na a takové, že pro všechna n existuje $m \geq n$ pro které $P[|\bar{X}_n - a| > \varepsilon] > \delta$, tedy s kladnou pravděpodobností se výběrový průměr vždy odrazí od jakékoliv zvolené konstanty a . $\diamond$



Obrázek 5.1. Vývoj $\bar{X}_n(\omega)$ v závislosti na n pro 100 různých ω (barevně odlišeno) pro veličiny s rozdělením ze Cvičení 5.28.

Zákon velkých čísel dává silný argument pro používání pravděpodobnostních a statistických modelů při zkoumání náhodných jevů. Bohužel nic neříká o pravděpodobnostním chování posloupnosti $\sum_1^n X_i/n$ kromě toho, že tato posloupnost konverguje v pravděpodobnosti.

¹²Toto rozdělení se nazývá Paretoovo rozdělení a využívá se k modelování určitých typů finančních dat.

5.7. Centrální limitní věta a její použití

Jedním z nejkrásnějších výsledků teorie pravděpodobnosti je *centrální limitní věta*. Její historie sahá k Abrahamu de Moivrovi, který ve snaze vylepšit Bernoulliův zákon velkých čísel¹³ ukázal konvergenci pravděpodobností binomického rozdělení při pevném p k funkci dnes známé jako hustota normálního rozdělení. První obecnější variantu centrální limitní věty, stále pro binomické rozdělení, odvodil Pierre Simon Laplace v roce 1812 a této větě se říká Moivrova-Laplaceova¹⁴.

Věta 5.29 (Moivrova-Laplaceova věta). *Nechť $X_1, X_2, \dots$ jsou iid náhodné veličiny s alternativním rozdělením s parametrem p . Pak pro každé x platí*

$$P \left[\frac{\sum_{i=1}^n (X_i - p)}{\sqrt{np(1-p)}} \leq x \right] \rightarrow \Phi(x),$$

kde Φ označuje distribuční funkci rozdělení $N(0,1)$.

Přestože Ljapunovův důkaz centrální limitní věty je nesmírně elegantní a poučný, je také bohužel velmi dlouhý.

Ukážeme si několik kroků důkazu používaného v současnosti¹⁵.

Označme $Y_n = \sum_{k=1}^n X_k$. Náhodná veličina $Z_n = (Y_n - np) / \sqrt{np(1-p)}$ má charakteristickou funkci

$$\begin{aligned} \tilde{F}_{Z_n}(t) &= E \exp(itZ_n) = E \exp \left(it \frac{Y_n - np}{\sqrt{np(1-p)}} \right) \\ &= E \prod_{k=1}^n \exp \left(it \frac{X_k - p}{\sqrt{np(1-p)}} \right) = \exp \left(\frac{-it\sqrt{np}}{\sqrt{1-p}} \right) \prod_{k=1}^n E \exp \left(\frac{itX_k}{\sqrt{np(1-p)}} \right) \\ &= \exp \left(\frac{-it\sqrt{np}}{\sqrt{1-p}} \right) \left(E \exp \left(\frac{itX_1}{\sqrt{np(1-p)}} \right) \right)^n = \exp \left(\frac{-it\sqrt{np}}{\sqrt{1-p}} \right) \tilde{F}_{X_1}^n \left(\frac{t}{\sqrt{np(1-p)}} \right). \end{aligned}$$

Snadno ověříme, že $\tilde{F}_{X_1}(t) = 1 - p + pe^{it}$ a proto

$$\tilde{F}_{Z_n}(t) = \left[1 - p \left(1 - \exp \left(\frac{it}{\sqrt{np(1-p)}} \right) \right) \right]^n.$$

Proveďme pro libovolné pevné t limitní přechod $\tilde{F}_{Z_n}(t)$ pro $n \rightarrow \infty$. Přepíšme

$$\left[1 - p \left(1 - \exp \left(\frac{it}{\sqrt{np(1-p)}} \right) \right) \right]^n = \exp \left\{ n \log \left[1 - p \left(1 - \exp \left(\frac{it}{\sqrt{np(1-p)}} \right) \right) \right] \right\}$$

¹³Šlo v podstatě o speciální verzi zákona velkých čísel pro posloupnost bernoulliiovských pokusů, dnes bychom řekli pro binomické rozdělení s konstantním p a n rostoucím do nekonečna.

¹⁴De Moivre zemřel v roce 1754 zatímco Laplace se narodil v roce 1749, takže spolu nikdy nemohli pracovat. De Moivrova věta byla vydána v roce 1733, dlouho před Laplaceovým narozením, dvacet let po Bernoulliově *Ars Conjectandi* (které však bylo sepsáno mnohem dříve). Laplace, který svým dílem podstatně zasáhl do vývoje pravděpodobnosti, na větě pracoval zhruba 40 let! Z dnešního hlediska však první korektní důkaz centrální limitní věty připisujeme až Alexandru Michailoviči Ljapunovovi, který jej publikoval v roce 1901. Tak zdlouhavé byly počátky pravděpodobnosti a budování jejích solidních matematických základů.

¹⁵Tento důkaz spočívá v použití netriviálního tvrzení spojujícího charakteristické funkce a konvergenci v distribuci. Pokud pro posloupnost náhodných veličin $X_1, X_2, \dots$ a náhodnou veličinu X platí $\tilde{F}_{X_n}(t) \rightarrow \tilde{F}_X(t)$ pro každé t , pak X_n konvergují k X v distribuci. Charakteristická funkce věrna svému názvu charakterizuje rozdělení a navíc převádí spojitost v distribuci na bodovou konvergenci—a naopak.

Pro dostatečně velké n můžeme použít rozvoj logaritmu i exponenciely. označme si pro přehlednost $t_n = t / \sqrt{np(1-p)}$. Dostáváme tak

$$\log(1 - p(1 - e^{it_n})) = -p(1 - e^{it_n}) - \frac{p^2(1 - e^{it_n})^2}{2} + O((1 - e^{it_n})^3)$$

a

$$1 - e^{it_n} = -it_n + \frac{t_n^2}{2} + O(t_n^3) = -i \frac{t}{\sqrt{np(1-p)}} + \frac{t^2}{2np(1-p)} + O(n^{-3/2}).$$

Protože i $O((1 - e^{it_n})^3) = O(n^{-3/2})$ můžeme psát

$$\log(1 - p(1 - e^{it_n})) = -p \left(-i \frac{t}{\sqrt{np(1-p)}} + \frac{t^2}{2np(1-p)} \right) - p^2 \frac{t^2}{2np(1-p)} + O(n^{-3/2})$$

a dále

$$\exp \left\{ n \log \left[1 - p \left(1 - \exp \left(\frac{it}{\sqrt{np(1-p)}} \right) \right) \right] \right\} = \exp \left\{ \frac{it \sqrt{np}}{\sqrt{1-p}} - \frac{t^2}{2} + O(n^{-3/2}) \right\}.$$

Dohromady pak

$$\tilde{F}_{Z_n}(t) = \exp \left\{ \frac{-it \sqrt{np}}{\sqrt{1-p}} \right\} \exp \left\{ \frac{it \sqrt{np}}{\sqrt{1-p}} - \frac{t^2}{2} + O(n^{-3/2}) \right\} \rightarrow e^{-t^2/2}.$$

Nyní již jen stačí porovnat získanou limitní funkci s charakteristickou funkcí normovaného normálního rozdělení

$$\int_{-\infty}^{\infty} e^{itx} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = e^{-t^2/2}.$$

Centrální limitní věta není omezena jen na bernoulliiovské pokusy, ale je opravdu univerzálním zákonem pravděpodobnosti.

Věta 5.30 (CLV pro stejně rozdělené náhodné veličiny). *Bud' $X_1, X_2, \dots$ posloupnost iid náhodných veličin s konečným nenulovým rozptylem $\sigma^2 = \text{var } X_1$ a střední hodnotou $\mu = E X_1$. Pak pro každé $x \in \mathbb{R}$ platí*

$$P \left[\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} \leq x \right] \xrightarrow{n \rightarrow \infty} \Phi(x),$$

kde Φ označuje distribuční funkci rozdělení $N(0,1)$. Krátce píšeme $\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{d} N(0,1)$

Přepisem dostaneme ekvivalentní znění věty pro výběrový průměr:

$$\sqrt{n} \frac{\bar{X}_n - \mu}{\sqrt{\sigma^2}} \xrightarrow{d} N(0,1), \quad \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

Ta věta zní téměř neuvěřitelně. Bez ohledu na to, jaké rozdělení má náhodný výběr, výběrový průměr se nejenom blíží ke střední hodnotě (jak praví zákon velkých čísel), ale náhodné chování vhodně normovaného průměru se stabilizuje na normálním rozdělení. A věta platí i pro diskrétní náhodné veličiny. Stačí jen konečný rozptyl! Několik konkrétních příkladů jsme si již ukázali v Kapitole 4.3., viz obrázky 4.2, 4.4 a 4.5.

Posloupnost náhodných veličin $\sqrt{n} \frac{\bar{X}_n - \mu}{\sqrt{\sigma^2}}$ má asymptoticky normované normální rozdělení. Tento fakt je základem mnoha metod matematické statistiky. Bez nadsázky, toto je dokonalá věta. Těžko říci, co je podstatou tohoto „přirodního

zákona“, normální rozdělení souvisí například s rovnicí vedení tepla, s entropií. Také celkem snadno můžeme ukázat, že pro libovolný počet nezávislých náhodných veličin $X_1, \dots, X_n$ s rozdělením $N(0, 1)$ má náhodná veličina $Z = n^{-1/2} \sum X_i$ také normované normální rozdělení, jedná se proto o určitý pevný bod. V každém případě se jedná o fascinující výsledek.

V čem je klíčová nezávislost? Extrémním případem závislosti je například $X_i = X_1$, nebo $X_i = (-1)^i X_1$. Sami můžete vidět, že v těchto případech nelze očekávat konvergenci k normálnímu rozdělení v obecných případech. Intuitivně je nezávislost důležitá k tomu, aby se vyrovnávaly kladné a záporné odchylky od střední hodnoty, ale to samo o sobě k asymptotické normalitě nestačí. Na druhou stranu, vzájemná nezávislost ani stejné rozdělení nejsou nutnou podmínkou k platnosti CLV, tak jako jsme to viděli již u ZVČ. Různá zobecnění CLV bez požadavku nezávislosti či stejného rozdělení najdeme v literatuře, zde se jimi zabývat nebudeme.

Centrální limitní věta se obvykle používá k určení pravděpodobnosti, k určení intervalu či k určení potřebného počtu pozorování. Jednotlivé úlohy v podstatě odpovídají hledání jedné neznámé v rovnici odvozené pomocí CLV. K tomu se využívají běžně dostupné tabulky hodnot distribuční funkce Φ (například i na mobilním telefonu se systémem android v pokročilé kalkulačce *Calc 991ex plus* či ve speciální aplikaci *Probability Distributions*).

Cvičení 5.31 (Příklady použití CLV). Zkuste nejprve sami přijít na to, jak použít CLV pro daný úkol a poté se podívejte na příklad možného řešení. Značením $u_n \approx u$ označujeme skutečnost, že u_n konverguje k u (zde půjde o posloupnost reálných hodnot) a n je dost velké, takže $|u_n - u|$ je malé.

- (1) *Určení pravděpodobnosti.* Chceme vědět, s jakou pravděpodobností bude počet úspěchů v Bernoulliových pokusech vyšší, než a . Máme $X_1, \dots, X_n$ iid s alternativním rozdělením s parametrem p . Určete $P[\sum_{i=1}^n X_i > a]$ (počítejte přibližně s využitím CLV)?

Použijeme CLV a stejné úpravy na obě strany. Cílem je získat jeden z tvarů uvedených ve větě 5.30.

$$\begin{aligned} P\left[\sum X_i > a\right] &= P\left[\frac{\sum X_i - np}{\sqrt{np(1-p)}} > \frac{a - np}{\sqrt{np(1-p)}}\right] = 1 - P[\dots \leq \dots] \\ &\approx 1 - \Phi\left(\frac{a - np}{\sqrt{np(1-p)}}\right). \end{aligned}$$

Dnes již výkonné počítače umožňují dosti přesně a rychle určit hledanou binomickou pravděpodobnost i pro velká n . Zkuste porovnat přesné hodnoty pravděpodobností s těmi spočítanými pomocí CLV (ale dejte pozor, aby zvolený program nepoužíval nějaké dobré normální aproximace, ale opravdu počítal přesné pravděpodobnosti).

- (2) *Určení počtu pokusů.* Chceme vědět, kolik pokusů máme udělat, aby se relativní počet úspěchů v Bernoulliových pokusech (tedy podíl úspěchů k počtu pokusů) lišil od teoretické pravděpodobnosti nejvýše o ε s pravděpodobností nejvýše α . Jinými slovy hledáme n tak, aby $P[|\bar{X}_n - p| > \varepsilon] \leq \alpha$.

Znova využijeme CLV a upravujeme. Obdobnými úpravami jako výše dostaneme

$$\begin{aligned} P \left[\sqrt{n} \frac{|\bar{X}_n - p|}{\sqrt{p(1-p)}} > a \right] &= 1 - P \left[\sqrt{n} \frac{\bar{X}_n - p}{\sqrt{p(1-p)}} > a \right] + P \left[\sqrt{n} \frac{\bar{X}_n - p}{\sqrt{p(1-p)}} < -a \right] \\ &\approx 1 - \Phi(a) + \Phi(-a). \end{aligned}$$

S využitím symetrie normálního rozdělení, jmenovitě $\Phi(a) = 1 - \Phi(-a)$, poslední výraz upravíme na $2(1 - \Phi(a))$. To znamená, že hledáme a tvaru $\frac{\sqrt{n}\varepsilon}{\sqrt{p(1-p)}}$ tak, aby $2(1 - \Phi(a)) \leq \alpha$, tedy $a \geq \Phi^{-1}(1 - \frac{\alpha}{2})$. Z tohoto a potom vypočteme potřebné n .

- (3) *Určení intervalu.* Každý z n účastníků korespondenčního semináře dokončí všechny úkoly—a získá tak nárok na odměnu—s pravděpodobností p (nezávisle na ostatních). Kolik musí mít pořadatelé v zásobě dáreků, chtějí-li s pravděpodobností 0,99 mít odměnu pro každého úspěšného řešitele?

Triviální odpověď je n . Pak máme *jistotu*, že se dostane na každého. Ale zároveň s pravděpodobností $1 - p^n$ (a ta může být *hodně* velká) nám nějaký dárek zbude. Jak asi tušíme, pokud bychom koupili n dáreků, tak nám jich zbude *opravdu hodně*.

Označíme-li X_i náhodnou veličinu „účastník uspěl“, pak $\sum X_i$ je počet dáreků, které potřebujeme. Okamžitě vidíme, že můžeme využít CLV a po několika úpravách dospět k asymptotické rovnosti

$$P \left[\sum X_i \leq a \right] = P \left[\frac{\sum X_i - np}{\sqrt{np(1-p)}} \leq \frac{a - np}{\sqrt{np(1-p)}} \right] \approx \Phi \left(\frac{a - np}{\sqrt{np(1-p)}} \right).$$

Poslední výraz má být nejméně 0,99, z čehož pak plyne nerovnice

$$\frac{a - np}{\sqrt{np(1-p)}} \geq \Phi^{-1}(0,99) \Rightarrow a \geq np + \sqrt{np(1-p)}\Phi^{-1}(0,99).$$

Alespoň tolik dáreků musíme mít připraveno. Porovnejte pro různá nastavení n a p s hodnotami n a np , tedy maximálním počtem dáreků a střední hodnotou úspěšných účastníků.

◊

Ve větě 5.6 jsme viděli, že konvergence v pravděpodobnosti „přežije“ transformaci spojitou funkcí, pokud tedy $X_n \xrightarrow{d} X$, tak i $g(X_n) \xrightarrow{d} g(X)$ pro spojitě zobrazení g . Pro konvergenci k normálnímu rozdělení tak, jak jej známe z centrální limitní věty máme dokonce ještě zajímavější výsledek, pokud je g diferencovatelná.

Věta 5.32 (Delta věta). *Mějme $Y_1, Y_2, \dots$ posloupnost náhodných veličin a předpokládejme $\sqrt{n}(Y_n - \mu) \xrightarrow{d} N(0, \sigma^2)$. Mějme dále diferencovatelnou funkci g . Pak*

$$\sqrt{n}(g(Y_n) - g(\mu)) \xrightarrow{d} N(0, (g'(\mu))^2 \sigma^2)$$

Důkaz. Důkaz této věty vyžaduje poněkud hlubší znalost konvergence v distribuci. Základní myšlenku důkazu ukážeme i bez této znalosti. Pro rozdíl $\sqrt{n}(g(Y_n) -$

$g(\mu)$) použijeme Taylorův rozvoj

$$\sqrt{n}(g(Y_n) - g(\mu)) = \sqrt{n}g'(\mu)(Y_n - \mu) + \sqrt{n}g''(\mu)(Y_n - \mu)^2/2 + O((Y_n - \mu)^2).$$

První člen rozvoje podle předpokladů věty konverguje v distribuci k požadovanému rozdělení $N(0, (g'(\mu))^2\sigma^2)$. Protože z věty o spojitém zobrazení posloupnost $n(Y_n - \mu)^2$ konverguje v distribuci, musí (zde se odkazujeme na pokročilejší znalost konvergence v distribuci) posloupnost $n(Y_n - \mu)^2/\sqrt{n}$ konvergovat k nule v pravděpodobnosti. Zbytek je aplikací Sluckého věty 5.7 $\square$

Delta věta dává velmi univerzální a mocný nástroj. Ukažme si její použití na příkladu Poissonova rozdělení.

Cvičení 5.33. Předpokládejme, že máme posloupnost $X_1, X_2, \dots$ nezávislých náhodných veličin s Poissonovým rozdělením s parametrem λ . Již víme, že $E X = \text{var } X = \lambda$. Z centrální limitní věty plyne $\sqrt{n}(\bar{X}_n - \lambda) \xrightarrow{d} N(0, \lambda)$. Funkce $g(x) = e^{-x}$ je všude diferencovatelná a platí $g(\lambda) = e^{-\lambda} = P[X = 0]$.

Pomocí Delta věty můžeme odvodit, že posloupnost $\sqrt{n}(e^{-\bar{X}_n} - e^{-\lambda})$ konverguje v distribuci k rozdělení $N(0, \lambda(g'(\lambda))^2) = N(0, \lambda e^{-2\lambda})$. $\diamond$

*5.8. Konvergence L_p a skoro jistě

Konvergence v pravděpodobnosti je základním typem konvergence pro zákon velkých čísel. Silnějším typem konvergence je konvergence v momentech.

Definice 5.34 (Konvergence v L_p , konvergence v kvadratickém středu). Mějme posloupnost náhodných veličin $X_1, X_2, \dots$ a náhodnou veličinu X takové, že $E|X|^p < \infty$ a $E|X_i|^p < \infty$ pro všechna i . Řekneme, že X_n konvergují k X v L_p , pokud

$$\lim_{n \rightarrow \infty} E|X_n - X|^p = 0.$$

Tuto konvergenci značíme $X_n \xrightarrow{L_p} X$.

Speciálně pro $p = 2$ mluvíme o konvergenci v kvadratickém středu, proto se někdy užívá zápis $\text{l.i.m} X_n = X$, podle anglického *limit in (the quadratic) mean*. Dalším důležitým případem je $p = 1$.

Uvědomme si, že i v této definici potřebujeme, aby všechny v ní uvedené náhodné veličiny byly definované na *stejném* pravděpodobnostním prostoru. Jinak nejsme schopni dát význam výrazu $E|X_n - X|$.

Poznámka 5.35. Jak jsme viděli v nerovnostech pro momenty výše, platí-li $X_n \xrightarrow{L_p} X$ pro nějaké $p > 0$, pak také $X_n \xrightarrow{L_q} X$ pro $0 < q < p$. Tato vlastnost platí díky konečnosti míry P , obecně pro nekonečné míry neplatí.

Cvičení 5.36. Uvažujte posloupnost náhodných veličin X_n a X s konečnými středními hodnotami.

Ukažte, že pokud posloupnost X_n *nekonverguje* v pravděpodobnosti k X , pak X_n *nekonverguje* k X v L_1 smyslu.

Ukažte naopak, že pokud $X_n \xrightarrow{L_1} X$, pak také $X_n \xrightarrow{P} X$. $\diamond$

Konvergence v L_p je tedy silnější než konvergence v pravděpodobnosti. Někdy se ale snáz dokazuje.

Tuto kapitolu uzavřeme zmínkou o konvergenci *skoro jistě*. Již jsme uvedli, že z konvergence v pravděpodobnosti nemůžeme usuzovat na konvergenci posloupností $X_n(\omega)$. Silnější než konvergence v pravděpodobnosti je konvergence skoro jistě (ale jen díky konečnosti P , pro nekonečné míry toto neplatí).

Definice 5.37 (Konvergence skoro jistě). Bud'te X náhodná veličina a $X_1, X_2, \dots$ posloupnost náhodných veličin definovaných na *stejném* pravděpodobnostním prostoru. Řekneme, že X_n konverguje skoro jistě k X , pokud

$$P[X_n \rightarrow X] = 1.$$

Tuto konvergenci značíme $X_n \xrightarrow{\text{sj}} X$.

Místo sj se můžeme i v české literatuře setkat se zkratkou as z anglického *almost surely*. Konvergence skoro jistě znamená, že existuje množina Ω_c taková, že $P(\Omega_c) = 1$ a pro všechna $\omega \in \Omega_c$ posloupnost $X_n(\omega)$ konverguje k $X(\omega)$. Jinými slovy platí

$$\forall \omega \in \Omega_c \forall \varepsilon > 0 \exists n(\omega, \varepsilon) : n \geq n(\omega, \varepsilon) \Rightarrow |X_n(\omega) - X(\omega)| \leq \varepsilon.$$

Za zmínku stojí závislost $n(\omega, \varepsilon)$ nejenom na ε , ale také na ω ¹⁶. Konvergenci skoro jistě uvádíme pro úplnost, pro její významné místo v pravděpodobnostní i statistické teorii.

Věta 5.38 (Vztahy mezi konverencemi II). Bud'te $X_1, X_2, \dots$ a X náhodné veličiny definované na *stejném* pravděpodobnostním prostoru. Pak

$$X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{d} X.$$

Pokud navíc všechny náhodné veličiny mají konečnou střední hodnotu platí

$$X_n \xrightarrow{L_1} X \Rightarrow X_n \xrightarrow{P} X.$$

Důkaz. Druhé tvrzení je důsledkem cvičení 5.36

□

Problémy k dalšímu procvičení

1. Jaká je pravděpodobnost, že při 10 000 hodech symetrickou mincí padne rub více než 4 900 krát? Nalezněte nejprve přesné řešení (výraz) a následně řešte pomocí CLV.

Uvažujeme počet úspěchů v nezávislých pokusech, takže přesné rozdělení známe, ale je komplikované vyčíslit výslednou hodnotu. Pro aproximaci pomocí CLV si definujte vhodné veličiny X_i , které jsou nezávislé a stejně rozdělené. Následně proveďte vhodné úpravy, abyste požadovanou pravděpodobnost vyjádřili pomocí veličiny ze znění CLV.

¹⁶Jste-li seznámeni s konverencemi *skoro všude* a *v míře*, můžete tyto konvergence snadno vidět i v konverencích skoro jistě a v pravděpodobnosti. Konečnost P má některé důsledky, které pro obecné míry neplatí.

2. Pořádáte narozeninový večírek pro 100 hostů. Lze předpokládat, že počet chlebičků, které sní náhodně vybraný host, je náhodná veličina se střední hodnotou 5 a rozptylem 1 a že jednotliví hosté konzumují nezávisle na sobě a jejich konzumace jsou stejně rozdělené náhodné veličiny.
- (a) S jakou pravděpodobností sní hosté nejvýše 490 chlebičků?
 - (b) Kolik musíte objednat chlebičků, aby jich byl nedostatek (hosté by měli ještě hlad) s pravděpodobností menší než 0.1?
 - (c) Kolik hostů může přijít na oslavu, jestliže chcete mít jistotu, že objednaných 500 chlebičků bude stačit s pravděpodobností větší než 95 %?
 - (d) Označme jako C celkový počet chlebičků, které sní pozvaných 100 hostů. Nalezněte $t > 0$ takové, aby platilo

$$P(-t < C - 500 < t) \geq 0.99,$$

tj. hledáme t takové, že veličina C bude v intervalu $(500 - t, 500 + t)$ s pravděpodobností alespoň 0.99. Řešte pomocí CLV i pomocí Čebyševovy nerovnosti a výsledky porovnejte.

Všimněte si, že v příkladě 1 jsme byli schopni vyjádřit výsledek přesně, jen bylo komplikované ho vyčíslit, a proto nám pomohla aproximace pomocí CLV. V tomto příkladě dokonce rozdělení X_i vůbec neznáme a známe jen jejich střední hodnotu a rozptyl. Takže bez pomoci CLV bychom nebyli schopni spočítat žádnou z uvedených úloh (a)–(c).

3. Pojišťovna má pojištěno 1 000 osob stejného věku. Pravděpodobnost úmrtí v daném roce je u každého pojištěného 0,01. Pojištěnci platí roční pojistné 1 200 Kč a v případě úmrtí je oprávněné osobě vyplaceno 80 000 Kč.
- (a) Jaký je v daném roce očekávaný zisk (resp. ztráta) pojišťovny?
 - (b) Jaká je pravděpodobnost, že pojišťovna utrpí v daném roce ztrátu?
 - (c) Jaký zisk je ředitel pojišťovny schopen garantovat představenstvu s pravděpodobností 90 %?
 - (d) Kolik by musela mít pojišťovna klientů (při stávajícím nastavení výše plateb), aby s pravděpodobností alespoň 99 % vydělala více než 10 000 Kč ročně?

Zamyslete se nad následujícím: Proč máme v zadání, že jsou pojištěnci přibližně stejného věku? Jaký předpoklad by byl porušen, kdyby nebyly stejného věku?

4. V Dolní Lhotě se koná výstava dojníc na kterou se sjede 10 000 lidí z širokého okolí. Každý návštěvník výstavy si potřebuje v jediném bankomatu, který je v Dolní Lhotě k dispozici, vybrat hotovost. V bankomatu se nacházejí pouze tisícikorunové bankovky. Konkrétní osoba vybere nezávisle na ostatních K tisícikorun. Předpokládejme, že K je náhodnou veličinou, jenž se řídí Poissonovým rozdělením s parametrem $\lambda = 1$. Kolik musí být před začátkem výstavy v bankomatu tisícikorun, aby s pravděpodobností alespoň 0,99 nedošlo k celkovému vybrání bankomatu během výstavy?
5. Hodíme stokrát šestistěnnou hrací kostkou. Určete přibližnou hodnotu pravděpodobnosti, s jakou výsledný součet leží v rozmezí od 320 do 380 (včetně)?
6. Pořádáte svatební hostinu a objednali jste 200 zákusků. Ze zkušenosti víte, že počet zákusků, který sní náhodný host, se řídí Poissonovým rozdělením se střední hodnotou 4. Kolik může nejvýše dorazit hostů na hostinu, aby se s

- pravděpodobností alespoň 0.9 nemusel žádný z hostů v jídle omezovat (tj. aby mohl sníst tolik zákusků, kolik jen chce)?
7. Počet studentů, kteří během konzultačních hodin v jednom týdnu navštíví profesora A, je roven k s pravděpodobností $1/5$ pro $k = 1, \dots, 5$. Zjistěte, s jakou pravděpodobností bude profesor A během akademického roku (40 týdnů) konzultovat s nejvýše 100 studenty. Při řešení příkladu předpokládejte, že počty konzultacechtivých studentů v jednotlivých týdnech jsou vzájemně nezávislé.
 8. Pojišťovna pojišťuje 10 000 řidičů stejného typu automobilu. Každý řidič zaplatí na začátku roku 10 tisíc Kč ročního pojistného. S pravděpodobností 0,9 řidič během roku nezpůsobí nehodu (a pojišťovna nic nevyplácí). S pravděpodobností 0,09 způsobí řidič drobnou nehodu, při které bude pojišťovna vyplácet 50 tisíc Kč. Konečně s pravděpodobností 0,01 způsobí řidič větší nehodu, což bude pro pojišťovnu znamenat plnění ve výši 450 tisíc Kč.
 - (a) S jakou pravděpodobností pojišťovna vydělá více než 5 milionů Kč?
 - (b) Na jaký minimální zisk se může ředitel pojišťovny těšit na konci roku s pravděpodobností 0,95?
 - (c) Kolik řidičů by musela pojišťovna pojišťovat, aby pravděpodobnost toho, že nebude ve ztrátě, byla alespoň 0,999?
 9. Životnost jedné žárovky má exponenciální rozdělení se střední hodnotou 10 hodin. Jakmile se jedna žárovka porouchá, nahradíme ji ihned další. Kolik máme zakoupit žárovek, abychom měli jistotu, že budeme moci svítit alespoň 600 hodin s pravděpodobností alespoň 95%?
 10. Nechť X_n má exponenciální rozdělení se střední hodnotou $1/n$. Ukažte, že $X_n \xrightarrow{P} 0$.
 11. Dokažte následující tvrzení: Nechť $\{X_n\}$ je posloupnost náhodných veličin taková, že $E X_n \rightarrow a \in \mathbb{R}$ a $\text{var } X_n \rightarrow 0$ pro $n \rightarrow \infty$. Pak $X_n \xrightarrow{P} a$.
Návod: Použijte Markovovu nerovnost.

O odhadech

Odhad je asi nejdůležitější částí práce s náhodnými veličinami. Je jedno, zdali mluvíme o odhadu, nebo o statistickém učení, strojovém učení¹. Podstatou je, že z experimentu jehož výsledkem jsou data náhodné povahy chceme získat informace zobecňující pozorované výsledky na celou populaci. Důležité je stále mít na paměti, že pracujeme s náhodnými veličinami a tak i naše závěry mají náhodný charakter. Druhou skutečností, kterou mějme na paměti je vliv předpokladů o modelu. Každý předpoklad nějakým způsobem ovlivní výpočty a závěry a chybný předpoklad povede častěji k chybným závěrům, aniž bychom to museli včas poznat.

Rozdělení náhodného vektoru obvykle neznáme. Míra toho, co neznáme či potřebujeme nějakým způsobem odhadnou je různá. V prvním přiblížení můžeme rozlišit dvě základní situace (nedělejme si ovšem iluze o úplnosti tohoto výčtu):

- (1) **Parametrický přístup:** Pro rozdělení náhodné veličiny uvažujeme nějaký model, máme tedy představu o tvaru hustoty rozdělení nebo o distribuční funkci. Předpokládáme, že náhodná veličina má rozdělení patřící do nějaké třídy popsatelné funkcí známou až na konečný (malý) počet parametrů. Příkladem může být počet úspěchů v nějakém počtu pokusů. Model binomického rozdělení je naprosto vyhovující, můžeme-li považovat úspěchy v jednotlivých pokusech za nezávislé a nastávající se stejnou pravděpodobností. V tomto případě obvykle potřebujeme *odhadnout neznámé parametry*, tedy obvykle jednu či několik hodnot². Mezi parametrické modely patří také modelování závislosti jedné veličiny na jiných (regresní analýza) nebo modely časového vývoje systému (náhodné procesy) a mnoho dalších.

¹Algoritmické metody jsou velmi populární, ale zabývají se hlavně jednoduššími statistickými úlohami, klasifikací či predikcí. Neměli bychom však podlehnout pokušení naplnit počítač daty a čekat na výsledek. Analýza náhodných dat je komplexní problém začínající již u kladení otázek, sběru relevantních a kvalitních dat, ověřování předpokladů, volby metod, a končící správnou interpretací výsledků; samotné počítačové zpracování je jen jedním z kroků.

²Ačkoliv parametrem může být i funkce, ale to je samostatná oblast modelů.

- (2) **Neparametrický přístup:** O rozdělení (hustotě) předpokládáme jen celkem málo. Například existence některých momentů a spojitost rozdělení jsou typické (slabé) požadavky kladené na rozdělení. V tomto případě obvykle chceme *odhadnout některé charakteristiky rozdělení*, jeho konkrétní tvar nás moc nezajímá. Častou otázkou tohoto typu je, zda dvě náhodné veličiny mají stejné střední hodnoty (rozptyl, ...), nebo zda jsou nezávislé (nekorelované). Součástí neparametrických odhadů jsou také odhady hustoty náhodných veličin pomocí histogramů.

6.1. Výběrová statistika a její realizace

V kapitole 4 jsme vždy mluvili o náhodném výběru jako o posloupnosti n nezávislých a stejně rozdělených náhodných veličin $X_1, \dots, X_n$. To je výhodné ve chvíli, kdy potřebujeme pracovat s funkcí náhodného výběru jako s náhodnou veličinou. Tuto funkci často nazýváme statistikou.

Je-li $X_1, \dots, X_n$ náhodný výběr a $g : \mathbb{R}^n \rightarrow \mathbb{R}$ borelovsky měřitelná funkce, pak náhodnou veličinu $T_n = g(X_1, \dots, X_n)$ nazýváme *výběrovou statistikou*, krátce také jen *statistikou*³.

Výběrová statistika může být pochopitelně založena na náhodném výběru náhodných vektorů libovolné dimenze a může nabývat obecnějších hodnot než jen reálných čísel. I v takovém případě mluvíme o výběrové statistice. Výběrovou statistikou je například výběrový průměr, nejmenší pozorovaná hodnota, empirická distribuční funkce a další.

Pro rozlišení náhodné veličiny a její naměřené hodnoty se používá značení rozlišující malá a velká písmena. Po provedení pokusu (náhodného výběru) dostaneme pozorování. Tato pozorování již nepovažujeme za náhodné veličiny, ale za jejich realizaci, proto je neznačíme velkými písmeny jako náhodné veličiny, ale malými písmeny, jako obvyklé proměnné.

Pro náhodný vektor (výběr) $\mathbf{X} = (X_1, \dots, X_n)^\top$, je vektor $\mathbf{x} = (x_1, \dots, x_n)^\top$ jeho *realizací*, x_i je naměřená hodnota náhodné veličiny X_i . Realizaci náhodného výběru používáme jako argument výběrových statistik, čímž dostáváme realizaci výběrové statistiky.

Cvičení 6.1. Uvažujme pokus hodu šestistěnnou kostkou. Buď $X_1, \dots, X_n$ náhodný výběr, tedy n nezávislých hodů touto kostkou a T_n výběrovou statistikou označující počet šestek v těchto n hodech. Pak T_n je náhodná veličina s binomickým rozdělením $\text{Bi}(n, p)$, kde p je pravděpodobnost šestky. Zřejmě

$$T_n = g(X_1, \dots, X_n) = \sum_{i=1}^n \chi(X_i = 6)$$

Proveďte opakovaně n hodů, například m -krát, a zaznamenejte počty šestek $t_{n,i}$, $i \in \{1, \dots, m\}$ v jednotlivých pokusech. Hodnoty $t_{n,i}$ představují několik konkrétních realizací náhodné veličiny T_n . $\diamond$

³Všimněme si, že funkce g je funkcí n proměnných. Mohli bychom psát g_n , ale uvidíme, že předpis funkce g v sobě obvykle n přirozeně obsahuje a umožňuje tak použití pro libovolný rozsah výběru. Naopak u statistiky T_n index obvykle uvádíme s ohledem na zkoumání jejich asymptotických vlastností a pro zdůraznění rozsahu výběru, ze kterého je získána.

Na výběrovou statistiku tak nahlížíme oběma způsoby. Zkoumáme-li ji jako náhodnou veličinu, pak obvykle odvozujeme její rozdělení, limitní vlastnosti při n jdoucím do nekonečna, teoretické momenty T_n a další charakteristiky. Můžeme také zjistit, jak se její rozdělení vztahuje k rozdělení F_X , hledat asymptotické rozdělení a tak dále. Zejména zkoumání závislosti T_n na n a na parametrech rozdělení F_X je významnou součástí práce s výběrovými statistikami. Realizaci výběrové statistiky t_n jako konkrétní hodnotu můžeme porovnávat s předpokládanými vlastnostmi statistiky T_n a případně vznést pochyby o platnosti modelu či jiných předpokladů, pokud hodnota t_n vychází velmi nečekaně s ohledem na teoretické rozdělení T_n . Také jde o hodnotu, se kterou dále pracujeme ve výpočtech.

6.2. Bodový odhad

Bodový odhad je návod, jak z náhodného výběru spočítat hodnotu kterou bychom mohli nahradit neznámý parametr či charakteristiku rozdělení náhodné veličiny. Takový pojem se matematicky formálně nedefinuje snadno, protože jde o velmi široký pojem.

Definice 6.2 (Bodový odhad). Bud' X náhodná veličina s distribuční funkcí F_X a $\theta \in \Theta$ neznámá hodnota spjatá s F_X (např. neznámý parametr či jiná charakteristika). Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení F_X , tedy $X_1, \dots, X_n$ jsou nezávislé náhodné veličiny s distribuční funkcí F_X . Bodový odhad neznámého θ je funkce $g : \mathbb{R}^n \rightarrow \Theta$, jejíž předpis nezávisí⁴ na rozdělení F_X (ani jeho parametrech). V souladu se zvyklostmi značíme bodový odhad pomocí stříšky,

$$\hat{\theta}_n = g(X_1, \dots, X_n).$$

Obvykle $\hat{\theta}_n$ označuje i realizaci $g(x_1, \dots, x_n)$, ale můžeme dát přednost značení t_n pokud chceme zdůraznit, že jde o realizaci bodového odhadu.

Bodový odhad je v tomto pojetí výběrová statistika, která

- (1) má hodnoty v prostoru hodnot neznámého parametru (charakteristiky) rozdělení F_X a
- (2) nevyužívá žádnou informaci kromě předpokladů o modelu a realizace náhodného výběru.

Definici bodového odhadu jsme zúžili na případ náhodného výběru, ale takové omezení není nutné. Odhad můžeme zavést i obecněji, podstatné je, že odhad nevyužívá neznámé informace o modelu a rozdělení.

Poznámka 6.3. Čtenář v tuto chvíli možná cítí nejistotu a ptá se „Co je tedy vlastně odhad, jak jej mám spočítat, jaký je vzorec?“ a my se mu vůbec nedivíme. Úloha odhadu je velice obecná a obsahuje v sobě více problémů. Nejprve si musíme ujasnit co chceme odhadovat (úloha). Protože odhad je náhodná veličina, počítá se přeci z náhodných dat, musíme stanovit kritérium kvality odhadu, tedy jak měřit a hodnotit *odchylku* odhadu od skutečnosti (kritérium). Od těchto dvou bodů se teprve odvíjí postup, výpočet odhadu, tedy volba funkce g . Důležité je, že *postup*

⁴I zde jde o funkci n proměnných, kde n je rozsah náhodného výběru. Hodnota n však není pevná a proto ji občas zdůrazníme v indexu, píšeme tedy g_n .

nesmí používat žádné neznámé informace, ale jen náhodný výběr a předpoklady modelu.

6.3. Nestrannost a konzistence odhadu

Aby byl odhad užitečný, musí mít vhodné vlastnosti. Například by měl být s velkou pravděpodobností dostatečně blízko neznámé hodnotě θ , ať je tato hodnota jakákoliv. To může na první pohled znít podivně, když hodnotu θ neznáme. Přesto jsme se již s takovým chováním potkali dříve.

Cvičení 6.4. Předpokládejme $X_1, \dots, X_n$ náhodný výběr z rozdělení s neznámou konečnou střední hodnotou $E X$. Ukažte, že pro *jakoukoliv* hodnotu $E X$ platí $E \bar{X}_n = E X$. Tato rovnost proto platí bez ohledu na to, čemu se $E X$ rovná. $\diamond$

Uvedený příklad ukazuje takzvanou nestrannost. Tedy skutečnost, že se odhad *v průměru* rovná odhadované hodnotě. To je naprosto přirozený požadavek na kvalitu odhadu.

Definice 6.5 (Nestrannost odhadu). Bud' $X_1, X_2, \dots, X_n$ náhodný výběr z rozdělení F_X a bud' θ odhadovaný parametr. Bodový odhad $\hat{\theta}_n$ nazveme nestranným, pokud $\forall \theta \in \Theta$ platí $E \hat{\theta}_n = \theta$ je-li θ skutečnou hodnotou parametru. Pokud odhad není nestranný nazveme ho *vychýleným* (biased) a rozdíl $E \hat{\theta}_n - \theta$ je *vychýlkou* (bias).


Mnoho nestranných odhadů jsme již viděli v kapitole o výběrových momentech. Připomeňme si zejména výběrový průměr, výběrový rozptyl, výběrovou kovarianci a empirickou distribuční funkci.

Cvičení 6.6. Bud' $X_1, \dots, X_n$ náhodný výběr z Poissonova rozdělení s neznámým parametrem $\lambda > 0$. Pak $\bar{X}_n$ je podle Věty 4.9 nestranným odhadem λ , jelikož $E X_1 = \lambda$. Naproti tomu odhad $\hat{\lambda}_n = \frac{1}{n-3} \sum_{i=1}^n X_i$ je vychýlený odhad λ , protože

$$E \hat{\lambda}_n = \frac{1}{n-3} \sum_{i=1}^n E X_i = \frac{n\lambda}{n-3} > \lambda.$$

Nakonec si uvědomme, že odhad $\tilde{\lambda}_n = X_1$ je zřejmě také nestranným odhadem λ . Může však takový odhad být užitečný?

Uvažujme náhodný výběr o rozsahu n a odhady $\bar{X}_n$, $\hat{\lambda}_n$ a $\tilde{\lambda}_n$. Provedeme-li pokus opakovaně (pro různé hodnoty $\omega \in \Omega$), pak pro nestranný odhad bychom „v průměru“ měli dostat hodnotu blízkou skutečnému λ . Obrázek 6.1 zobrazuje situaci pro $n = 20$, $\lambda = 5$ a 500 opakování, tj. 500 realizací náhodných veličin $\bar{X}_n$, $\hat{\lambda}_n$ a $\tilde{\lambda}_n$ (znázorněny šedými body). Červená čára odpovídá skutečné hodnotě λ a modrá zobrazuje průměr spočtený z uvedených 500 realizací. Pro nestranné odhady barevné přímky téměř splývají, naopak pro vychýlený odhad $\hat{\lambda}_n$ vidíme výraznou odlišnost. Hodnoty odhadu $\hat{\lambda}_n$ jsou ve většině případů vyšší než skutečné λ , což odpovídá tomu, že je tento odhad vychýlený směrem nahoru (spočetli jsme, že $E \hat{\lambda}_n > \lambda$). Odhad $\tilde{\lambda}$ sice je nestranný, ale na první pohled vidíme jeho velký rozptyl, zejména porovnáme-li jej s rozptylem odhadu $\bar{X}_n$. $\diamond$



Obrázek 6.1. Různé odhady λ pro výběr o rozsahu $n = 20$ z Poissonova rozdělení s parametrem $\lambda = 5$. Znázorněno je 500 nezávislých realizací (šedé body), jejich průměr (modrá přímka) a skutečná hodnota λ (červená přímka). Pro lepší porovnání je v prvních dvou obrázcích volen stejný rozsah osy y .

Cvičení 6.7. Bud' $X_1, \dots, X_n$ náhodný výběr z Poissonova rozdělení s neznámým parametrem $\lambda > 0$. Pak $\bar{X}_n$ je nestranným odhadem λ , ale $\exp(-\bar{X}_n)$ není nestranným odhadem $\exp(-\lambda) = P[X = 0]$. Nestranným odhadem $P[X = 0]$ je relativní četnost nul v náhodném výběru. $\spadesuit$

Poznamenejme, že $\exp(-\bar{X}_n)$ v žádném případě není špatný odhad pravděpodobnosti $P[X = 0]$. To, že není nestranný nemusí vadit, někdy lze odhad na nestranný upravit, někdy bývá vychýlený odhad dokonce lepší v jiných ohledech, může mít například mnohem menší rozptyl. Podstatné ale je, aby případné vychýlení odhadu konvergovalo k nule při rostoucím rozsahu výběru.

Druhým přirozeným požadavkem na odhad je, aby se odhad *blížil odhadované hodnotě*. Tomu říkáme konzistence odhadu.

Definice 6.8 (Konzistence odhadu). Bud' $X_1, X_2, \dots, X_n$ náhodný výběr z rozdělení F_X a bud' θ odhadovaný parametr. Bodový odhad $\hat{\theta}_n$ nazveme konzistentním, pokud $\forall \theta \in \Theta$ platí $\hat{\theta}_n \xrightarrow{P} \theta$ je-li θ skutečnou hodnotou parametru.

Konzistence odhadu bývá úzce spojena se zákonem velkých čísel, ale toto spojení není výlučné.

Cvičení 6.9. Bud' $X_1, \dots, X_n$ náhodný výběr z Poissonova rozdělení s neznámým parametrem $\lambda > 0$. Pak $\bar{X}_n$ je podle zákona velkých čísel konzistentním odhadem λ . Odhad $\exp(-\bar{X}_n)$ je konzistentním odhadem $\exp(-\lambda) = P[X = 0]$ podle zákona velkých čísel a věty o spojitém zobrazení. $\diamond$

Cvičení 6.10. Necht' $X_1, \dots, X_n$ je opět náhodný výběr z Poissonova rozdělení s neznámým parametrem $\lambda > 0$ a uvažujme odhady $\hat{\lambda}_n = \frac{1}{n-3} \sum_{i=1}^n X_i$ a $\tilde{\lambda}_n = X_1$ ze Cvičení 6.6.

Odhad $\hat{\lambda}_n$ můžeme přepsat jako $\hat{\lambda}_n = \frac{n}{n-3} \bar{X}_n$. Jelikož $\frac{n}{n-3} \rightarrow 1$ a $\bar{X}_n \xrightarrow{P} \lambda$, plyne z Důsledku 5.8, že $\hat{\lambda}_n$ je konzistentní odhad.

Naoproti tomu odhad $\tilde{\lambda}_n$ rozhodně není konzistentní. Kdyby byl konzistentní, pak by pro každé $\lambda > 0$ muselo platit, že $\tilde{\lambda}_n \xrightarrow{P} \lambda$. Zvolme tedy například $\lambda = 1/2$ a $\varepsilon = 3/4$. Pak

$$P[|\tilde{\lambda}_n - \lambda| > \varepsilon] = P[|X_1 - 1/2| > 3/4] = P[X_1 > 5/4] > 0$$


a s rostoucím n se poslední pravděpodobnost nijak nemění, tj. určitě nekonverguje k nule. Proto odhad nemůže být konzistentní.

Uvažujme jedno pevné $\omega \in \Omega$ a pro něj realizace náhodných veličin $X_i, i = 1, \dots, n$ pro rostoucí n . Potom můžeme znázornit graf závislosti $\bar{X}_n(\omega)$, $\hat{\lambda}_n(\omega)$ a $\tilde{\lambda}_n(\omega)$ na n , podobně jako v Kapitole 4 (např. obrázek 4.3). Výsledný graf je znázorněn na obrázku 6.2. Vidíme, že s rostoucím n se $\bar{X}_n(\omega)$ a $\hat{\lambda}_n(\omega)$ blíží skutečné hodnotě parametru λ . Pro jinou volbu ω bychom pozorovali analogický vývoj, jelikož tyto dva odhady jsou konzistentní. Naproti tomu odhad $\tilde{\lambda}_n$ se skutečné hodnotě λ nijak nepřibližuje, což je opět v souladu s naším předchozím závěrem. $\diamond$

Mohlo by se zdát, že konzistentní odhad je *asymptoticky nestranný*, protože se v pravděpodobnosti blíží k odhadované konstantě. Z konvergence $\hat{\theta}_n \xrightarrow{P} \theta$ však bez dalších předpokladů *neplyne* $E\hat{\theta}_n \rightarrow \theta$. Postačující podmínkou pro to, aby konzistentní odhad byl také asymptoticky nestranný je například požadavek $\limsup E\hat{\theta}_n^2 < \infty$.

Cvičení 6.11. Uvažujme hustotu $f(x) = \exp(-x+a)\chi(x > a)$ s odpovídající distribuční funkcí F a náhodný výběr $X_1, \dots, X_n$ z tohoto rozdělení. Ukažte, že $\min\{X_1, \dots, X_n\}$ je konzistentním odhadem a .

Navržený odhad není součtem a proto zde nelze použít zákon velkých čísel. Lze však poměrně snadno odvodit rozdělení minima. Označme $X_{(1)} = \min\{X_1, \dots, X_n\}$



Obrázek 6.2. Realizace $\bar{X}_n(\omega)$, $\hat{\lambda}_n(\omega)$ a $\tilde{\lambda}_n(\omega)$ pro jedno konkrétní $\omega \in \Omega$ v závislosti na rozsahu výběru n pro Poissonovo rozdělení s parametrem $\lambda = 5$.

minimum náhodného výběru⁵. Pro minimum je snadné odvodit pro libovolné $x > a$ pravděpodobnost

$$P[X_{(1)} > x] = P[X_i > x \forall i] = \prod_{i=1}^n P[X_i > x] = (1 - F(x))^n = e^{-n(x-a)},$$

kde první rovnost je důsledkem skutečnosti, že pokud minimum splňuje $X_{(1)} > x$ tehdy a jen tehdy, pokud tuto nerovnost splňují všechna pozorování, druhá rovnost je důsledkem nezávislosti a poslední je snadný výpočet. Pro libovolné $\varepsilon > 0$ proto platí

$$P[|X_{(1)} - a| > \varepsilon] = P[X_{(1)} > a + \varepsilon] = e^{-n\varepsilon} \xrightarrow{n \rightarrow \infty} 0,$$

čímž jsme ověřili konvergenci v pravděpodobnosti a tím i konzistenci. $\diamond$

Než přistoupíme ke konstrukci odhadu, shrňme si ještě několik již zřejmých tvrzení do věty.

Věta 6.12. *Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení s distribuční funkcí F_X .*

- (1) *Existuje-li konečný r -tý moment rozdělení F_X , pak $\widehat{E X^r}$ je nestranným a konzistentním odhadem $E X^r$. Pokud existuje konečná střední hodnota $E X$ je výběrový průměr $\bar{X}_n$ nestranným a konzistentním odhadem $E X$.*
- (2) *Existuje-li konečný druhý moment rozdělení F_X , pak výběrový rozptyl S_n^2 je nestranný a konzistentní odhad rozptylu $\text{var } X$.*
- (3) *Hodnota empirické distribuční funkce $\hat{F}_n(x)$ je nestranným a konzistentním odhadem $F_X(x)$.*
- (4) *Existuje-li konečná hodnota $\psi_X(a)$ momentové vytvořující funkce v bodě a , pak*

$$\hat{\psi}_n(a) = \frac{1}{n} \sum_{i=1}^n \exp(aX_i)$$

⁵Někdy se můžeme potkat se značením $X_{1:n}$ zdůrazňujícím, že jde o nejmenší z n hodnot. V česky psané literatuře se ale častěji vyskytuje zde uvedené značení.

je nestranným a konzistentním odhadem $\psi_X(a)$.

Náhodný výběr je proto důležitým nástrojem pro zkoumání náhodných veličin. Podstatné je, aby opravdu šlo o náhodný výběr, tedy o nezávislé a stejně rozdělené náhodné veličiny.

6.4. Odhady metodou momentů

Metoda momentů je asi nejpřímější metoda odhadu parametrů rozdělení náhodné veličiny. Nedává vždy optimální odhady, ale pro svou jednoduchost a názornost je vhodnou volbou, navíc je méně citlivá na porušení nezávislosti, než třeba metoda maximální věrohodnosti. Princip metody momentů spočívá ve skutečnosti, že pokud distribuční funkce F náhodné veličiny X závisí na nějakém neznámém parametru θ , pak obvykle i momenty X závisí na θ .

Předpokládejme, že chceme odhadnout neznámý parametr θ , jehož hodnoty se nacházejí v množině $\Theta \subset \mathbb{R}^d$ (my se obvykle pohybujeme v rozsazích $d = 1, 2, 3$). Necht' momenty náhodné veličiny X existují alespoň do řádu d a závisí na parametru θ , tedy necht' platí

$$E X^r = \mu_r(\theta), r = 1, 2, \dots, d,$$

kde funkce $\mu_r(\theta)$ jsou známé díky předpokladu na rozdělení. Levou stranu nahradíme výběrovými momenty a řešíme soustavu *momentových rovnic*

$$\overline{E X^r} = \mu_r(\hat{\theta}_n), r = 1, 2, \dots, d,$$

čili hledáme $\hat{\theta}_n$ splňující tyto rovnice. Obvykle je pro d -rozměrný parametr potřeba právě d těchto rovnic, někdy však může stačit i méně rovnic k nalezení jednoznačného řešení. Řešení momentových rovnic říkáme *momentové odhady*, případně odhady momentovou metodou.

Řešení momentových rovnic nejsou hledané parametry, ale jejich odhady! Bohužel dochází občas k záměně parametru a jeho odhadu. Odhad je odhad, jde o náhodnou veličinu, může být (byť třeba s malou pravděpodobností) nepřipustně daleko od skutečné hodnoty parametru, to musíme mít na paměti, když s odhady pracujeme.

Obecně odhady momentovou metodou nemusí být nestranné, někdy je možné je na nestranné upravit, samozřejmě pokud máme opravdu náhodný výběr z daného rozdělení. Hlavní výhodou této metody je jednoduchost a pochopitelnost. Další velkou výhodou je konzistence výběrových momentů. Pokud jsou funkce μ_r spojitě funkce parametru, pak obvykle snadno ukážeme konzistenci momentových odhadů.

Cvičení 6.13. Bud' $X_1, \dots, X_n$ náhodný výběr z exponenciálního rozdělení s hustotou $f(x) = \lambda e^{-\lambda x}$ pro $x > 0$ a $f(x) = 0$ jinak. Najděte odhad parametru $\lambda > 0$ momentovou metodou a zjistěte jeho vlastnosti.

Protože parametr je jednorozměrný, stačí jediná momentová rovnice obsahující λ jako neznámou. Protože $E X = 1/\lambda$ (ověřte!), je momentovou rovnicí a jejím řešením

$$\overline{X}_n = \frac{1}{\hat{\lambda}} \Rightarrow \hat{\lambda} = \frac{1}{\overline{X}_n}.$$

Ze zákona velkých čísel víme, že $\bar{X}_n \xrightarrow{P} 1/\lambda$ a protože $1/x$ je funkce spojitá na intervalu $(0, \infty)$, tak použitím věty o spojitém zobrazení ověříme $1/\bar{X}_n \xrightarrow{P} \lambda$, odhad je tedy konzistentní.

Nestrannost je složitější. Na první pohled je vidět, že funkce $1/x$ je konvexní a proto z Jensenovy nerovnosti plyne

$$E \frac{1}{\bar{X}_n} \geq \frac{1}{E \bar{X}_n} = \lambda,$$

a protože funkce $1/x$ je ryze konvexní, rovnost nenastává. My však dokonce ani nevíme, jestli $E 1/\bar{X}_n$ je konečná (je určitě > 0 , takže existuje, konečná či nekonečná). Pokud je konečná, je možné, že k opravě na nestranný odhad stačí málo, podobně jako u výběrového rozptylu. K tomu, abychom dokázali spočítat $E 1/\bar{X}_n$, potřebujeme znát rozdělení náhodné veličiny $\sum X_i$. V kapitole o náhodných vektorech jsme si ukázali, že spočítat distribuční funkci součtu dvou náhodných veličin umíme. Mohli bychom tedy postupovat indukcí a odvodit distribuční funkci součtu n náhodných veličin. Později si také ukážeme, jak určit hustotu součtu. Tím se však teď nezabývejme a použijme známou skutečnost, že v tomto případě je hustota součtu $Y = \sum X_i$ rovna

$$f_Y(y) = \begin{cases} \frac{\lambda^n y^{n-1}}{(n-1)!} e^{-\lambda y} & y > 0 \\ 0 & y < 0. \end{cases}$$

Proto pro $n > 1$

$$E \frac{1}{\bar{X}_n} = E \frac{n}{Y} = \int_0^\infty \frac{n}{y} \frac{\lambda^n y^{n-1}}{(n-1)!} e^{-\lambda y} dy = \frac{n\lambda}{n-1} \int_0^\infty \frac{\lambda^{n-1} y^{n-2}}{(n-2)!} e^{-\lambda y} dy = \frac{n\lambda}{n-1}.$$

Pro $n = 1$ je střední hodnota nekonečná. Vidíme, že odhad nestranný není, ale jeho oprava na nestranný je snadná. Odhad momentovou metodou jednoduše vynásobíme hodnotou $(n-1)/n$ a tím dostaneme nestranný odhad⁶. $\diamond$

Cvičení 6.14. Uvažujme rozdělení s dvěma parametry, konkrétně s hustotou $f(x) = \lambda e^{-\lambda(x-a)}$ pro $x > a$ a $f(x) = 0$ jinak. Najděte odhad parametrů a a $\lambda > 0$ momentovou metodou a zjistěte jeho vlastnosti.

Jedná se o obměnu předchozího příkladu posunutím náhodných veličin o konstantu a . Protože nyní máme dva parametry, budeme pochopitelně potřebovat dvě rovnice. Označíme-li X náhodnou veličinu s hustotou f , tak snadno ověříme

$$E X = a + \frac{1}{\lambda}, \quad E X^2 = \frac{2}{\lambda^2} + \frac{2a}{\lambda} + a^2.$$

Máme-li k dispozici náhodný výběr $X_1, \dots, X_n$, dostaneme dvě momentové rovnice

$$\hat{\mu}_1 = \bar{X}_n = \hat{a} + \frac{1}{\hat{\lambda}}, \quad \hat{\mu}_2 = \frac{2}{\hat{\lambda}^2} + \frac{2\hat{a}}{\hat{\lambda}} + \hat{a}^2.$$

⁶Pokud bychom však neměli náhodný výběr, například pokud by náhodné veličiny $X_1, \dots, X_n$ nebyly nezávislé, ale pouze nekorelované, pak nemáme správně určené rozdělení Y nedostaneme nestranný odhad ani pomocí uvedené opravy. Přesto odhad díky platnosti zákona velkých čísel a věty o spojitém zobrazení zůstává konzistentní, s opravou i bez. Bez platnosti zákona velkých čísel však nemáme zaručenu ani konzistenci.

Je vidět, že $\widehat{\mu}_2 - (\widehat{\mu}_1)^2 = 1/\widehat{\lambda}^2$, což odpovídá i skutečnosti $\text{var } X = 1/\lambda^2$. Odhadem parametru λ momentovou metodou je proto

$$\widehat{\lambda} = \frac{1}{\sqrt{\widehat{\mu}_2 - (\widehat{\mu}_1)^2}}.$$

Dosazením do první momentové rovnice dostaneme i momentový odhad parametru a , kterým je

$$\widehat{a} = \widehat{\mu}_1 - \sqrt{\widehat{\mu}_2 - (\widehat{\mu}_1)^2}.$$

◊

Odhad však je *nejednoznačný* v tom smyslu, že můžeme mít více vhodných odhadů téhož parametru. Toto je dobré mít na paměti vždy, když s odhadem pracujeme. Spolu s hodnotou odhadu je vždy správné sdělit i metodu, kterou jsme odhad konstruovali.

Cvičení 6.15. Vraťme se k předchozímu příkladu. Ve cvičení 6.11 jsme viděli, že parametr a také můžeme odhadnout minimem z pozorování, což je konzistentní odhad parametru a (na hodnotě parametru λ přitom konzistence nezávisí). Pokud volíme $\widehat{a} = X_{(1)}$, pak z momentové rovnice $\overline{X}_n = \widehat{a} + 1/\widehat{\lambda}$ dostaneme odhad

$$\widehat{a} = X_{(1)}, \quad \widehat{\lambda} = \frac{1}{\overline{X}_n - X_{(1)}}.$$

◊

Jak se rozhodnout mezi více odhady? Pokud jsme schopni spočítat rozptyl odhadů, je dobré použít vždy ty s menším rozptylem. Zároveň by odhad měl být pokud možno nestranný, alespoň asymptoticky, určitě by měl být konzistentní. Odhad s nulovým rozptylem bývá neúčinný, je to podobné jako bychom na otázku kolik je hodin odpovídali vždy „osm“. Rozptyl takového odhadu je nulový a dvakrát denně je naprosto přesný. Žádná další pozitiva tohoto odhadu nenalézáme, kromě jeho početní nenáročnosti. U některých odhadů může hrát roli i náročnost numerických výpočtů, například při řešení soustavy rovnic vyžadující postupy numerické matematiky, případně při hledání řešení optimalizační úlohy.

Mezi další oblíbené metody odhadu patří metoda maximální věrohodnosti, metoda nejmenších čtverců, ale i další metody závislé na typu úlohy. Tato problematika však již přesahuje rámec přednášky.

*6.5. Histogram: odhad hustoty spojitého rozdělení

Empirické rozdělení je vždy diskrétní. Zatímco u empirické distribuční funkce toto není na překážku a empirická distribuční funkce je vhodným odhadem skutečné distribuční funkce, u spojitých náhodných veličin nastává potíž a odhad hustoty se stává svébytným problémem.

Pro diskrétní náhodnou veličinu je empirické rozdělení dáno empirickými četnostmi hodnot, tedy pro náhodný výběr $X_1, \dots, X_n$ můžeme bez obav definovat odhad hustoty předpisem

$$\widehat{p}_{n,s} = \frac{1}{n} \sum_{i=1}^n \chi(X_i = s) = \widehat{F}_n(s) - \widehat{F}_n(s-),$$

$\widehat{p}_{n,s}$ je tedy přímo odhadem pravděpodobnosti

$$p_s = P[X = s] = F(s) - F(s-).$$

Vzhledem k vlastnostem distribuční funkce diskretní náhodné veličiny a empirické distribuční funkce platí pro diskretní náhodnou veličinu $E \widehat{p}_{n,s} = p_s$. Opravdu, nechť $P[X = s] > 0$. Pak existuje největší $r < s$ takové, že $P[X = r] > 0$ a $P[r < X < s] = 0$. Proto $p_s = F(s) - F(r)$ a $\widehat{p}_{n,s} = \widehat{F}_n(s) - \widehat{F}_n(r)$. Ze zákona velkých čísel navíc platí konzistence tohoto odhadu, $\widehat{p}_{n,s} \xrightarrow{P} p_s$.

Pro spojitou náhodnou veličinu sice dostaneme také „správnou“ střední hodnotu, $E \widehat{p}_{n,s} = 0 = F(s) - F(s-)$, ale nikoliv výsledek, který bychom chtěli, tedy $E \widehat{p}_{n,s} = f(s) = F'(s)$ (v bodech, kde derivace F existuje).

Problém tak nastává s empirickou hustotou spojitě náhodné veličiny, pro kterou nemáme přirozenou definici. Mohli bychom zkusit nahradit empirickou distribuční funkci nějakou spojitou verzí, která bude mít derivaci všude s výjimkou několika „spojovacích“ bodů. Možností, jak $\widehat{F}_n$ udělat spojitou je více, například můžeme uvažovat $\tilde{F}_n$ vzniklou tak, že po částech lineárně propojíme hodnoty $\widehat{F}_n$ v bodech skoků. Až na body skoků původní funkce $\widehat{F}_n$ má $\tilde{F}_n$ nenulovou po částech konstantní derivaci všude tam, kde je různá od nuly či jedné. Jednotlivé obdélníčky pod empirickou hustotou mají obsah odpovídající relativní četnosti hodnoty pravého krajního bodu intervalu v náhodném výběru, pro spojitou náhodnou veličinu obvykle $1/n$. Takto vzniklá empirická hustota je velice neuspořádaná a navíc se hranice konstantních částí mění s každým pozorováním. Přesto se můžeme tímto odhadem hustoty inspirovat a navrhnout jiný odhad přímo z dat bez použití empirické distribuční funkce.

Histogram zkonstruujeme tak, že zvolíme vhodně intervaly možných hodnot náhodné veličiny X , řekněme $[a_0, a_1), [a_1, a_2), \dots, [a_{k-1}, a_k]$, kde $-\infty < a_0 < \dots < a_k < \infty$. Zjistíme počet členů náhodného výběru $X_1, \dots, X_n$ v každém intervalu a určíme (konstantní) hodnotu $\widehat{f}_n$ pro každý interval. Uvažujme například interval $[a_i, a_{i+1})$. Řekněme, že pro n_i z n hodnot $X_1, \dots, X_n$ platí $a_i \leq X_j < a_{i+1}$ (a_0 a a_k volíme tak, aby platilo $\sum n_i = n$). Obdélník o délkách stran $a_{i+1} - a_i$ a $\widehat{f}_n(a_i)$ má mít plochu n_i/n , z čehož plyne volba


$$\widehat{f}_n(x) = \frac{n_i}{n(a_{i+1} - a_i)}, x \in [a_i, a_{i+1}).$$

Z uvedené volby plyne, že $\int_{-\infty}^{\infty} \widehat{f}_n(x) dx = 1$, také $\widehat{f}_n(x) \geq 0$ pro všechna x , jde tedy o hustotu nějaké náhodné veličiny. Tato hustota sice přesně neodpovídá (ani nemůže) empirické distribuční funkci, ale jde o velmi názorné zobrazení rozdělení pozorování do malých oblastí. Pro tuto jednoduchost a názornost je histogram asi nejčastěji používaný odhad hustoty spojitě náhodné veličiny. Příklady histogramů jsou znázorněny na obrázku 6.3.

V „předpočítačových“ dobách byl používán velmi jednoduchý a přesto elegantní náhled na hustotu, obrázek zvaný *lodyha s listem* (stem-and-leaf plot). Spočívá v tom, že data rozdělíme na stejné intervaly, obvykle tak, že v intervalu se hodnoty liší jen v poslední číslici. Vlevo vypíšeme shodnou část čísla (lodyha) a vpravo vypisujeme koncové číslice (tvar listu). Zde je příklad pro hodnoty 47, 49, 52, 53, ..., 88, 90.

9	0
8	1, 3, 5, 8
7	2, 2, 5, 6, 7, 7
6	4, 5, 7, 7, 9
5	2, 3, 6, 7
4	7, 9

Kromě okamžitého porovnání četností jednotlivých intervalů si můžeme přirozeně přepočítat i jednotlivé výsledky. Je zřejmé, že smysl má lodyha s listy pouze v případě, že jednotlivé intervaly jsou stejně dlouhé, aby porovnání četností v nich mělo kýžený efekt. Tento diagram není vhodný pro velmi rozsáhlé náhodné výběry, ale i dnes najde své uplatnění pro přehledné znázornění náhodných výběrů o rozsahu desítek až malých stovek.




Obrázek 6.3. Histogramy zkonstruované pro jeden náhodný výběr o rozsahu $n = 100$ ze standardního normálního rozdělení pro různé nastavení počtu intervalů.

Volba šířky a počtu intervalů histogramu (i lodyhy s listem) je poměrně zásadní, viz obrázek 6.3, a je předmětem mnoha studií. Obvykle jde o kompromis

mezi dostatečnou *lokalitou* zaručenou úzkými intervaly na jedné straně, a *malou variabilitou* výšky sousedních sloupečků, což naopak zaručují široké intervaly. Standardní Scottovo pravidlo říká, že délka intervalů by měla být okolo $3,5S_n n^{-1/3}$, kde n je rozsah náhodného výběru a S_n je odmocnina z výběrového rozptylu (výběrová směrodatná odchylka)⁷.

Porovnáním histogramu a teoretické hustoty můžeme, podobně jako Rutherford, dojít k závěru, že model a pozorování vykazují značný nesoulad, viz obrázek 6.4. Pokud po důkladné kontrole provedení experimentu nenajdeme žádná pochybení, můžeme zpochybnit teoretické předpoklady modelu a možná i posunout poznání o kousek dále.



Obrázek 6.4. Zvažujeme-li pro naše data model normálního rozdělení, je rozumné porovnat histogram s hustotou normálního rozdělení (červená křivka), jež hož parametry odpovídají výběrovému průměru a výběrovému rozptylu našich dat. Na levém obrázku histogram koresponduje s proloženou křivkou a normální model se tedy zdá být rozumný pro tato data. Naopak na obrázku vpravo lze pozorovat značný nesoulad mezi histogramem a hustotou normálního rozdělení, což indikuje, že v tomto případě není rozumné uvažovat normální model.

Cvičení 6.16. Vygenerujte 100 hodnot z libovolného spojitého rozdělení a srovnajte data podle velikosti. Potom s pomocí počítače můžete experimentovat s počtem intervalů, do kterých data rozdělíte a s dělicími body těchto intervalů a nechat si vykreslit výšky sloupečků. Můžete k tomu použít také některou ze stránek nabízejících vykreslení histogramu⁸, případně volně šířené prostředí pro výpočty R⁹.

Všímejte si změn ve tvaru histogramu. Poté můžete zkusit vygenerovat rozsáhlejší náhodné výběry a pozorovat vliv rozsahu výběru na výsledek. ♠

⁷Dnes je často používán také jádrový odhad hustoty, což můžeme velmi zjednodušeně popsat jako vyhlazený histogram. O bohatosti tohoto problému je možné se přesvědčit zadáním „kernel density estimation“ do vyhledávače.

⁸např. <https://www.socscistatistics.com/descriptive/histograms/default.aspx>

⁹Hlavní stránka projektu R je www.r-project.org. Pěkné grafické rozhraní pro R je zdarma pro běžné používání, ke stažení je Rstudio zde: <https://rstudio.com/>

Problémy k dalšímu procvičení

1. Lze předpokládat, že počet gólů vstřelených v jednom fotbalovém zápase v jedné konkrétní soutěži se řídí Poissonovým rozdělením, tj.

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots,$$

kde $\lambda > 0$ je neznámý parametr. Dále lze uvažovat, že počty gólů vstřelené v různých zápasech jsou vzájemně nezávislé a stejně rozdělené náhodné veličiny. Budeme zaznamenávat počty gólů v n zápasech a naměříme tak veličiny $X_1, \dots, X_n$.

- (a) Nalezněte odhad $\hat{\lambda}_n$ parametru λ momentovou metodou.
- (b) Rozhodněte, zda je odhad $\hat{\lambda}_n$ nestranný a konzistentní.
- (c) Uvažujte odhady $\check{\lambda}_n = (X_1 + X_n)/2$ a $\tilde{\lambda}_n = \frac{1}{n-1} \sum_{i=1}^n X_i$. Zjistěte, zda jsou tyto odhady nestranné a konzistentní odhady λ . Který z nich je rozumnější?

Dále nás bude zajímat odhad pravděpodobnosti, že v daném zápase nepadne ani jeden gól, tj. odhad $p_0 = P(X_1 = 0) = e^{-\lambda}$. Uvažujme následující dva odhady p_0 :

$$W_n = \frac{1}{n} \sum_{i=1}^n \chi(X_i = 0), \quad V_n = e^{-\bar{X}_n}.$$

- (d) Vyšetřete vlastnosti odhadů W_n a V_n
 - (e) Obdrželi jsme následující hodnoty:
0, 3, 1, 4, 1, 3, 2, 2, 2, 3, 3, 1, 3, 2, 3, 5, 3, 4, 5, 3.
Spočtěte pro ně odhad λ i odhady p_0 .
 - (f) Navrhněte odhad pravděpodobnosti, že v zápase padne přesně 6 gólů.
Spočtěte pro výše uvedená data.
2. Nechť $X_1, X_2, \dots$ jsou nezávislé náhodné veličiny s rovnoměrným rozdělením na intervalu $[0, a]$, kde $a > 0$ je neznámý parametr.
- (a) Odhadněte parametr a momentovou metodou.
 - (b) Rozhodněte, zda je odhad z (a) nestranný a konzistentní.
3. Nechť $X_1, \dots, X_n$ jsou nezávislé náhodné veličiny s alternativním rozdělením s parametrem $p \in (0, 1)$.
- (a) Odhadněte p momentovou metodou. Je výsledný odhad nestranný a konzistentní?
 - (b) Je $\hat{p}_n = \frac{1}{n-1} \sum_{i=1}^n X_i^2$ konzistentní a nestranný odhad parametru p ?
 - (c) Je $\tilde{p}_n = X_1 - X_2 + X_3$ konzistentní a nestranný odhad parametru p ?
 - (d) Vyšetřete, zda je $\bar{X}_n(1 - \bar{X}_n)$ nestranný a konzistentní odhad parametrické funkce $p(1 - p)$.
4. Uvažujte náhodný výběr $X_1, \dots, X_n$ z rozdělení s hustotou

$$f(x) = \begin{cases} \frac{p}{x^{p+1}} & x \geq 1, \\ 0 & \text{jinak,} \end{cases}$$

kde $p > 2$ je neznámý parametr.

(a) Odhadněte parametr p momentovou metodou.

(b) Vyšetřete vlastnosti odhadu z (a).

(c) Uvažujte odhad p ve tvaru $U_n = \frac{n}{\sum_{i=1}^n \log X_i}$. Zjistěte, zda se jedná o konzistentní odhad.

(d) Navrhněte alespoň dva různé konzistentní odhady $P(X_i > 2)$.

5. V rybníce plave 100 rybiček, z nichž a je zlatých, kde $a > 0$ je neznámé číslo. Rádi bychom odhadli a . Budeme uvažovat následující postupy a odhady.

(a) Vylovíme postupně s vrácením 10 rybiček a pro každou zaznamenáme, zda je zlatá. Odhadněte na základě tohoto pokusu neznámé a . Dále vyšetřete střední hodnotu a rozptyl tohoto odhadu.

Označme jako $X_i = \chi(i - \text{tá vylovená rybička je zlatá})$. Pak $X_1, \dots, X_{10}$ jsou nezávislé a stejně rozdělené.

(b) Nyní vylovíme najednou 10 rybiček (tj. bez vrácení). Odhadněte na základě tohoto pokusu neznámé a a opět vyšetřete střední hodnotu a rozptyl tohoto odhadu.

Volíme-li X_i jako v (a), pak veličiny X_i jsou stejně rozdělené, ale nejsou nezávislé. Je-li nyní Y počet vylovených zlatých rybiček, pak rozdělení Y je hypergeometrické (viz také příklad 2 z kapitoly 2, momenty tohoto rozdělení byly úkolem cvičení 5 v kapitole 3).

(c) Nyní budeme postupně lovit rybičky s vrácením, ale pouze dokud nevylovíme první zlatou rybičku. Zaznamenáme si počet pokusů. Navrhněte odhad a z těchto dat.

Označte si Z počet všech pokusů. Pak $Z-1$ má zjevně geometrické rozdělení s parametrem $p = a/100$. K dispozici máte jednu realizaci veličiny Z a z ní zkonstruuje momentový odhad.

Principy statistické inference

Jednou ze součástí práce s daty je vyvracení hypotéz. Pokud nějaká data jsou v rozporu s očekáváním, pak hypotézu můžeme zpochybnit a po potvrzení i zavrhnout. Newtonova fyzika se tak ukázala jako nepřesná v určitých měřítkách, některé léčivé látky nemají dostatečně průkazný vliv na zdraví a mnoho dalších příkladů každý z nás zná. Co však znamená, že data jsou v rozporu s očekáváním? I když budeme házet naprosto pravidelnou kostkou, v podstatě nikdy nebude empirická četnost všech výsledků rovna $1/6$ a to ani v případě, že počet hodů bude násobkem šesti. Pravděpodobnost toho, že pozorujeme právě sto jedniček, sto dvojek a tak dále v šesti stech hodech je u naprosto symetrické kostky $600!/(6^{100}100!)^6$, což je přibližně¹ $2,46 \cdot 10^{-7}$. Je proto mnohem pravděpodobnější, že pokus neskončí přesně vyváženě. Jaká odchylka empirických četností od teoretických je ještě tolerovatelná a kdy už naopak model zpochybnit? Jednoduchá odpověď² na toto neexistuje², my si zde ukážeme základy statistického rozhodování³. Ukážeme si rozhodnutí o hypotéze o jednorozměrném parametru na základě intervalového odhadu. Předem však zdůrazňujeme, že jde jen o malý a omezený náhled do problematiky.

7.1. Asymptotické intervalové odhady

Odhad neznámého parametru jednoznačnou hodnotou, jako jsme to viděli v úloze bodového odhadu, je užitečný ve chvíli, kdy potřebujeme s odhadem dále pracovat, počítat s ním v modelu, ukázat výsledky. Takovým bodovým odhadem je například odhad volebních preferencí kandidátů do Evropského parlamentu.

Někdy ale potřebujeme vzít do úvahy, že odhad je náhodná veličina a proto je s ním spojena *nejistota*. V takovém případě je možné použít intervalový odhad,

¹Podle výpočtu provedeného na www.wolframalpha.com

²Sama otázka je těžká. Navíc do hry vstupují důsledky špatného rozhodnutí, které nemůžeme úplně pominout; jiná odchylka u kostky může být tolerována doma při hře *Člověče, nezlob se*, a jiná v *doupěti hazardních hráčů*.

³Tedy rozhodování (učení) na základě experimentu, pozorování náhodných dat

tedy odhad jehož výsledkem není jedna hodnota, ale interval hodnot. Intervalový odhad se také může hodit při zkoumání otázek na hodnotu parametru. Ptáme-li se, zda na kostce padá jednička s pravděpodobností $p_1 = 1/6$, je nám jasné, že jen s malou pravděpodobností bude relativní četnost jedniček v experimentu (tedy bodový odhad pravděpodobnosti) *roven přesně* $1/6$ a to i v případě, že skutečně platí $p_1 = 1/6$. Naproti tomu intervalový odhad s *velkou pravděpodobností obsahuje* hodnotu $1/6$, pokud platí $p_1 = 1/6$ (samozřejmě za předpokladu použití vhodné zkounsturovaného intervalového odhadu pro správně provedený experiment).

Pro Bernoulliho pokusy můžeme s pomocí centrální limitní věty zkusit *přibližně určit* neznámou pravděpodobnost p . Vyjít můžeme ze cvičení 5.31. Víme-li, kolik pokusů n jsme učinili a kolik úspěchů u jsme zaznamenali, pak pro každé p víme, jaká je pravděpodobnost, že náhodná veličina U (počet úspěchů) bude „blízko“ zaznamenané hodnoty u . Co to však znamená *blízko*?

Zvolíme-li pevně délku $2d$ intervalu $(a - d, a + d)$, pak v normálním rozdělení $N(0, 1)$ má mezi intervaly s délkou $2d$ největší pravděpodobnost interval $(-d, d)$. O tom se snadno přesvědčíme pohledem na hustotu normálního rozdělení, neboť pravděpodobnost intervalu je dána integrálem z hustoty přes tento interval. Pravděpodobnost intervalu $(-d, d)$ je $\Phi(d) - \Phi(-d) = 2\Phi(d) - 1$. Má-li tento interval mít předepsanou pravděpodobnost alespoň $1 - \alpha$, pak d zvolíme s ohledem na tento požadavek, tedy $d_\alpha = \Phi^{-1}(1 - \alpha/2)$. Asymptoticky dostáváme

$$P \left[-d_\alpha \leq \frac{U - np}{\sqrt{np(1-p)}} \leq d_\alpha \right] = P \left[(U - np)^2 \leq d_\alpha^2 np(1-p) \right] \rightarrow 1 - \alpha$$

Odtud můžeme dostat řešením kvadratické rovnice $(U - np)^2 = d_\alpha^2 np(1-p)$ s neznámou p dva kořeny závislé $k_{1,2}(U, n, d_\alpha)$ závislé na hodnotách U, n a d (tyto kořeny nevycházejí v moc elegantním tvaru, ale existují vždy dva). Platí tedy

$$P[k_1(U, n, d_\alpha) \leq p \leq k_2(U, n, d_\alpha)] \rightarrow 1 - \alpha.$$

Uvědomme si hlavně, že náhodnou veličinou je zde U , čili náhodné jsou *meze intervalu* $[k_1(U, n, d_\alpha), k_2(U, n, d_\alpha)]$. Tento interval v sobě tedy obsahuje neznámou hodnotu p s pravděpodobností blížící se $1 - \alpha$, jde tedy o nějaký *intervalový odhad*.

Ukázali jsme si hlavní myšlenku (asymptotického) intervalového odhadu. Pokusme se opět intervalový odhad definovat v matematickém smyslu. Konkrétní naplnění této definice závisí vždy na úloze, kterou řešíme.

Definice 7.1 (Intervalový odhad). Bud' $X_1, \dots, X_n$ náhodný výběr z $P_\theta, \theta \in \Theta \subset \mathbb{R}$ neznámý parametr⁴. *Intervalovým odhadem* nazveme dvojici funkcí $L(X_1, \dots, X_n) \rightarrow \mathbb{R}$ a $U(X_1, \dots, X_n) \rightarrow \mathbb{R}$, jejichž předpis nezávisí na θ a které splňují $P[L(X_1, \dots, X_n) \leq \theta \leq U(X_1, \dots, X_n)] \geq 1 - \alpha$ pro každé θ , je-li θ skutečnou hodnotou parametru. Interval $[L(X_1, \dots, X_n), U(X_1, \dots, X_n)]$ nazýváme *intervalem spolehlivosti* pro parametr θ s hladinou spolehlivosti $1 - \alpha$.

⁴Omezili jsme se na případ reálného jednorozměrného parametru. Odhady pro vícerozměrné parametry jsou možné, místo intervalového odhadu však musíme definovat takzvané konfidenční množiny což přináší další úkol v hledání tvaru této množiny—kartézský součin jednorozměrných intervalů obvykle není vhodný.

Klíčovou vlastností je opět nezávislost krajních bodů intervalu na neznámých charakteristikách rozdělení. Důležité je pochopení skutečnosti, že interval spolehlivosti pokrývá s danou pravděpodobností neznámou hodnotu parametru θ . Interpretace, že parametr θ se vyskytuje s určitou pravděpodobností v intervalu spolehlivosti je zavádějící, neboť vyvolává dojem, že konstantní hodnotou je interval spolehlivosti a parametr je náhodný.

Najít obecně intervalový odhad není snadné. Pokusíme se zformulovat obecný návod, jak v mnoha případech lze postupovat. V každém případě je ale nutné vycházet z úlohy a z předpokladů modelu rozdělení sledované náhodné veličiny. Snadné a obecné je odvození intervalu spolehlivosti pro střední hodnotu pomocí centrální limitní věty s využitím Sluckého věty. Použitím delta věty je pak možné odvodit i intervalové odhady pro spojitou diferencovatelnou funkci střední hodnoty.

Na odvození intervalového odhadu pro neznámou střední hodnotu si ukážeme hlavní myšlenku konstrukce.

Cvičení 7.2. Bud' $X_1, \dots, X_n$ náhodný výběr z rozdělení s nenulovým konečným rozptylem $\text{var } X = \sigma^2$. Najděte pro neznámou střední hodnotu intervalový odhad s hladinou spolehlivosti 0,95.

Víme, že vhodným *bodovým odhadem* střední hodnoty je výběrový průměr. Pro výběrový průměr platí centrální limitní věta, konkrétně použijeme její tvar

$$P \left[\sqrt{n} \frac{|\bar{X}_n - EX|}{\sigma} \leq q \right] = P \left[\sqrt{n} \frac{\bar{X}_n - EX}{\sigma} \leq q \right] - P \left[\sqrt{n} \frac{\bar{X}_n - EX}{\sigma} \leq -q \right] \rightarrow \Phi(q) - \Phi(-q),$$

kde na pravé straně chceme hodnotu 0,95. Ze symetrie normovaného normálního rozdělení plyne $\Phi(q) = 1 - \Phi(-q)$ a proto hledáme q tak, aby $0,95 = 2\Phi(q) - 1$, neboli $\Phi(q) = 0,975$. Z tabulek kvantilové funkce normovaného normálního rozdělení zjistíme, že v tomto případě $q \doteq 1,96$. Snadnými úpravami dostaneme

$$0,95 \doteq P \left[\sqrt{n} \frac{|\bar{X}_n - EX|}{\sigma} \leq 1,96 \right] = P \left[\bar{X}_n - 1,96 \left(\frac{\sigma^2}{n} \right)^{1/2} \leq EX \leq \bar{X}_n + 1,96 \left(\frac{\sigma^2}{n} \right)^{1/2} \right].$$

Obvykle neznáme rozptyl σ^2 , ale pouze jeho konzistentní odhad S_n^2 , protože $\sigma^2/S_n^2 \xrightarrow{P} 1$ a použitím Sluckého věty dostáváme konvergenci v distribuci

$$\sqrt{n} \frac{\bar{X}_n - EX}{S_n} = \sqrt{n} \frac{\bar{X}_n - EX}{\sigma} \frac{\sigma}{S_n} \xrightarrow{d} N(0, 1).$$

Proto platí

$$0,95 \doteq P \left[\bar{X}_n - 1,96 \left(\frac{S_n^2}{n} \right)^{1/2} \leq EX \leq \bar{X}_n + 1,96 \left(\frac{S_n^2}{n} \right)^{1/2} \right]$$

a hledaným intervalovým odhadem je interval $[\bar{X}_n - 1,96(S_n^2/n)^{1/2}, \bar{X}_n + 1,96(S_n^2/n)^{1/2}]$. Tento náhodný interval má asymptotickou spolehlivost 0,95, což znamená, že pro dostatečně velká n obsahuje neznámou hodnotu EX s pravděpodobností 0,95. $\diamond$

Intervalový odhad střední hodnoty je symetrický kolem výběrového průměru $\bar{X}_n$, což je důsledkem symetrie normálního rozdělení. Další náhodnou veličinou

zahrnutou v intervalovém odhadu je výběrový rozptyl. Obě tyto hodnoty, výběrový průměr a výběrový rozptyl, jsou konzistentními bodovými odhady střední hodnoty a rozptylu, pokud je rozptyl nenulový a konečný. Z tvaru odhadu vidíme, že intervalový odhad se zužuje (s ohledem na náhodnost výběrového rozptylu „jen“ v pravděpodobnosti) s roztoucím rozsahem výběru n . Naopak intervalový odhad je širší, pokud zvyšujeme jeho hladinu spolehlivosti. Obvyklými volbami pro spolehlivost intervalového odhadu jsou hodnoty 0,9, 0,95 a 0,99. Volba hladiny spolehlivosti musí být provedena před dalšími kroky výpočtu, abychom neovlivnili skutečnost, zda intervalový odhad obsahuje či neobsahuje konkrétní hodnotu⁵. Obvykle se snažíme najít vhodný kompromis mezi dostatečně úzkým intervalovým odhadem (široký interval má malou informativní cenu) a dostatečnou hladinou spolehlivosti (závěry učiněné z odhadu s malou spolehlivostí nemají velkou váhu). U každého intervalového odhadu je nutné říci jeho hladinu spolehlivosti a rozsah výběru.

Cvičení 7.3. Předpokládejme posloupnost nezávislých náhodných veličin s neznámým rozdělením P_X . Chceme odhadnout pravděpodobnost $p_1 = P[X > 1]$ a odvodit asymptotický intervalový odhad pro p_1 . Víme, že $p_1 = 1 - F(1)$, tedy že můžeme použít empirickou distribuční funkci $\hat{F}_n(1)$, která je konzistentním a nestranným odhadem. Navíc ale také platí asymptotická normalita e.d.f.

Protože $\hat{F}_n(x) = 1/n \sum \chi(X_i \leq x)$, jde o aritmetický průměr nezávislých stejně rozdělených náhodných veličin. A pro ten platí CLV, pokud máme zaručen nenulový a konečný rozptyl, což zde triviálně platí, neboť charakteristická funkce množiny χ nabývá jen hodnot 0 a 1. S pomocí věty 4.6 víme, že rozptyl $\text{var } \hat{F}_n(x) = n^{-1} F(x)(1 - F(x))$. Tím máme vše připraveno pro použití CLV.

$$P \left[\frac{\hat{F}_n(x) - F(x)}{\sqrt{F(x)(1 - F(x))}} \sqrt{n} \leq x \right] \rightarrow \Phi(x),$$

což s pomocí snadných operací a s využitím Sluckého věty po nahrazení rozptylu $F(x)(1 - F(x))$ jeho konzistentním odhadem $\hat{F}_n(x)(1 - \hat{F}_n(x))$ vede k asymptotickému intervalovému odhadu s hladinou spolehlivosti $1 - \alpha$ ve tvaru

$$\left[\hat{F}_n(x) - \sqrt{\frac{\hat{F}_n(x)(1 - \hat{F}_n(x))}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right), \hat{F}_n(x) + \sqrt{\frac{\hat{F}_n(x)(1 - \hat{F}_n(x))}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right].$$

Snadnou úpravou pak dostaneme asymptotický intervalový odhad pro $1 - F(1)$.

Přidejme předpoklad, že distribuční funkce F odpovídá exponenciálnímu rozdělení. Pak víme, že $1 - F(1) = e^{-\lambda}$. Víme, že střední hodnota $E X = 1/\lambda$ a můžeme tedy uvažovat odhad s využitím asymptoticky normálního odhadu pro $1/\lambda$. Platí

$$P \left[\frac{\bar{X}_n - \lambda^{-1}}{\sqrt{\lambda^{-2}}} \sqrt{n} \leq x \right] \rightarrow \Phi(x), \text{ což znamená } \sqrt{n}(\bar{X}_n - \lambda^{-1}) \xrightarrow{d} N(0, \lambda^{-2}).$$

⁵Například chceme-li, aby intervalový odhad obsahoval hodnotu 0, pak toho „vhodnou“ volbou hladiny spolehlivosti vždy dosáhneme a naopak. To však již zavání nepřipustnou manipulací s výsledky.

S využitím delta věty na funkci $g(u) = \exp(-u^{-1})$ dostaneme

$$\sqrt{n}(\exp(-1/\bar{X}_n) - e^{-\lambda}) \xrightarrow{d} N(0, \lambda^2 e^{-2\lambda}), \text{ neboli } \sqrt{n}(\exp(-1/\bar{X}_n)e^{\lambda} - 1) \xrightarrow{d} N(0, \lambda^2),$$

neboť $(g'(u))^2 = u^{-4} \exp(-u^{-1})$. Odtud je konstrukce intervalového odhadu již otázkou snadné úpravy a použití Sluckého věty pro neznámý rozptyl λ^2 . $\diamond$

Algoritmický návod jak obecně postupovat při konstrukci intervalového odhadu není. Shrňme si však jednotlivé kroky, které můžeme při konstrukci použít.

- (1) Vyjděme z vhodného bodového odhadu. Ten podle požadavků nezávisí na neznámých charakteristikách rozdělení. Vhodným odhadem míníme zejména konzistentní odhad.
- (2) Na základě konstrukce konzistentního bodového odhadu hledáme náhodnou veličinu $H(X_1, \dots, X_n, \theta)$, jejíž rozdělení (asymptoticky) nezávisí na θ , k čemuž často můžeme použít centrální limitní větu. Příklady jsme viděli výše.
- (3) Najdeme kvantily $l(\alpha), u(\alpha)$ rozdělení náhodné veličiny H takové, že $P[l(\alpha) \leq H \leq u(\alpha)] \geq 1 - \alpha$. Je-li (asymptotické) rozdělení H normální $N(0, 1)$, pak použijeme kvantily $l(\alpha) = q(\alpha/2) = \Phi^{-1}(\frac{\alpha}{2})$ a $u(\alpha) = q_{1-\alpha/2} = \Phi^{-1}(1 - \frac{\alpha}{2})$.
- (4) Ekvivalentními algebraickými úpravami nebo řešením (ne)rovnice vyjádříme neznámý parametr, abychom přešli od nerovností $l(\alpha) \leq H \leq u(\alpha)$ k *ekvivalentním* nerovnostem

$$L(X_1, \dots, X_n, l(\alpha), u(\alpha)) \leq \theta \leq U(X_1, \dots, X_n, l(\alpha), u(\alpha)).$$

Někdy musíme použít ještě Sluckého větu a delta větu. Příklady jsme opět uvedli výše.

7.2. Intervalový odhad pro rozdíl dvou středních hodnot

Jednou z nejčastějších úloh je porovnání dvou populací. Můžeme tak sledovat výsledky testu, fyzické testy, nebo změnu zdravotního stavu u dvou populací. Chceme zjistit jak se od sebe tyto dvě populace „v průměru“ liší, jaký je rozdíl jejich středních hodnot. K tomu je nejlepší získat dva nezávislé náhodné výběry, jeden z každé populace. Kromě bodového odhadu rozdílu nás bude zajímat především intervalový odhad pro rozdíl středních hodnot. Při dostatečně velké hladině spolehlivosti totiž pak můžeme vyloučit, nebo naopak nevyloučit, nějakou významnou hodnotu rozdílu.

Sledujeme-li počet dní do vyléčení u skupiny pacientů s novým způsobem léčby oproti pacientům s dosavadním způsobem léčby. Předpokládáme, že průměrná doba léčby novou metodou je μ_N a průměrná doba léčby původní metodou je μ_S . Na základě náhodných výběrů jsme schopni odvodit intervalový odhad pro $\mu_N - \mu_S$ a byli bychom rádi, kdyby intervalový odhad pro rozdíl průměrné doby byl podmnožinou záporných čísel, tedy neobsahoval nulu. Pokud totiž intervalový odhad s dostatečnou hladinou spolehlivosti nulu obsahuje, nemůžeme vyloučit, že průměrná doba léčby se významně neliší. Slovo *významně* zde znamená, že rozdíl je natolik patrný, že jej můžeme zobecnit na celou populaci, ovšem vždy

je na místě dodat hladinu spolehlivosti a okolnosti experimentu⁶. Hladinu spolehlivosti musíme volit předem, jinak totiž hrozí ovlivnění závěrů experimentu tím, že bychom volili takovou hladinu spolehlivosti, aby podle potřeby nula byla či nebyla v intervalovém odhadu obsažena.

Obvyklé předpoklady a značení jsou:

- (1) Existují dvě populace (skupiny) u nichž se zajímáme o nějakou hodnotu—náhodnou veličinu. Například kvalitu piva, rychlost výpočtu, rozměr, krevní tlak, Náhodné veličiny příslušné rozdělení těchto dvou populací označíme X a Y .
- (2) Náhodný výběr z populace 1 označíme $X_1, \dots, X_n$, náhodný výběr z populace 2 označíme $Y_1, \dots, Y_n$. Shoda rozsahu obou výběrů vede k velkému zjednodušení řešení problému. Nestejné rozsahy výběrů m a n jsou možné, ale pokud chceme konstruovat asymptotický intervalový odhad, musíme klást předpoklady na konvergenci podílu m/n . K tomu se vrátíme v poznámce později.
- (3) Předpokládáme, že oba výběry pochází ze stejného typu rozdělení, lišícího se jen svými parametry. Značíme μ_X střední hodnotu X a μ_Y střední hodnotu Y , podobně σ_X^2 rozptyl X a σ_Y^2 rozptyl Y . Často je předpokládána shoda rozptylů, což značně zjednodušuje postup, my si ukážeme obecnější případ různých (nenulových a konečných) rozptylů.

Z předpokladů plyne, že $X - Y$ je náhodná veličina se střední hodnotou $\mu_X - \mu_Y$ a s rozptylem $\sigma_X^2 + \sigma_Y^2$. Konzistentním bodovým odhadem pro rozdíl $\mu_X - \mu_Y$ je samozřejmě rozdíl výběrových průměrů. Pro výběrové průměry $\bar{X}_n$ a $\bar{Y}_m$ platí

$$E(\bar{X}_n - \bar{Y}_m) = E\bar{X}_n - E\bar{Y}_m = \mu_X - \mu_Y, \quad \text{var}(\bar{X}_n - \bar{Y}_m) = \text{var}\bar{X}_n + \text{var}\bar{Y}_m = \frac{1}{n}(\sigma_X^2 + \sigma_Y^2).$$

Proto můžeme použít centrální limitní větu pro náhodné veličiny $Z_i = X_i - Y_i$ a dostaneme

$$\sqrt{n} \frac{\bar{X}_n - \bar{Y}_n - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2 + \sigma_Y^2}} = \sqrt{n} \frac{\bar{Z}_n - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2 + \sigma_Y^2}} \xrightarrow{d} N(0, 1).$$

Odtud již odvození intervalového odhadu pro rozdíl středních hodnot zvládneme snadno. Neznámé rozptyly σ_X^2 a σ_Y^2 nahradíme jejich konzistentními odhady S_X^2 a S_Y^2 a použijeme Sluckého větu. Dostaneme asymptotickou rovnost

$$P \left[|\bar{X}_n - \bar{Y}_n - (\mu_X - \mu_Y)| \leq \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{S_X^2 + S_Y^2}{n}} \right] \doteq 1 - \alpha$$

a proto asymptotickým intervalovým odhadem rozdílu $\mu_X - \mu_Y$ s hladinou spolehlivosti $1 - \alpha$ je interval

$$\left[\bar{X}_n - \bar{Y}_n - \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{S_X^2 + S_Y^2}{n}}, \bar{X}_n - \bar{Y}_n + \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{S_X^2 + S_Y^2}{n}} \right]$$

⁶Může se stát, že intervalový odhad opravdu neobsahuje nulu a rozdíl tedy prohlásíme za významný s danou hladinou spolehlivosti. Tehdy mluvíme o *statistické významnosti*. Zároveň však tento interval může být natolik úzký a blízký nule, že praktický dopad takového rozdílu je zanedbatelný, tedy z hlediska užitku rozdíl středních hodnot významný není.

Cvičení 7.4. Uvažujme dvě města. Máme rozhodnout, zda děti z obou měst mají stejnou šanci zvládnout test. Předpokládáme že ano a tento předpoklad chceme „potvrdit“. Naše rozhodnutí je ale založené na náhodných veličinách, je tedy také náhodné a můžeme dospět k chybnému zamítnutí předpokladu o stejných šancích, aniž bychom o tom věděli. Stanovme proto největší přípustnou pravděpodobnost chybného odmítnutí stejných šancí a označme ji α . Hodnotu α obvykle volíme 0,05 (případně v rozmezí 0,01 až 0,1, ale volba α je samostatný problém).

Vybereme n dětí z jednoho města a n dětí z druhého města. Musí jít o náhodný výběr. Všechny děti budou psát test. V prvním městě dostaneme výsledky $X_1, \dots, X_n$ (body za test), ve druhém městě $Y_1, \dots, Y_n$. Rozptyl výsledků neznáme a musíme jej odhadnout. Odhadneme též střední bodové zisky v obou městech:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, S_X^2 = \frac{1}{n-1} \sum (X_i - \bar{X}_n)^2, \quad \bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i, S_Y^2 = \frac{1}{n-1} \sum (Y_i - \bar{Y}_n)^2.$$

Spočítáme intervalový odhad pro $\mu_X - \mu_Y$ na hladině spolehlivosti $1 - \alpha$. Pokud $\mu_X = \mu_Y$ pak pravděpodobnost, že intervalový odhad *neobsahuje* 0 je nejvýše α , hodnota pravděpodobnosti, kterou jsme zvolili na začátku. Nepokrývá-li intervalový odhad hodnotu 0, pak zavrhneme hypotézu o stejných průměrných výsledcích dětí ze dvou skupin a řekneme, že děti z těchto měst nemají šanci zvládnout test stejně dobře (a dodáváme „se statistickou významností α “, čímž sdělujeme podstoupené riziko chybného zamítnutí předpokladu $\mu_X - \mu_Y = 0$). $\diamond$

Cvičení 7.5. Intervalový odhad pro rozdíl středních hodnot můžeme použít také pro porovnání pravděpodobností. Pravděpodobnost jakéhokoliv jevu je střední hodnotou indikátoru tohoto jevu, čili střední hodnotou Bernoulliho náhodné veličiny.

Jakožto náruživí hráči RPG hry chceme zjistit, zda na našich dvou oblíbených hracích kostkách (bílé a černé) padá hodnota 6 se stejnou pravděpodobností. Jednoduchou cestou, jak toto zjistit je provést oběma kostkami mnoho hodů a porovnat počty šestek. Opět musíme stanovit malou pravděpodobnost α , řekneme $\alpha = 0,01$ (což je relativně přísná pravděpodobnost vyžadující relativně hodně pokusů). Předpokládejme, že naše trpělivost a čas nám umožní provést každou z kostek 144 hodů. Na bílé kostce jsme hodili šestku ve 22 hodech, na černé ve 26 hodech. Můžeme říci, že se pravděpodobnosti šestek *významně* liší, nebo ne?

Označíme-li X_i indikátory šestky na bílé kostce a Y_i indikátory šestky na černé kostce, pak $E X_i$ je pravděpodobnost šestky na bílé kostce a $E Y_i$ na černé kostce. Zopakujeme dříve uvedenou konstrukci intervalového odhadu. Máme $\bar{X}_{144} - \bar{Y}_{144} = -1/36$, dále

$$S_X^2 = \frac{1}{143} \sum_{i=1}^{144} \left(X_i - \frac{22}{144} \right)^2 = \frac{1}{143} \left(22 \frac{122^2}{144^2} + 122 \frac{22^2}{144^2} \right) = \frac{22 \cdot 122}{143 \cdot 143}, \quad S_Y^2 = \frac{26 \cdot 118}{143 \cdot 144}.$$

Hodnota $\Phi^{-1}(0,995) = 2,576$. Intervalový odhad s hladinou spolehlivosti 0,99 je

$$\left[-\frac{1}{36} - 2,576 \sqrt{\frac{22 \cdot 122 + 26 \cdot 118}{143 \cdot 144^2}}, -\frac{1}{36} + 2,576 \sqrt{\frac{22 \cdot 122 + 26 \cdot 118}{143 \cdot 144^2}} \right] = [-0,141, 0,086].$$

Na hladině spolehlivosti 0,99 tedy neodmítneme předpoklad, že obě kostky hází šestku se stejnou pravděpodobností, protože 0 je v intervalovém odhadu pro rozdíl pravděpodobností. $\diamond$

Samozřejmě můžeme rozhodovat o libovolném rozdílu středních hodnot. Budeme-li předpokládat, že $\mu_X - \mu_Y = \delta$, pak tuto hypotézu zamítneme s hladinou významnosti α , pokud v intervalovém odhadu pro $\mu_X - \mu_Y$ není obsažena hodnota δ .

Asymptotické intervalové odhady mají hladinu spolehlivosti $1 - \alpha$ jen přibližně. Kolik pozorování je potřeba k dobré aproximaci nelze říci univerzálně, ale nemusí jít o tisíce, ani o stovky. Záleží ale také na rozdělení, ke kterému intervalový odhad sestavujeme. V předchozím cvičení jsme sledovali výskyt šestky, tedy relativně častý jev. Pokud bychom chtěli porovnávat velmi malé pravděpodobnosti, měli bychom provést mnohem více pokusů.

Zde uvedené postupy jsou jen drobnou úkázkou velmi základních metod analýzy dat. Jejich hlavní předností je pochopitelnost, minimální předpoklady, snadné použití. Závěry učiněné na základě těchto metod však je dobré používat s vědomím, že jsme nepoužili žádnou z pokročilých metod a mají jen přibližný (asymptotický) charakter. Jediné nástroje, které používáme jsou centrální limitní věta a Sluckého věta, případně delta věta a o rozděleních předpokládáme pouze konečnost rozptylů. Důležitým předpokladem je samozřejmě nezávislost obsažená v pojmu náhodný výběr. Pro vlastní porovnání pravděpodobnosti šestky na dvou kostkách jsou postačující, pro posouzení kvality vakcíny proti koronavirům potřebujeme pokročilé metody a jejich kvalifikované použití.

Tuto kapitolu uzavřeme heuristickou poznámkou o intervalovém odhadu pro rozdíl středních hodnot v případě nestejných rozsahů výběru. Předpokládejme, že máme náhodné výběry $X_1, \dots, X_n$ a $Y_1, \dots, Y_m$. Snadno ověříme rovnost $\text{var}(\bar{X}_n - \bar{Y}_m) = \sigma_X^2/n + \sigma_Y^2/m$. Proto vypadá *samozřejmě* navrhnout intervalový odhad vycházející z „asymptotické normality“ ve tvaru

$$\frac{\bar{X}_n - \bar{Y}_m - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \xrightarrow{d} N(0, 1).$$

Tato konvergence v distribuci však není vůbec zřejmá, už jen proto, že máme dva rozsahy výběrů, n a m . Na druhou stranu, pokud předpokládáme pro rozsahy výběrů $n \rightarrow \infty$ i $m \rightarrow \infty$, centrální limitní věta dává pozitivní výsledky

$$\frac{\bar{X}_n - \mu_X}{\sqrt{\sigma_X^2/n}} \xrightarrow{d} N(0, 1), \quad \frac{\bar{Y}_m - \mu_Y}{\sqrt{\sigma_Y^2/m}} \xrightarrow{d} N(0, 1).$$

Označme $s = \sigma_X^2/\sigma_Y^2$ a přepišme obě posloupnosti do tvaru

$$\begin{aligned} \frac{\bar{X}_n - \mu_X}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} &= \frac{\bar{X}_n - \mu_X}{\sqrt{\sigma_X^2/n}} \left(\frac{\sigma_X^2/n}{\sigma_X^2/n + \sigma_Y^2/m} \right)^{1/2} = \frac{\bar{X}_n - \mu_X}{\sqrt{\sigma_X^2/n}} \left(\frac{sm/n}{sm/n + 1} \right)^{1/2} \\ \frac{\bar{Y}_m - \mu_Y}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} &= \frac{\bar{Y}_m - \mu_Y}{\sqrt{\sigma_Y^2/m}} \left(\frac{\sigma_Y^2/m}{\sigma_X^2/n + \sigma_Y^2/m} \right)^{1/2} = \frac{\bar{Y}_m - \mu_Y}{\sqrt{\sigma_Y^2/m}} \left(\frac{1}{sm/n + 1} \right). \end{aligned}$$

Přidejme důležitý předpoklad $m/n \rightarrow c$, kde c je konečná kladná konstanta, díky kterému platí

$$\frac{\bar{X}_n - \mu_X}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \xrightarrow{m,n \rightarrow \infty} N\left(0, \frac{sc}{sc+1}\right), \quad \frac{\bar{Y}_m - \mu_Y}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \xrightarrow{m,n \rightarrow \infty} N\left(0, \frac{1}{sc+1}\right)$$

Pro nezávislé náhodné veličiny U a V s normálním rozdělením platí, že jejich rozdíl má opět normální rozdělení se střední hodnotou $E U - E V$ a s rozptylem $\text{var } U + \text{var } V$. Díky tomu dostaneme konečně požadovanou konvergenci v distribuci

$$\frac{\bar{X}_n - \mu_X}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} - \frac{\bar{Y}_m - \mu_Y}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} = \frac{\bar{X}_n - \bar{Y}_m - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \xrightarrow{m,n \rightarrow \infty} N(0, 1).$$

Připomeňme ještě jednou předpoklad $m/n \rightarrow c \in (0, \infty)$. Ted' již můžeme použít i Sluckého větu a odvodit asymptotický intervalový odhad

$$\left[\bar{X}_n - \bar{Y}_n - \Phi^{-1}(1 - \alpha/2) \sqrt{S_X^2/n + S_Y^2/m}, \bar{X}_n - \bar{Y}_n + \Phi^{-1}(1 - \alpha/2) \sqrt{S_X^2/n + S_Y^2/m} \right]$$

s přibližnou hladinou spolehlivosti $1 - \alpha$.

*7.3. Principy statistického rozhodování

Základním principem statistického rozhodování je přiznání faktu, že jde o empirický závěr založený na pozorování náhodných veličin a naší představě o modelu. Podívejme se na příklad s testováním dětí ve dvou městech. Vycházíme z modelu, že děti nějak nezávisle na sobě získávají body z testu a tyto výsledky tvoří nějakou náhodnou veličinu o jejíž střední hodnotu nám jde. Otázka zní, zda střední hodnota výsledků testu v obou městech je stejná, nebo není.

Tím jsme pokročili dále. V rámci předpokladů máme dvě tvrzení, která se navzájem vylučují (a doplňují). Jedno z těchto tvrzení je velmi konkrétní: střední hodnoty se rovnají. Druhé tvrzení je volnější, říká, že se střední hodnoty nerovnají, ale tento rozdíl nespecifikujeme. Na základě dat chceme jedno z těchto tvrzení vyloučit⁷ a dále pracovat s nevyloučeným tvrzením.

Víme však, že rozhodování na základě náhodného výběru má náhodný charakter. Jiný náhodný výběr vede k jinému odhadu střední hodnoty, takže výběrem jiných dětí bychom dospěli k jinému číslu⁸. Mohou tak nastat dvě situace: odmítneme nepravdivé tvrzení (to bychom rádi), nebo odmítneme pravdivé tvrzení (to bychom neradi). My ale nebudeme vědět, jestli jsme chybu udělali nebo ne, kdybychom to věděli, tak nemusíme podstupovat tyto úvahy. Chceme tedy *minimalizovat pravděpodobnost* chybného rozhodnutí. Tvrzení jsou však dvě (označme je v souladu s tradicí H_0 a H_1 , podle slova *hypotéza*) a minimalizace pravděpodobnosti chybného zamítnutí H_0 zvyšuje pravděpodobnost chybného zamítnutí H_1 , tyto pravděpodobnosti nelze minimalizovat současně.

⁷Nebo alespoň dočasně vyloučit, poznání je dynamický proces.

⁸Proto je zde důležitý opravdu náhodný výběr. Pokud by škola mohla rozhodovat o tom, kteří žáci se účastní testu, pak byt mohla být motivována vybrat specifickou skupinu a tím by byl výsledek znehodnocen.

Postupujeme tedy tak, že stanovíme nejvyšší přípustnou pravděpodobnost α zamítnutí tvrzení H_0 v případě, že je pravdivé. Za tohoto omezení hledáme rozhodovací pravidlo tak, aby pravděpodobnost chybného odmítnutí H_1 byla co nejmenší. Pravděpodobnosti α říkáme *statistická hladina*.

V případě jednorozměrné charakteristiky náhodné veličiny (střední hodnota, parametr rozdělení, ...) můžeme použít asymptotický intervalový odhad této charakteristiky. Rozhodnutí na základě intervalového odhadu provedeme takto:

- Pokud hodnota obsažená v tvrzení H_0 je pokryta intervalovým odhadem, pak tvrzení H_0 neodmítneme.
- Pokud jsou hodnoty H_0 a intervalového odhadu disjunktní, pak H_0 zamítneme.

Proto by intervalový odhad měl splňovat dva požadavky.

- (1) Je-li tvrzení H_0 pravdivé, pak by měl s pravděpodobností $1 - \alpha$ obsahovat hodnoty z H_0 .
- (2) Měl by být co nejkratší.

Vraťme se k příkladu s průměrným výsledkem testů. Žádoucí je, aby žáci z různých měst dosahovali stejných výsledků, pak nebude třeba zasahovat. Proto naši pracovní hypotézou je $E X - E Y = 0$. Pro charakteristiku $E X - E Y$ umíme najít asymptotický intervalový odhad, který tuto hodnotu pokryje s pravděpodobností alespoň $1 - \alpha$. Je-li tedy opravdu $E X - E Y = 0$, pak s pravděpodobností nejvýše α intervalový odhad nulu *neobsahuje* a my tím pádem tvrzení H_0 zamítneme. Zároveň plyne z tvaru normálního rozdělení, že navržený intervalový odhad

$$\left[\bar{X}_n - \bar{Y}_n - \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{S_X^2 + S_Y^2}{n}}, \bar{X}_n - \bar{Y}_n + \Phi^{-1}(1 - \alpha/2) \sqrt{\frac{S_X^2 + S_Y^2}{n}} \right]$$

je nejkratší mezi těmi, které z asymptotické normality bodového odhadu $\bar{X}_n - \bar{Y}_n$ můžeme odvodit.

Podobně lze postupovat například u hodu kostkou. Ptáme-li se například, zda jednička padá s pravděpodobností $1/6$, můžeme na základě empirických pokusů odvodit asymptotický intervalový odhad s hladinou spolehlivosti $1 - \alpha$ pro pravděpodobnost jedničky. Pokud tento odhad nepokrývá hodnotu $1/6$, zamítneme hypotézu o tom, že by na dané kostce padala jednička s pravděpodobností $1/6$ na *hladině statistické významnosti* $1 - \alpha$.

Rozhodování založené na asymptotických intervalových odhadech ale nemůže poskytnout metodu vhodnou pro všechny případy. Také nejde o vždy optimální metodu a vzhledem k asymptotické povaze je statistická hladina jen přibližná, limitně se blíží stanovené hladině.

Může se zdát, že rozhodování ve stylu zamítnu/nezamítnu je svou dichotomií poněkud omezené. Musíme si však uvědomit, že jsem si vždy vědomi náhodného charakteru tohoto rozhodnutí a také nutnosti dalšími experimenty zpřesňovat naše poznání. Již z volby slova „*nezamítnutí*“ místo mnohem jednoznačnějšího „*přijetí*“ je zřejmé, že si necháváme prostor pro případnou budoucí revizi tohoto rozhodnutí.

Problémy k dalšímu procvičení

1. Počty vstřelených gólů v jednotlivých fotbalových zápasech jsou nezávislé náhodné veličiny s Poissonovým rozdělením s neznámým parametrem $\lambda > 0$. Pro data z roku 2008 máme k dispozici 306 zápasů, kde bylo vstřeleno v průměru 2.92 gólů a výběrový rozptyl vyšel $(1.64)^2$.
 - (a) Zkonstruuje intervalový odhad se spolehlivostí 95 % pro střední počet vstřelených gólů v jednom zápase.
Vyjděte z CLV a následně použijte Sluckého větu, čímž nahradíte neznámou kvantitu ve jmenovateli.
 - (b) Zkonstruuje 95%-ní intervalový odhad pro pravděpodobnost, že v zápase nepadne žádný gól.
Nápověda: Využijte výsledek z (a) a ten vhodně transformujte.
 - (c) Navrhněte ještě alternativní intervalový odhad pravděpodobnosti, že v zápase nepadne žádný gól, víme-li, že v 15 zápasech z celkových 306 nepadl žádný gól. Porovnejte s výsledkem z (b).
Nápověda: Uvažujte namísto X_i jen identifikátory toho, zda $[X_i = 0]$. Střední hodnota těchto veličin je právě hledaná pravděpodobnost.
2. Předpokládejme, že délky obsluhy jednotlivých zákazníků na poště (v minutách) jsou nezávislé náhodné veličiny s exponenciálním rozdělením s neznámým parametrem $\lambda > 0$, tj. s hustotou $f(x) = \lambda e^{-\lambda x} \chi(x \geq 0)$. Délka obsluhy 16 po sobě jdoucích zákazníků trvala celkem 25 minut.
 - (a) Sestrojte 95%-ní asintervalový odhad pro střední dobu obsluhy jednoho zákazníka na poště.
 - (b) Sestrojte 95%-ní intervalový odhad pro λ .
 - (c) Sestrojte 95%-ní intervalový odhad pravděpodobnosti, že délka obsluhy bude trvat méně než 2 minuty.
Předpokládejme, že $n = 16$ je již dostatečně velké pro aproximaci pomocí centrální limitní věty, a proto hledejte asymptotické intervalové odhady.
3. Uvažujme fiktivní anketu o volebních preferencích před volbami prezidenta, ve které ze 100 náhodně dotázaných respondentů (kteří plánují jít k volbám) 35 odpovědělo, že bude v blížících se volbách volit kandidáta A.
 - (a) Zkonstruuje intervalový odhad se spolehlivostí 95 % pro pravděpodobnost p , s jakou občan ČR (jdoucí k volbám) volí kandidáta A. Je pravděpodobné, že bude kandidát A zvolen v prvním kole?
 - (b) Jestliže podíl voličů zůstane stejný jako v (a), kolik osob se musíme zeptat, aby šířka intervalového odhadu byla maximálně 2%?
4. Náhodná veličina X má spojitě rozdělení s hustotou

$$f(x) = \begin{cases} \frac{2}{a^2}x & x \in [0, a], \\ 0 & \text{jinak,} \end{cases}$$

kde $a > 0$ je neznámý parametr. Provedli jsme $n = 100$ nezávislých opakováních měření a obdrželi jsme náhodný výběr $X_1, \dots, X_{100}$ takový, že $\bar{X}_{100} = 4/9$.

- (a) Sestrojte intervalový odhad střední hodnoty $E X$ se spolehlivostí 95 %.
- (b) Sestrojte intervalový odhad parametru a se spolehlivostí 95 %.

Podmiňování

Práce s podmíněnou pravděpodobností a s podmíněným rozdělením je základní dovedností nutnou k dokonalému zvládnutí práce s náhodnou veličinou. Stejně jako u definice podmíněné pravděpodobnosti lze podmínku chápat jako dodatečnou informaci, nebo zpřesnění. Na rozdíl od podmíněné pravděpodobnosti z první kapitoly však nyní musíme pracovat i s jevy s nulovou pravděpodobností.

Začneme však tím jednodušším, diskrétním náhodným vektorem.

8.1. Podmíněné rozdělení a podmíněná střední hodnota diskrétního náhodného vektoru

V celé této kapitole uvažujme dvourozměrný diskrétní náhodný vektor s hodnotami v podmnožině $\mathbb{Z}^2$, případně vícerozměrný náhodný vektor s hodnotami v $\mathbb{Z}^d$. Rozšíření na obecnější množinu hodnot je přímočaré, speciální případ uvažujeme čistě kvůli přehlednosti značení.

Pro diskrétní náhodnou veličinu Z označme $\text{sp}(Z) = \{n; P[Z = \ell] > 0\}$. Definice podmíněného rozdělení vychází přímo z definice podmíněné pravděpodobnosti.

Definice 8.1 (Podmíněné rozdělení diskrétního náhodného vektoru). Bud' $\mathbf{X} = (Y, Z)^T$ diskrétní náhodný vektor. Pak pro každé $\ell \in \text{sp}(Z)$ definujeme podmíněné rozdělení Y za podmínky $Z = \ell$:

$$P[Y = k | Z = \ell] = \frac{P[Y = k, Z = \ell]}{P[Z = \ell]}, k \in \mathbb{Z}.$$

Podmínka $Z = \ell$ může přidat další informaci také pro náhodnou veličinu Y . Samozřejmě, pokud Y a Z jsou nezávislé, pak informace $Z = \ell$ žádné upřesnění pro Y nepřináší.

Věta 8.2. Bud' $\mathbf{X} = (Y, Z)^T$ diskrétní náhodný vektor. Pak Y a Z jsou nezávislé náhodné veličiny tehdy a jen tehdy pokud pro každé $\ell \in \text{sp}(Z)$ platí $P[Y = k | Z = \ell] = P[Y = k]$.

Důkaz. Jsou-li Y a Z nezávislé, pak pro libovolná k a n platí $P[Y = k, Z = \ell] = P[Y = k]P[Z = \ell]$. Přímou z definice dostaneme $P[Y = k|Z = \ell] = P[Y = k]$ pro každé $\ell \in \text{sp}(Z)$.

Nechť naopak platí $P[Y = k|Z = \ell] = P[Y = k]$ pro každé $\ell \in \text{sp}(Z)$, $k \in \mathbb{Z}$. Pak z definice podmíněného rozdělení platí $P[Y = k, Z = \ell] = P[Y = k|Z = \ell]P[Z = \ell] = P[Y = k]P[Z = \ell]$ pro každé $k \in \mathbb{Z}$, $\ell \in \text{sp}(Z)$. Pro $\ell \notin \text{sp}(Z)$ platí $P[Z = \ell] = 0$ a proto $P[Y = k, Z = \ell] = 0 = P[Y = k]P[Z = \ell]$. $\square$

Podmíněné rozdělení je „dalším do party“ ke sdruženému a marginálnímu rozdělení náhodného vektoru. Jak je vidět z definice, podmíněné rozdělení je právě tím stavebním kamenem, který umožní sestavit sdružené rozdělení. Známe-li sdružené rozdělení náhodného vektoru X , pak můžeme určit všechna marginální a podmíněná rozdělení. Z marginálních rozdělení sdružené jednoznačně určit nelze. Pokud známe marginální rozdělení Y a podmíněná rozdělení Z za podmínky $[Y = k]$ pro všechna $k \in \text{sp}(Y)$, pak umíme spočítat i sdružené rozdělení $(Y, Z)^T$.

Cvičení 8.3. Mějme 6 mincí a jednu kostku. Hodíme kostkou a hodíme tolika mincemi, jaký výsledek padl na kostce. Určete sdružené rozdělení výsledku na kostce a počtu líců na mincích a marginální rozdělení počtu líců.

Sdružené rozdělení určíme snadno. Označme K výsledek hodu kostkou a L počet líců na mincích. Hodnoty K jsou zřejmě $1, \dots, 6$ a za podmínky $[K = k]$ je rozdělení počtu líců na mincích binomické s parametry k a $1/2$. Celkem tak dostáváme

$$P[K = k, L = \ell] = P[L = \ell|K = k]P[K = k] = \begin{cases} \frac{1}{6} \binom{k}{\ell} 2^{-k} & k = 1, 2, \dots, 6, \ell = 0, \dots, k \\ 0 & \text{jinak.} \end{cases}$$

♠

Od podmíněného rozdělení je již přímá cesta k podmíněné střední hodnotě a obecně k podmíněným momentům. Jde o charakteristiky podmíněného rozdělení pro konkrétní podmínku.

Definice 8.4 (Podmíněná střední hodnota a rozptyl). Bud' $X = (Y, Z)^T$ diskrétní náhodný vektor a $\ell \in \text{sp}(Z)$. Bud' $g : \mathbb{R}^2 \rightarrow \mathbb{R}$. Podmíněná střední hodnota $g(Y, Z)$ za podmínky $Z = \ell$ je definována

$$E(g(Y, Z)|Z = \ell) = \sum_k g(k, \ell)P[Y = k|Z = \ell],$$

má-li tento součet smysl. Speciálně podmíněná střední hodnota Y za podmínky $Z = \ell$ je

$$E(Y|Z = \ell) = \sum_k kP[Y = k|Z = \ell],$$

pokud součet existuje. Existuje-li konečná podmíněná střední hodnota $E(Y|Z = \ell)$, definujeme podmíněný rozptyl

$$\text{var}(Y|Z = \ell) = E(Y - E(Y|Z = \ell)|Z = \ell)^2 = \sum_k (k - E(Y|Z = \ell))^2 P[Y = k|Z = \ell]$$

Věta 8.5. Bud' $\mathbf{X} = (Y, Z)^T$ diskrétní náhodný vektor a $\text{var}(Y|Z = \ell)$ podmíněný rozptyl Y za podmínky (při) $Z = \ell$. Pak

$$\text{var}(Y|Z = \ell) = E(Y^2|Z = \ell) - (E(Y|Z = \ell))^2.$$

Důkaz. Příímým výpočtem jako v důkazu obdobné věty pro nepodmíněný rozptyl dostaneme

$$\begin{aligned} \text{var}(Y|Z = \ell) &= \sum_k k^2 P[Y = k|Z = \ell] - 2 E(Y|Z = \ell) \underbrace{\sum_k k P[Y = k|Z = \ell]}_{E(Y|Z = \ell)} \\ &\quad + (E(Y|Z = \ell))^2 \underbrace{\sum_k P[Y = k|Z = \ell]}_1 \\ &= E(Y^2|Z = \ell) - (E(Y|Z = \ell))^2. \end{aligned}$$

□

Věta 8.6. Bud' $\mathbf{X} = (Y, Z)^T$ diskrétní náhodný vektor a necht' $E(Y|Z = \ell)$ existuje. Pak

$$E(YZ|Z = \ell) = \ell E(Y|Z = \ell).$$

Důkaz. Příímým výpočtem z definice zjistíme

$$E(YZ|Z = \ell) = \sum_k k \ell P[Y = k|Z = \ell] = \ell \sum_k k P[Y = k|Z = \ell] = \ell E(Y|Z = \ell).$$

□

Podobně lze zavést podmíněné rozdělení i v případě vícerozměrných náhodných vektorů. Je-li $\mathbf{X} = (Y_1, Y_2, Z)^T$ náhodný vektor, můžeme pro $\ell \in \text{sp}(Z)$ definovat

$$P[Y_1 = k_1, Y_2 = k_2|Z = \ell] = \frac{P[Y_1 = k_1, Y_2 = k_2, Z = \ell]}{P[Z = \ell]}, \quad k_1 \in \mathbb{Z}, k_2 \in \mathbb{Z}$$

a odtud i definovat $E(g(Y_1, Y_2, Z)|Z = \ell)$. Také můžeme samozřejmě zavést složené $P[Z = \ell|Y_1 = k_1, Y_2 = k_2]$, pokud pravděpodobnost podmínky je nenulová, tedy $P[Y_1 = k_1, Y_2 = k_2] > 0$ a pomocí tohoto podmíněného rozdělení i podmíněnou střední hodnotu $E(g(Z, Y_1, Y_2)|Y_1 = k_1, Y_2 = k_2)$.

8.2. Podmíněné rozdělení a podmíněná střední hodnota spojitého náhodného vektoru

Podstatně složitější situace nastává, chceme-li podmiňovat spojitou náhodnou veličinou. Pravděpodobnosti $P[Z = z]$ jsou nulové pro všechna z a jak víme, nulou nelze dělit. Přesto i zde je možné dobře definovat podmíněné rozdělení pomocí podmíněné hustoty při zachování všech vlastností, které rozdělení má mít.

Definice 8.7 (Podmíněná hustota). Bud' $X = (Y, Z)^T$ absolutně spojitý náhodný vektor se sdruženou hustotou $f_{Y,Z}$. Definujme $f_{Y|Z}(y)$ předpisem:

$$f_{Y|Z}(y) = \begin{cases} \frac{f_{Y,Z}(y,z)}{f_Z(z)} & f_Z(z) > 0 \\ 0 & \text{jinak} \end{cases}$$

a tuto funkci (proměnné y indexovanou z) nazveme podmíněnou hustotou rozdělení Y za podmínky $Z = z$, případně hustotou podmíněného rozdělení Y za podmínky $Z = z$.

Nyní pojd' me ověřit, že takto definovaná hustota je opravdu hustotou.

Marginální hustota je $f_Z(z) = \int_{-\infty}^{\infty} f_{Y,Z}(y,z) dy$. Pokud je rovna nule, potom nutně $f_{Y,Z}(y,z) = 0$ pro všechna (skoro všechna) y , protože $f(y,z) \geq 0$. V opačném případě

$$\int_{-\infty}^{\infty} f_{Y|Z}(y) dy = \int \frac{f_{Y,Z}(y,z)}{f_Z(z)} dy = \frac{\int_{-\infty}^{\infty} f_{Y,Z}(y,z) dy}{f_Z(z)} = \frac{f_Z(z)}{f_Z(z)} = 1$$

kdykoliv $f_Z(z) > 0$, funkce $f_{Y|Z}(y)$ tedy má vlastnosti hustoty, je nezáporná a její integrál je 1.

K tomu, abychom však mohli opravdu hustotu $f_{Y|Z}$ považovat za podmíněnou hustotu, potřebujeme ověřit ještě jeden fakt.

Podívejme se na pravděpodobnost $P[Y \in A, Z \in B]$, kde $P[Z \in B] > 0$. Z definice víme, že $P[Y \in A, Z \in B] = P[Y \in A|Z \in B]P[Z \in B]$ a dále $P[Z \in B] = \int_B f_Z(z) dz$.

$$\begin{aligned} P[Y \in A, Z \in B] &= \int_A \int_B f_{Y,Z}(y,z) dy dz = \int_B \int_A f_{Y,Z}(y,z) dy dz \\ &= \int_B \left(\int_A \frac{f_{Y,Z}(y,z)}{f_Z(z)} dy \right) f_Z(z) dz = \int_B \left(\int_A f_{Y|Z}(y) dy \right) f_Z(z) dz. \end{aligned}$$

Tato rovnost platí pro libovolné množiny A a B takové, že $P[Z \in B] > 0$. Vidíme analogii s větou o úplné pravděpodobnosti a důvod, proč je interpretace $f_{Y|Z}$ coby podmíněné hustoty možná¹.

Definice 8.8 (Podmíněná střední hodnota). Bud' $X = (Y, Z)^T$ absolutně spojitý náhodný vektor, $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ taková, že $E|g(Y, w)| < \infty$. Pak definujeme

$$E(g(Y, Z)|Z = z) = \int_{-\infty}^{\infty} g(y, z) f_{Y|Z}(y) dy$$

a speciálně $E(Y|Z = z) = \int_{-\infty}^{\infty} y f_{Y|Z}(y|z) dy$.

Podobně jako v případě diskrétního náhodného vektoru i zde můžeme rozšířit definici podmíněné hustoty na vícerozměrný náhodný vektor a podmiňovat více než jednou složkou tohoto vektoru. I zde platí $E(YZ|Z = \ell) = \ell E(Y|Z = \ell)$, pokud podmíněná střední hodnota $E(Y|Z = \ell)$ existuje.

Podmíněná střední hodnota je lineární stejně jako její nepodmíněná varianta. Pokud existují konečné podmíněné střední hodnoty $E(Y_1|Z = \ell)$ a $E(Y_2|Z = \ell)$, pak

¹Rovnost zůstává v platnosti, pokud funkci $f_{Y|Z}$ nadefinujeme v konečně či spočetně mnoha bodech úplně libovolně. Proto občas mluvíme o *verzi* podmíněné hustoty, abychom zdůraznili tuto skutečnost.

existuje podmíněná střední hodnota $E(Y_1 + Y_2|Z = \ell) = E(Y_1|Z = \ell) + E(Y_2|Z = \ell)$. Pro libovolnou konstantu c dále platí $E(cY|Z = \ell) = c E(Y|Z = \ell)$ a $E(c|Z = \ell) = c$.

8.3. Podmíněná střední hodnota jako náhodná veličina

V této sekci omezíme výklad na diskrétní náhodný vektor. Pro spojitý náhodný vektor můžeme postupovat stejně, ale je vhodné mít hlubší znalosti z teorie míry, abychom mohli korektně vše definovat a dokázat. Pro základní pochopení však postačí diskrétní verze.

Výsledky

Kapitola 1

1. Buffonova úloha: $\frac{2l}{\pi t}$.
2. **doplnit**
3. Sekretářka:
 - (a) $1 - 1/2 + 1/3! - \dots + (-1)^n 1/n! = \sum_{k=1}^n (-1)^{k+1} 1/k! = 1 - \sum_{k=0}^n (-1)^k / k!$,
 - (b) $1 - \sum_{k=0}^n (-1)^k / k! \rightarrow 1 - e^{-1} = 1 - 1/e$ pro $n \rightarrow \infty$.
4. **doplnit**
5. **doplnit**
6. Kostky:
 - (a) $1/16$,
 - (b) $1/2$.
7. Alespoň jedna šestka:
 - (a) $11/36$,
 - (b) $1 - (5/6)^n$.
8. Vlak: $\sum_{k=0}^9 \binom{10}{k} \left(\frac{10-k}{10}\right)^{16} (-1)^k$.
9. Klíče:
 - (a) $1/n$,
 - (b) $(1 - 1/n)^{k-1} \cdot 1/n$.
10. Jevy jsou závislé.
11. (a) neplatí, A^C a B^C jsou nezávislé,
 (b) platí,
 (c) neplatí,
 (d) platí,
 (e) neplatí.
12. $1 - 0.9^3$.
13. Dostihy: 0.6.
14. Tenistka:

- (a) $2/25 = 0.080$,
 (b) $8/23 \doteq 0.348$.
15. Profesor: $\frac{3^3}{4^4 - 3^4} = \frac{27}{175}$.
16. **doplnit**
17. Studenti:
 (a) $28/45$,
 (b) ze skupiny B,
 (c) $1 - (0.2)^3(0.4)^4(0.6)^2$.
18. Mandarinky: $15/400$.
19. Krabice: $n/(m+n)$.
20. Krabice s míčky: $528/5915 = 0.089$.
21. Spam:
 (a) $3/75$,
 (b) $8/25$.
22. Lovci: $3/29$, $8/29$ a $18/29$.
23. Mince: $\frac{1}{(e-1)(k+1)!}$ pro $k = 0, 1, 2, \dots$
24. Bílá kulička: $5/12$.
25. Truhly: $2/3$.
26. Obrazy: **doplnit**
27. Kostka a 5 a 7: $2/5$.

Kapitola 2

1. Basketbalista: $P(X = n) = \binom{n+k-1}{n} p^k (1-p)^n$ pro $n = 0, 1, 2, \dots$
2. Bonbóny: $P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$, pro $\max\{0, K - N + n\} \leq k \leq \min\{K, n\}$.
3. Generátor čísel:
 (a) rovnoměrné rozdělení na $[0, 1]$,
 (b) $P[X = 0.5] = 0$, $P[X < 0.5] = F(x) = \int_0^{1/2} f(x) dx$,
 (c) není. Označme $Y = X^2$, pak distribuční funkce Y je
- $$F_Y(y) = \begin{cases} 0 & y \leq 0 \\ \sqrt{y} & y \in (0, 1), \\ 1 & y \geq 1 \end{cases}$$
- (d) $(b-a)X + a$ má rovnoměrné rozdělení na $[a, b]$.
4. Vlak:
 (a) $c = 1/5$,

$$(b) F(x) = \begin{cases} 0 & x < 0, \\ 1 - e^{-x/5} & x \geq 0, \end{cases}$$

$$(c) P[X > 5] = e^{-1},$$

$$(d) P[2 < X < 5] = e^{-2} - e^{-5},$$

$$(e) P[X > 10 | X > 5] = e^{-5},$$

$$(f) Y = 5 + 3X,$$

$$F_Y(y) = \begin{cases} 0 & y < 5, \\ 1 - e^{-\frac{y-5}{15}} & y \geq 5, \end{cases}, \quad f_Y(y) = \begin{cases} \frac{1}{15}e^{-\frac{y-5}{15}} & y \geq 5, \\ 0 & \text{jinak,} \end{cases}$$

$$P[Y > 20] = P[X > 5] = e^{-1},$$

$$(g) P[Z = k] = P[k-1 \leq X < k] = e^{-(k-1)}[1 - e^{-1}] = q(1-q)^{k-1}, \text{ kde } q = 1 - e^{-1}.$$

Tedy Z má geometrické rozdělení s parametrem q .

$$(h) U \text{ má rovnoměrné rozdělení na } [0, 1],$$

$$(i) \text{ Je-li } U \text{ číslo vygenerované z } [0, 1], \text{ pak } X = F_X^{-1}(U) \text{ má rozdělení ze zadání, kde } F_X^{-1}(u) = -5 \log(1-u).$$

$$5. (a) c = 1,$$

$$(b) P[X > 1/2] = 7/8,$$

$$(c)$$

$$F(x) = \begin{cases} 0 & x < 0, \\ \frac{x^2}{2} & x \in [0, 1), \\ 2x - \frac{x^2}{2} - 1 & x \in [1, 2), \\ 1 & x \geq 2. \end{cases}$$

$$6. c = 1/2, P[|X| > 2] = e^{-2}.$$

7. Exponenciální rozdělní je bez paměti:

$$P[X > a + d | X > d] = \frac{1 - F(a + d)}{1 - F(d)} = 1 - F(a) = P[X > a].$$

8. Log-normální rozdělení: distribuční funkce je

$$F_Y(y) = P[X \leq \log y] = \Phi\left(\frac{\log y - \mu}{\sigma}\right),$$

kde Φ je distribuční funkce $N(0, 1)$, hustota tedy je

$$f_Y(y) = \frac{1}{y \sqrt{2\pi\sigma^2}} e^{-\frac{(\log y - \mu)^2}{2\sigma^2}} \chi(y > 0).$$

9. Nezávislost transformovaných veličin: Použijte např. větu 2.22.

10. Rodina:

$X \backslash Y$	0	1	2
0	0	0	1/8
1	0	1/4	1/8
2	1/8	1/4	0
3	1/8	0	0

(a) sdružené rozdělení je

(b) marginální rozdělení Y je $\text{Bi}(2, 1/2)$ a marginální rozdělení X je $\text{Bi}(3, 1/2)$,

(c) veličiny jsou závislé.

11. Ponožky:

$X \backslash Y$	0	1	2
(a) 0	0	1/10	1/10
1	1/10	4/10	1/10
2	1/10	1/10	0

(b) 6/10,

(c) jsou závislé.

12. Oslava:

(a) $c = 1$,

(b) $f_X(x) = x + 1/2$ pro $x \in (0, 1)$ a $f_X(x) = 0$ jinak;
 $f_Y(y) = y + 1/2$ pro $y \in (0, 1)$ a $f_Y(y) = 0$ jinak,

(c) veličiny X a Y jsou závislé,

(d) $P(X > Y) = 1/2$.

13. Čekání na MDH:

(a) $f_X(x) = e^{-x} \chi(x > 0)$, $f_Y(y) = \frac{1}{2} e^{-y/2} \chi(y > 0)$,

(b) jsou nezávislé,

(c) $P[Y > X] = 2/3$.

14. Děti: Stirlingův vzorec dává

$$\binom{2n}{n} \approx \frac{2^{2n}}{\sqrt{\pi n}}.$$

Platí

$$P[X_i = 1, i = 1 \dots, 82] = (P[X_1 = 1])^{82} 2$$

a za pomoci nerovnosti z nápovědy pro $n = 10000$ a $p = 0.485$, $q = 0.515$ dostaneme požadovanou nerovnost.

Kapitola 3

1. $c = 1/14$, $E X = \frac{18}{7}$, $\text{var } X = \frac{19}{49}$,

$$F(x) = \begin{cases} 0 & x < 1, \\ \frac{1}{14} & x \in [1, 2), \\ \frac{5}{14} & x \in [2, 3), \\ 1 & x \geq 3, \end{cases}$$

$$P(X \geq 2) = \frac{13}{14}.$$

Rozdělení Y : $P(Y = 0) = 4/14 = 2/7$ a $P(Y = 1) = 1/14 + 9/14 = 10/14 = 5/7$, tj. Y má alternativní rozdělení $A(p)$ s parametrem $p = 5/7$; $E Y = \frac{5}{7}$.

2. $a = 1/4$, $E X = 5/12$, $\text{var } X = 155/144$, rozdělení Y : $P(Y = 0) = 1/2$, $P(Y = 1) = P(Y = 4) = 1/4$, $E Y = 5/4$.

3. $E X = p$, $\text{var } X = p(1 - p)$.

4. Pokud $X \sim \text{Bi}(n, p)$, pak $E X = np$.

5. Bonbóny:

(a) $E X = n \frac{K}{N},$

(b) $\text{var } X = n \frac{K(N-K)(N-n)}{N^2(N-1)}.$

6. Negativně binomické rozdělení: Geometrické rozdělení s parametrem p má střední hodnotu $(1-p)/p$ a rozptyl $(1-p)/p^2$. Pro X s negativně binomickým $\text{Nb}(r, p)$ platí, že X má stejné rozdělení jako $\sum_{i=1}^r Y_i$, kde $Y_i \sim \text{Geom}(p)$ jsou nezávislé. Proto $E X = r(1-p)/p$ a $\text{var } X = r(1-p)/p^2$.

7. Poissonovo rozdělení:

(a) $E X = \lambda,$

(b) $\Psi_X(t) = e^{\lambda(e^t-1)}$ pro $t \in \mathbb{R}$.

8. Pro $\text{Exp}(\lambda)$:

(a) $E X = \frac{1}{\lambda},$

(b) $\Psi_X(t) = \frac{\lambda}{\lambda-t}$ pro $t < \lambda$.

9. $c = 1/(e-1),$

$$F(x) = \begin{cases} 0 & x < 0, \\ \frac{e^x - 1}{e - 1}, & x \in [0, 1], \\ 1 & x > 1, \end{cases}$$

$$E X = \frac{1}{e-1}, \text{var } X = \frac{e^2 - 3e + 1}{(e-1)^2}.$$

10. Krychle: $E V = a^3/4, \text{var } V = 9/112 \cdot a^6$.

11. (a) Y má rovnoměrné rozdělení na intervalu $[0, 1]$,


(b) $E Z = 3/2, \text{var } Z = 3/4$.

12. (a) $c = 1/2,$

$$F(x) = \begin{cases} 0, & x < 0, \\ (1 - \cos x)/2 = \sin^2(x/2), & 0 \leq x \leq \pi, \\ 1, & x > \pi, \end{cases}$$

(b) $E X = \pi/2 = \text{medián } X$ (plyne ihned ze symetrie hustoty),

(c) $F^{-1}(u) = \arccos(1-2u), u \in (0, 1)$, viz následující obrázek.



13. Hody mincí:

(a) sdružené rozdělení je dáno v následující tabulce:

		Y		
		0	1	2
X	0	0	1/8	1/8
	1	1/8	1/4	1/8
	2	1/8	1/8	0

(b) marginální rozdělení X je $P(X = 0) = 1/4$, $P(X = 1) = 1/2$, $P(X = 2) = 1/4$ a totéž pro Y ,
veličiny jsou závislé,

(c) $\text{cov}(X, Y) = -1/4$, $\rho_{XY} = -1/2$.

14. Klobouky:

(a) X_i má alternativní rozdělení $P(X_i = 1) = 1/n$, proto $E X_i = 1/n$, $\text{var } X_i = (n-1)/n^2$,

(b) jsou závislé, jelikož např. $P(X_i = 1, X_j = 1) = \frac{1}{n(n-1)} \neq P(X_i = 1)P(X_j = 1) = \frac{1}{n^2}$,

(c) kovariance je $\frac{1}{n^2(n-1)}$,

(d) $E X = 1$, $\text{var } X = 1$.

15. (a) $c = 4$,

(b) $f_X(x) = x \cdot e^{-x^2} I[x \geq 0]$, $f_Y(y) = 2y \cdot e^{-y^2} I[y \geq 0]$, X a Y jsou nezávislé,

(c) $E(X^2 + Y^2) = 2$.

Kapitola 4

1. Maximum a minimum:

(a) $F_U(u) = [F(u)]^n$, $f_U(u) = n[F(u)]^{n-1}f(u)$,

(b) $F_V(v) = 1 - [1 - F(v)]^n$, $f_V(v) = n[1 - F(v)]^{n-1}f(v)$,

(c) $E U = n/(n+1)$, $\text{var}(U) = n/[(n+1)^2(n+2)]$, $E V = 1/(n+1)$,
 $\text{var}(V) = n/[(n+1)^2(n+2)]$.

Kapitola 5

Poznámka: Některé výsledky z této kapitoly mohou vyjít numericky trochu odlišně v porovnání s výsledky uvedenými níže, a to v závislosti na tom, v kterých mezikrocích a jak moc zaokrouhlíte.

1. Hody mincí:

Přesná pravděpodobnost: $P(\sum_{i=1}^{10000} X_i > 4900) = 1 - \sum_{k=0}^{4900} \binom{10000}{k} \frac{1}{2^{10000}} = 0.9767$,
aproximace pomocí CLV: $P(\sum_{i=1}^{10000} X_i > 4900) \doteq \Phi(2) = 0.9772$.

2. Večírek

(a) 0.159,

- (b) alespoň 513 chlebíčků,
 - (c) nejvýše 96 hostů,
 - (d) CLV: $t \geq 25.8$, Čebyšev $t \geq 100$.
3. Pojišťovna:
- (a) očekávaný zisk je 400 000 Kč,
 - (b) pravděpodobnost ztráty je 0.056,
 - (c) s pravděpodobností 0.9 bude zisk vyšší než 77 302 Kč,
 - (d) alespoň 2193 klientů.
4. Bankomat: alespoň 10 230 tisícikorunových bankovek.
5. Kostka: 0,921.
6. Hostina: nejvýše 45 hostů.
7. Konzultace: 0,013.
8. Pojišťovna II.
- (a) 0,858
 - (b) 2 044 960
 - (c) 22 337.
9. Měli bychom zakoupit alespoň 75 žárovek.

Kapitola 6

1. Fotbal:
- (a) $\hat{\lambda}_n = \bar{X}_n$,
 - (b) je to nestranný i konzistentní odhad λ ,
 - (c) $\hat{\lambda}_n$ je nestranný a není konzistentní, $\tilde{\lambda}_n$ není nestranný (je asymptoticky nestranný) a je konzistentní,
 - (d) W_n je nestranný a konzistentní odhad $e^{-\lambda}$, jelikož veličiny $Y_i = I[X_i = 0]$ jsou iid z alternativního rozdělení s parametrem p_0 a W_n je jejich výběrový průměr.
 V_n není nestranný, ale konzistentní odhad $e^{-\lambda}$. Konzistence plyne z (b) a spojitosti funkce e^{-x} . Z Jensenovy nerovnosti plyne, že odhad není nestranný.
 - (e) Vychází $\bar{X}_n = 2,700$, $W_n = 0,050$, $V_n = 0,067$.
 - (f) Platí $p_6 = P[X = 6] = \lambda^6 e^{-\lambda} / 6!$ a tedy možné odhady jsou

$$\widehat{p}_6 = \frac{1}{n} \sum_{i=1}^n \chi(X_i = 6), \quad \widetilde{p}_6 = (\bar{X}_n)^6 e^{-\bar{X}_n} / 6!.$$

Pro daná data $\widehat{p}_6 = 0$, $\widetilde{p}_6 = 0,036$.

2. Rovnoměrné rozdělení:
- (a) $\hat{a}_n = 2\bar{X}_n$,
 - (b) je nestranný i konzistentní.
3. Alternativní rozdělení:
- (a) odhad parametru p je $\frac{1}{n} \sum_{i=1}^n X_i$, je nestranný i konzistentní,

- (b) $\hat{p}_n$ není nestranný, ale je konzistentní odhad parametru p ,
 (c) $\tilde{p}_n$ je nestranný, ale není konzistentní odhad parametru p ,
 (d) odhad není nestranný, ale je konzistentní.
4. (a) Je-li $p > 1$, pak $E X = p/(p - 1)$ a

$$\widehat{p}_n = \frac{\bar{X}_n}{\bar{X}_n - 1}.$$

Je-li $p \leq 1$, pak $E X = \infty$ a momentový odhad neexistuje. Ze zadání ale máme uvažovat $p > 2$.

- (b) Pro $p > 2$ máme splněné předpoklady ZVČ a tedy $\bar{X}_n \xrightarrow{P} E X = p/(p - 1)$ a podle věty o spojitě transformaci pak $\widehat{p}_n \xrightarrow{P} p$ a tedy odhad je konzistentní. Nestrannost: $\widehat{p}_n = g(\bar{X}_n)$, kde $g(x) = x/(x - 1)$. Funkce g je na $(1, \infty)$ konvexní a tedy podle Jensenovy nerovnosti $E \widehat{p}_n > p$ a odhad tedy není nestranný.
- (c) Odhad je konzistentní (použijeme Zákon velkých čísel na posloupnost veličin $Y_i = \log X_i$).
- (d) V daném modelu platí $F(x) = (1 - 1/x^p) \cdot I(x \geq 1)$ a tedy $\mathbb{P}(X_i > 2) = 1/2^p = 2^{-p}$. Proto možné odhady jsou:

$$T_n = \frac{1}{n} \sum_{i=1}^n \chi(X_i > 2), \quad U_n = 2^{-\widehat{p}_n} = 2^{\frac{\bar{X}_n}{\bar{X}_n - 1}}.$$

5. Rybník:

- (a) V tomto případě X_i mají alternativní rozdělení s parametrem $a/100$ a jsou nezávislé. Momentový odhad a je $\widehat{a}_{10} = 100\bar{X}_{10} = 10Y$, kde Y je počet vylovených zlatých rybiček.
 $E \widehat{a}_{10} = 100 E X_1 = a$ a odhad je tedy nestranný,

$$\text{var } \widehat{a}_{10} = 100^2 \frac{1}{100} \sum_{i=1}^{10} \text{var } X_i = \frac{a(100 - a)}{10}.$$

- (b) Volíme opět $\widehat{a}_{10} = 10Y$, kde Y je počet vylovených rybiček. Platí

$$E Y = \frac{a}{10}, \quad \text{var } Y = \frac{10a(100 - a)(100 - 10)}{100^2 \cdot 99},$$

proto nyní

$$E \widehat{a}_{10} = a, \quad \text{var } \widehat{a}_{10} = \frac{a(100 - a)}{10} \frac{90}{99}.$$

- (c) Je-li Z počet pokusů, pak $E Z = \frac{100}{a}$ a tedy volíme odhad $\tilde{a} = \frac{100}{Z}$.

Kapitola 7

1. Góly:

- (a) asympt. intervalový odhad se spolehlivostí 95%: (2,736;3,104) (rozptyl odhadnut S_n^2) nebo (2,729;3,111) (rozptyl odhadnut $\bar{X}_n$),

- (b) provedeme příslušnou transformaci na meze z (a) a dostaneme (0, 0449; 0, 0648) nebo (0, 0445; 0, 0653),
- (c) vezmeme příslušné veličiny s alternativním rozdělením a dostaneme intervalový odhad (0,025; 0,073).

2. Pošta:

- (a) na základě CLV a Sluckého věty (rozptyl odhadnut jako $1/\bar{X}_n^2$) dostaneme (0,797, 2,328),
- (b) provedeme transformací $1/x$ na (a) a dostaneme (0, 430; 1, 255),
- (c) příslušnou transformací (b) dostaneme (0, 576; 0, 919).

3. (a) Z CLV (0, 257; 0, 443),

(b) $n \geq 8740$.

4. (a) Vychází $E X_1 = 2/3 \cdot a$, $\text{var } X_1 = a^2/18$. Využijeme CLV a vztah mezi střední hodnotou a rozptylem v tomto rozdělení a dostaneme interval

$$\left(\bar{X}_n - \frac{3\bar{X}_n}{6\sqrt{2n}} u_{1-\alpha/2}, \bar{X}_n + \frac{3\bar{X}_n}{6\sqrt{2n}} u_{1-\alpha/2} \right),$$

numericky pak (0, 414; 0, 475),

(b) dostaneme jako $3/2 \cdot$ interval z (a), numericky dostaneme (0, 620; 0, 713).

Literatura

1. Jiří Anděl, *Matematika náhody*, MatfyzPress, 2000.
2. ———, *Statistické úlohy, historky a paradoxy*, MatfyzPress, 2018.
3. Václav Dupač and Marie Hušková, *Pravděpodobnost a matematická statistika*, 2. ed., Karolinum, 2013.
4. Geoffrey Grimmett and David Stirzaker, *Probability and random processes*, 3. ed., Oxford University Press, 2001.
5. Karel Zvára and Josef Štěpán, *Pravděpodobnost a matematická statistika*, 6. ed., MatfyzPress, 2019.

Rejstřík

σ -algebra
borelovská, 20
borelovská na $\mathbb{R}^d$, 24

Buffonova úloha, 14

disjunktní rozklad, 10
distribuční funkce, 22, 24
 charakterizace, 23
 náhodného vektoru, marginální, 26
 náhodného vektoru, sdružená, 27
 vlastnosti, 22, 25

hustota, 28
 marginální, 28
 náhodného vektoru, 28

jevy
 doplňkové, 4
 jisté, 4
 nemožné, 4
 náhodné, 4

korelace, 56
 vlastnosti, 60
 vztah s nezávislostí, 57

korelační matice, 59

kovariance, 56
 vlastnosti, 60

kvantil, 39, 61
 funkce náhodné veličiny, 63

kvantilová funkce, 39

medián, 61
 optimalita, 64
modus, 62

nerovnost
 Bonferroniho, 13
 Chernoffova, 87
 Jenssenova, 50
 Markovova, 86
 Čebyševova, 87

nezávislost
 ekvivalentní podmínky, 32
 náhodných jevů, 13
 náhodných veličin, 32
 vztah s korelací, 57

náhodná veličina, 20

náhodná veličina
 distribuční funkce, 22
 indukované jevy, 20
 rozdělení, 21
 transformace, 38

náhodné veličiny
 nezávislé, 32

náhodný vektor, 24
 distribuční funkce, 24
 hustota, 28
 marginální rozdělení, 26
 s diskrétním rozdělením, 27
 sdružené rozdělení, 27
 se spojitým rozdělením, 27

pravděpodobnost

aposteriorní, 11
apriorní, 11
podmíněná, 8
pravděpodobnostní míra, 3
pravděpodobnostní prostor, 3

rozdělení, 21
Bernoulliho, alternativní, 33
binomické, 33
diskrétní, 27
exponenciální, 35
funkce náhodné veličiny, 38
Gaussovo, normální, 35, 37
geometrické, 33
hypergeometrické, 34, 37
marginální, 26
multinomické, 36
negativně binomické, 34
Paretovo, 35
Poissonovo, 34
rovnoměrné diskrétní, 34
rovnoměrné spojité, 35
sdružené, 27
spojité, 27

rozptyl, 51
alternativní interpretace, 65
součtu náhodných veličin, 58
výpočet, 53
roztržitá sekretářka, 14

směrodatná odchylka, 53
střední hodnota, 45
diskrétní n.v., 46
linearita, 55
náhodného vektoru, 54
optimalita, 63
spojité n.v., 46
výpočet, 48
šikmost, 51

varianční matice, 59

věta

Bayesova, 10
Borelovo-Cantelliovo lemma, 89
inkluze a exkluze, 6
o postupném podmiňování, 9
o úplné pravděpodobnosti, 10
spojitost pravděpodobnostní míry,
7